



上海交通大学巴黎卓越工程师学院
Ecole d'Ingénieurs Paris SJTU

Optimisation

孔思佳

Cours assuré par la professeure 孔思佳
2025 – 2026



Table des matières

1	Introduction	9
1.1	Qu'est-ce que l'optimisation ?	9
1.1.1	Optimisation linéaire	9
1.1.2	Optimisation non linéaire	12
2	Outils techniques	15
2.1	Algèbre linéaire	15
2.2	Topologie dans $\mathbb{R}^n$	15
2.3	Calcul différentiel	17
2.4	Analyse convexe	20
2.5	Exercices	23
3	Conditions d'optimalité en optimisation sans contrainte	25
3.1	Introduction	25
3.2	Direction réalisable et direction de descente	25
3.3	Résultats d'existence et d'unicité	27
3.4	Les conditions d'optimalité	29
3.5	Exercices	31
4	Méthode de gradient (pour des problèmes sans contrainte)	33
4.1	Introduction	33
4.2	Méthode de gradient	33
4.2.1	Algorithme de recherche de pas de descente	34
4.2.2	Algorithme de descente de gradient	36
4.3	Application de la méthode de gradient	38
4.4	Exercices	42
5	Méthode de Newton et quasi-Newton (pour des problèmes sans contrainte)	43
5.1	Introduction	43
5.2	Méthode de Newton	43
5.2.1	Convergence du gradient	45
5.2.2	Approximation à l'ordre 2	46
5.2.3	Convergence globale	46
5.3	Méthode de Quasi-Newton	50
5.3.1	Principes d'obtention des formules de mise à jour	51
5.3.2	Recherche linéaire et conditions de Wolfe	55
5.3.3	Convergence de BFGS	55
6	Conditions d'optimalité en optimisation sous contraintes	57
6.1	Introduction	57
6.2	Résultats d'existence et d'unicité	57
6.3	Les conditions de Lagrange	58
6.3.1	Contraintes d'égalité linéaires	58
6.3.2	Contraintes d'égalité non linéaires	60
6.4	Les conditions de Kuhn et Tucker	63
6.4.1	Contraintes d'inégalité	63

6.4.2	Conditions de Kuhn et Tucker	65
6.5	Problème avec contraintes d'égalité et d'inégalité	66
6.5.1	Qualifications des contraintes	67
6.5.2	Conditions de Karush, Kuhn et Tucker	69
7	Algorithme du simplexe (contraintes d'égalité)	73
7.1	Solution d'optimisation linéaire (OL)	73
7.1.1	Théorème d'existence de solutions optimales d'OL	74
7.1.2	Solution de base	75
7.2	Méthode graphique	76
7.3	Algorithme du simplexe	77
7.4	Tableau du simplexe	84
7.5	Convergence de l'algorithme du simplexe	86
7.5.1	Convergence dans le cas non dégénéré	86
7.5.2	Convergence dans le cas dégénéré	86
7.6	Exercices	87
8	Autres méthodes primales	89
8.1	Méthodes de pénalisation	89
8.1.1	Méthode de pénalisation externe	89
8.1.2	Méthode de pénalisation interne	90
8.1.3	Estimation des multiplicateurs	91
8.2	Méthodes par résolution des équations de Kuhn et Tucker	91
8.2.1	Cas des contraintes d'égalité	91
8.2.2	Méthode de Wilson	92
8.2.3	Cas des contraintes d'inégalité	92

Liste des codes Python

4.1 Méthode de gradient	38
5.1 Méthode de Newton	48
5.2 Méthode de quasi-Newton (DPF)	53
5.3 Méthode de quasi-Newton (BFGS)	54

Liste des figures

1.1	Déformation par la force de la corde	13
3.1	Un minimum global est donc aussi un minimum local	26
3.2	Direction réalisable	26
3.3	Demi-espace des directions de descente d de f en x	27
3.4	Existence de minimum pour une fonction coercive	29
4.1	Condition d'Armijo	35
4.2	Méthode de gradient à pas fixe	40
5.1	Exemple de méthode de Newton	47
5.2	Exemple de méthode de Newton	49
5.3	Exemple de méthode de Newton	50
6.1	Exemple de direction admissible en x	59
6.2	Projection sur plan	60
6.3	Plan tangent	61
6.4	Contraintes actives	63
6.5	Cone admissible	64
6.6	Exemple de programme quadratique	66
7.1	Exemple de méthode graphique	77
7.2	Problème de flot maximum	87

Chapitre 1

Introduction

1.1 Qu'est-ce que l'optimisation ?

Un problème d'optimisation est un problème où une fonction est maximisée ou minimisée par rapport à un ensemble donné. La fonction à minimiser ou à maximiser est appelée fonction objectif, et l'ensemble est appelé domaine réalisable (ou domaine des contraintes). Dans ce cours, un domaine réalisable est toujours considéré comme un sous-ensemble de $\mathbb{R}^n$ (espace vectoriel réel à n dimensions) et la fonction objectif est une fonction de $\mathbb{R}^n$ dans $\mathbb{R}$.

Pour le même problème, la fonction

Dans ce cours, nous avons divisé les problèmes d'optimisation en deux catégories : les problèmes linéaires et les problèmes non linéaires.

On commence par introduire la minimisation sans contrainte. Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$, un problème de minimisation sans contrainte est un problème de la forme

$$(\mathcal{P}) \quad \min_{x \in \mathbb{R}^n} f(x)$$

L'étude de ces problèmes est importante pour diverses raisons. Beaucoup de problèmes d'optimisation avec contraintes peuvent être transformés en problèmes d'optimisation sans contrainte (multiplicateur de Lagrange, méthodes de pénalité, ...). L'étude des problèmes d'optimisation sans contrainte trouve aussi des applications dans la résolution des systèmes non linéaires. Ensuite, le problème le plus typique, et celui sur lequel nous nous concentrons le plus ici, est celui de l'optimisation avec des contraintes, et nous en ferons une introduction simple dans ce premier chapitre.

1.1.1 Optimisation linéaire

Parmi eux, le problème de la planification linéaire (*linear programming problem*) est un problème d'optimisation sur $\mathbb{R}^n$, où la fonction objectif est une fonction linéaire, c'est-à-dire qu'elle est de la forme

$$c_1x_1 + c_2x_2 + \cdots + c_nx_n$$

avec $c_i \in \mathbb{R}$, $i = 1, \dots, n$, et un domaine réalisable est un ensemble fini d'inégalités linéaires et d'égalités de contraintes

$$a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n \leq b_i \quad i = 1, \dots, m$$

et

$$a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n = b_i \quad i = m + 1, \dots, r$$

La planification linéaire est un outil extrêmement puissant pour résoudre les problèmes d'optimisation dans un large éventail d'applications. Une courte liste de domaines d'application comprend l'allocation des ressources, la planification de la production, le stockage, l'aménagement, la planification du transport, l'emplacement des installations, la planification de l'équipage, l'optimisation d'un portefeuille d'actions, l'estimation des paramètres, etc.

Définition 1.1 – Optimisation linéaire (avec contraintes)/*Linear programming*/线性规划

Un problème d'optimisation linéaire (OL) consiste à minimiser une fonction linéaire sur un polyèdre convexe. Un problème d'OL est sous forme standard/*standard form*/标准形式, s'il est de la forme

$$\min\{c^\top \cdot x, A \cdot x = b, x \geq 0\} \quad (\text{OL})$$

où $A \in \mathcal{M}_{m,n}$, $b \in \mathbb{R}^m$, $c \in \mathbb{R}^n$.

Remarque 1.1

Soit $(\mathcal{P})$ un problème d'optimisation linéaire, nous pouvons toujours le mettre sous forme standard. Voici quelques techniques usuelles.

1. **Problème de maximisation** : un problème de maximisation est équivalent à un problème de minimisation sous la forme standard comme

$$\max(c^\top \cdot x) = -\min(-c^\top \cdot x)$$

2. **Contraintes d'inégalité** : $A \cdot x \leq b$ ou $A \cdot x \geq b$.

On peut introduire une suite de variable $z \in \mathbb{R}^m$, $z \geq 0$ telle que

$$A \cdot x + z = b \text{ ou } A \cdot x - z = b$$

Ceci pourra s'écrire en matrice par blocs comme

$$\begin{bmatrix} A & I \end{bmatrix} \cdot \begin{bmatrix} x \\ z \end{bmatrix} = b \text{ ou } \begin{bmatrix} A & -I \end{bmatrix} \cdot \begin{bmatrix} x \\ z \end{bmatrix} = b$$

Donc les contraintes d'inégalité deviennent des contraintes d'égalité sous la forme standard avec les variables

$$\begin{bmatrix} x \\ z \end{bmatrix} \geq 0.$$

Une telle variable z est appelée une variable d'écart/*slack variable*/松弛变量.

3. **Variables négatives** : $x \leq 0$.

Il est facile de se ramener à la forme standard. Il suffit de remplacer la variable x par $x' = -x$. Par exemple : la forme standard du problème

$$\min\{c^\top \cdot x, A \cdot x = b, x \leq 0\}$$

est

$$\min\{(-c)^\top \cdot x', A \cdot x' = -b, x' \geq 0\}$$

4. **Variables libres** : $x \in \mathbb{R}^n$.

On pourra ajouter des variables $y, z \in \mathbb{R}_+^n$, telles que

$$x = y - z$$

En remplaçant la variable libre x par $y - z$, on va rendre le problème d'optimisation linéaire sous la forme standard. Par exemple :

$$\min\{c^\top \cdot x, A \cdot x = b, x \in \mathbb{R}^n\}$$

En remplaçant x par $y - z$, on obtient sa forme standard

$$(\mathcal{P}) \quad \min \left\{ \begin{bmatrix} c^\top & -c^\top \end{bmatrix} \cdot \begin{bmatrix} y \\ z \end{bmatrix} : \begin{bmatrix} A & -A \end{bmatrix} \cdot \begin{bmatrix} y \\ z \end{bmatrix} = b, \begin{bmatrix} y \\ z \end{bmatrix} \geq 0 \right\}$$

où la variable du problème $(\mathcal{P})$ sous forme standard est $\begin{bmatrix} y \\ z \end{bmatrix}$.

Nous commençons par un exemple en deux dimensions. En modélisant cet exemple, nous passerons en revue quatre étapes dans le développement du problème d'OL :

1. Identifier les *variables de décision*.
2. Déterminer la quantité que l'on souhaite minimiser (ou maximiser) et écrire l'expression de la *fonction objectif* en tant que fonction linéaire à l'aide des variables de décision.
3. Identifier les contraintes explicites et écrire l'expression fonctionnelle de chaque *contrainte* sous forme d'équation linéaire ou d'inégalité linéaire.
4. Déterminer les contraintes implicites et écrire chaque *contrainte* comme une équation linéaire ou une inégalité linéaire.

Exemple 1.1 – Usine de verre

Un fabricant de verres souhaite optimiser sa production afin de maximiser son profit. Il produit des chopes à bière et des flûtes à champagne personnalisées. Le profit sur une caisse de chopes à bière est de 25 euros tandis que le profit sur une caisse de flûtes à champagne est de 20 euros. Les gobelets sont fabriqués avec une machine appelée extrudeuse qui se nourrit de sable. Chaque caisse de chopes à bière nécessite 10 kg de sable tandis que les verres à champagne nécessitent 6 kg par caisse. L'approvisionnement quotidien en sable est limité à 900 kg maximum. Environ 15 caisses de l'un ou de l'autre produit peuvent être produites par heure. Pour le moment, la famille veut limiter son travail à 8 heures par jour.

Les variables de décision. On note

B le nombre de caisses de chopes à bière à produire quotidiennement.

C le nombre de caisses de flûtes à champagne à produire quotidiennement.

L'objectif de l'entreprise. Maximiser le profit quotidien.

Le modèle d'optimisation.

$$\text{Maximiser } 25B + 20C$$

Les contraintes explicites.

contrainte de sable : $10B + 6C \leq 900$,

contrainte d'horaires de travail $\frac{1}{15}B + \frac{1}{15}C \leq 8$.

Les contraintes implicites.

$$0 \leq B, 0 \leq C$$

L'ensemble du modèle du problème de l'usine de gobelets peut maintenant être énoncé succinctement comme

$$\begin{aligned}
 (\mathcal{P}) \quad & \max \quad 25B + 20C \\
 & s.c. \quad 10B + 6C \leq 900 \\
 & \quad \quad \frac{1}{15}B + \frac{1}{15}C \leq 8 \\
 & \quad \quad B \geq 0, C \geq 0
 \end{aligned}$$

Exemple 1.2 – Problème de transport

Une entreprise de distribution doit transporter un produit disponible en quantité d_i aux dépôts $i = 1, \dots, m$ vers des destinations j où la demande est b_j , $j = 1, \dots, n$. Supposons que

1. La demande totale doit être égale à l'offre totale

$$\sum_{i=1}^m d_i = \sum_{j=1}^n b_j$$

2. Le coût unitaire de transport de i à j est $c_{i,j}$.

Les variables de décision. On note $x_{i,j}$ la quantité non-négative transportée de i à j .

L'objectif de l'entreprise. Minimiser le coût total de transport.

Le modèle d'optimisation.

$$\text{Minimiser } \sum_{i=1}^m \sum_{j=1}^n c_{i,j} x_{i,j}$$

Les contraintes

$$\begin{aligned} \sum_{i=1}^m x_{i,j} &= b_j \quad (j = 1, \dots, n) \\ \sum_{j=1}^n x_{i,j} &= d_i \quad (i = 1, \dots, m) \\ x_{i,j} &\geq 0 \quad (i = 1, \dots, m; j = 1, \dots, n) \end{aligned}$$

1.1.2 Optimisation non linéaire

Définition 1.2 – Optimisation non linéaire / *Linear programming* / 非线性规划

Un problème d'optimisation non linéaire (ONL) s'écrit sous la forme générale suivante :

$$\min\{f(x), g(x) \leq 0, h(x) = 0\} \quad (\text{ONL})$$

où les fonctions f, g et h sont typiquement non-linéaires. L'équation $g(x) \leq 0$ désigne ce que nous appellerons des contraintes d'inégalité et l'équation $h(x) = 0$ des contraintes d'égalité.

Exemple 1.3 – Portefeuille d'actions

Soit A, B et C trois titres d'un portefeuille. On note r_A, r_B et r_C leur rentabilité moyenne (espérance) et $\sigma_A, \sigma_B, \sigma_C$ leur volatilité (écart type). Soit x, y, z les poids respectifs investis dans chaque titre. On a donc $x + y + z = 1$ avec $x, y, z \geq 0$. On souhaite une rentabilité plus grande en moyenne que α .

$$xr_A + yr_B + zr_C \geq \alpha$$

et on souhaite minimiser le risque (variance)

$$f(x, y, z) = x^2 \sigma_A^2 + y^2 \sigma_B^2 + z^2 \sigma_C^2$$

On cherche donc à résoudre le problème

$$\begin{aligned} (\mathcal{P}) \quad & \inf_{(x,y,z) \in K} f(x, y, z) = x^2 \sigma_A^2 + y^2 \sigma_B^2 + z^2 \sigma_C^2 \\ \text{s.c.} \quad & xr_A + yr_B + zr_C \geq \alpha \\ & x + y + z = 1 \\ & (x, y, z) \in (\mathbb{R}_+)^3 \end{aligned}$$

Exemple 1.4 – Un problème en mécanique

On considère une corde horizontale de longueur 1 tendue à ses deux extrémités, avec une tension τ . La déviation éventuelle de la corde par rapport à sa position d'équilibre est désignée par $u(x)$, où $x \in [0, 1]$. Les extrémités étant fixées, on aura toujours $u(0) = u(1) = 0$. On néglige le poids de la corde par rapport à la tension τ , cela permet d'affirmer qu'en l'absence d'action extérieure, la corde est au repos et on a donc $u(x) = 0, \forall x \in [0, 1]$.

Supposons maintenant que la corde est écartée de sa position d'origine. Alors on peut montrer que l'énergie

potentielle associée à cette déformation (supposée petite) est

$$E(u) = \frac{1}{2} \int_0^1 \tau \left(\frac{du}{dx} \right)^2 dx$$

En l'absence d'obstacle, la position de repos $u(x) = 0$ minimise cette énergie. Il peut alors être intéressant d'étudier un problème où un obstacle empêche la corde de prendre la position triviale $u(x) = 0$. Intuitivement, on voit bien que la corde va toucher l'obstacle en certains points, mais pas forcément en tous les points de l'intervalle $[0, 1]$ (cela va dépendre de la forme de l'obstacle).

Supposons par exemple que cet obstacle peut être représenté par une fonction $v(x) \geq 0$. Alors la présence de l'obstacle se traduit par la condition


$$u(x) \geq v(x), x \in]0, 1[$$

Si on veut connaître la déformation $u(x)$ de la corde lorsque l'obstacle est présent, on peut donc penser qu'il est raisonnable de considérer le problème

$$\begin{aligned} (\mathcal{P}) \quad & \min_u \quad f(u) = \frac{1}{2} \int_0^1 \tau \left(\frac{du}{dx} \right)^2 dx \\ & \text{s.c.} \quad u(x) \geq v(x), x \in]0, 1[\\ & \quad \quad u(0) = u(1) = 0 \end{aligned}$$

Il s'agit, techniquement parlant, d'un problème de calcul des variations, et donc l'inconnue est une fonction (la fonction $u(x)$). Il semble donc pour l'instant impossible de le mettre sous forme standard (voir la figure 1.1, de la présente page).

Figure 1.1 – Déformation par la force de la corde



Chapitre 2

Outils techniques

2.1 Algèbre linéaire

Voir le livre [2].

Rappel 2.1 – Matrice définie positive / *Positive-definite matrix* / 正定矩阵

Soit M une matrice symétrique réelle d'ordre n . Elle est dite *définie positive* si elle est positive et inversible, autrement dit si elle vérifie l'une des quatre propriétés équivalentes suivantes

1. Pour toute matrice colonne non nulle x à n éléments réels, on a $x^\top \cdot M \cdot x > 0$.
Autrement dit, la forme quadratique définie par M est strictement positive pour $x \neq 0$.
2. Toutes les valeurs propres de M (qui sont nécessairement réelles) sont strictement positives.
3. La forme bilinéaire symétrique

$$\mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}, (x, y) \mapsto x^\top \cdot M \cdot y$$

est un produit scalaire sur $\mathbb{R}^n$.

4. Il existe une matrice $N \in \mathcal{M}_n(\mathbb{R})$ inversible telle que $M = N^\top \cdot N$.
Autrement dit, M est congruente à la matrice identité.

2.2 Topologie dans $\mathbb{R}^n$

Voir le livre [1].

Rappel 2.2 – Boule ouverte, fermée de $\mathbb{R}^n$ / *Open, closed ball* / 开球, 闭球

On se place dans $\mathbb{R}^n$, muni de la norme euclidienne $\|\cdot\|$ et du produit scalaire euclidien $\langle \cdot, \cdot \rangle$. Pour $x \in \mathbb{R}^n$ et $r > 0$, on note $\text{BO}(x, r)$ la boule ouverte de centre x et de rayon r et $\text{BF}(x, r)$ la boule fermée correspondante

$$\begin{aligned}\text{BO}(x, r) &= \{y \in \mathbb{R}^n, \|y - x\| < r\} \\ \text{BF}(x, r) &= \{y \in \mathbb{R}^n, \|y - x\| \leq r\}\end{aligned}$$

Définition 2.1 – Ensemble ouvert, fermé de $\mathbb{R}^n$ / *Open, closed set* / 开集, 闭集

- Un sous-ensemble O de $\mathbb{R}^n$ est un *ouvert* de $\mathbb{R}^n$ si

$$\forall x \in O, \exists r_x > 0, \text{BO}(x, r_x) \subset O$$

On dit aussi que O est ouvert dans $\mathbb{R}^n$.

- Un sous-ensemble F de $\mathbb{R}^n$ est un *fermé* de $\mathbb{R}^n$ si son complémentaire $\mathbb{R}^n \setminus F$ est ouvert.

Propriété 2.1

1. Les ensembles $\emptyset$ et $\mathbb{R}^n$ sont ouverts dans $\mathbb{R}^n$.
2. Une réunion quelconque d'ouverts est ouverte.
3. Une intersection finie d'ouverts est ouverte. Voici un contre-exemple pour l'intersection infinie

$$\bigcap_{n \in \mathbb{N}^*} \left] -\frac{1}{n}, 1 + \frac{1}{n} \right[= [0, 1]$$

Définition 2.2 – Voisinage/Neighbourhood/邻域

Soit $a \in \mathbb{R}^n$, on dit que V est un *voisinage* de a dans $\mathbb{R}^n$ si

$$\exists \varepsilon > 0, \text{BO}(a, \varepsilon) \subset V$$

L'ensemble des voisinages de a sera noté par $\mathcal{V}(a)$.

Propriété 2.2

1. L'ensemble $\mathcal{V}(a)$ est stable par intersections finies (i.e., $\forall (V_1, V_2, \dots, V_n) \in \mathcal{V}(a)^n, V_1 \cap V_2 \cap \dots \cap V_n \in \mathcal{V}(a)$).
2. L'ensemble $\mathcal{V}(a)$ est stable par croissance (i.e., $\forall V \in \mathcal{V}(a), V \subset W \Rightarrow W \in \mathcal{V}(a)$).

Définition 2.3 – Partie bornée/Bounded set/有界集合

Soit A une partie d'un espace métrique $(\mathbb{R}^n, d)$,

1. on dit que A est *bornée* si

$$\exists x \in \mathbb{R}^n, \exists r \in \mathbb{R}_+^*, A \subset \text{BO}(x, r)$$

2. on dit qu'une fonction $f : \Omega \rightarrow \mathbb{R}^n$ est *bornée* si

$$f(\Omega) \text{ est borné}$$

Propriété 2.3

Soit A une partie non vide d'un espace métrique $(\mathbb{R}^n, d)$. Les trois assertions suivantes sont équivalentes.

1. A est bornée
2. $\forall x \in \mathbb{R}^n, \exists r \in \mathbb{R}_+^*, A \subset \text{BO}(x, r)$
3. $\text{diam}(A) = \sup\{d(x, y) \mid (x, y) \in A^2\} < +\infty$

Définition 2.4 – Fonction coercive/Coercive function/强制泛函

Soit $f : A \rightarrow \mathbb{R}$ une fonction numérique continue définie sur une partie $A \subset \mathbb{R}^n$ fermée mais pas bornée. On dit que f est *coercive* si

$$\lim_{\|x\| \rightarrow +\infty, x \in A} f(x) = +\infty$$

Autrement dit, f est *coercive* si

$$\forall M > 0, \exists N > 0 \text{ tel que } \|x\| > N \text{ et } x \in A \Rightarrow f(x) > M$$

Rappel 2.3 – Adhérence/*Closure*/闭包

Soit E un espace euclidien et soit $A \subset E$. On appelle *adhérence de A dans E* le plus petit fermé de E contenant A (plus petit pour l'inclusion), et on le note $\overline{A}$.

Propriété 2.4

Soit E un espace euclidien et soit $A \subset E$.

1. Pour tout fermé F de E tel que $A \subset F$, on a $\overline{A} \subset F$.
2. Alors l'adhérence de A est définie par

$$\overline{A} = \left\{ x \in E, \exists (a_n) \in A^{\mathbb{N}}, \|a_n - x\| \xrightarrow{n \rightarrow +\infty} 0 \right\}$$

L'ensemble $\overline{A}$ est donc l'ensemble des limites des suites d'éléments de A . Un point de l'adhérence de A est dit *adhérent* à A .

Rappel 2.4 – Valeur d'adhérence d'une suite

Soit E un espace euclidien, et soit $(u_n)_{n \in \mathbb{N}} \in E^{\mathbb{N}}$ une suite, on dit que $\alpha \in E$ est une *valeur d'adhérence* de $(u_n)_{n \in \mathbb{N}}$ s'il existe une suite extraite de $(u_n)_{n \in \mathbb{N}}$ qui converge vers α . On note

$$\text{Adh}((u_n)_{n \in \mathbb{N}}) \stackrel{\text{Not}}{=} \{ \ell \in E, \ell \text{ est une valeur d'adhérence de } (u_n)_{n \in \mathbb{N}} \}$$

Proposition 2.1

Soit $u \in E^{\mathbb{N}}$, et $a \in E$, alors

$$[a \in \text{Adh}(u)] \iff \left[\forall \varepsilon > 0, \{n \in \mathbb{N}, u_n \in BO(a, \varepsilon)\} \text{ est infini} \right]$$

Rappel 2.5 – Compact

Soit A une partie d'un espace métrique (E, d) , on dit que A est *compacte* si elle vérifie

$$\forall u \in A^{\mathbb{N}}, \text{Adh}(u) \cap A \neq \emptyset$$

Autrement dit, toute suite $(u_n)_{n \in \mathbb{N}} \in A^{\mathbb{N}}$ admet une valeur d'adhérence dans A .

Remarque 2.1

On peut dire aussi, de toute suite de A on peut extraire une sous-suite *convergente dans* A .

2.3 Calcul différentiel

Voir le livre [1].

Rappel 2.6 – Dérivée partielle/*Partial derivative*/偏导数

Soit O un ouvert non vide de $\mathbb{R}^n$ et soit $f : O \rightarrow \mathbb{R}^p$.

— On dit que f est *admet une dérivée partielle par rapport à la j -ième variable en $x \in O$* si la fonction

$$t \longmapsto f(x_1, \dots, x_{j-1}, t, x_{j+1}, \dots, x_n)$$

est dérivable en x_j .

— Si c'est le cas, le vecteur dérivé de $\mathbb{R}^p$ obtenu (ou nombre dérivé si $p = 1$) est noté

$$\frac{\partial f}{\partial x_j}(x) \quad \text{ou} \quad \partial_j f(x)$$

— Si f admet une dérivée partielle par rapport à la j -ième variable en tout $x \in O$, on définit la j -ième dérivée partielle de f par

$$\partial_j f : \begin{cases} O & \longrightarrow \mathbb{R}^p \\ x & \longmapsto \partial_j f(x) \end{cases}$$

Remarque 2.2 – Dérivée directionnelle / *Directional derivative* / 方向导数

Pour un vecteur $v \in \mathbb{R}^n$ non nul, on peut définir plus généralement (sous réserve d'existence) la *dérivée directionnelle* de f dans la direction v en x , notée $\partial_v f(x)$, par ^a

$$\partial_v f(x) = \lim_{t \rightarrow 0} \frac{f(x + t \cdot v) - f(x)}{t}$$

En particulier, $\partial_j f(x)$ est la dérivée directionnelle de f dans la direction e_j (le j -ième vecteur de la base canonique de $\mathbb{R}^n$) en x

$$\partial_j f(x) = \lim_{t \rightarrow 0} \frac{f(x + t \cdot e_j) - f(x)}{t}$$

Toujours sous réserve d'existence, la *dérivée directionnelle* de f dans la direction v est alors définie par

$$\partial_v f : \begin{cases} O & \longmapsto \mathbb{R}^p \\ v & \longmapsto \partial_v f(x) \end{cases}$$

^a. Pour t assez petit, $x + t \cdot v \in O$ car O est un ouvert de $\mathbb{R}^n$.

Rappel 2.7 – Fonction différentiable et différentielle en un point / *Differentiable function* / 可导方程

Soit O un ouvert non vide de $\mathbb{R}^n$ et soit $x_0 \in O$. Une fonction $f : O \rightarrow \mathbb{R}^p$ est *différentiable* en $x_0 \in O$ s'il existe une application linéaire $df_{x_0} \in \mathcal{L}(\mathbb{R}^n, \mathbb{R}^p)$ telle que, pour tout $h \in \mathbb{R}^n$ tel que $x_0 + h \in O$,

$$f(x_0 + h) = f(x_0) + df_{x_0}(h) + o_{h \rightarrow 0_{\mathbb{R}^n}}(\|h\|)$$

Si c'est le cas, df_{x_0} s'appelle la *différentielle* de f en x_0 .

Remarque 2.3 – Lien entre différentielle et dérivée (dimension 1)

Soit I un intervalle ouvert non vide de $\mathbb{R}$, soit $x_0 \in I$ et soit $f : I \rightarrow \mathbb{R}$. Alors f est différentiable en x_0 si et seulement si elle est dérivable en x_0 . Si c'est le cas, pour tout $h \in \mathbb{R}$ tel que $x_0 + h \in I$,

$$f(x_0 + h) = f(x_0) + f'(x_0)h + o_{h \rightarrow 0}(h)$$

On en déduit que $df_{x_0}(h) = f'(x_0)h$ pour tout $h \in \mathbb{R}$. En particulier, $f'(x_0) = df_{x_0}(1)$.

Remarque 2.4 – Lien entre différentielle et dérivées partielles

Soit O un ouvert non vide de $\mathbb{R}^n$, soit $x_0 \in O$ et soit $f : O \rightarrow \mathbb{R}^p$. Si f est différentiable en x_0 , alors elle admet des dérivées partielles en x_0 et

$$df_{x_0} : h \mapsto \sum_{j=1}^n \partial_j f(x_0) h_j$$

Si c'est le cas, pour tout $h \in \mathbb{R}^n$ tel que $x_0 + h \in O$,

$$f(x_0 + h) = f(x_0) + \sum_{j=1}^n \partial_j f(x_0) h_j + o_{h \rightarrow 0_{\mathbb{R}^n}}(\|h\|)$$

Rappel 2.8 – Différentielle d'une fonction composée

Soit O un ouvert non vide de $\mathbb{R}^n$, soit $x_0 \in O$ et soit $f : O \rightarrow \mathbb{R}^p$. Soit également O' un ouvert non vide de $\mathbb{R}^p$ contenant $f(O)$ et soit $g : O' \rightarrow \mathbb{R}^q$. On peut alors considérer

$$g \circ f : O \subset \mathbb{R}^n \xrightarrow{f} f(O) \subset O' \subset \mathbb{R}^p \xrightarrow{g} \mathbb{R}^q$$

Si f est différentiable en x_0 et si g est différentiable en $f(x_0)$, alors $g \circ f$ est différentiable en x_0 et

$$d(g \circ f)_{x_0} = (dg_{f(x_0)}) \circ df_{x_0} \quad (2.1)$$

Rappel 2.9 – Gradient/Gradient/梯度

Soit f une fonction définie sur un ouvert O de $\mathbb{R}^n$ à valeurs dans $\mathbb{R}$ et soit $a \in O$. Lorsque f est différentiable en a , on appelle *gradient de f en a* le vecteur

$$\nabla f(a) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(a) \\ \vdots \\ \frac{\partial f}{\partial x_n}(a) \end{bmatrix} \in \mathbb{R}^n$$

Remarque 2.5 – Lien entre différentielle et gradient

Si $p = 1$ (donc $f : O \rightarrow \mathbb{R}$), on peut représenter la forme linéaire $df_{x_0} \in \mathcal{L}(\mathbb{R}^n, \mathbb{R})$ à l'aide du produit scalaire (théorème de représentation, voir le cours « algèbre linéaire avancé ») : il existe un unique vecteur $\nabla f(x_0) \in \mathbb{R}^n$, appelé *gradient de f en x_0* , tel que

$$\forall h \in \mathbb{R}^n, \quad df_{x_0}(h) = \langle \nabla f(x_0), h \rangle$$

De plus, si $\mathcal{E} = (e_1, \dots, e_n)$ est une base orthonormée de $\mathbb{R}^n$ (par exemple la base canonique), alors

$$\text{Mat}_{\mathcal{E}}(\nabla f(x_0)) = \begin{bmatrix} \partial_{e_1} f(x_0) \\ \vdots \\ \partial_{e_n} f(x_0) \end{bmatrix}$$

Rappel 2.10 – Matrice jacobienne/Jacobian matrix/雅可比矩阵

Soit O un ouvert non vide de $\mathbb{R}^n$, soit $x_0 \in O$ et soit $f : O \rightarrow \mathbb{R}^p$ différentiable en x_0 . La matrice de la différentielle $df_{x_0} \in \mathcal{L}(\mathbb{R}^n, \mathbb{R}^p)$ de f en x_0 dans les bases canoniques de $\mathbb{R}^n$ et de $\mathbb{R}^p$ est appelée la *matrice jacobienne de f en x_0* , notée $J_f(x_0)$.

On a donc

$$J_f(x_0) = \left[\partial_j f_i(x_0) \right]_{\substack{1 \leq i \leq p \\ 1 \leq j \leq n}} = \begin{bmatrix} \partial_1 f_1(x_0) & \partial_2 f_1(x_0) & \cdots & \partial_n f_1(x_0) \\ \partial_1 f_2(x_0) & \partial_2 f_2(x_0) & \cdots & \partial_n f_2(x_0) \\ \vdots & \vdots & \ddots & \vdots \\ \partial_1 f_p(x_0) & \partial_2 f_p(x_0) & \cdots & \partial_n f_p(x_0) \end{bmatrix} \in M_{p,n}(\mathbb{R})$$

Définition 2.5 – Matrice hessienne / *Hessian matrix* / 海森矩阵

Soit $x_0 \in \mathbb{R}^n$ et $f : \mathbb{R}^n \rightarrow \mathbb{R}$ dont toutes les dérivées partielles secondes existent en x_0 , alors la *matrice hessienne* (ou simplement la *hessienne*) de f en x_0 , notée $H_f(x_0)$, est la matrice carrée définie par

$$H_f(x_0) = \left[\frac{\partial^2 f}{\partial x_i \partial x_j}(x_0) \right]_{(i,j) \in \llbracket 1, n \rrbracket^2} \in M_{n,n}(\mathbb{R})$$

Remarque 2.6

D'après le théorème de Schwarz (voir le Poly de Y1S2), si f est une fonction de classe $\mathcal{C}^2$ définie sur un ouvert O de $\mathbb{R}^n$ et $\forall x_0 \in O$, on a $\frac{\partial^2 f}{\partial x_i \partial x_j}(x_0) = \frac{\partial^2 f}{\partial x_j \partial x_i}(x_0)$ pour $\forall (i, j) \in \llbracket 1, n \rrbracket^2$, et donc $H_f(x_0)$ est symétrique.

Rappel 2.11 – Développement limité / *Taylor expansion* / 泰勒展开

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ différentiable en $x \in \mathbb{R}^n$, alors f admet un *développement limité à l'ordre 1 en x* , donné par

$$f(x+h) = f(x) + df_x(h) + o(\|h\|)$$

ou bien sous la forme matricielle

$$f(x+h) = f(x) + \langle \nabla f(x), h \rangle + o(\|h\|)$$

Proposition 2.2 – Développement limité d'ordre 2

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ deux fois différentiable en $x \in \mathbb{R}^n$, alors f admet un *développement limité à l'ordre 2 en x* , donné par

$$f(x+h) = f(x) + df_x(h) + \frac{1}{2} d^2 f_x(h, h) + o(\|h\|^2)$$

ou bien sous la forme matricielle

$$f(x+h) = f(x) + \langle \nabla f(x), h \rangle + \frac{1}{2} \langle H_f(x) \cdot h, h \rangle + o(\|h\|^2)$$

2.4 Analyse convexe

Rappel 2.12 – Ensemble convexe / *Convex set* / 凸集

Soit $S \subset \mathbb{R}^n$, S est dit *convexe* si

$$\forall (x, y) \in S^2, \forall t \in [0, 1], t.x + (1-t).y \in S$$

Rappel 2.13 – Fonction convexe / *Convex function* / 凸函数

Soit $S \subset \mathbb{R}^n$ un ensemble convexe non vide. Une fonction $f : S \rightarrow \mathbb{R}$ est dite *convexe* si

$$\forall (x, y) \in S^2, \forall t \in [0, 1], f(t.x + (1-t).y) \leq t f(x) + (1-t) f(y)$$

f est dite strictement convexe si l'inégalité est stricte dès que $x \neq y$ et $t \in]0, 1[$.

Rappel 2.14 – Fonction strictement convexe / *Strictly convex function* / 严格凸函数

Soit E un espace vectoriel (ou affine) réel. On dit qu'une fonction $f : E \rightarrow \mathbb{R} \cup \{+\infty\}$ est *strictement convexe* si, pour tous x et y distincts dans E et pour tout $t \in]0, 1[$, on a

$$f(t.x + (1-t).y) < t f(x) + (1-t) f(y)$$

Exemple 2.1 – Contre-exemple

La fonction $f(x) = \langle a, x \rangle + \alpha$ sur $x \in \mathbb{R}$ avec $a \in \mathbb{R}^n$ et $\alpha \in \mathbb{R}$ est convexe, mais elle n'est pas strictement convexe.

Définition 2.6 – Fonction fortement convexe / *Strongly convex function* / 强凸函数

Soit E un espace vectoriel (ou affine) réel. On dit qu'une fonction $f : E \rightarrow \mathbb{R} \cup \{+\infty\}$ est *fortement convexe* de module $m > 0$ si, pour tous x et y distincts dans E et pour tout $t \in]0, 1[$, on a

$$f(t.x + (1-t).y) \leq t f(x) + (1-t) f(y) - \frac{m}{2} t(1-t) \|x - y\|^2$$

On dit également que f est m -fortement convexe.

Proposition 2.3 – Fonction fortement convexe

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction deux fois différentiable. Alors f est m -fortement convexe

1. s'il existe une constante $m > 0$ telle que

$$\forall (x, h) \in \mathbb{R}^n, \langle H_f(x) \cdot h, h \rangle \geq m \|h\|^2$$

2. si la fonction $f(x) - \frac{m}{2} \|x\|^2$ est convexe.

Théorème 2.1 – Caractérisation de la convexité par le gradient

Soit $C \subset \mathbb{R}^n$ un ouvert convexe, $f : C \subset \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction différentiable, alors f est convexe si et seulement si

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle, \forall (x, y) \in C^2$$

La fonction f est strictement convexe si et seulement si

$$f(y) > f(x) + \langle \nabla f(x), y - x \rangle, \forall (x, y) \in C^2, x \neq y$$

Démonstration 1

On voit bien l'interprétation géométrique de ce dernier résultat quand $n = 1$: le graphe d'une fonction convexe f se trouve toujours au-dessus de la tangente en un point donné.
Soit f convexe i.e.

$$\forall (x, y) \in C^2, \forall t \in [0, 1] : f(x + t.(y - x)) \leq f(x) + t(f(y) - f(x))$$

En retranchant $f(x)$ aux deux termes de l'inégalité précédente et en divisant par t , on obtient

$$\frac{f(x + t.(y - x)) - f(x)}{t} \leq f(y) - f(x)$$

En faisant tendre t vers 0, on a bien

$$\langle \nabla f(x), y - x \rangle = \lim_{t \rightarrow 0} \frac{f(x + t.(y - x)) - f(x)}{t} \leq f(y) - f(x)$$

Soit à présent $(x, y) \in C^2$ et $t \in [0, 1]$. Posons $x_t = (1-t).x + t.y = x + t.(y - x)$. En retranchant respectivement

x et y de x_t on obtient

$$\begin{cases} x_t - x = t.(y - x) \\ x_t - y = -(1 - t).(x - y) \end{cases}$$

En appliquant la relation à la fonction f (dans le théorème) respectivement aux points (x, x_t) et (y, x_t) , on obtient

$$\begin{cases} f(x) \geq f(x_t) - t\langle \nabla f(x_t), y - x \rangle \\ f(y) \geq f(x_t) + (1 - t)\langle \nabla f(x_t), y - x \rangle \end{cases}$$

En multipliant respectivement ces deux inégalités par $(1 - t)$ et t

$$\begin{cases} (1 - t)f(x) \geq (1 - t)f(x_t) - t(1 - t)\langle \nabla f(x_t), y - x \rangle \\ tf(y) \geq tf(x_t) + t(1 - t)\langle \nabla f(x_t), y - x \rangle \end{cases}$$

En sommant les deux inégalités on obtient la relation assurant la convexité de f .

Théorème 2.2 – Caractérisation de la convexité par la matrice hessienne

Soit $C \subset \mathbb{R}^n$ un ouvert convexe, $f : C \subset \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction deux fois différentiable, alors

- 1. f est convexe si et seulement si pour tout $x \in C$, $H_f(x)$ est semi-définie positive ($H_f(x) \geq 0$)*
- 2. f est strictement convexe si $H_f(x)$ est définie positive ($H_f(x) > 0$).*
- 3. f est fortement convexe si et seulement si $H_f(x)$ est définie positive ($H_f(x) > 0$).*

Démonstration 2

Supposons que f est convexe, et soit $x \in C$. Vu que C est ouvert, alors pour tout $y \in \mathbb{R}^n$, il existe $t \in \mathbb{R}^*$ suffisamment petit tel que $x + t.y \in C$. D'après le théorème précédent et la différentiabilité d'ordre 2 de f on a

$$f(x + t.y) \geq f(x) + \langle \nabla f(x), t.y \rangle$$

$$f(x + t.y) = f(x) + \langle \nabla f(x), t.y \rangle + \frac{1}{2} \langle H_f(x) \cdot (t.y), t.y \rangle + t^2 \|y\|^2 \epsilon(t.y)$$

En substituant, la deuxième équation dans la première on obtient

$$\frac{1}{2} \langle H_f(x) \cdot (t.y), t.y \rangle + t^2 \|y\|^2 \epsilon(t.y) \geq 0$$

En divisant cette inégalité par t^2 et en faisant tendre $t \rightarrow 0$, on conclut que la hessienne est semi-définie positive. Inversement, supposons que la matrice hessienne est semi-définie positive en tout point de C . Considérons $(x, y) \in C^2$ et $t \in]0, 1[$ et posons $y_t = t.x + (1 - t).y = y + t.(x - y)$. Du développement de Taylor de f , on a

$$f(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle H_f(y_t) \cdot (y - x), y - x \rangle$$

Notons que $\hat{y} \in C$ par convexité. De la semi-définie positivité de la matrice hessienne $H_f(y_t)$, on déduit que

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$$

Puisque x et y sont quelconques dans C , la convexité de f se déduit du théorème précédent.

Le corolaire suivant est immédiat.

Propriété 2.5

Soit f une forme quadratique définie par

$$f(x) = \frac{1}{2} \langle A \cdot x, x \rangle - \langle b, x \rangle$$

alors f est convexe si et seulement si $A \geq 0$, et strictement convexe si et seulement si $A > 0$.

Cela provient du fait que $H_f(x) = A$. En réalité on a même

$$f \text{ fortement convexe} \iff A > 0$$

Proposition 2.4 – Propriétés des fonctions fortement convexes

Soit $m > 0$ et $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction m -fortement convexe. Alors f vérifie les propriétés suivantes

1. f est strictement convexe.
2. Pour tous $(x, y) \in (\mathbb{R}^n)^2$,

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{m}{2} \|y - x\|^2$$

3. f est coercive.
4. f admet un unique minimum global^a x^* .
5. Pour tout $x \in \mathbb{R}^n$,

$$f(x^*) \geq f(x) - \frac{1}{2m} \|\nabla f(x)\|^2 \text{ et } \|x - x^*\| \leq \frac{2}{m} \|\nabla f(x)\|$$

a. La définition du minimum global sera donnée dans la chapitre prochaine.

Démonstration 3

Soit f une fonction m -fortement convexe.

1. Comme pour tout $x \in \mathbb{R}^n$, la matrice hessienne $H_f(x)$ est définie positive, f est strictement convexe.
2. Soit $(x, y) \in (\mathbb{R}^n)^2$. D'après la formule de Taylor, il existe $z \in]x, y[$ tel que

$$f(y) = f(x) + \langle \nabla f(x), y - x \rangle + \frac{1}{2} \langle H_f(z) \cdot (y - x), y - x \rangle$$

En appliquant l'inégalité de m -forte convexité au dernier terme on obtient la minoration annoncée.

3. En prenant $x = 0$ dans l'inégalité précédente on a

$$f(y) \geq f(x) + \langle \nabla f(0), y \rangle + \frac{m}{2} \|y\|^2$$

Cette fonction minorante est coercive, donc f est elle aussi coercive.

4. f est strictement convexe et coercive, elle admet donc un unique minimum global.
5. Soit $x \in \mathbb{R}^n$. Alors, pour tout $y \in \mathbb{R}^n$,

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{m}{2} \|y - x\|^2$$

Le terme de droite est une fonction quadratique de la variable y qui est minimale en $y^* = x - \frac{1}{m} \nabla f(x)$ et cette valeur minimale vaut $f(x) - \frac{1}{2m} \|\nabla f(x)\|^2$.

Ainsi, on a pour tout $y \in \mathbb{R}^n$,

$$f(y) \geq f(x) - \frac{1}{2m} \|\nabla f(x)\|^2$$

En prenant $y = x^*$ on a

$$f(x^*) \geq f(x) - \frac{1}{2m} \|\nabla f(x)\|^2$$

2.5 Exercices

- 2.1 Trouvez une matrice M d'ordre n symétrique non définie positive telle que sur deux sous-espaces vectoriels supplémentaires E_1 et E_2 de $\mathbb{R}^n$, on ait $\langle M \cdot x, x \rangle > 0$, pour tout $x \in E_1 \setminus \{0\}$ et pour tout $x \in E_2 \setminus \{0\}$.

Remarque. Une matrice peut donc être définie positive dans deux sous-espaces supplémentaires sans être définie positive.

- 2.2 a. Si A est une matrice symétrique définie positive, il existe $\alpha > 0$ tel que $\langle A \cdot x, x \rangle \geq \alpha \|x\|_2^2$, pour tout $x \in \mathbb{R}^n$. Donnez la meilleure constante α .
- b. Si A est une matrice quelconque, il existe $\alpha > 0$ tel que $\|A^\top \cdot A \cdot x\|_2 > m \|A \cdot x\|_2$, pour tout $x \in \mathbb{R}^n$. Donnez la meilleure constante α . En déduire que $x \mapsto \|A^\top \cdot x\|_2$ est une norme sur $\text{Im}(A)$.

- 2.3 Soit $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ une fonction définie par :

$$f(x, y) = x^4 - 4xy + y^4$$

- a. Montrer que f est coercive à l'aide de la norme $\sup : \|(x, y)\|_\infty = \max(|x|, |y|)$.

- b. Trouver le minimum global de f sur $\mathbb{R}^2$.

2.4 Soit une fonction $f : \mathbb{R}^3 \rightarrow \mathbb{R}$ définie par :

$$f(x, y, z) = e^{x-y} + e^{y-x} + z^2$$

- a. Calculer sa hessienne et étudier son signe. Montrer que f est convexe sur $\mathbb{R}^3$.
 b. Déterminer les points critiques de f . En déduire le minimum global de f .

2.5 Soit $u : \mathbb{R}^3 \rightarrow \mathbb{R}^2$, $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$, et $h = f \circ u$ où

$$f(u) = \begin{bmatrix} u_1^2 - u_2 \\ u_1 + u_2^2 \end{bmatrix}, u(x) = \begin{bmatrix} x_1 + x_3 \\ x_2^2 - x_3 \end{bmatrix}$$

Calculer la matrice jacobienne de f .

2.6 Les fonctions suivantes, sont-elles convexes ? Sont-elles strictement convexes ?

- a. La fonction linéaire $f(x) = \langle x, a \rangle + \alpha$;
 b. $f(x) = \|x\|_2$;
 c. $f(x) = \|x\|_\infty$;
 d. $f + g$ (si f est strictement convexe et que g est convexe).

2.7 Soit $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ la fonction définie par $f(x, y) = 2x^3 + 6xy - 3y^2 + 2$ pour tout $(x, y) \in \mathbb{R}^2$.

- a. Déterminer les extréma locaux de la fonction f .
 b. La fonction f possède-t-elle des extréma globaux sur $\mathbb{R}^2$?
 c. Représenter le segment de droite L défini par

$$L = \{(x, y) \in \mathbb{R}^2 \mid -2 \leq x \leq 0, y = x + 1\}$$

et déterminer les extréma globaux de la restriction de f à L , en précisant en quels points de L ils sont atteints.

2.8 On considère la fonction définie pour tout $(x, y) \in \mathbb{R}^2$ par

$$f(x, y) = xy e^{-\frac{1}{2}(x^2 + y^2)}$$

- a. Etudier les extréma locaux de f sur $\mathbb{R}^2$. On pourra utiliser les symétries de la fonction f pour réduire le nombre de cas à étudier.
 b. Démontrer que $f(x, y) \rightarrow 0$ quand $\|(x, y)\| \rightarrow \infty$.
 c. Déduire de ce qui précède l'existence des extréma globaux de f sur $\mathbb{R}^2$ et les déterminer.

2.9 Une boîte rectangulaire doit être construite. On désigne par x_1 , x_2 , x_3 les dimensions de la boîte : x_3 est la hauteur de la boîte, x_1 et x_2 sont les dimensions du fond de la boîte.

La boîte n'a pas de couvercle. Les côtés et le fond de la boîte seront fait en un métal coûtant 1 euro par centimètre carré. On veut construire une boîte de coût minimum et de volume au moins 10 centimètres cube.

- a. Formuler le problème.
 b. On a à résoudre un problème sous contraintes. Montrer que nécessairement toute solution optimale vérifie $x_3 = \frac{10}{x_1 x_2}$. Se ramener alors à un programme linéaire sans contrainte en les variables x_1 et x_2 que l'on formulera.

2.10 Un nouvel entrepôt doit être placé de sorte que la somme des carrés des distances à 4 entrepôts déjà existants soit minimisée.

Les 4 entrepôts sont localisés aux points $(1, 2)$, $(-2, 4)$, $(2, 6)$ et $(-6, -3)$.

On note x_1 et x_2 les coordonnées du nouvel entrepôt.

- a. Formuler le problème.
 b. On note f la fonction à minimiser. Montrer que f est convexe.
 c. Résoudre le problème en cherchant un point critique de f .

Chapitre 3

Conditions d'optimalité en optimisation sans contrainte

3.1 Introduction

On suppose dans tout ce chapitre que $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est une fonction objectif une ou deux fois différentiable, et qu'elle admet (au moins) un minimum local. On notera x^* le minimum (local) de f . Pour résoudre les problèmes d'optimisation, on s'intéresse au problème suivant : trouver le minimum d'une fonction f . D'un point de vue mathématique, les problèmes sans ou sous contrainte(s) peuvent être décrits comme

- Le problème d'optimisation sans contrainte

$$f(x^*) = \inf_{x \in \mathbb{R}^n} f(x)$$

- Le problème d'optimisation sous contraintes

$$f(x^*) = \inf_{x \in C} f(x)$$

où $C \subseteq \mathbb{R}^n$. Si C est fermé et borné (donc compact) et si f est continue sur C , alors il existe un minimum global atteint en un point de C et un maximum global atteint en un point de C .

En dimension 1, si $f : \mathbb{R} \rightarrow \mathbb{R}$ est dérivable, alors tout point x^* réalisant un minimum/local vérifie

$$f'(x^*) = 0$$

De plus, un point réalisable $x^* \in C$ est (voir la figure 3.1, page suivante)

- un minimum global de la fonction f sur le domaine C si

$$f(x^*) \leq f(x), \forall x \in C$$

- un minimum local (point critique) de f sur C si

$$\exists \varepsilon > 0, \forall x \in C, \|x - x^*\| \leq \varepsilon \Rightarrow f(x^*) \leq f(x)$$

Dans ce chapitre, on se concentre sur le problème d'optimisation sans contrainte. Le cas sous contraintes sera étudié au Chapitre 6.


3.2 Direction réalisable et direction de descente

Définition 3.1 – Direction réalisable/*Feasible direction*/可行方向

Soit $S \subseteq \mathbb{R}^n$, $S \neq \emptyset$. Un vecteur $d \in \mathbb{R}^n$ est appelé *direction réalisable au point* $x \in S$ si


$$\exists \lambda^* > 0, \forall \lambda \in]0, \lambda^*], x + \lambda.d \in S$$

Figure 3.1 – Un minimum global est donc aussi un minimum local



Notons $Z(x)$ l'ensemble des directions réalisables au point x .

Figure 3.2 – Direction réalisable



Remarque 3.1

1. L'ensemble $Z(x)$ n'est jamais vide, car $0 \in Z(x)$.
2. L'ensemble $Z(x)$ n'est pas forcément fermé.

Définition 3.2 – Direction de descente/Descent direction/下降方向

Soit $x \in \mathbb{R}^n$, un vecteur $d \in Z(x)$ est

1. la *direction de descente* au point x si

$$\exists \lambda^* > 0, \forall \lambda \in]0, \lambda^*], f(x + \lambda.d) \leq f(x)$$

2. la *direction stricte de descente* au point x si

$$\exists \lambda^* > 0, \forall \lambda \in]0, \lambda^*], f(x + \lambda.d) < f(x)$$

Notons $D(x)$ l'ensemble des directions de descente au point x .

Proposition 3.1 – Caractérisation des directions de descente

Soient $f \in \mathcal{C}^1(\mathbb{R}^n, \mathbb{R})$, $x \in \mathbb{R}^n$ et $d \in \mathbb{R}^n \setminus \{0\}$, alors

- (a) si d est une direction de descente en x , alors $\langle \nabla f(x), d \rangle \leq 0$,
- (b) si $\nabla f(x) \neq 0$ alors $d = -\nabla f(x)$ est une direction de descente stricte en x .

Démonstration 4

- (a) Soit $d \in \mathbb{R}^n \setminus \{0\}$ une direction de descente en x . Alors par définition, $\exists \lambda^* > 0$ tel que

$$f(x + \lambda.d) \leq f(x), \forall \lambda \in]0, \lambda^*]$$

Soit $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ définie par $\varphi(\lambda) = f(x + \lambda.d)$. On a $\varphi \in \mathcal{C}^1(\mathbb{R}, \mathbb{R})$, alors

$$\varphi'(\lambda) = \langle \nabla f(x + \lambda.d), d \rangle$$

Comme d est une direction de descente, on peut aussi écrire

$$\varphi(\lambda) \leq \varphi(0), \forall \lambda \in]0, \lambda^*]$$

et donc

$$\forall \lambda \in]0, \lambda^*[, \frac{\varphi(\lambda) - \varphi(0)}{\lambda} \leq 0$$

En passant à la limite lorsque λ tend vers 0, on déduit que $\varphi'(0) \leq 0$, c.à.d. $\langle \nabla f(x), d \rangle \leq 0$.


- (b) Soit $d = -\nabla f(x) \neq 0$. On veut montrer qu'il existe $\lambda^* > 0$ tel que si $\lambda \in]0, \lambda^*]$ alors $f(x + \lambda.d) < f(x)$ ou encore que $\varphi(\lambda) < \varphi(0)$ où φ est la fonction définie en 1 ci-dessus. On a

$$\varphi'(0) = \langle \nabla f(x), d \rangle = -|\nabla f(x)|^2 < 0$$

Comme φ' est continue, il existe $\lambda^* > 0$ tel que si $\lambda \in]0, \lambda^*]$ alors $\varphi'(\lambda) < 0$. Si $\lambda \in]0, \lambda^*]$ alors $\varphi(\lambda) - \varphi(0) = \int_0^\lambda \varphi'(t) dt < 0$, et on a donc bien $\varphi(\lambda) < \varphi(0)$ pour tout $\lambda \in]0, \lambda^*]$, ce qui prouve que d est une direction de descente stricte en x .

L'ensemble des directions strictes de descente de f en x , $\{d \in \mathbb{R}^n, \langle \nabla f(x), d \rangle < 0\}$, forme un demi-espace (voir la figure 3.3, de la présente page) ouvert de $\mathbb{R}^n$.

Figure 3.3 – Demi-espace des directions de descente d de f en x



Quelques questions à réfléchir

- (1) Pour $f(x + \lambda.d)$, que se passe-t-il si λ est choisi avec des valeurs différentes ?
- (2) Quel résultat obtiendrons-nous si nous choisissons itérativement la direction de descente ?

3.3 Résultats d'existence et d'unicité

Avant d'étudier les propriétés de la solution du problème d'optimisation sans contrainte, il faut assurer de leur existence.

Théorème 3.1 – Théorème d'existence (Weierstrass)

Soient C un ensemble compact (fermé et borné) non vide de $\mathbb{R}^n$ et $f : C \rightarrow \mathbb{R}$ une fonction continue sur C , alors f admet un minimum x^* sur C . Autrement dit, il existe un point x^* de C minimum global de f sur C

$$\forall x \in C, f(x) \geq f(x^*)$$

Démonstration 5

Soit $(x_m)_{m \in \mathbb{N}}$ une suite minimisante de f sur C , c'est-à-dire d'éléments de C telle que

$$x_m \in C, \forall m \in \mathbb{N} \text{ et } \lim_{m \rightarrow +\infty} f(x_m) = \inf_{x \in C} f(x)$$

Comme C est borné, la suite minimisante est bornée, donc on peut extraire une sous-suite notée $(x_{\varphi(m)})_{m \in \mathbb{N}}$ qui converge vers un élément x^* de C car C est un ensemble fermé dans $\mathbb{R}^n$. Cette suite extraite vérifie

$$\lim_{m \rightarrow +\infty} f(x_{\varphi(m)}) = f(x^*)$$

car f est continue. Par unicité de la limite

$$f(x^*) = \inf_{x \in C} f(x)$$

Donc f réalise son minimum dans C .

Remarque 3.2

1. De la même façon, il existe un point de maximum global de f sur C .
2. Si la fonction f n'est pas continue alors elle n'admet pas nécessairement de minimum.
3. Une fonction continue sur un fermé borné n'atteint pas toujours son minimum dans un espace de dimension infinie.
4. L'existence d'une suite minimisante provient de la définition de l'inf.
5. Rappelons qu'un compact C de $\mathbb{R}^n$ est caractérisé par la propriété que toute suite de points de l'ensemble C admet une valeur d'adhérence dans l'ensemble.

Dans le cas des problèmes d'optimisation sans contrainte ($C = \mathbb{R}^n$), le théorème suivant est posé

Théorème 3.2 – Théorème d'existence (sans contrainte)

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continue et coercive (i.e. infinie à l'infini : $\lim_{\|x\| \rightarrow +\infty} f(x) = +\infty$) alors f admet au moins un minimum sur $\mathbb{R}^n$. Autrement dit, il existe un point x^* de $\mathbb{R}^n$ minimum global de f sur $\mathbb{R}^n$

$$\forall x \in \mathbb{R}^n, f(x) \geq f(x^*)$$

Démonstration 6

Soit $(x_m)_{m \in \mathbb{N}}$ une suite minimisante dans $\mathbb{R}^n$, c'est-à-dire

$$\lim_{m \rightarrow +\infty} f(x_m) = \inf_{x \in \mathbb{R}^n} f(x)$$

Comme f est coercive, la suite $(x_m)_{m \in \mathbb{N}}$ ne peut pas partir à l'infini donc elle est bornée. Donc il existe $R > 0$ tel que $(x_m)_{m \in \mathbb{N}} \subset \text{BF}(0, R)$ compact. Donc il existe une sous-suite extraite notée $(x_{\varphi(m)})_{m \in \mathbb{N}}$ de $\mathbb{R}^n$ qui converge vers un $x^* \in \mathbb{R}^n$

$$x_{\varphi(m)} \xrightarrow{m \rightarrow +\infty} x^* \in \mathbb{R}^n$$

Or f est continue, donc


$$\lim_{m \rightarrow +\infty} f(x_{\varphi(m)}) = f(x^*)$$

Par unicité de la limite

$$f(x^*) = \inf_{x \in \mathbb{R}^n} f(x)$$

Donc, f réalise son minimum dans $\mathbb{R}^n$.

Figure 3.4 – Existence de minimum pour une fonction coercive



Pour une fonction coercive, il existe un point x^* qui atteint le minimum : $x^* \in \arg \min_{x \in \mathbb{R}^n} f(x)$.

Théorème 3.3 – Théorème d'unicité (sans contrainte)

Soit $C \subset \mathbb{R}^n$ un convexe. Si $f : C \rightarrow \mathbb{R}$ est strictement convexe et qu'elle admet un minimum sur C , alors il existe un unique minimum $x^* \in C$ de f tel que

$$\forall x \in C, f(x) \geq f(x^*)$$

Démonstration 7

Soit f strictement convexe, supposons qu'il existe $x^*, \bar{x}$ dans C deux minimums de la fonction f sur $\mathbb{R}^n$ tels que

$$x^* \neq \bar{x} \text{ et } f(x^*) = f(\bar{x}) = \inf_{x \in \mathbb{R}^n} f(x)$$

Soit $\tilde{x} = \lambda \bar{x} + (1 - \lambda)x^* \in C$ car C convexe avec $\lambda \in]0, 1[$ et comme f est strictement convexe

$$f(\tilde{x}) < \lambda f(\bar{x}) + (1 - \lambda)f(x^*) = f(x^*) = \inf_{x \in \mathbb{R}^n} f(x)$$

Ceci fournit une contradiction, donc $x^* = \bar{x}$.

3.4 Les conditions d'optimalité

Ce qui suit reste valable dans le cas où $f : C \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, lorsque le minimum x^* se trouve à l'intérieur de l'ensemble des contraintes C .

Théorème 3.4 – Conditions nécessaires (pour des cas sans contrainte)

Soit x^* un minimum local du problème

$$\inf_{x \in \mathbb{R}^n} f(x)$$

Alors, x^* vérifie nécessairement

- **condition nécessaire du premier ordre** : si f est différentiable en x^* , on a $\nabla f(x^*) = 0$;
- **condition nécessaire du second ordre** : si f est deux fois différentiable au point x^* , alors la forme quadratique $H_f(x^*)$ est semi-définie positive, c'est-à-dire

$$\forall h \in \mathbb{R}^n, \langle H_f(x^*) \cdot h, h \rangle \geq 0$$

où H_f est la matrice hessienne, définie par les coefficients $\frac{\partial^2 f}{\partial x_i \partial x_j}$.

Démonstration 8

Condition nécessaire du premier ordre

On écrit $f(x^*) \leq f(x^* + \varepsilon h) = f(x^*) + \varepsilon \langle \nabla f(x^*), h \rangle + |\varepsilon h| \varphi(\varepsilon h)$, avec $\varphi(\varepsilon h) \xrightarrow{\varepsilon \rightarrow 0} 0$, ce qui donne $0 \leq \varepsilon \langle \nabla f(x^*), h \rangle + |\varepsilon h| \varphi(\varepsilon h)$. On divise alors par $\varepsilon > 0$ puis on fait tendre ε vers 0^+ . Enfin, en choisissant dans le développement précédent $\pm h$ pour tout $h \in \mathbb{R}^n$, la conclusion s'ensuit.

Condition nécessaire du second ordre

On utilise un développement de Taylor-Young à l'ordre 2 et on utilise les mêmes notations que précédemment. On a

$$f(x^* + h) = f(x^*) + \langle \nabla f(x^*), h \rangle + \frac{1}{2} \langle H_f(x^*) \cdot h, h \rangle + \|h\|^2 \varphi(h) = f(x^*) + \frac{1}{2} \langle H_f(x^*) \cdot h, h \rangle + \|h\|^2 \varphi(h)$$

Comme précédemment, on remplace h par εh , h quelconque, ε petit, puis on divise par ε^2 et on fait tendre ε vers 0.

Remarque 3.3

La réciproque est fausse. Pourquoi ?

Exemple 3.1

Les exemples $f(x) = x^3$, $f(x) = x^4 \dots$

Exemple 3.2

Trouver, s'il existe, le minimum de $f(x, y) = x^2 - xy + y^2 + 2x - y + 1$.

La première étape consiste à annuler les deux dérivées partielles afin de détecter le ou les points candidats.

$$\begin{cases} \frac{\partial f}{\partial x}(x, y) = 2x - y + 2 = 0 \\ \frac{\partial f}{\partial y}(x, y) = -x + 2y - 1 = 0 \end{cases}$$

Résolvons ce système d'équations. Les solutions sont $x = -1$ et $y = 0$. Donc, un point unique est à considérer.

La deuxième étape consiste à vérifier la matrice hessienne de la fonction f , on a

$$H_f = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$$

La matrice admet 1 et 3 pour valeurs propres. La fonction est donc (fortement) convexe et le point $(-1, 0)$ est bien un minimum.

Théorème 3.5 – Conditions suffisantes (pour des cas sans contrainte)

Soit f une fonction de classe $\mathcal{C}^1$ définie sur $\mathbb{R}^n$. On suppose que $\nabla f(x^*) = 0$ et que f est deux fois différentiable en x^* . Alors, x^* est un minimum (local) de f si l'une des deux conditions suivantes est vérifiée :

- (a) $H_f(x^*)$ est définie positive,
- (b) $\exists r > 0$ tel que f est deux fois différentiable sur $BO(x^*, r)$ et la forme quadratique $H_f(x)$ est semi-définie positive pour tout $x \in BO(x^*, r)$.

Remarque 3.4

Le caractère «semi-défini positif» de la hessienne en x^* ne suffit pas pour conclure, comme en atteste l'exemple $f(x) = x^3$. En revanche, le caractère «défini-positif» de la hessienne n'est pas nécessaire, comme en témoigne l'exemple $f(x) = x^4$.

Démonstration 9

$H_f(x^*)$ est définie positive, par conséquent, il existe $\alpha > 0$ tel que $\langle H_f(x^*) \cdot h, h \rangle \geq \alpha \|h\|^2$ pour tout $h \in \mathbb{R}^n$ (rappelons que α peut être choisi égal à la plus petite valeur propre de la matrice hessienne de f en x^*). On écrit alors la formule de Taylor-Young à l'ordre 2 en x^*

$$f(x^* + h) = f(x^*) + \frac{1}{2} \langle H_f(x^*) \cdot h, h \rangle + \|h\|^2 \varphi(h) \geq f(x^*) + \left(\frac{\alpha}{2} + \varphi(h) \right) \|h\|^2 > f(x^*)$$

pourvu que h soit choisi assez petit, puisque $\varphi(h) \xrightarrow{h \rightarrow 0} 0$.

Proposition 3.2 – Conditions nécessaires et suffisantes (pour des cas sans contrainte)

Soit f une fonction convexe de classe $\mathcal{C}^1$, définie sur $\mathbb{R}^n$ et x^ un point de $\mathbb{R}^n$. Alors, x^* est un minimum local (donc global) de f si et seulement si $\nabla f(x^*) = 0$.*

Exemple 3.3

Soit une fonction objectif avec $x = (x_1, \dots, x_n) \in \mathbb{R}^n$, et $b = (b_1, \dots, b_n) \in (\mathbb{R}_+)^n$ définie par

$$f(x) : \begin{cases} \mathbb{R}^n \rightarrow \mathbb{R} \\ x \mapsto \sum_{i=1}^n (e^{x_i} - b_i x_i) \end{cases}$$

On observe alors que f est de classe $\mathcal{C}^\infty(\mathbb{R}^n)$, son gradient est donné par

$$\nabla f(x)_i = e^{x_i} - b_i$$

et sa matrice hessienne est diagonale avec

$$H_f(x)_{ii} = e^{x_i}$$

- (a) Puisque f est convexe, tout point critique est point de minimum global.
- (b) Puisque f est strictement convexe, s'il existe un point critique, il est unique.
- (c) Puisque f n'est pas fortement convexe, on ne peut pas utiliser la convexité pour démontrer l'existence d'un point critique.

Alors, on examine les résultats que différentes valeurs b_i apporteront.

- (1) Si $b_i > 0$, $i = 1, \dots, n$ alors il existe un unique point critique

$$\nabla f(x)_i = 0 \iff x_i = \ln(b_i)$$

C'est l'unique point de minimum global dans $\mathbb{R}^n$.

- (2) Si $\exists b_i \leq 0$, alors il n'existe pas de point critique, donc pas de minimum.

3.5 Exercices

3.1 Soit $f : \mathbb{R}^3 \rightarrow \mathbb{R}$, $f(x, y, z) = x^2 + y^2 + z^2 + xy + yz + xz - 3x - 4y - z + 4$.

- a. Mettre f sous la forme d'une fonction quadratique $f(x) = \frac{1}{2} \langle A \cdot x, x \rangle - \langle b, x \rangle + c$ avec A est une matrice symétrique, $b \in \mathbb{R}^3$, $c \in \mathbb{R}$.
- b. Soient $\lambda_{\min}$ et $\lambda_{\max}$ la plus petite et la plus grande valeur propre de A . Montrer que

$$\forall x \in \mathbb{R}^3, \lambda_{\min} \|x\|_2^2 \leq \langle A \cdot x, x \rangle \leq \lambda_{\max} \|x\|_2^2$$

- c. Montrer que si A est définie positive alors f est « infinie à l'infini » et admet un minimum unique sur $\mathbb{R}^3$.

3.2 On considère un nuage de m points de $\mathbb{R}^2$: $M_i = (t_i, x_i)$, pour $i \in \{1, \dots, m\}$. Ces données sont souvent le résultat de mesures et on cherche à décrire le comportement global de ce nuage. En général, ces points ne

sont pas alignés. On cherche la droite approchant au mieux ces points par la méthode des moindres carrés.
Remarque : La méthode des moindres carrés consiste alors à rechercher la droite telle que la somme des carrés des distances des points du nuage à cette droite soit minimale.

Chapitre 4

Méthode de gradient (pour des problèmes sans contrainte)

4.1 Introduction

Dans ce chapitre on s'intéresse à la résolution d'un problème d'optimisation convexe sans contrainte de la forme

$$f(x^*) = \inf_{x \in \mathbb{R}^n} f(x)$$

où $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est une fonction convexe et deux fois différentiable (sur $\mathbb{R}^n$). Sous ces hypothèses on sait que résoudre le problème d'optimisation revient à résoudre les n équations non linéaires

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(x_1, \dots, x_n) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x_1, \dots, x_n) \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

Afin d'assurer l'existence et l'unicité d'une telle solution, nous allons supposer que f est fortement convexe.

4.2 Méthode de gradient

Rappel 4.1 – Direction de descente/*Descent direction*/下降方向

Soit x tel que $\nabla f(x) \neq 0$. Le vecteur $d \in \mathbb{R}^n$ est une direction de descente au point x si et seulement si $\langle \nabla f(x), d \rangle \leq 0$.

Algorithm 1 Algorithme général de descente

Données : Un point initial $x_0 \in \mathbb{R}^n$, un seuil de tolérance $\varepsilon > 0$

Résultat : Un point $x \in \mathbb{R}^n$ proche de x^*

```
1: Initialiser :  $x \leftarrow x_0$ 
2:            $k \leftarrow 0$ 
3: Fonction DESCENTE GÉNÉRAL
4:   Tant que  $\|\nabla f(x)\| \geq \varepsilon$  faire
5:     1. Déterminer une direction de descente  $d_k \in \mathbb{R}^n$ .
6:     2. Déterminer un pas de descente  $\delta_k > 0$  tel que  $f(x_k + \delta_k \cdot d_k) < f(x_k)$ .
7:     3. Mettre à jour  $x : x \leftarrow x_{k+1} = x_k + \delta_k \cdot d_k$ 
8:            $k \leftarrow k + 1$ 
9:   Fin Tant que
10:  Retourner  $x$ 
11: Fin Fonction
```

Remarque 4.1 – Condition de résiliation

La condition de résiliation n'est pas unique. Pouvez-vous penser à d'autres conditions possibles ?

- Nombre d'itérations
- Critère de tolérance
- Objectif de précision
- Convergence de la fonction de coût

Convergence : Si on fait abstraction du critère d'arrêt, un algorithme de descente produit une suite de points $(x_k)_{k \in \mathbb{N}}$ définie par la relation de récurrence

$$x_{k+1} = x_k + \delta_k \cdot d_k$$

et telle que $f(x_{k+1}) < f(x_k)$ (sauf si $x_k = x^*$ à partir d'un certain rang). L'étude de la convergence d'un tel algorithme de descente consiste donc à savoir si la suite $(x_k)_{k \in \mathbb{N}}$ converge vers x^* . On rappelle que si f est fortement convexe on a $\|x - x^*\| \leq \frac{2}{m} \|\nabla f(x)\|$, donc le critère d'arrêt $\|\nabla f(x)\| < \varepsilon$ implique $\|x - x^*\| \leq \frac{2\varepsilon}{m}$.

Vitesse de convergence : Une fois qu'on a prouvé qu'un algorithme converge (par exemple $(x_k)_{k \in \mathbb{N}}$ converge vers x^*), on s'intéresse à sa vitesse de convergence. On dit que la méthode est d'ordre $r \geq 1$, s'il existe une constante $C > 0$ telle que, pour k suffisamment grand

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^r} \leq C$$

- Si $r = 1$, il faut $C \in]0, 1[$ pour avoir convergence et on a alors convergence linéaire.
- Si $r = 2$, on a une convergence quadratique.
- Si $\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^r} = 0$ alors on dit que l'on a convergence superlinéaire (ce qui est le cas pour toutes les méthodes d'ordre $r > 1$).

Remarque 4.2

L'algorithme du descente à pas fixe est une méthode de descente utilisant un pas fixe

$$\forall k \in \mathbb{N}, \delta_k = \delta$$

4.2.1 Algorithme de recherche de pas de descente

Dans l'Algorithme 1, l'étape «Déterminer un pas de descente $\delta_k > 0$ tel que $f(x_k + \delta_k \cdot d_k) < f(x_k)$ » nous demande de chercher un pas approprié. Alors, nous allons nous limiter à deux méthodes, la méthode de pas de descente optimale (dite aussi exacte) et la méthode de pas de descente par rebroussement.

Dans les deux cas, les données du problème sont une fonction f fortement convexe, un point actuel $x = x_k \neq x^*$, une direction de descente $d = d_k$ pour le point x , et on cherche un pas de descente $\delta = \delta_k > 0$ tel que $f(x + \delta \cdot d)$ soit «suffisamment plus petit» que $f(x)$.

Définition 4.1 – Méthode de pas de descente optimale

Pour f une fonction fortement convexe, $x \in \mathbb{R}^n$ et $d \in \mathbb{R}^n$ une direction de descente pour f en x , pour minimiser $f(x + \delta \cdot d)$, la méthode optimale donne le pas de descente comme ^a

$$\delta^* = \arg \min_{\delta > 0} f(x + \delta \cdot d)$$

a. $\arg \min f$ est l'ensemble des valeurs x pour lesquelles f atteint son minimum

$$\arg \min f \stackrel{\text{def}}{=} \left\{ x \in \mathbb{R}^n \mid \forall x' \in \mathbb{R}^n, f(x') \geq f(x) \right\}$$

Remarque 4.3

- Le pas de descente optimal est bien défini, c'est-à-dire que $\delta \mapsto f(x + \delta.d)$ admet un unique minimum global δ^* sur $]0, +\infty[$.
- On a $\delta = \delta^*$ si et seulement si $\langle \nabla f(x + \delta.d), d \rangle = 0$.

La méthode de rebroussement permet de calculer un pas de descente lorsque l'on ne sait pas minimiser la fonction f sur la demi-droite affine $\{x + \delta.d, t > 0\}$.

Définition 4.2 – Condition d'Armijo


Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe $\mathcal{C}^1$, $x \in \mathbb{R}^n$ et $d \in \mathbb{R}^n$. Soit $\alpha \in]0, 1[$. On dira que $t \geq 0$ satisfait la condition d'Armijo si

$$f(x + t.d) \leq f(x) + \alpha t \langle \nabla f(x), d \rangle$$

Lorsque d_k est une direction de descente, un pas de descente est un pas $\delta_k > 0$ qui assure que $f(x_{k+1}) \leq f(x_k)$, c'est-à-dire, $f(x_k + \delta_k.d_k) \leq f(x_k)$.

En $t = \delta$, $f(x_k + t.d_k)$ est en dessous de la droite de pente strictement négative $t \mapsto f(x_k) + \alpha t \langle \nabla f(x_k), d_k \rangle$.

Figure 4.1 – Condition d'Armijo



La variable t prend la plage de valeur $]0, \delta^*[$.

Définition 4.3 – Pas d'Armijo

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe $\mathcal{C}^1$, $x \in \mathbb{R}^n$ et $d \in \mathbb{R}^n$. Soit $\alpha \in]0, 1[$, $\beta \in]0, 1[$. On appelle pas d'Armijo, le réel $\tau > 0$ défini par

$$\tau = \max \{ \beta^n, n \in \mathbb{N} \text{ et } f(x + \beta^n.d) \leq f(x) + \alpha \beta^n \langle \nabla f(x), d \rangle \}$$

Remarque 4.4

Les plus importants sont le paramètre de rebroussement/*backtracking parameters*/回溯参数 α et le facteur d'échelle/*scale factor*/缩放因子 β .

Définition 4.4 – Méthode de pas de descente par rebroussement

Pour f une fonction fortement convexe, $x \in \mathbb{R}^n$ et $d \in \mathbb{R}^n$ une direction de descente pour f en x , il existe,

un entier $N \in \mathbb{N}$, deux réels $\alpha \in]0, 1[$ et $\beta \in]0, 1[$ tels que si $n \geq N$, on a

$$f(x + \beta^n \cdot d) \leq f(x) + \alpha \beta^n \langle \nabla f(x), d \rangle$$

La méthode de rebroussement donne le pas de descente comme

$$\delta^* = \beta^N$$

Remarque 4.5

1. Choisir une longueur de pas initiale, par exemple $\alpha = 0,5$ et $\beta = 0,9$.
2. Calculer la valeur de la fonction pour cette longueur de pas $f(x_{k+1}) = f(x_k + \alpha \beta \cdot d_k)$.
3. (a) Si la valeur diminue, accepter la longueur de pas.
(b) Sinon, réduire la longueur de pas par multiplier-la par le facteur d'échelle β . Alors, $x_{k+1} = x_k + \alpha \beta^2 \cdot d_k$.
4. Répéter les étapes 2 et 3 jusqu'à ce que les critères soient satisfaits.

4.2.2 Algorithme de descente de gradient

On s'intéresse maintenant à l'étude d'un algorithme de descente particulier appelé algorithme de descente de gradient. Cet algorithme utilise comme direction de descente $d = d_k$ au point $x = x_k$ le vecteur opposé du gradient, soit

$$d_k = -\nabla f(x_k)$$

Algorithm 2 Algorithme de descente

Données : Un point initial $x_0 \in \mathbb{R}^n$, un seuil de tolérance $\varepsilon > 0$

Résultat : Un point $x \in \mathbb{R}^n$ proche de x^*

- 1: Initialiser : $x \leftarrow x_0$
 - 2: $k \leftarrow 0$
 - 3: **Fonction** DESCENTE DE GRADIENT
 - 4: **Tant que** $\|\nabla f(x)\| \geq \varepsilon$ **faire**
 - 5: 1. Calculer $d_0 = -\nabla f(x)$ ($d_k = -\nabla f(x_k)$).
 - 6: 2. Déterminer un pas de descente $\delta_k > 0$ par la méthode optimale ou par la méthode de rebroussement.
 - 7: 3. Mettre à jour $x : x \leftarrow x_{k+1} = x_k + \delta_k \cdot d_k$
 - 8: $k \leftarrow k + 1$
 - 9: **Fin Tant que**
 - 10: **Retourner** x
 - 11: **Fin Fonction**
-

Attention, en pratique, on teste plutôt le critère d'arrêt après l'étape 1 afin de ne pas calculer deux fois $\nabla f(x_k)$. La convergence de l'algorithme est assurée par le théorème suivant.

Théorème 4.1 – Convergence de la méthode de gradient

Soient $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction fortement convexe telle que

$$\forall (x, h) \in (\mathbb{R}^n)^2, m\|h\|^2 \leq \langle H_f(x) \cdot h, h \rangle \leq M\|h\|^2$$

avec $0 < m \leq M$ et x_0 un point quelconque de $\mathbb{R}^n$. Alors l'algorithme de descente de gradient converge et on a une vitesse de convergence linéaire

$$\forall k \in \mathbb{N}, f(x_k) - f(x^*) \leq c^k (f(x_0) - f(x^*))$$

où $c \in [0, 1[$ dépend de la méthode de recherche de pas de descente et est donnée par

— $c = 1 - \frac{m}{N}$ pour la méthode exacte/optimale,

- $c = 1 - \min\left(2m\alpha, 2\beta\alpha\frac{m}{M}\right)$ pour la méthode de rebroussement utilisant les constantes $\alpha \in]0, 1[$ et $\beta \in]0, 1[$.

Démonstration 10

On peut démontrer qu'avec la condition $m\|h\|^2 \leq \langle H_f(x) \cdot h, h \rangle \leq M\|h\|^2$ ($0 < m \leq M$),

$$\frac{2}{m}(f(x_k) - f(x^*)) \leq \|x_k - x^*\|^2 \leq \frac{2}{M}(f(x_k) - f(x^*))$$

ce qui montre que la convergence de $(f(x_k))_{k \in \mathbb{N}}$ vers $f(x^*)$ implique la convergence de $(x_k)_{k \in \mathbb{N}}$ vers x^* .

— La preuve de la convergence linéaire dans le cas de la méthode optimale pour le calcul du pas de descente.

On suppose que l'algorithme de gradient est à l'itération k et que $x_k \neq x^*$ (sinon l'algorithme a convergé en un nombre fini $l \leq k$ d'itérations et la suite (x_k) est constante et égale à x^* à partir du rang l). Le point x_{k+1} est de la forme $x_{k+1} = x_k - \delta_k \nabla f(x_k)$ avec

$$\delta_k = \arg \min_{\delta > 0} f(x_k - \delta \nabla f(x_k))$$

Pour tous $(x, y) \in (\mathbb{R}^n)^2$,

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{M}{2} \|y - x\|^2$$

Alors, en prenant $x = x_k$ et $y = x_k - \delta \nabla f(x_k)$ pour tout $\delta > 0$ on a

$$\begin{aligned} f(x_k - \delta \nabla f(x_k)) &\leq f(x_k) + \langle \nabla f(x_k), -\delta \nabla f(x_k) \rangle + \frac{M}{2} \|\delta \nabla f(x_k)\|^2 \\ &= f(x_k) - \delta \|\nabla f(x_k)\|^2 + \delta^2 \frac{M}{2} \|\nabla f(x_k)\|^2 \end{aligned}$$

Par définition, le membre de gauche est minimal en $\delta = \delta_k$. Ainsi pour tout $\delta > 0$, on a

$$f(x_{k+1}) \leq f(x_k) + \left(\delta^2 \frac{M}{2} - \delta \right) \|\nabla f(x_k)\|^2$$

Le membre de droite est minimal en $\delta = \frac{1}{M}$, et pour cette valeur de δ on obtient la majoration

$$f(x_{k+1}) \leq f(x_k) - \frac{1}{2M} \|\nabla f(x_k)\|^2$$

On soustrait ensuite la valeur minimum $f(x^*)$ à cette inégalité

$$f(x_{k+1}) - f(x^*) \leq f(x_k) - f(x^*) - \frac{1}{2M} \|\nabla f(x_k)\|^2$$

Enfin, par forte convexité, pour tout $x \in \mathbb{R}^n$,

$$f(x^*) \geq f(x) - \frac{1}{2m} \|\nabla f(x)\|^2$$

et donc pour $x = x_k$,

$$\|\nabla f(x_k)\|^2 \geq 2m(f(x_k) - f(x^*))$$

Ainsi,

$$f(x_{k+1}) - f(x^*) \leq \left(1 - \frac{m}{M}\right) (f(x_k) - f(x^*))$$

Par récurrence, on a donc bien $f(x_k) - f(x^*) \leq c^k (f(x_0) - f(x^*))$ avec $c = 1 - \frac{m}{M} \in [0, 1[$.

— La preuve de la convergence linéaire dans le cas de la méthode de rebroussement.

(1) Montrer que pour tout $\delta \in [0, \frac{1}{M}]$ on a $\frac{M}{2}\delta^2 - \delta \leq -\frac{t}{2}$ (on pourra par exemple utiliser la convexité).

(2) En déduire que pour tout $\delta \in [0, \frac{1}{M}]$,

$$f(x_k + \delta \nabla f(x_k)) \leq f(x_k) - \alpha \delta \|\nabla f(x_k)\|^2$$

(3) En déduire que la méthode de rebroussement s'arrête soit en $\delta_k = 1$ soit pour une valeur $\delta_k \geq \frac{\beta}{M}$.

(4) En déduire que

$$f(x_{k+1}) \leq f(x_k) - \min\left(\alpha, \frac{\alpha\beta}{M}\right) \|\nabla f(x_k)\|^2$$

et conclure la preuve comme pour le cas du pas optimal.

En pratique, l'algorithme de gradient à pas optimal s'avère souvent plus efficace que l'algorithme de gradient à pas fixe

Exemple 4.1 – L'algorithme de gradient à pas optimal est plus efficace

La matrice hessienne de la forme quadratique $f(x, y) = x^2 + 100y^2$ est la matrice diagonale constante $H_f = \begin{bmatrix} 2 & 0 \\ 0 & 200 \end{bmatrix}$, alors $0 < 2.Id \leq H_f \leq 200.Id$. Donner le nombre d'itérations nécessaires pour approcher le minimum $(0, 0)$ de f sur $\mathbb{R}^2$ à 10^{-6} près, à partir de l'initialisation : $(x_0, y_0) = (1, 1)$.

— **à pas fixe**

Lorsque la matrice hessienne est mal conditionnée comme $\frac{M}{m} = \frac{200}{2} \gg 1$, l'algorithme est lent. Le taux de convergence optimal est obtenu pour un pas égal à : $\frac{1}{101} \approx 0.0099$. Pour cette valeur du pas, il faut près de 700 itérations pour approcher le minimum $(0, 0)$ de f à 10^{-6} près. Si le pas est supérieur à 0.01, l'algorithme diverge.

— **à pas optimal**

Le paramètre de tolérance ε utilisé pour la phase de recherche linéaire, étant fixé à 10^{-8} , il ne faut que 6 itérations pour approcher le minimum $(0, 0)$ de f à 10^{-6} près.

Il est cependant difficile de comparer objectivement les deux algorithmes, et le contre-exemple suivant montre l'impossibilité d'établir théoriquement, et pour toute initialisation donnée, la supériorité de l'algorithme du gradient à pas optimal, même lorsque le critère est une forme quadratique elliptique simple :

Exemple 4.2 – Mais pas toujours plus efficace ...

Si l'on cherche à minimiser $f = x^2 + 2y^2$ sur $\mathbb{R}^2$ à 10^{-6} près, à partir de toute initialisation (x_0, y_0) située sur la droite d'équation : $x = 2y$. Le pas optimal effectué à chaque étape est constant égal à $1/3$, et la vitesse de convergence linéaire de taux : $1/3$.

4.3 Application de la méthode de gradient

Exemple 4.3 – Méthode de gradient

Pour $(x, y) \in \mathbb{R}^n$, minimiser la fonction

$$f(x, y) = \frac{1}{2} \left((x + y - 4)^2 + (2x + 3y - 7)^2 + (4x + y - 9)^2 \right)$$

Session Python 4.1 – Méthode de gradient

Pour réaliser la méthode de gradient...

On commence par définir la fonction f avec les variables x et y

In[1] – Fonction f

```
1 def fonctionf(x, y):
2     f = ((x+y-4)**2 + (2*x+3*y-7)**2 + (4*x+y-9)**2)*0.5
3     return f
```

Ensuite, les dérivées partielles du premier ordre de la fonction f en termes de x et y

In[2] – Dérivations partielles

```
1 import sympy as sp
2 def deriv(x, y):
3     a, b = sp.symbols('a b', real = True)
4     fx = sp.diff(fonctionf(a, b), a).subs(a,x).subs(b,y)
5     fy = sp.diff(fonctionf(a, b), b).subs(a,x).subs(b,y)
6     return fx, fy
```

Les dérivés partielles $\frac{\partial f}{\partial x}$ et $\frac{\partial f}{\partial y}$ sont définies respectivement par **fx** et **fy**.

$$\begin{cases} \frac{\partial f}{\partial x}(x, y) = (x + y - 4) + (2x + 3y - 7) \times 2 + (4x + y - 9) \times 4 \\ \frac{\partial f}{\partial y}(x, y) = (x + y - 4) + (2x + 3y - 7) \times 3 + (4x + y - 9) \end{cases}$$

La méthode de gradient à pas fixe.

Premièrement, on présente une méthode de calcul itératif de gradients avec un pas fixe $\delta = 0.01$, à partir d'un point initial $(x, y) = (0, 0)$. La condition pour abandonner l'opération est que la valeur de la fonction ne diminue plus, ou que la différence entre les deux valeurs de fonction calculées soit inférieure à 10^{-6} .

In[3] – Méthode de gradient à pas fixe

```
1 # n = nombre maximal d'itérations
2 def gradient_pas_fixe(n):
3     delta = 0.01 # pas fixe
4     x, y = 0, 0 # point initial (0, 0)
5     f = fonctionf(x, y)
6     deriv_x, deriv_y = deriv(x, y)
7     m = 0
8     # Condition de résiliation
9     while m < n and deriv_x**2+deriv_y**2 > 1e-6 :
10         m += 1
11         deriv_x, deriv_y = deriv(x, y)
12         x = x - delta * deriv_x
13         y = y - delta * deriv_y
14         f = fonctionf(x, y)
15     return x, y, f, m
```

Le résultat d'une itération de 10, 100 et 1000 fois

In[4] – Vérification des résultats

```
1 gradient_pas_fixe(10)
```

Out[4]

(1.86918954756589, 1.13873258547825, 0.577979920341783, 10)

In[5]

```
1 gradient_pas_fixe(100)
```

Out [5]

(1.99835128077227, 1.09346955876043, 0.454563617991453, 100)

In [6]

```
1 gradient_pas_fixe(1000)
```


Out [6]

(1.99987219745699, 1.09110756879253, 0.454545563685425, 164)

Exemple 4.4

Nous prenons un exemple intuitif pour voir l'effet des tailles de pas fixe sur les résultats d'optimisation (voir la figure 4.2, de la présente page).

Figure 4.2 – Méthode de gradient à pas fixe



Les premières 10 itérations d'optimisation avec les pas fixes $\eta = 0,01$, $\eta = 0,1$ et $\eta = 0,5$.

En observant les trois images, on peut constater que :

1. Dans l'image de gauche, le taux d'apprentissage est trop faible. En conséquence, la solution ne peut pas être trouvée dans les dix premières étapes. Cependant, si l'algorithme continue à itérer sur une longue période, il peut éventuellement trouver la solution.
2. Dans l'image du milieu, le taux d'apprentissage semble parfaitement adapté. En quelques itérations, l'algorithme converge rapidement vers la solution finale.
3. À droite, le taux d'apprentissage est trop élevé. L'algorithme diverge, saute la région de données et s'éloigne progressivement de la solution réelle à chaque étape.

Ces exemples montrent l'importance de choisir une taille de pas adaptée pour l'apprentissage automatique. Lorsque cette taille de pas ne peut pas être prédéterminée, il est nécessaire d'utiliser d'autres méthodes de sélection.

La méthode de gradient à pas optimal.

L'idée de trouver un pas approprié δ_k à chaque étape est de résoudre l'équation

$$\langle \nabla f(x + \delta_k.d), d \rangle = 0$$

Ici, on utilise la fonction `sympy.solve()` en Python pour obtenir la solution de l'équation. Cette fonction ne peut parfois pas obtenir de solution analytique, et on peut alors utiliser la fonction de calcul numérique `sympy.nsolve()` pour approximer la solution. Cependant, il peut y avoir des erreurs dans la solution numérique, ce qui est un problème majeur avec Python.

In[3] – Pas optimal

```
1 import numpy
2 from sympy import *
3 def pas_optimal(x, y):
4     delta = symbols('delta')
5     deriv_x, deriv_y = deriv(x, y)
6     x_n = x - delta * deriv_x
7     y_n = y - delta * deriv_y
8     fonc = numpy.dot(deriv(x_n, y_n), deriv(x, y))
9     pas = solve(fonc, delta)
10    return pas[0]
```

Le pas ici changera en fonction de l'itération de calcul.

In[4] – Méthode de gradient à pas optimal

```
1 def gradient_pas_optimal(n):
2     x, y = 0, 0      # point initial (0, 0)
3     f = fonctionf(x, y)
4     deriv_x, deriv_y = deriv(x, y)
5     m = 0
6     # Condition de résiliation
7     while m < n and deriv_x**2+deriv_y**2 > 1e-6 :
8         m += 1
9         delta = pas_optimal(x, y)    # pas optimal
10        deriv_x, deriv_y = deriv(x, y)
11        x = x - delta * deriv_x
12        y = y - delta * deriv_y
13        f = fonctionf(x, y)
14    return x, y, f, m
```

Le résultat d'une itération de 1, 10 et 100 fois

In[5] – Vérification des résultats

```
1 gradient_pas_optimal(1)
```

Out [5]

(1.92303924998251, 1.21080249072973, 0.494297908066886, 1)

In[6] – Vérification des résultats

```
1 gradient_pas_optimal(10)
```

Out [6]

(1.99999939946619, 1.09090876334520, 0.454545454551995, 4)

On peut voir que cette méthode de descente de gradient à pas variable a obtenu un résultat stable après 10 itérations. Même s'il existe de légères différences par rapport aux résultats de la méthode à pas fixe, on peut encore conclure que cette méthode est plus efficace pour cet exemple.

4.4 Exercices

- 4.1 Supposons que vous avez une fonction de coût $f(x, y) = x^2 + 2y^2 - 2x - 4y + 1$ définie sur $\mathbb{R}^2$. Utilisez la méthode de descente de gradient pour trouver le minimum de cette fonction.
- 4.2 Considérez la fonction de coût suivante $J(w) = w^2 - 6w + 5$, avec $w \in \mathbb{R}$. Appliquez la méthode de descente de gradient pour trouver le minimum de la fonction en partant de $w = 0$.
- Utilisez un taux d'apprentissage (pas fixe) de 0,1.
 - Résolvez ce problème avec la méthode de descente à pas optimal.
 - Comparez les deux résultats.
- 4.3 (Méthode de Newton, voir l'Annexe A) Trouver la direction de descente pour la fonction de coût $f(x) = x^2 + y^2$ en $(1, 1)$ en utilisant l'algorithme de descente de gradient avec une précision de 0,001.
- 4.4 (Méthode de Newton, voir l'Annexe A) Utilisez la méthode de Newton pour trouver le minimum de la fonction $f(x) = x^3 - 3x^2 + 2$ en partant de $x_0 = 0,5$ avec une précision de 0,001.

Chapitre 5

Méthode de Newton et quasi-Newton (pour des problèmes sans contrainte)

5.1 Introduction

La méthode de Newton n'est pas à proprement parler une méthode d'optimisation. C'est une méthode de recherche de zéros d'une fonction $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$, autrement dit on résout $F(x) = 0$. L'idée en optimisation est d'appliquer cette méthode en vue de la résolution de l'équation $\nabla f(x) = 0$, condition nécessaire de premier ordre pour la détection d'extrema d'une fonction (cas sans contrainte).

5.2 Méthode de Newton

Pour une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ deux fois différentiable en x_k , la formule de Taylor-Young au second ordre au point x de la fonction f est

$$f(x) = f(x_k) + \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2} \langle H_f(x_k) \cdot (x - x_k), x - x_k \rangle + \|x - x_k\|^2 \varepsilon(x - x_k)$$

avec $\lim_{x_k \rightarrow x} \varepsilon(x - x_k) = 0$. Soit une fonction $g : \mathbb{R}^n \rightarrow \mathbb{R}$ définie par

$$g(x) = g(x_k) + \langle \nabla g(x_k), x - x_k \rangle + \frac{1}{2} \langle H_g(x_k) \cdot (x - x_k), x - x_k \rangle$$

qui est donc l'approximation d'ordre deux de f au voisinage de x . Cette fonction g est une fonctionnelle quadratique. Elle est donc minimale pour $x = x_k - H_g(x_k)^{-1} \cdot \nabla g(x_k)$. De même, pour la fonction f , la méthode de Newton est un algorithme de descente pour lequel la direction de descente d_k au point x_k est donnée par

$$d_k = -H_f(x_k)^{-1} \cdot \nabla f(x_k)$$

La recherche de cette direction de descente nécessite donc la résolution d'un système linéaire de taille $n \times n$.

Définition 5.1 – Méthode de Newton

La méthode de Newton est définie par une valeur initiale x_0 et par la relation de récurrence

$$x_{k+1} = x_k - H_f(x_k)^{-1} \cdot \nabla f(x_k)$$

tant que la matrice hessienne $H_f(x_k)$ est inversible et tant que $\nabla f(x_k) \neq 0$.

Attention : Il y a une grande différence entre trouver la direction de descente avec la méthode de descente de gradient et la méthode de Newton. Faisons une comparaison ici, en supposant que nous avons déjà sélectionné le pas de descente δ ,

- Descente de gradient : $x_{k+1} = x_k - \delta \cdot \nabla f(x_k)$,
- Newton : $x_{k+1} = x_k - H_f(x_k)^{-1} \cdot \nabla f(x_k)$.

La méthode de Newton et la méthode de descente de gradient sont toutes les deux itératives, mais la méthode de descente de gradient ne nécessite que la connaissance du gradient, tandis que la méthode de Newton utilise la matrice inverse de la matrice hessienne H_f du second ordre pour la résoudre. On peut alors dire que la méthode de Newton converge plus rapidement (moins d'itération). Mais chaque itération prend plus de temps que la descente de gradient.

Algorithm 3 Algorithme de descente de Newton

Données : Un point initial $x_0 \in \mathbb{R}^n$, un seuil de tolérance $\varepsilon > 0$

Résultat : Un point $x \in \mathbb{R}^n$ proche de x^*

```

1: Initialiser :  $x \leftarrow x_0$ 
2:            $k \leftarrow 0$ 
3: Fonction DESCENTE DE NEWTON
4:   Tant que  $\|\nabla f(x_k)\| \geq \varepsilon$  faire
5:     1. Calculer  $d_k = -H_f(x_k)^{-1} \cdot \nabla f(x_k)$ .
6:     2. Mettre à jour  $x : x \leftarrow x_{k+1} = x_k + d_k$ 
7:            $k \leftarrow k + 1$ 
8:   Fin Tant que
9:
10:  Retourner  $x$ 
11: Fin Fonction

```

Théorème 5.1 – Convergence quadratique de la méthode de Newton

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe $\mathcal{C}^2$.

On suppose que

(H1) Il existe $x^* \in \mathbb{R}^n$ tel que $\nabla f(x^*) = 0$.

(H2) La matrice hessienne au point critique est définie positive $H_f(x^*) > 0$.

(H3) La matrice hessienne est lipschitzienne au voisinage de x^* , c'est-à-dire, il existe $L > 0$ tel que :

$$\|H_f(x) - H_f(y)\|_{\mathcal{M}_n(\mathbb{R})} \leq L\|x - y\|$$

pour tous x, y suffisamment proches de x^* .

Alors, pour tout x_0 suffisamment proche de x^* , la suite définie par

$$x_{k+1} = x_k - H_f(x_k)^{-1} \cdot \nabla f(x_k)$$

est bien définie et converge quadratiquement vers x^* .

Autrement dit,

$$\|x_{k+1} - x^*\| \leq C\|x_k - x^*\|^2$$

pour une certaine constante $C > 0$.

Démonstration 11

Définition de l'erreur : Posons $e_k = x_k - x^*$. L'itération de Newton s'écrit

$$x_{k+1} = x_k - H_f(x_k)^{-1} \cdot \nabla f(x_k)$$

Donc

$$e_{k+1} = e_k - H_f(x_k)^{-1} \nabla f(x_k)$$

Développement limité : Comme $\nabla f(x^*) = 0$, on effectue un développement limité du gradient au voisinage de x^* .

Par la formule de Taylor avec reste intégral

$$\nabla f(x_k) = \nabla f(x^*) + \int_0^1 H_f(x^* + te_k) \cdot e_k dt$$

Comme $\nabla f(x^*) = 0$, on obtient

$$\nabla f(x_k) = \int_0^1 H_f(x^* + te_k) \cdot e_k dt$$

On ajoute $H_f(x_k)$

$$\nabla f(x_k) = H_f(x_k) \cdot e_k + \int_0^1 (H_f(x^* + te_k) - H_f(x_k)) \cdot e_k dt$$

Posons

$$r_k = \int_0^1 (H_f(x^* + te_k) - H_f(x_k)) \cdot e_k dt$$

Ainsi

$$\nabla f(x_k) = H_f(x_k) \cdot e_k + r_k$$

Estimation du reste : Par l'hypothèse lipschitzienne

$$\|H_f(x^* + te_k) - H_f(x_k)\|_{\mathcal{M}_n(\mathbb{R})} \leq L\|(x^* + te_k) - x_k\|$$

Or $(x^* + te_k) - x_k = (t - 1)e_k$. Donc

$$\|H_f(x^* + te_k) - H_f(x_k)\|_{\mathcal{M}_n(\mathbb{R})} \leq L(1 - t)\|e_k\|$$

Ainsi

$$\|r_k\| \leq \int_0^1 L(1 - t)\|e_k\|^2 dt = L\|e_k\|^2 \int_0^1 (1 - t) dt = \frac{L}{2}\|e_k\|^2$$

Formule d'erreur : Comme $\nabla f(x_k) = H_f(x_k) \cdot e_k + r_k$, on remplace dans l'itération

$$e_{k+1} = e_k - H_f(x_k)^{-1}(H_f(x_k) \cdot e_k + r_k)$$

Donc

$$e_{k+1} = -H_f(x_k)^{-1} \cdot r_k$$

Par l'inégalité de Cauchy-Schwartz

$$\|e_{k+1}\| \leq \|H_f(x_k)^{-1}\| \|r_k\|$$

Donc

$$\|e_{k+1}\| \leq \frac{L}{2} \|H_f(x_k)^{-1}\| \|e_k\|^2$$

Bornes sur l'inverse de la Hessienne : Comme $H_f(x^*) > 0$, la matrice hessienne est inversible.

Par continuité de la matrice hessienne, il existe un voisinage de x^* dans lequel $H_f(x_k)$ reste inversible et $\|H_f(x_k)^{-1}\| \leq \frac{1}{m}$ pour une constante $m > 0$. Ainsi

$$\|e_{k+1}\| \leq \frac{L}{2m} \|e_k\|^2$$

On pose $C = \frac{L}{2m}$. Alors :

$$\|e_{k+1}\| \leq C\|e_k\|^2$$

ce qui prouve la convergence quadratique.

Exemple 5.1 – Convergence du cas quadratique

Soit $f(x) = \frac{1}{2}x^\top \cdot A \cdot x - b^\top x + c$ avec $A > 0$.

On a $\nabla f(x) = A \cdot x - b$, et $H_f(x) = A$.

L'itération de Newton donne $x_{k+1} = x_k - A^{-1} \cdot (A \cdot x_k - b)$.

Donc $x_{k+1} = A^{-1} \cdot b = x^*$.

Ainsi $x_1 = x^*$.

Alors la méthode de Newton converge en une seule itération.

5.2.1 Convergence du gradient

Théorème 5.2 – Convergence du gradient de la méthode de Newton

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction fortement convexe telle que

$$\forall (x, h) \in (\mathbb{R}^n)^2, m\|h\|^2 \leq \langle H_f(x)h, h \rangle \leq M\|h\|^2$$

avec $0 < m \leq M$ et dont la matrice hessienne est lipschitzienne pour la constante $L > 0$,

$$\forall (x, y) \in \mathbb{R}^n, \|H_f(x) - H_f(y)\|_{\mathcal{M}_n(\mathbb{R})} \leq L\|x - y\|$$

Soit x_0 un point quelconque de $\mathbb{R}^n$. On pose $0 < \eta \leq \frac{m^2}{L}$ et $\gamma > 0$. Alors on a

— Si $\|\nabla f(x_k)\| \geq \eta$, alors $f(x_{k+1}) - f(x_k) \leq -\gamma$,

— Si $\|\nabla f(x_k)\| < \eta$, alors le pas $\delta_k = 1$ et $\frac{L}{2m^2} \|\nabla f(x_{k+1})\| \leq \left(\frac{L}{2m^2} \|\nabla f(x_k)\|\right)^2$.

En particulier, l'algorithme de Newton converge et sa vitesse de convergence est quadratique.

Démonstration 12

Convergence quadratique : Analysons les implications de la seconde condition. Supposons qu'à l'itération k , $\|\nabla f(x_k)\| < \eta$. Puisque $\eta \leq \frac{m^2}{L}$, on a $\|\nabla f(x_{k+1})\|^2 < \eta$, la deuxième condition est également satisfaite à l'itération $k+1$. C'est-à-dire, pour $\forall l \geq k$, $\|\nabla f(x_l)\|^2 < \eta$. Par conséquent, pour $\forall l \geq k$, l'algorithme prend un pas de Newton complet $\delta = 1$, et

$$\frac{L}{2m^2} \|\nabla f(x_{l+1})\|^2 \leq \left(\frac{L}{2m^2} \|\nabla f(x_l)\|\right)^2$$

En appliquant cette inégalité de manière récursive, on trouve que pour $l \geq k$,

$$\frac{L}{2m^2} \|\nabla f(x_l)\|^2 \leq \left(\frac{L}{2m^2} \|\nabla f(x_k)\|\right)^{2^{l-k}} \leq \left(\frac{1}{2}\right)^{2^{l-k}}$$

Donc, on a

$$f(x_l) - f(x^*) \leq \frac{1}{2m} \|\nabla f(x_l)\|^2 \leq \frac{2m^3}{L^2} \left(\frac{1}{2}\right)^{2^{l-k+1}}$$

Newton amorti : D'abord, nous dérivons une borne supérieure sur le nombre d'itérations dans la phase de Newton amortie. Puisque la fonction f diminue d'au moins γ à chaque itération, le nombre de pas de Newton amortis ne peut pas dépasser

$$\frac{f(x_0) - f(x^*)}{\gamma}$$

On peut borner le nombre d'itérations dans la phase de convergence quadratique. Cela nécessite d'avoir $f(x) - f(x^*) \leq \varepsilon$ après au plus

$$k = \log_2 \log_2(\varepsilon_0/\varepsilon)$$

itérations, avec $\varepsilon_0 = \frac{2m^3}{L^2}$. Alors, le nombre d'itérations jusqu'à ce que $f(x) - f(x^*) \leq \varepsilon$ soit majoré par

$$\frac{f(x_0) - f(x^*)}{\gamma} + k$$

Le terme k , qui limite le nombre d'itérations dans la phase de convergence quadratique, croît extrêmement lentement avec la précision requise ε , et peut être considéré comme une constante, disons 5 ou 6. (6 itérations donnent une précision d'environ $\varepsilon \approx 5 \cdot 10^{-20} \varepsilon_0$.)

Alors, on peut dire que le nombre d'itérations de Newton nécessaires pour minimiser f est majoré par $\frac{f(x_0) - f(x^*)}{\gamma} + 6$.

5.2.2 Approximation à l'ordre 2

Écrivons la formule de Taylor à l'ordre 2, aux points x_k et $x_k + d$:

$$f(x_k + d) = g(d) + \|d\|^2 \varepsilon(\|d\|)$$

où $g(d) = f(x_k) + \langle \nabla f(x_k), d \rangle + \frac{1}{2} \langle H_f(x_k) \cdot d, d \rangle$ et $\varepsilon : \mathbb{R} \rightarrow \mathbb{R}$ satisfait $\lim_{x \rightarrow 0} \varepsilon(x) = 0$. La fonction g est une approximation de f à l'ordre 2.

La méthode de Newton calcule le point critique de la fonction g . En effet, g est une fonction quadratique en d dans $\mathbb{R}^n$ donc $\nabla g(d) = \nabla f(x_k) + H_f(x_k) \cdot d$ et $H_g(d) = H_f(x_k)$. Donc si $H_f(x_k)$ est inversible, g a un unique point critique,

$$d_k = -H_f(x_k)^{-1} \cdot \nabla f(x_k)$$

Si $H_f(x_k)$ est symétrique définie positive, alors g est fortement convexe dans $\mathbb{R}^n$ et ce point critique est l'unique minimum global de g .

5.2.3 Convergence globale

L'avantage le plus important de la méthode de Newton est sa vitesse de convergence rapide. Cependant, le point initial de la méthode de base de Newton doit être proche du point minimum, sinon l'algorithme risque de ne pas converger. Donc, la convergence de Newton est dite locale. C'est la raison pour laquelle on introduit la méthode globale de Newton.

Pour garantir une convergence pour tout point de départ, dite convergence globale, on introduit une suite $(\delta_k)_{k \in \mathbb{N}}$ de réels positifs. On définit les itérations de la suite $(x_k)_{k \in \mathbb{N}}$ par

$$x_{k+1} = x_k + \delta_k \cdot d_k$$

où d_k est définie par la méthode de Newton. Il faut à présent choisir $(\delta_k)_{k \in \mathbb{N}}$.

Ici, on peut aussi choisir d'utiliser la méthode de pas de descente optimale (Définition 4.1) ou la méthode de pas de descente par rebroussement (Définition 4.4).

Algorithm 4 Algorithme de descente de Newton globale

Données : Un point initial $x_0 \in \mathbb{R}^n$, un seuil de tolérance $\varepsilon > 0$, (des paramètres $\alpha \in]0, \frac{1}{2}[$ et $\beta \in]0, 1[$ pour la méthode de rebroussement)

Résultat : Un point $x \in \mathbb{R}^n$ proche de x^*

```


1: Initialiser :  $x \leftarrow x_0$ 
2:            $k \leftarrow 0$ 
3: Fonction DESCENTE DE NEWTON GLOBALE
4:   Tant que  $\|\nabla f(x_k)\| \geq \varepsilon$  faire
5:     1. Calculer  $d_k = -H_f(x_k)^{-1} \cdot \nabla f(x_k)$ 
6:     2. Mettre à jour  $x : x \leftarrow x_{k+1} = x_k + d_k$ 
7:      $k \leftarrow k + 1$ 
8:   Fin Tant que
9:
10:  Retourner  $x$ 
11: Fin Fonction
```

Exemple 5.2

Trouver le point zéro de la fonction

$$f(x) = x^2 - C$$

Figure 5.1 – Exemple de méthode de Newton



Le processus de trouver zéro de la fonction $f(x) = x^2 - C$ avec la méthode de Newton.

Évidemment, la racine carrée de C un zéro de la fonction $f(x) = x^2 - C$.

L'idée de la méthode de Newton est d'approcher le point zéro positif depuis le point initial à l'aide de la série de Taylor. On choisit un point initial x_0 arbitrairement. À chaque étape, on trouve les points $(x_i, f(x_i))$ et on trace la tangente en ce point. L'intersection de cette ligne tangente et de l'axe horizontal est le point x_{i+1} . x_{i+1} est plus proche de zéro que x_i . Ainsi, après quelques itérations, nous pouvons obtenir une intersection très proche du zéro $x^* = \sqrt{C}$.

Figure 5.1 a montre les deux étapes itératives pour obtenir x_1 et x_2 à partir de x_0 . Par itération continue, en se rapprochant progressivement du point zéro, lorsque le point $x_{n-1} - x_n \leq \varepsilon$ est assez petit, la solution approchée peut être considérée comme une bonne approximation de la solution exacte.

Pour les problèmes d'optimisation, trouver l'extremum de la fonction peut être équivalent à trouver le gradient de la fonction égal à zéro. Alors, on commence par définir le gradient d'une fonction f définie par $f(x) = x^2 - C$.

Session Python 5.1 – Méthode de Newton

Pour réaliser la méthode de Newton...

In[1] – Définition de fonction f

```
1 def fonctionfx(x):
2     fx = x**2 - 3
3     return fx
```

La pente de la ligne tangente d'un point nous demande de connaître la dérivée de cette fonction, on peut aussi dire que c'est la matrice hesienne de fonction f

In[2] – Matrice hesienne de fonction f

```
1 def hessienne(x):
2     Hfx = 2*x
3     return Hfx
```

In[3] – Méthode de Newton

```
1 def newton(x0,N,eps):
2     x = x0
3     fx = fonctionfx(x)
4     m = 0
5     while m < N and abs(fx) > eps:
6         m += 1
7         H = hessienne(x)
8         x = x - fx/H
9         fx = fonctionfx(x)
10    return x, fx, m
```

Le résultat d'une itération de 1 et 5 fois

In[4] – Vérification des résultats

```
1 newton(1,1,1e-6)
```

Out [4]

(2.0, -2, 1)

In[5] – Vérification des résultats

```
1 newton(1,5,1e-6)
```

Out [5]

(1.7320508100147276, 8.47267411785424e-09, 4)


Exemple 5.3 – Contre-exemple

Trouver le point zéro de la fonction

$$\nabla f(x) = x^3 - \frac{1}{2}x + 1$$

On peut suivre les même étapes comme l'exemple 5.2. Si le point initial x_0 est choisi dans la figure 5.2, alors après quelques étapes itératives, il est possible de trouver un point x_n qui soit assez proche du zéro x^* .

Figure 5.2 – Exemple de méthode de Newton



Le processus pour trouver le zéro de la fonction $f(x) = x^3 - \frac{1}{2}x + 1$ avec la méthode de Newton.

In[1] – Contre-exemple de méthode de Newton

```
1 def fonctionfx(x):
2     fx = x**3 - 1/2*x + 1
3     return fx
4
5 def Hfx(x):
6     Hfx = 3*x**2-1/2
7     return Hfx
8
9 def newton(x0,N,eps):
10     x = x0
11     fx = fonctionfx(x)
12     m = 0
13     while m < N and abs(fx) > eps:
14         m += 1
15         H = Hfx (x)
16         x = x - fx/H
17         fx = fonctionfx(x)
18     return x, fx, m
```

Veuillez vérifier l'effet des différentes valeurs initiales, des différentes conditions de terminaison et des différentes étapes d'itération sur les résultats.

In[2] – Vérification des résultats

```
1 import math
2 newton(math.sqrt(1/6)*(1+1e-15),50,1e-6)
```

Out [2]

(-1830586.3320772392, -6.134379590062379e+18, 50)

In [3] – Vérification des résultats

```
1 newton(math.sqrt(1/6)*(1+1e-15),100,1e-6)
```

Out [3]

(-1.165373043378158, -1.128555471296977e-09, 89)

In [4] – Vérification des résultats

```
1 newton(math.sqrt(1/6)*(1+1e-15),100,1e-6)
```


Out [4]

ZeroDivisionError : float division by zero

On peut finalement trouver qu'il y a deux problèmes existants (voir la figure 5.3, de la présente page) :

- le point initial n'est pas bien choisi (pas assez proche du point zéro),
- un point x_i dans le processus d'itération où la pente de la fonction est extrêmement petite (la ligne tangente et de l'axe horizontal se croisent à un point assez loin).

Figure 5.3 – Exemple de méthode de Newton



Le processus de trouver le point zéro de la fonction $f(x) = x^3 - \frac{1}{2}x + 1$ avec la méthode de Newton.

5.3 Méthode de Quasi-Newton

Pour certain problèmes, on cherche à éviter le calcul de la hessienne ne ainsi que son inverse car

- ce calcul demande trop de temps,
- on ne dispose pas de dérivées secondes, et leur calcul est très coûteux,
- la fonction objectif n'est pas deux fois dérivable.

L'idée est de remplacer la matrice hessienne $H_f(x_k)$ (ou son inverse) par une suite d'approximations B_k (ou G_k) symétriques définies positives, que l'on met à jour à chaque itération, impliquant seulement des évaluations de la fonction objectif ainsi que ses dérivées premières.

Définition 5.2 – Méthode de quasi-Newton

Une méthode de quasi-Newton est définie par une valeur initiale x_0 , une suite de matrices inversibles B_k et par la récurrence

$$d_k = -B_k^{-1} \cdot \nabla f(x_k), x_{k+1} = x_k + d_k$$

tant que $\nabla f(x_k) \neq 0$.

Algorithm 5 Algorithme de descente de Quasi-Newton

Données : Un point initial $x_0 \in \mathbb{R}^n$, un seuil de tolérance $\varepsilon > 0$, (des paramètres $\alpha \in]0, \frac{1}{2}[$ et $\beta \in]0, 1[$ pour la méthode de rebroussement)

Résultat : Un point $x \in \mathbb{R}^n$ proche de x^* , B_k ou G_k

```
1: Initialiser :  $x \leftarrow x_0$ 
2:            $B \leftarrow B_0$  ou  $G \leftarrow G_0$ 
3:            $k \leftarrow 0$ 
4: Fonction DESCENTE DE QUASI-NEWTON
5:   Tant que  $\|\nabla f(x_k)\| \geq \varepsilon$  faire
6:     1. Calculer  $d_k = -B_k^{-1} \cdot \nabla f(x_k)$  ou  $d_k = -G_k \cdot \nabla f(x_k)$ .
7:     2. Déterminer un pas de descente  $\delta_k > 0$  par la méthode optimale ou la méthode de rebroussement avec
       les paramètres  $\alpha$  et  $\beta$ .
8:     3. Mettre à jour :  $x \leftarrow x_{k+1} = x_k + \delta_k \cdot d_k$ 
9:            $B \leftarrow B_{k+1}$  ou  $G \leftarrow G_{k+1}$ 
10:           $k \leftarrow k + 1$ 
11:   Fin Tant que
12:
13:   Retourner  $x$ ,  $B_k$  ou  $G_k$ 
14: Fin Fonction
```

5.3.1 Principes d'obtention des formules de mise à jour

Ensuite, on introduit deux algorithmes pour mettre itérativement à jour de matrice approximative.

Supposons que B_k est connue et construisons B_{k+1} qui doit être une approximation de la matrice $H_f(x_{k+1})$. La fonction $f(x)$ est une fonction continue différentiable d'ordre 2. Pour $\nabla f(x)$ au point x_{k+1} , on obtient l'approximation de Taylor d'ordre 1

$$\nabla f(x) = \nabla f(x_{k+1}) + H_f(x_{k+1}) \cdot (x - x_{k+1}) + \mathcal{O}(\|x - x_{k+1}\|^2)$$

Si $x = x_k$, $\Delta_k = x_{k+1} - x_k$, $\gamma_k = \nabla f(x_{k+1}) - \nabla f(x_k)$, on obtient

$$H_f(x_{k+1}) \cdot \Delta_k + \mathcal{O}(\|\Delta_k\|^2) = \gamma_k$$

En ignorant maintenant le terme d'ordre supérieur $\|\Delta_k\|^2$, on espère que la matrice B_{k+1} qui se rapproche de la matrice hessienne satisfait l'équation (Algorithme BFGS)

$$B_{k+1} \cdot \Delta_k = \gamma_k$$

ou sa matrice inverse G_{k+1} satisfait (Algorithme DFP)

$$G_{k+1} \cdot \gamma_k = \Delta_k$$

On suppose que le nombre d'étapes d'itération est $n > 0$.

Si $n = 1$: Avec $B_0 = 1$, on retrouve la formule de la sécante.

Si $n > 1$: L'équation matricielle $B_{k+1} \cdot \Delta_k = \gamma_k$ à $n \times n$ inconnues et elle ne fournit que n équations linéaires,

- Comme la hessienne est symétrique, on impose la symétrie pour B_{k+1} (ce qui est logique pour que $B_{k+1} \approx H_f(x_{k+1})$), donc il reste $n^2 - \frac{n^2-n}{2} = \frac{n^2+n}{2}$ inconnues, ce qui laisse le choix pour une infinité de matrices «quasi-Newton».

- En se donnant une matrice initiale B_0 (par exemple $B_0 = I$, la matrice identité), on construit une suite de matrices (B_k) , par la relation

$$B_{k+1} = B_k + C_k$$

où C_k est une matrice facile à calculer.

Formules de correction de rang un (SR1)

Théorème 5.3 – Formules de Correction de rang un

Si on veut calculer B_{k+1} , destinée à approcher $H_f(x_{k+1})$, alors B_{k+1} doit vérifier l'équation «quasi-Newton» $B_{k+1} \cdot \Delta_k = \gamma_k$. Alors, on trouve

$$B_{k+1} = B_k + \frac{(\gamma_k - B_k \cdot \Delta_k) \cdot (\gamma_k - B_k \cdot \Delta_k)^\top}{(\gamma_k - B_k \cdot \Delta_k)^\top \cdot \Delta_k}$$

Si on veut calculer $G_{k+1} = B_{k+1}^{-1}$, destinée à approcher $H_f(x_{k+1})^{-1}$, alors G_{k+1} doit vérifier l'équation «quasi-Newton» $G_{k+1} \cdot \gamma_k = \Delta_k$. Alors, on trouve

$$G_{k+1} = G_k + \frac{(\Delta_k - G_k \cdot \gamma_k) \cdot (\Delta_k - G_k \cdot \gamma_k)^\top}{(\Delta_k - G_k \cdot \gamma_k)^\top \cdot \gamma_k}$$

Démonstration 13

Puisque la matrice hessienne est symétrique, il est souhaitable que l'approximation qu'on construit le soit également. Ceci est possible si on utilise une formule de mise à jour de la forme

$$B_{k+1} = B_k + a_k \cdot u_k \cdot u_k^\top$$

avec u_k un vecteur de $\mathbb{R}^n$ et a_k une constante. On note que la matrice $u_k \cdot u_k^\top$ est symétrique puisque $(u \cdot u^\top)^\top = (u^\top)^\top \cdot u = u \cdot u^\top$ et elle est de rang 1 car elle est le produit de deux matrices de rang 1. Il est facile de calculer a_k et u_k explicitement.

La matrice B_{k+1} doit vérifier l'équation de quasi-Newton, donc

$$\gamma_k = (B_k + a_k \cdot u_k \cdot u_k^\top) \cdot \Delta_k \Rightarrow \gamma_k - B_k \cdot \Delta_k = a_k \cdot u_k \cdot (u_k^\top \cdot \Delta_k)$$

- Si $\gamma_k - B_k \cdot \Delta_k = 0$, alors $B_{k+1} = B_k$.
- Si $\gamma_k - B_k \cdot \Delta_k \neq 0$, en prenant $a_k = \frac{1}{u_k^\top \cdot \Delta_k}$, on a $u_k = \gamma_k - B_k \cdot \Delta_k$, on trouve

$$B_{k+1} = B_k + \frac{(\gamma_k - B_k \cdot \Delta_k) \cdot (\gamma_k - B_k \cdot \Delta_k)^\top}{(\gamma_k - B_k \cdot \Delta_k)^\top \cdot \Delta_k}$$

Algorithme DFP (Davidson-Fletcher-Powell)

Dans l'algorithme DFP, G_k est sélectionné comme l'approximation de H_k^{-1} . En supposant que la matrice G_{k+1} à chaque étape d'itération est composée de G_k plus deux autres termes

$$G_{k+1} = G_k + P_k + Q_k$$

où P_k et Q_k sont des matrices indéterminées. Alors,

$$G_{k+1} \cdot \gamma_k = G_k \cdot \gamma_k + P_k \cdot \gamma_k + Q_k \cdot \gamma_k$$

Pour que G_{k+1} satisfasse la condition de quasi-Newton, P_k et Q_k peuvent être satisfaits

$$\begin{aligned} P_k \cdot \gamma_k &= \Delta_k \\ Q_k \cdot \gamma_k &= -G_k \cdot \gamma_k \end{aligned}$$

Donc, P_k et Q_k peuvent être choisis comme

$$\begin{aligned} P_k &= \frac{\Delta_k \cdot \Delta_k^\top}{\Delta_k^\top \cdot \gamma_k} \\ Q_k &= -\frac{G_k \cdot \gamma_k \cdot \gamma_k^\top \cdot G_k}{\gamma_k^\top \cdot G_k \cdot \gamma_k} \end{aligned}$$

La formule itérative de la matrice G_{k+1} peut être obtenue par

$$G_{k+1} = G_k + \frac{\Delta_k \cdot \Delta_k^\top}{\Delta_k^\top \cdot \gamma_k} - \frac{G_k \cdot \gamma_k \cdot \gamma_k^\top \cdot G_k}{\gamma_k^\top \cdot G_k \cdot \gamma_k}$$

On peut prouver que si la matrice initiale G_0 est définie positive, alors chaque matrice G_k dans le processus d'itération est définie positive.

Exemple 5.4

Trouver le point zéro de la fonction

$$f(x) = x^2 - 3$$

On prend le même exemple pour présenter sa résolution avec Python.

Session Python 5.2 – Méthode de quasi-Newton (DPF)

Pour réaliser la méthode de quasi-Newton avec l'algorithme de DPF...

In[1] – Algorithme de DPF

```
1 def Newton_DPF(x0,N,f,df,eps):
2     it = 0 #itmax = N
3     x = x0
4     fx = f(x0)
5     G = 1 # matrice initiale
6     liste_x = np.zeros(N+1)
7     liste_fx = np.zeros(N+1)
8     liste_x[0] = x0
9     liste_fx[0] = f(x0)
10    while np.abs(fx) > eps and it < N:
11        it += 1
12        fx = f(x)
13        Delta = -G*fx
14        x = x + Delta
15        fx_new = f(x)
16        gamma = fx_new - fx
17        G = G + Delta**2/(Delta*gamma) - (G**2*gamma**2)/(gamma**2*G)
18        liste_x[it] = x
19        liste_fx[it] = fx
20    return liste_x, liste_fx, it
```

Algorithme BFGS (Broyden-Fletcher-Goldfarb-Shanno)

DFP utilise G_k pour approximer l'inverse H_k^{-1} de la matrice hessienne, tandis que dans l'algorithme BFGS, B_k est sélectionné pour approximer la matrice hessienne H_k , et la condition correspondante de quasi-Newton est

$$B_{k+1} \cdot \Delta_k = \gamma_k$$

Supposons que la matrice B_{k+1} à chaque étape d'itération est composée de B_k plus deux éléments supplémentaires

$$B_{k+1} = B_k + P_k + Q_k$$

où P_k et Q_k sont des matrices indéterminées. Alors,

$$B_{k+1} \cdot \gamma_k = B_k \cdot \gamma_k + P_k \cdot \gamma_k + Q_k \cdot \gamma_k$$

Pour que G_{k+1} satisfasse la condition de quasi-Newton, P_k et Q_k doivent vérifier

$$\begin{aligned} P_k \cdot \Delta_k &= \gamma_k \\ Q_k \cdot \Delta_k &= -B_k \cdot \gamma_k \cdot \Delta_k \end{aligned}$$

Donc, P_k et Q_k peuvent être

$$P_k = \frac{\gamma_k \cdot \gamma_k^\top}{\gamma_k^\top \cdot \Delta_k}$$

$$Q_k = -\frac{B_k \cdot \Delta_k \cdot \Delta_k^\top \cdot B_k}{\Delta_k^\top \cdot B_k \cdot \Delta_k}$$

La formule itérative de la matrice B_{k+1} peut être donnée par

$$B_{k+1} = B_k + \frac{\gamma_k \cdot \gamma_k^\top}{\gamma_k^\top \cdot \Delta_k} - \frac{B_k \cdot \Delta_k \cdot \Delta_k^\top \cdot B_k}{\Delta_k^\top \cdot B_k \cdot \Delta_k}$$

On peut aussi prouver que si la matrice initiale B_0 est définie positive, alors chaque matrice B_k dans le processus d'itération est définie positive.

Si $G_k = B_k^{-1}$, $G_{k+1} = B_{k+1}^{-1}$, on peut appliquer la formule de Sherman-Morrison pour réécrire la formule itérative ci-dessus comme

$$G_{k+1} = \left(I - \frac{\Delta_k \cdot \gamma_k^\top}{\Delta_k^\top \cdot \gamma_k} \right) \cdot G_k \cdot \left(I - \frac{\Delta_k \cdot \gamma_k^\top}{\Delta_k^\top \cdot \gamma_k} \right)^\top + \frac{\Delta_k \cdot \Delta_k^\top}{\Delta_k^\top \cdot \gamma_k}$$

Exemple 5.5

Trouver le zéro de la fonction

$$f(x) = x^2 - 3$$

On prend le même exemple pour présenter la résolution avec Python.

Session Python 5.3 – Méthode de quasi-Newton (BFGS)

Pour réaliser la méthode de quasi-Newton avec l'algorithme de BFGS...

In[1] – Algorithme de BFGS

```

1  def Newton_BFGS(x0,N,f,df,eps):
2      it = 0 #itmax = N
3      x = x0
4      fx = f(x0)
5      B = 1 # matrice initiale
6      liste_x = np.zeros(N+1)
7      liste_fx = np.zeros(N+1)
8      liste_x[0] = x0
9      liste_fx[0] = f(x0)
10     while np.abs(fx) > eps and it < N:
11         it += 1
12         fx = f(x)
13         Delta = -fx/B
14         x = x + Delta
15         fx_new = f(x)
16         gamma = fx_new - fx
17         B = B + gamma**2/(Delta*gamma)-(B**2*Delta**2)/(Delta**2*B)
18         liste_x[it] = x
19         liste_fx[it] = fx
20     return liste_x, liste_fx, it

```

Deux chose à réfléchir après le cours :

- Les algorithmes DFP et BFGS, elles donnent le même résultat après n (par exemple 5) étapes ou pas.
- Essayez de résoudre le problème $\nabla f(X) = 0$ avec $f(x, y) = \frac{1}{2} \left((x + y - 4)^2 + (2x + 3y - 7)^2 + (4x + y - 9)^2 \right)$ et $X = (x, y)$.

5.3.2 Recherche linéaire et conditions de Wolfe

Dans les sections précédentes, nous avons présenté la méthode BFGS sous la forme simplifiée :

$$x_{k+1} = x_k + d_k$$

ce qui correspond implicitement à un pas unitaire $\alpha_k = 1$. Cette version est appelée : *full BFGS step*.

Cependant, dans la pratique et dans la théorie de convergence, la méthode BFGS s'écrit plus généralement :

$$x_{k+1} = x_k + \alpha_k \cdot d_k$$

où

1. $d_k = -B_k \cdot \nabla f(x_k)$ est une direction de descente, où B_k est une approximation de l'inverse de la matrice hessienne ;
2. $\alpha_k > 0$ est la taille du pas (*taille du pas* ou *step size*).

Si $B_k > 0$, alors :

$$\nabla f(x_k)^\top d_k = -\nabla f(x_k)^\top \cdot B_k \cdot \nabla f(x_k) < 0$$

et donc d_k est une direction de descente. Prendre systématiquement $\alpha_k = 1$ peut provoquer

- une divergence ;
- une augmentation de la fonction objectif ;
- une perte de stabilité numérique ;
- la perte de la définie-positivité des matrices BFGS.

Il est donc nécessaire de choisir une taille de pas appropriée.

La recherche linéaire (*line search*) consiste à déterminer une valeur de $\alpha_k > 0$ satisfaisant certaines conditions de décroissance et de courbure.

Définition 5.3 – Condition de Wolfe

Soient $0 < c_1 < c_2 < 1$, les conditions suivantes sont satisfaites

(C1) La **condition d'Armijo** garantit une décroissance suffisante de la fonction objectif

$$f(x_k + \alpha_k \cdot d_k) \leq f(x_k) + c_1 \alpha_k \cdot \nabla f(x_k)^\top \cdot d_k$$

(C2) La **condition de courbure** contrôle la variation du gradient le long de la direction de recherche

$$\nabla f(x_k + \alpha_k \cdot d_k)^\top \cdot d_k \geq c_2 \cdot \nabla f(x_k)^\top \cdot d_k$$

Si la direction d_k est une direction de descente et si α_k satisfait les conditions de Wolfe, alors $y_k^\top \cdot s_k > 0$.

Par définition $s_k = \alpha_k \cdot d_k$. De plus $y_k = \nabla f(x_{k+1}) - \nabla f(x_k)$.

Ainsi

$$y_k^\top \cdot s_k = \alpha_k \cdot y_k^\top \cdot d_k$$

Or

$$y_k^\top \cdot d_k = \nabla f(x_{k+1})^\top \cdot d_k - \nabla f(x_k)^\top \cdot d_k$$

D'après la condition de courbure de Wolfe

$$\nabla f(x_{k+1})^\top \cdot d_k \geq c_2 \cdot \nabla f(x_k)^\top \cdot d_k$$

Donc

$$y_k^\top \cdot d_k \geq (c_2 - 1) \cdot \nabla f(x_k)^\top \cdot d_k$$

Comme d_k est une direction de descente $\nabla f(x_k)^\top \cdot d_k < 0$. Et comme $c_2 - 1 < 0$, on obtient $y_k^\top \cdot d_k > 0$.

Puisque $\alpha_k > 0$, on conclut $y_k^\top \cdot s_k > 0$. Cette propriété assure que les matrices BFGS restent définies positives.

5.3.3 Convergence de BFGS

Théorème 5.4 – Convergence superlinéaire de BFGS

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de classe $\mathcal{C}^2$.

On suppose que

(H1) Il existe $x^* \in \mathbb{R}^n$ tel que $\nabla f(x^*) = 0$.

(H2) La matrice hessienne au point critique est définie positive $H_f(x^*) > 0$.

(H3) La matrice hessienne est lipschitzienne au voisinage de x^* , c'est-à-dire, il existe $L > 0$ tel que :

$$\|H_f(x) - H_f(y)\|_{\mathcal{M}_n(\mathbb{R})} \leq L\|x - y\|$$

pour tous x, y suffisamment proches de x^* .

et si la recherche linéaire satisfait les conditions de Wolfe, alors la méthode BFGS vérifie

$$\lim_{k \rightarrow \infty} \frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|} = 0$$

La convergence est donc superlinéaire.

Démonstration 14

Contrairement à Newton,

- BFGS n'utilise pas la Hessienne exacte ;
- il construit une approximation satisfaisant la condition de sécante

$$B_{k+1}s_k = y_k$$

La convergence quadratique n'est généralement pas obtenue sans hypothèses supplémentaires très fortes.

Chapitre 6

Conditions d'optimalité en optimisation sous contraintes

6.1 Introduction

On s'intéresse maintenant à des problèmes d'optimisation de la forme

$$(\mathcal{PC}) \quad \begin{cases} \inf_{x \in C} & f(x) \\ \text{s.c.} & g(x) \leq 0 \\ & h(x) = 0 \end{cases}$$

où $C \subseteq \mathbb{R}^n$, les fonctions f , g et h sont différentiables au moins une fois, et f est typiquement non linéaire. On suppose qu'il existe p contraintes d'inégalité $(g_i)_{i \in \llbracket 1, p \rrbracket}$ et q contraintes d'égalité $(h_j)_{j \in \llbracket 1, q \rrbracket}$. Cependant nous étudierons le cas où g et h sont linéaires avec un intérêt tout particulier. Dans ce chapitre nous allons nous efforcer d'obtenir les conditions d'optimalité associées au problème sous contraintes. Les chapitres suivants mettront ensuite l'accent sur les méthodes numériques permettant de le résoudre. Nous nous intéresserons précisément dans ce chapitre aux problèmes sous contraintes d'égalité (Section 5.3) ou d'inégalité (Section 5.4).

6.2 Résultats d'existence et d'unicité

Dans le cas des problèmes d'optimisation sous contraintes, le théorème suivant est utile

Théorème 6.1 – Théorème d'existence (sous contraintes)

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continue.

- (1) Si C est un sous-ensemble compact (fermé borné) de $\mathbb{R}^n$, alors il existe $x^* \in C$ tel que $f(x^*) = \inf_{x \in C} f(x)$.
- (2) Si C est un sous-ensemble fermé de $\mathbb{R}^n$, et si f est coercive (infinie à l'infini : $\lim_{\|x\| \rightarrow +\infty} f(x) = +\infty$), alors il existe $x^* \in C$ tel que $f(x^*) = \inf_{x \in C} f(x)$.

Démonstration 15

- (1) Si C est un sous-ensemble compact de $\mathbb{R}^n$, comme f est continue, elle atteint ses bornes sur C , d'où l'existence de x^* .
- (2) Si f est coercive, alors il existe $R > 0$ tel que si $\|x\| > R$ alors $f(x) > f(0)$, donc $\inf_{x \in C} f(x) = \inf_{x \in C \cap \text{BF}(0, R)} f(x)$. L'ensemble $C \cap \text{BF}(0, R)$ est compact, comme intersection de deux compacts. Donc, par ce qui précède, il existe $x^* \in C$ tel que $f(x^*) = \inf_{x \in C \cap \text{BF}(0, R)} f(x) = \inf_{x \in C} f(x)$.

Théorème 6.2 – Théorème d’unicité (sous contraintes)

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction continue. On suppose que f est strictement convexe et que C est convexe. Alors il existe au plus un élément x^* de C tel que $f(x^*) = \inf_{x \in C} f(x)$.

Démonstration 16

Soit f strictement convexe, supposons qu’il existe $x^*, \bar{x}$ dans C deux minimums de la fonction f sur $\mathbb{R}^n$ tels que

$$x^* \neq \bar{x} \text{ et } f(x^*) = f(\bar{x}) = \inf_{x \in \mathbb{R}^n} f(x)$$

Alors, si $\lambda \in]0, 1[$, on a $\tilde{x} = \lambda \bar{x} + (1 - \lambda) x^* \in C$ car C convexe, et comme f est strictement convexe

$$f(\tilde{x}) < \lambda f(\bar{x}) + (1 - \lambda) f(x^*) = f(x^*) = \inf_{x \in \mathbb{R}^n} f(x)$$

Ceci fournit une contradiction, donc $x^* = \bar{x}$.

6.3 Les conditions de Lagrange

On va tout d’abord s’intéresser au problème suivant, dit problème d’optimisation sous contraintes d’égalité seulement ($\mathcal{PCE}$)

$$(\mathcal{PCE}) \quad \begin{cases} \inf_{x \in \mathbb{R}^n} & f(x) \\ \text{s.c.} & h(x) = 0 \end{cases}$$

La raison par laquelle on s’intéresse en premier au problème sous contraintes d’égalité est qu’ils sont plus faciles à traiter. Nous allons dans un premier temps nous intéresser au cas où les contraintes sont linéaires.

6.3.1 Contraintes d’égalité linéaires

Un problème d’optimisation sous contraintes d’égalité linéaires est sous la forme

$$(\mathcal{PCE}) \quad \begin{cases} \inf_{x \in C} & f(x) \\ \text{s.c.} & A \cdot x - b = 0 \end{cases}$$

où A est une matrice $q \times n$ avec $q \leq n$ et $b \in \mathbb{R}^q$. On notera $C = \{x \in \mathbb{R}^n, A \cdot x - b = 0\}$. Nous allons maintenant définir le concept de direction admissible dans C .

Définition 6.1 – Direction admissible (problème sous contraintes d’égalité linéaires)

On dit que $d \in \mathbb{R}^n$ est une *direction admissible* en $x \in C$ s’il existe $\alpha > 0$ tel que

$$x + t.d \in C, \quad \forall t \in [-\alpha, \alpha]$$

On a $A \cdot (x + t.d) - b = t.A \cdot d$ puisque $x \in C$, et donc les directions admissibles d sont caractérisées par

$$A \cdot d = 0$$

Théorème 6.3 – Existence des multiplicateurs de Lagrange (problème sous contraintes d’égalité linéaires)

Soit $x^* \in C = \{x \in \mathbb{R}^n, h(x) = 0\}$ un point régulier solution du problème sous contraintes d’égalité linéaires, vérifiant donc


$$f(x^*) \leq f(x), \quad \forall x \in C$$

Alors il existe nécessairement un vecteur des multiplicateurs de Lagrange $\lambda \in \mathbb{R}^q$ vérifiant

$$\nabla f(x^*) + A^\top \cdot \lambda = 0$$

Si de plus A est de rang q alors λ est unique.

Figure 6.1 – Exemple de direction admissible en x



Démonstration 17 unicité du multiplicateur

Soit d une direction admissible, vérifiant donc $d \in \text{Ker}(A)$. Pour tout $t \in \mathbb{R}$ on a

$$f(x^*) \leq f(x^* + t.d)$$

alors on en déduit que pour $\forall d \in \text{Ker}(A)$,

$$\langle \nabla f(x^*), d \rangle = \lim_{t \rightarrow 0} \frac{f(x^* + t.d) - f(x^*)}{t} = 0$$

Soit $\nabla f(x^*) \in (\text{Ker}(A))^\perp$, donc $\nabla f(x^*) \in \text{Im}(A^\top)$. Il existe donc un vecteur λ tel que

$$\nabla f(x^*) = -A^\top \cdot \lambda$$

ce qui démontre le résultat. Pour l'unicité, supposons qu'il existe deux vecteurs λ_1 et λ_2 vérifiant

$$\nabla f(x^*) = -A^\top \cdot \lambda_1 = -A^\top \cdot \lambda_2$$

On a donc

$$A^\top \cdot (\lambda_1 - \lambda_2) = 0$$

et donc $\lambda_1 - \lambda_2 = 0$ si A est de rang q .

Exemple 6.1 – Distance d'un point à un plan

On cherche à calculer la distance d'un point $x_0 \in \mathbb{R}^n$ au plan défini par l'équation $A \cdot x = b$, où $A \in \mathcal{M}_{q \times n}$ avec $\text{rang}(A) = q$. Ce problème se pose sous la forme

$$(\mathcal{PCE}) \quad \begin{cases} \min_{x \in \mathbb{R}^n} & \frac{1}{2} \|x_0 - x\|^2 \\ \text{s.c.} & A \cdot x = b \end{cases}$$

On pose donc $f(x) = \frac{1}{2} \|x_0 - x\|^2$. On a

$$\nabla f(x) = -(x_0 - x)$$

et donc le système d'optimalité est donné par

$$(x^* - x_0) + A^\top \cdot \lambda^* = 0 \tag{1}$$

$$A \cdot x^* = b \tag{2}$$

En multipliant l'équation (1) par A on peut exprimer λ^* par

$$\lambda^* = (A \cdot A^\top)^{-1} \cdot (A \cdot x_0 - b)$$

et on obtient en substituant λ^* dans l'équation (1)

$$x = (I - A^\top \cdot (A \cdot A^\top)^{-1} \cdot A) \cdot x_0 + A^\top \cdot (A \cdot A^\top)^{-1} \cdot b$$


Un problème voisin est celui de la projection d'une direction d sur le plan $A \cdot x = 0$. Le résultat précédent donne donc

$$d^* = P \cdot d$$

avec $P = I - A^\top \cdot (A \cdot A^\top)^{-1} \cdot A$.

FIGURE 6.1 –

Figure 6.2 – Projection sur plan



La solution $x = p(x_0)$ est en fait la projection de x_0 sur plan $A \cdot x = b$.

6.3.2 Contraintes d'égalité non linéaires

Nous étudions maintenant le problème sous la forme

$$(\mathcal{PCE}) \quad \begin{cases} \inf_{x \in \mathbb{R}^n} & f(x) \\ \text{s.c.} & h(x) = 0 \end{cases}$$

où $h : \mathbb{R}^n \rightarrow \mathbb{R}^q$ est différentiable. On note comme précédemment $C = \{x \in \mathbb{R}^n, h(x) = 0\}$. Le concept de direction admissible dans C ne peut pas se définir comme pour les contraintes linéaires, car pour $x^* \in C$ il peut ne pas exister $\alpha > 0$ et $d \in \mathbb{R}^n$ tels que $x^* + t \cdot d \in C$. On doit donc définir le concept de courbe admissible.

Considérons une courbe $x(t)$ définie pour $t \geq 0$ vérifiant

$$\begin{cases} x(t) \in C, & \forall t \in [-\alpha, \alpha], \alpha > 0 \\ x(0) = x^* \end{cases}$$

Puisque $x(t) \in C$ on a $h_j(x(t)) = 0$ pour $1 \leq j \leq q$ et on peut écrire que

$$\frac{d}{dt} h_j(x(t)) = \langle \nabla h_j(x(t)), x'(t) \rangle = 0, \quad 1 \leq j \leq q$$

Si on note $y = x'(0)$ le vecteur tangent à la courbe $x(t)$ en $t = 0$, on a donc

$$\langle \nabla h_j(x^*), y \rangle = 0, \quad 1 \leq j \leq q$$

Cela conduit à la définition suivante


Définition 6.2 – Direction admissible (problème sous contraintes d'égalité non linéaires)

On dit que $d \in \mathbb{R}^n$ est une direction admissible en $x^* \in C$ s'il existe $\alpha > 0$ et une courbe $x(t)$ vérifiant

$$\begin{cases} x(t) \in C, \forall t \in [-\alpha, \alpha] \\ x(0) = x^* \\ x'(0) = d \end{cases}$$

On notera alors $d \in T(x^*)$.

Figure 6.3 – Plan tangent



Le plan $T(x^*)$ est tangent à la surface C en x^* , selon la courbe admissible $x(t)$, passant par $x(0) = x^*$ où le vecteur d est tangent à la courbe.

L'ensemble $T(x^*)$ définit le plan tangent (voir Figure 6.3) à C en x^* . L'analyse faite précédemment montre que l'on a l'implication.

$$d \in T(x^*) \Rightarrow \langle \nabla h_j(x^*), d \rangle = 0, 1 \leq j \leq q$$

qui sera insuffisante pour montrer la condition nécessaire d'optimalité. Nous allons donc maintenant nous attacher à montrer sous quelles conditions la relation $\langle \nabla h_j(x^*), d \rangle = 0$ est une condition suffisante d'appartenance à $T(x^*)$.

Définition 6.3 – Point régulier (problème sous contraintes d'égalité non linéaires)

On dit que x^* est un point régulier pour la contrainte $h(x) = 0$ si

- (1) $h(x^*) = 0$;
- (2) les vecteurs $\nabla h_j(x^*)$ sont linéairement indépendants.

Si on note $J_h(x^*) \in \mathcal{M}_{n,q}$ la jacobienne de h , on a $J_h(x^*) = [\nabla h_1(x^*) \quad \cdots \quad \nabla h_q(x^*)]$, la condition d'indépendance linéaire des $\nabla h_j(x^*)$ peut s'écrire

$$\text{rang}(J_h(x^*)) = q$$

et on a donc $J_h(x^*)^\top \cdot x'(0) = 0$ pour toute courbe admissible $x(t)$.

Proposition 6.1

Si x^ est un point régulier pour la contrainte $h(x) = 0$, alors*

$$J_h(x^*)^\top \cdot d = 0 \Rightarrow d \in T(x^*)$$

Démonstration 18

Soit $y \in \mathbb{R}^n$ vérifiant $J_h(x^*)^\top \cdot d = 0$. On considère la courbe $x(t)$ donnée par

$$x(t) = x^* + t \cdot d + J_h(x^*) \cdot u(t)$$

La fonction $u(t) \in \mathbb{R}^q$, pour l'instant inconnue, va être déterminée de telle façon que $h(x(t)) = 0$. On va pour cela poser le problème de la détermination de $u(t)$ sous la forme d'une équation implicite. On définit la fonction $F : \mathbb{R} \times \mathbb{R}^q \rightarrow \mathbb{R}^q$ par

$$F(t, u) = h(x^* + t.d + J_h(x^*) \cdot u(t))$$

Le problème de la détermination de $u(t)$ se ramène donc à la résolution de l'équation

$$F(t, u) = 0$$

au voisinage du point $(0, 0)$. On a d'une part $F(0, 0) = h(x^*) = 0$ et

$$\frac{\partial}{\partial u} F(t, u) = J_h(x^*)^\top \cdot J_h(x^* + t.d + J_h(x^*) \cdot u(t))$$

soit

$$\frac{\partial}{\partial u} F(0, 0) = J_h(x^*)^\top \cdot J_h(x^*)$$

La matrice $\frac{\partial}{\partial u} F(0, 0)$ est inversible puisque par hypothèse $J_h(x^*)$ est de rang p . On peut alors appliquer le théorème des fonctions implicites : il existe un voisinage du point $(0, 0)$ et une fonction $u(t)$ tels que

$$F(t, u) = 0 \iff u = u(t)$$

Notons que l'on a donc nécessairement $u(0) = 0$ puisque $F(0, 0) = 0$.

On a donc maintenant

$$x'(t) = d + J_h(x^*) \cdot u'(t)$$

soit en $t = 0$ soit

$$x'(0) = d + J_h(x^*) \cdot u'(0)$$

Montrons que $u'(0) = 0$. Pour cela on écrit que l'on a

$$\frac{d}{dt} h(x(t)) = J_h(x(t)) \cdot (d + J_h(x^*) \cdot u'(t)) = 0$$

puisque $h(x(t)) = 0$, et donc en $t = 0$ la relation précédente prend la forme

$$\left. \frac{d}{dt} h(x(t)) \right|_{t=0} = J_h(x^*)^\top \cdot d + J_h(x^*)^\top \cdot J_h(x^*) \cdot u'(0) = 0$$

Le premier terme du second membre est nul par hypothèse, et donc $u'(0) = 0$ puisque $J_h(x^*)^\top \cdot J_h(x^*)$ est inversible. Donc $x'(0) = d$, soit $d \in T(x^*)$, ce qui démontre le résultat annoncé.

Théorème 6.4 – Théorème de Lagrange (problème sous contraintes d'égalité non linéaires)

Soit $x^* \in C = \{x \in \mathbb{R}^n, h(x) = 0\}$ un point régulier solution du problème sous contraintes d'égalité non linéaires, vérifiant donc

$$f(x^*) \leq f(x), \forall x \in C$$

Alors il existe nécessairement un vecteur $\lambda \in \mathbb{R}^q$ unique vérifiant

$$\nabla f(x^*) + J_h(x^*) \cdot \lambda = 0$$

soit encore

$$\nabla f(x^*) + \sum_{j=1}^q \lambda_j \cdot \nabla h_j(x^*) = 0$$

Les composantes du vecteur λ sont appelées multiplicateurs de Lagrange.

Démonstration 19

Considérons une courbe $x(t)$ définie pour $t \in [-\alpha, \alpha]$ vérifiant

$$\begin{cases} x(t) \in C, & \forall t \in [-\alpha, \alpha], \alpha > 0 \\ x(0) = x^* \end{cases}$$

On a $f(x(0)) \leq f(x(t))$ pour tout $t \in [-\alpha, \alpha]$, donc nécessairement

$$\left. \frac{d}{dt} f(x(t)) \right|_{t=0} = \langle \nabla f(x^*), x'(0) \rangle = 0$$

ce qui signifie que $\nabla f(x^*)$ se trouve dans l'orthogonal du plan tangent $T(x^*)$ à C en x^* . Si l'on utilise l'équivalence

$$T(x^*) = (\text{Ker}(J_h(x^*)))^\top \iff T(x^*)^\perp = \text{Im}(J_h(x^*))$$

il existe donc un vecteur $\lambda \in \mathbb{R}^q$ tel que

$$\nabla f(x^*) = -J_h(x^*) \cdot \lambda$$

L'unicité résulte du fait que $J_h(x^*)$ est de rang q et se montre comme dans le cas linéaire.

6.4 Les conditions de Kuhn et Tucker

6.4.1 Contraintes d'inégalité

On s'intéresse maintenant au problème suivant, dit problème d'optimisation avec contraintes d'inégalité seulement

$$(PCI) \quad \begin{cases} \inf_{x \in C} f(x) \\ s.c. \quad g(x) \leq 0 \end{cases}$$

où $g : \mathbb{R}^n \rightarrow \mathbb{R}^p$, est différentiable (il n'y a ici aucune condition sur p). On notera C l'ensemble des points admissibles, c'est-à-dire $C = \{x \in \mathbb{R}^n, g_i(x) \leq 0, i \in \llbracket 1, p \rrbracket\}$.

Au point solution de ce problème d'optimisation avec contraintes d'inégalité il va de soi que les contraintes effectivement actives vérifieront $g_i(x^*) = 0$. Cependant, puisque l'on ne sait pas a priori quelles sont ces contraintes, le passage de problème d'optimisation avec contraintes d'inégalité à un problème du type problème d'optimisation avec contraintes d'égalité n'est pas direct.


Définition 6.4 – Contrainte active(saturée)/Active constraint/积极约束

Soit une contrainte d'inégalité $g_i(x) \leq 0$ et x^* un point de $\mathbb{R}^n$. Si x^* satisfait $g_i(x^*) < 0$, on dit que la contrainte est inactive en x^* , tandis que si x^* satisfait $g_i(x^*) = 0$, on dit que la contrainte est *active* ou *saturée* en x^* .^a

Notons $A(x^*) = \{i \in \llbracket 1, p \rrbracket \mid g_i(x^*) = 0\} \subseteq \{1, \dots, p\}$ l'ensemble des indices des contraintes actives en x^* .

^a. Voir Figure 6.4

Figure 6.4 – Contraintes actives



g_1 et g_2 sont actives en x^* tandis que g_i ($i \neq 1, i \neq 2$) sont inactives en x^* .

Proposition 6.2

Soit $d \in \mathbb{R}^n$ une direction admissible en $x^* \in C$, alors on a nécessairement

$$\langle \nabla g_i(x^*), d \rangle \leq 0, i \in A(x^*)$$

Démonstration 20

Considérons une courbe $x(t)$ définie pour $t \in [-\alpha, \alpha]$ vérifiant

$$\begin{cases} x(t) \in C, & \forall t \in [-\alpha, \alpha], \alpha > 0 \\ x(0) = x^* \\ x'(0) = d \end{cases}$$

Comme $g_i(x^*) < 0$ pour $i \notin A(x^*)$, on aura toujours $g_i(x(t)) < 0$ pour t suffisamment petit. Par contre, pour $i \in A(x^*)$ on doit avoir $g_i(x(t)) \leq 0$ pour t suffisamment petit. Si on utilise le développement de Taylor de $g_i(x(t))$ en $t = 0$ on doit donc avoir

$$g_i(x^*) + t\langle \nabla g_i(x^*), d \rangle + t\varepsilon(t) \leq 0$$

Puisque $g_i(x^*) = 0$ il faut donc nécessairement que l'on ait

$$\langle \nabla g_i(x^*), d \rangle \leq 0$$


Définition 6.5 – Cône des directions admissibles

On dit qu'un arc paramétré $x : [0, \varepsilon] \rightarrow \mathbb{R}^n$ de classe $\mathcal{C}^n$ est une courbe admissible si $x(0) = x^*$ et $x(t) \in C$, pour $t > 0$ au voisinage de 0.

On appelle direction admissible en x^* les vecteurs tangents à des courbes admissibles au point x^* .

On note $C_{ad}(x^*)$ le cône des directions admissibles en x^* .

Figure 6.5 – Cone admissible



Cône admissible : toutes les directions admissibles d en x^* forment le cône admissible en x^* .

Comme dans le cas des contraintes d'égalité, on doit définir la notion de point régulier, qui est nécessaire pour que la condition précédente soit suffisante.

Définition 6.6 – Point régulier (problème sous contraintes d'inégalité)

On dit que x^* est un point régulier pour la contrainte $g(x) \leq 0$ si

- (1) $g(x^*) \leq 0$;
- (2) les vecteurs $\nabla g_i(x^*)$ sont linéairement indépendants.

Sous l'hypothèse de régularité de x^* on aura, comme dans le cas des contraintes d'égalité

$$\langle \nabla g_i(x^*), y \rangle \leq 0, i \in A(x^*) \Rightarrow y \in C(x^*)$$

La proposition suivante permet d'effectuer le premier pas vers les conditions d'optimalité de Kuhn et Tucker.

Proposition 6.3

Soit x^* la solution du problème sous contraintes d'inégalité. Il existe $\eta > 0$ tel que

$$\forall x \in BO(x^*, \eta), g_i(x) < 0, i \notin A(x^*)$$

Alors x^* est la solution du problème

$$(\mathcal{PCI}) \quad \begin{cases} \inf_{x \in BO(x^*, \eta)} f(x) \\ \text{s.c.} \quad g_i(x) = 0, i \in A(x^*) \end{cases}$$

Ce résultat est uniquement dû à la continuité de g , et montre que l'on est localement ramené à un problème avec contraintes d'égalité.

6.4.2 Conditions de Kuhn et Tucker

Théorème 6.5 – Conditions de Kuhn et Tucker

Soit $x^* \in C$ un point régulier solution du problème sous contraintes d'inégalité. Alors il existe un unique vecteur $\mu \in \mathbb{R}^p$ tel que

$$\begin{aligned} \nabla f(x^*) + \sum_{i=1}^p \mu_i \cdot \nabla g_i(x^*) &= 0 \\ \mu_i &\geq 0, i = 1, \dots, p \\ \mu_i g_i(x^*) &= 0, i = 1, \dots, p \end{aligned}$$

Démonstration 21

La relation $\nabla f(x^*) + \sum_{i=1}^p \mu_i \cdot \nabla g_i(x^*) = 0, \mu_i g_i(x^*) = 0$ sont une conséquence directe du théorème de Lagrange, car il suffit de prendre $\mu_i = 0$ pour $i \notin A(x^*)$. On peut ensuite montrer que $\mu_i \geq 0$ par l'absurde : supposons qu'il existe $k \in A(x^*)$ tel que $\mu_k < 0$. On définit l'ensemble

$$S_k = \{x \in \mathbb{R}^n, g_i(x) = 0, i \in A(x^*), i \neq k\}$$

On définit $y \in \mathbb{R}^n$ tel que

$$\begin{aligned} \langle \nabla g_i(x^*), y \rangle &= 0, i \in A(x^*), i \neq k \\ \langle \nabla g_k(x^*), y \rangle &= -1 \end{aligned}$$

Alors y est une direction admissible en x^* puisque

$$\langle \nabla g_i(x^*), y \rangle \leq 0, i \in A(x^*)$$

et que x^* est un point régulier. Il existe donc une courbe $x(t) \in S_k$ et vérifiant de plus $x(t) \in C$, pour $t \in [-\alpha, \alpha]$, telle que $x'(0) = y$. On a donc

$$\begin{aligned} \left. \frac{d}{dt} f(x(t)) \right|_{t=0} &= \langle \nabla f(x^*), y \rangle \\ &= - \sum_{i \in A(x^*)} \mu_i \langle \nabla g_i(x^*), y \rangle \\ &= -\mu_k \langle \nabla g_k(x^*), y \rangle = \mu_k < 0 \end{aligned}$$


ce qui est impossible car f est minimum en x^* .

Exemple 6.2 – Interprétation géométrique des conditions de Kuhn et Tucker

On cherche à résoudre le problème

$$(\mathcal{PCI}) \quad \begin{cases} \min_{x \in \mathbb{R}^2} \frac{1}{2} \|x_0 - x\|^2 \\ \text{s.c.} \quad x_1 \geq 0 \\ \quad \quad x_2 \geq 0 \\ \quad \quad x_1 + x_2 \leq 1 \end{cases}$$

Figure 6.6 – Exemple de programme quadratique



où $x_0 = (1, \frac{1}{2})$. Il s'agit d'un problème avec contraintes d'inégalité se mettant sous la forme $g(x) \leq 0$ avec

$$g(x) = (-x_1, -x_2, x_1 + x_2 - 1)$$

Sur le dessin 6.6, on peut s'assurer que très probablement seule la contrainte numéro 3 est active. On peut s'en persuader par le calcul de la façon suivante : on peut tenter de résoudre le système

$$\begin{aligned}\nabla f(x) + \mu_3 \cdot \nabla g_3(x) &= 0 \\ g_3(x) &= 0\end{aligned}$$

soit ici

$$\begin{aligned}x - x_0 + \mu_3 (1, 1) &= 0 \\ x_1 + x_2 &= 1\end{aligned}$$

ou bien encore

$$\begin{aligned}x_1 + \mu_3 &= 1 \\ x_2 + \mu_3 &= \frac{1}{2} \\ x_1 + x_2 &= 1\end{aligned}$$

dont la solution est donnée par

$$x_1 = \frac{3}{4}, x_2 = \frac{1}{4}, \mu_3 = \frac{1}{4}$$

On a bien $\mu_3 \geq 0$ ce qui justifie *a posteriori* le choix de saturer la contrainte numéro 3.

6.5 Problème avec contraintes d'égalité et d'inégalité

On veut minimiser f sur l'ensemble C des contraintes données par les inégalités et les égalités

$$C = \{x \in \mathbb{R}^n, g_i(x) \leq 0, i \in \llbracket 1, p \rrbracket, h_j(x) = 0, j \in \llbracket 1, q \rrbracket\}$$

où les f , g_i et h_j sont des fonctions de classe $\mathcal{C}^1$ de $\mathbb{R}^n$ dans $\mathbb{R}$. Donc, les problèmes d'optimisation peuvent s'écrire sous la forme

$$(\mathcal{PC}) \quad \inf \{f(x), x \in C\}$$

6.5.1 Qualifications des contraintes

La compréhension des qualifications des contraintes est essentielle pour étudier les conditions de Karush-Kuhn-Tucker (KKT) dans le contexte des problèmes d'optimisation avec contraintes.

La qualification des contraintes est une condition qui garantit que les contraintes du problème ne sont pas «trop restrictives» ou «trop lâches», ce qui permet aux conditions KKT de s'appliquer. En d'autres termes, si les contraintes ne sont pas qualifiées, les conditions KKT ne peuvent pas garantir qu'une solution est optimale pour le problème d'optimisation avec contraintes.

Définition 6.7 – Qualification des contraintes / *Constraint qualification* / 约束规范

Les contraintes sont dites qualifiées en $\bar{x}$ si les deux conditions suivantes sont satisfaites

- (a) les vecteurs $\nabla h_1(\bar{x}), \dots, \nabla h_q(\bar{x})$ sont linéairement indépendants;
- (b) il existe une direction $d \in \mathbb{R}^n$ telle que l'on ait, pour tout $i \in A(\bar{x})$ et $j \in \llbracket 1, q \rrbracket$,

$$\langle \nabla g_i(\bar{x}), d \rangle \leq 0 \text{ et } \langle \nabla h_j(\bar{x}), d \rangle = 0$$

Remarque 6.1

On définit une ensemble

$$L(\bar{x}) = \{d \in \mathbb{R}^n, \langle \nabla g_i(\bar{x}), d \rangle \leq 0, \forall i \in A(\bar{x}), \langle \nabla h_j(\bar{x}), d \rangle = 0, \forall j \in \llbracket 1, q \rrbracket\}$$

Alors, l'ensemble $L(\bar{x})$ est un cône polyédrique / *linearized cone* / 线性化锥 (convexe fermé non-vidé). C'est en effet une approximation linéaire de l'ensemble C au point $\bar{x}$.

Propriété 6.1

Si $\overline{Z(\bar{x})} = L(\bar{x})$, alors les contraintes sont qualifiées.

Proposition 6.4

Pour tout $\bar{x} \in C$, on a $\overline{Z(\bar{x})} \subset L(\bar{x})$.

Démonstration 22

Soit $\bar{x} \in C$, alors pour tout $d \in Z(\bar{x})$, il existe $\lambda^* > 0$, on a

$$\forall \lambda \in]0, \lambda^*], \bar{x} + \lambda.d \in C$$

C'est-à-dire,

$$\forall \lambda \in]0, \lambda^*], g(\bar{x} + \lambda.d) \leq 0, h(\bar{x} + \lambda.d) = 0$$

où

$$g_i(\bar{x} + \lambda.d) \leq g_i(\bar{x}) = 0, \forall i \in A(\bar{x})$$

$$h_j(\bar{x} + \lambda.d) = 0, \forall j \in \llbracket 1, q \rrbracket$$

Les développements limités à l'ordre 1 de g_i et h_j donnent

$$g_i(\bar{x} + \lambda.d) - g_i(\bar{x}) = \underbrace{\lambda}_{>0} \langle \nabla g_i(\bar{x}), d \rangle + o(\|\lambda.d\|)$$

$$h_j(\bar{x} + \lambda.d) = \underbrace{h_j(\bar{x})}_{=0} + \underbrace{\lambda}_{>0} \langle \nabla h_j(\bar{x}), d \rangle + o(\|\lambda.d\|)$$

On a donc

$$\langle \nabla g_i(\bar{x}), d \rangle \leq 0, \forall i \in A(\bar{x})$$

$$\langle \nabla h_j(\bar{x}), d \rangle = 0, \forall j \in \llbracket 1, q \rrbracket$$

On obtient que

$$\forall \bar{x} \in C, Z(\bar{x}) \subset L(\bar{x})$$

Comme l'ensemble $L(\bar{x})$ est fermé et $Z(\bar{x}) \subset L(\bar{x})$, donc

$$\forall \bar{x} \in C, \overline{Z(\bar{x})} \subset L(\bar{x})$$

Remarque 6.2

L'inclusion inverse de Proposition 6.4 n'est pas toujours vraie. Voici un contre-exemple.

Exemple 6.3 – Contre-exemple

Soit $D = \{x \in \mathbb{R}, -x^2 \geq 0\}$. Montrer que 0 n'est pas un point régulier de D .

Réponse : L'ensemble D est le singleton $\{0\}$, donc

$$Z(0) = \overline{Z(0)} = D = \{0\}$$

Mais $L(0) = \{d \in \mathbb{R}, -d \times 2 \times 0 \geq 0\} = \mathbb{R}$. On a donc l'inclusion stricte $\overline{Z(0)} \subset L(0)$. Donc 0 n'est pas un point régulier de D .

1. **Affinité (QC-A).** Si g et h sont des applications linéaires (ou affines), on a $\overline{Z(\bar{x})} = L(\bar{x})$.

Démonstration 23

D'après la Proposition 6.4, il suffit de montrer que $L(\bar{x}) \subset \overline{Z(\bar{x})}$.

Soit $d \in L(\bar{x})$, on a

$$\begin{aligned} \langle \nabla g_i(\bar{x}), d \rangle &\leq 0, \forall i \in A(\bar{x}) \\ \langle \nabla h_j(\bar{x}), d \rangle &= 0, \forall j \in \llbracket 1, q \rrbracket \end{aligned}$$

Par affinité de h et de g , on a pour tout $\alpha > 0$,

$$\begin{aligned} h_j(\bar{x} + \alpha.d) &= \underbrace{h_j(\bar{x})}_{=0} + \alpha \underbrace{\langle \nabla h_j(\bar{x}), d \rangle}_{=0} = 0 \\ \forall i \in A(\bar{x}), g_i(\bar{x} + \alpha.d) &= \underbrace{g_i(\bar{x})}_{=0} + \alpha \underbrace{\langle \nabla g_i(\bar{x}), d \rangle}_{\leq 0} \leq 0 \end{aligned}$$

Pour tout $i \in \llbracket 1, p \rrbracket \setminus A(\bar{x})$, comme $g_i(\bar{x}) < 0$ et par la continuité de g_i , on obtient alors

$$\forall i \in \llbracket 1, p \rrbracket \setminus A(\bar{x}), \exists \alpha^* > 0, \forall \alpha \in]0, \alpha^*], g_i(\bar{x} + \alpha.d) \leq 0$$

Donc

$$\exists \alpha^* > 0, \forall \alpha \in]0, \alpha^*], \bar{x} + \alpha.d \in C$$

Ceci implique

$$d \in \overline{Z(\bar{x})}$$

Donc

$$L(\bar{x}) \subset \overline{Z(\bar{x})}$$

2. **Slater (QC-S).** Si $(\mathcal{P})$ est un problème d'optimisation convexe (f convexe, g convexe, h affine), et qu'il existe au moins un point absolument réalisable.

Autrement dit,

$$\exists \bar{x} \in C \text{ tel que } \exists i \in \llbracket 1, p \rrbracket, g_i(\bar{x}) < 0, \forall j \in \llbracket 1, q \rrbracket, h_j(\bar{x}) = 0$$

Démonstration 24

Par analogue comme dans la démonstration de (QC-A), on va montrer que $L(\bar{x}) \subset \overline{Z(\bar{x})}$.

Soit $d \in L(\bar{x})$, on a

$$\begin{aligned} \langle \nabla g_i(\bar{x}), d \rangle &\leq 0, \forall i \in A(\bar{x}) \\ \langle \nabla h_j(\bar{x}), d \rangle &= 0, \forall j \in \llbracket 1, q \rrbracket \end{aligned}$$

Par affinité de h_j , on a pour tout $\alpha > 0$,

$$h_j(\bar{x} + \alpha.d) = \underbrace{h_j(\bar{x})}_{=0} + \alpha \underbrace{\langle \nabla h_j(\bar{x}), d \rangle}_{=0} = 0$$

Pour tout $i \in A(\bar{x})$, par convexité de g_i , il existe $\overset{\circ}{x} \in C$ tel que $g_i(\overset{\circ}{x}) < 0$ et $g_i(\bar{x}) = 0$, on a

$$0 > g_i(\overset{\circ}{x}) \geq \underbrace{g_i(\bar{x})}_{=0} + \langle \nabla g_i(\bar{x}), \overset{\circ}{x} - \bar{x} \rangle = \langle \nabla g_i(\bar{x}), \overset{\circ}{x} - \bar{x} \rangle$$

Pour tout $\lambda \in]0, 1[$, notons $\hat{d}(\lambda) = (1 - \lambda).d + \lambda.(\overset{\circ}{x} - \bar{x})$, comme

$$\langle \nabla g_i(\bar{x}), d \rangle \leq 0, \text{ et } \langle \nabla g_i(\bar{x}), \overset{\circ}{x} - \bar{x} \rangle < 0$$

donc

$$\langle \nabla g_i(\bar{x}), \hat{d}(\lambda) \rangle = \underbrace{(1 - \lambda)}_{>0} \underbrace{\langle \nabla g_i(\bar{x}), d \rangle}_{\leq 0} + \underbrace{\lambda}_{>0} \underbrace{\langle \nabla g_i(\bar{x}), \overset{\circ}{x} - \bar{x} \rangle}_{< 0} < 0, \forall \lambda \in]0, 1[$$

On obtient donc

$$\forall i \in A(\bar{x}), \forall \lambda \in]0, 1[, g_i(\bar{x} + \lambda.\hat{d}(\lambda)) = \underbrace{g_i(\bar{x})}_{=0} + \underbrace{\alpha}_{>0} \underbrace{\langle \nabla g_i(\bar{x}), \hat{d}(\lambda) \rangle}_{< 0} + o(\|\alpha.\hat{d}(\lambda)\|)$$

Alors, pour $\alpha \rightarrow 0^+$, on a

$$\forall \lambda \in]0, 1[, \lim_{\alpha \rightarrow 0^+} \frac{g_i(\bar{x} + \alpha.\hat{d}(\lambda))}{\|\alpha.\hat{d}(\lambda)\|} = \frac{\langle \nabla g_i(\bar{x}), \hat{d}(\lambda) \rangle}{\|\alpha.\hat{d}(\lambda)\|} < 0$$

Donc

$$\forall \lambda \in]0, 1[, \exists \alpha^* > 0, \forall \alpha \in]0, \alpha^*], g_i(\bar{x} + \alpha.\hat{d}(\lambda)) < 0$$

Par continuité de $\hat{d}$ et de g_i , il suffit de prendre $\lambda \rightarrow 0^+$ pour déduire que

$$\forall i \in A(\bar{x}), \exists \alpha^* > 0, \forall \alpha \in]0, \alpha^*], g_i(\bar{x} + \alpha.d) \leq 0$$

Pour tout $i \in [1, p] \setminus A(\bar{x})$, comme $g_i(\bar{x}) < 0$ et par continuité de g_i , on obtient alors

$$\forall i \in [1, p] \setminus A(\bar{x}), \exists \alpha^* > 0, \forall \alpha \in]0, \alpha^*], g_i(\bar{x} + \alpha.d) \leq 0$$

Donc

$$\exists \alpha^* > 0, \forall \alpha \in]0, \alpha^*], \bar{x} + \alpha.d \in C$$

Ceci implique

$$d \in \overline{Z(\bar{x})}$$

Donc

$$L(\bar{x}) \subset \overline{Z(\bar{x})}$$

3. **Indépendance linéaire (QC-IL).** Si les contraintes actives (c'est-à-dire les contraintes qui sont satisfaites avec égalité) sont linéairement indépendantes en x^* .

$$\sum_{i=1}^p \lambda_i \nabla g_i(x^*) + \sum_{j=1}^q \mu_j \nabla h_j(x^*) = 0$$

où λ_i et μ_j sont des multiplicateurs de Lagrange associés aux contraintes actives d'inégalité et d'égalité respectivement, admet une unique solution $(\lambda, \mu) = (0, 0)$.

4. **Mangasarian-Fromovitz (QC-MF).** S'il existe un point $x^* \in \mathbb{R}^n$ tel que les conditions suivantes sont satisfaites

- Les contraintes sont actives, c'est-à-dire $g_i(x^*) = 0$ pour tout i tel que $g_i(x^*) \leq 0$.
- Le gradient des contraintes actives est linéairement indépendant, c'est-à-dire que les vecteurs $\nabla g_i(x^*)$ pour les i tels que $g_i(x^*) = 0$ sont linéairement indépendants.

Alors, il existe un nombre $\epsilon > 0$ tel que, pour tout vecteur $d \in \mathbb{R}^n$ vérifiant $\|d\| < \epsilon$, toutes les contraintes actives restent satisfaites, c'est-à-dire que $g_i(x^* + t.d) \leq 0$ pour tout t suffisamment petit.

6.5.2 Conditions de Karush, Kuhn et Tucker

Définition 6.8 – Lagrangien du problème ($\mathcal{P}$)

On appelle Lagrangien du problème ($\mathcal{P}$) la fonction définie sur $\mathbb{R}^n \times \mathbb{R}_+^p \times \mathbb{R}^q$ par

$$\mathcal{L}(x, \mu, \lambda) = f(x) + \sum_{i=1}^p \mu_i g_i(x) + \sum_{j=1}^q \lambda_j h_j(x)$$

Les conditions de Karush-Kuhn-Tucker (ou Kuhn-Tucker) sont une généralisation des multiplicateurs de Lagrange qui permettent de résoudre des problèmes d'optimisation sous contraintes non linéaires.

Théorème 6.6 – Conditions de KKT (Karush-Kuhn-Tucker)

On introduit l'ensemble des contraintes

$$C = \{x \in \mathbb{R}^n, g_i(x) \leq 0, \forall i \in \llbracket 1, p \rrbracket, h_j(x) = 0, \forall j \in \llbracket 1, q \rrbracket\}$$

On suppose les contraintes qualifiées en x^* . Alors, une condition nécessaire pour que x^* soit un minimum de f sur C est que

— **les conditions nécessaires d'optimalité d'ordre 1**

Soit $f, g_i, i \in \llbracket 1, p \rrbracket, h_j, j \in \llbracket 1, q \rrbracket$, des fonctions différentiables en x^* .

(a) (Réalisation primale)

$$x^* \in C$$

(b) (Réalisation duale et stationnarité)

$$\exists \mu \in (\mathbb{R}_+)^p, \exists \lambda \in \mathbb{R}^q, \nabla_x \mathcal{L}(x^*, \mu, \lambda) = \nabla f(x^*) + \sum_{i=1}^p \mu_i \cdot \nabla g_i(x^*) + \sum_{j=1}^q \lambda_j \cdot \nabla h_j(x^*) = 0$$

où $\nabla_x \mathcal{L}(x^*, \mu, \lambda)$ désigne le gradient de la fonction $x \mapsto \mathcal{L}(x, \mu, \lambda)$ au point x^* .

(c) (Complémentarité)

$$\mu_i g_i(x^*) = 0, i \in \llbracket 1, p \rrbracket$$

— **les conditions nécessaires d'optimalité d'ordre 2**

Si de plus $f, g_i, i \in \llbracket 1, p \rrbracket, h_j, j \in \llbracket 1, q \rrbracket$ sont des fonctions deux fois différentiables en x^* , alors $\exists \mu \in (\mathbb{R}_+)^p, \exists \lambda \in \mathbb{R}^q$,

$$\forall d \in \mathcal{T}(x^*), \langle H_{\mathcal{L}}(x^*, \mu, \lambda) \cdot d, d \rangle \geq 0$$

où $\mathcal{T}(x^*)$ est un espace tangent défini par

$$\mathcal{T}(x^*) = \{d \in \mathbb{R}^n, \langle \nabla g_i(x^*), d \rangle = 0, \forall i \in A(x^*), \langle \nabla h_j(x^*), d \rangle = 0, \forall j \in \llbracket 1, q \rrbracket\}$$

et $H_{\mathcal{L}}(x^*, \mu, \lambda)$ est la matrice hessienne de la fonction $x \mapsto \mathcal{L}(x, \mu, \lambda)$ au point x^* .

Remarque 6.3

- Un point vérifiant les conditions (KKT) est stationnaire (ou critique) pour le problème $(\mathcal{P})$. On dit que ce point est un point KKT.

Un point KKT n'est pas forcément un minimum local. (par exemple : $f(x) = x^3$ et $g_1(x) = -x - 1$ avec $p = 1, q = 0$.)

- Il est possible qu'un point non régulier soit un minimum local. Dans ce cas, on ne peut pas vérifier les conditions KKT.

- Si le saut de dualité s'annule, alors un point régulier est un minimum si, et seulement s'il vérifie les conditions KKT.

Démonstration 25

On peut retrouver le système d'optimalité en introduisant le lagrangien du problème qui est la fonction

$$\mathcal{L} : \mathbb{R}^n \times \mathbb{R}^p \times \mathbb{R}^q \rightarrow \mathbb{R}$$

$$(x, \mu, \lambda) \mapsto f(x) + \sum_{i=1}^p \mu_i g_i(x) + \sum_{j=1}^q \lambda_j h_j(x)$$

Le nom des multiplicateurs de Lagrange vient du fait que les μ_i et λ_j multiplient les contraintes dans le lagrangien. Les conditions nécessaires d'optimalité s'écrivent alors

$$\nabla_x \mathcal{L}(x^*, \mu, \lambda) = 0, \mu \in (\mathbb{R}_+)^p, \langle \mu, g(x^*) \rangle = 0$$

Théorème 6.7 – Condition suffisante (cas convexe)

On dit que le problème de minimisation $\inf_{x \in C} f(x)$ est convexe si f est convexe et de classe $\mathcal{C}^1$, si les contraintes d'inégalité sont aussi convexes et de classe $\mathcal{C}^1$ et si les contraintes d'égalité sont affines.

Soit (x^, μ^*, λ^*) un point vérifiant les conditions KKT, avec f, g, h deux fois différentiables en x^* . On suppose que*

$$\forall d \in \mathcal{T}(x^*) \setminus \{0\}, \langle H_{\mathcal{L}}(x^*, \mu^*, \lambda^*) \cdot d, d \rangle > 0$$

Autrement dit, la matrice hessienne $H_{\mathcal{L}}(x^, \mu^*, \lambda^*)$ est définie positive. Alors x^* est un minimum local du problème $(\mathcal{P})$.*

Démonstration 26

Soit $x^* \in C$ un point KKT. On a donc

$$\nabla f(x^*) = - \sum_{i=1}^p \mu_i \cdot \nabla g_i(x^*) - \sum_{j=1}^q \lambda_j \cdot \nabla h_j(x^*)$$

La fonction f étant convexe sur C ,

$$\begin{aligned} f(x) - f(x^*) &\geq \langle \nabla f(x^*), x - x^* \rangle \\ &= \sum_{i=1}^p \mu_i \langle \nabla g_i(x^*), x^* - x \rangle + \sum_{j=1}^q \lambda_j \langle \nabla h_j(x^*), x^* - x \rangle \end{aligned} \quad (6.1)$$

Par qualification des contraintes, les fonctions h_j étant affines, elles peuvent s'exprimer comme

$$h_j(x) = h_j(x^*) + \langle \nabla h_j(x^*), x - x^* \rangle$$

Or, comme x et x^* sont dans C , on a $h_j(x) = h_j(x^*) = 0$ car ce sont des contraintes d'égalité. Donc $\langle \nabla h_j(x^*), x - x^* \rangle = 0$, alors

$$f(x) - f(x^*) \geq \sum_{i=1}^p \mu_i \langle \nabla g_i(x^*), x^* - x \rangle \geq \sum_{i=1}^p \mu_i (g_i(x^*) - g_i(x))$$

où nous avons utilisé le fait que les contraintes g_i sont convexes. Par ailleurs, comme chaque $\mu_i \geq 0$ et $g_i(x) \leq 0$ pour tout $x \in C$, on a donc $\sum_{i=1}^p \mu_i g_i(x) \leq 0$ et donc

$$f(x) - f(x^*) \geq \sum_{i=1}^p \mu_i g_i(x^*)$$

Finalement, par la condition de complémentarité, si $g_i(x^*) < 0$ alors $\mu_i = 0$, et si $g_i(x^*) = 0$ alors $\mu_i \geq 0$, d'où la conclusion

$$f(x) \geq f(x^*)$$

Proposition 6.5 – Condition nécessaire et suffisante (cas convexe)

Soit x^ un point KKT. Alors, x^* est un minimum local (donc global) de f si et seulement s'il existe des nombres positifs $\mu_1, \dots, \mu_p$ et des nombres réels $\lambda_1, \dots, \lambda_q$ tels que $\nabla_x \mathcal{L}(x^*, \mu^*, \lambda^*) = 0$.*

$$(KKT) \begin{cases} \nabla f(x^*) + \sum_{i=1}^p \mu_i \cdot \nabla g_i(x^*) + \sum_{j=1}^q \lambda_j \cdot \nabla h_j(x^*) = 0 \\ \mu_i \geq 0, \quad \mu_i g_i(x^*) = 0, \quad \forall i \in \llbracket 1, p \rrbracket \end{cases} \iff x^* \text{ solution}$$

Résumé : Démarche pour résoudre un problème de minimisation.

La démarche pour résoudre un problème de minimisation sous contraintes se décompose en quatre étapes.

- (1) On montre a priori que le problème admet une solution. Pour cela, on pourra utiliser les conditions suffisantes d'existence (Théorème 6.7). Il sera parfois nécessaire d'utiliser des raisonnements spécifiques au problème donné.
- (2) On cherche ensuite les points satisfaisant les conditions nécessaires de KKT. On note cet ensemble E_1 .
- (3) On cherche les points où la contrainte n'est pas qualifiée. On appelle cet ensemble E_2 .

- (4) Si le problème a une solution, le minimum appartient à $E_1 \cap E_2$. Un minimum est donc un point minimum dans $E_1 \cap E_2$.

Remarque 6.4

Dans le cas convexe, il suffit de trouver des points vérifiant les conditions nécessaires d'optimalité pour pouvoir conclure à l'existence d'un minimum.

Exemple 6.4

On considère le problème de minimisation sous contrainte

$$\inf_{x^2+y^2 \geq 1} f(x, y) = x^4 + 3y^4$$

- (1) **Existence.** On sait que pour tous $(x, y) \in \mathbb{R}^2$,

$$f(x, y) \geq 2x^2 + 6y^2 - 4 \geq 2\|(x, y)\|^2 - 4 \xrightarrow{\|(x, y)\| \rightarrow +\infty} +\infty$$

On en déduit que f est infinie à l'infini, et l'ensemble des contraintes $C = \{(x, y) \in \mathbb{R}^2, g(x, y) \leq 0\}$, avec $g(x, y) = 1 - x^2 - y^2$ est fermé, ce qui garantit l'existence de solution(s) pour le problème d'optimisation ci-dessus.

- (3) **Qualification de la contrainte.** QC-IL

- (3) **Conditions d'optimalité au premier ordre.** Le théorème de Kuhn-Tucker assure l'existence de $\mu \in \mathbb{R}_+$ tel que $\nabla f(x, y) + \mu \nabla g(x, y) = 0$.

- (a) (Réalisation primale) $(x, y) \in C = \{(x, y) \in \mathbb{R}^2, g(x, y) = 1 - x^2 - y^2 \leq 0\}$.
 (b) (Réalisation duale et stationnarité) On en a besoin que $\nabla_x \mathcal{L}(x^*, \mu^*, \lambda^*) = 0$, alors

$$\begin{cases} \frac{\partial \mathcal{L}}{\partial x}(x^*, \mu^*, \lambda^*) = 4x^3 - 2\mu x = 0 \\ \frac{\partial \mathcal{L}}{\partial y}(x^*, \mu^*, \lambda^*) = 12y^3 - 2\mu y = 0 \end{cases}$$

- (c) (Complémentarité) Avec la contrainte $g(x, y) = 1 - x^2 - y^2$,

$$\mu g(x, y) = \mu(x^2 + y^2 - 1) = 0$$

- (4) Supposons que l'on ait $\mu = 0$. Alors, $x = y = 0$. Impossible car $(0, 0)$ n'appartient pas à l'ensemble des contraintes. Donc, on a nécessairement $\mu > 0$.
 (5) Des deux premières équations, on tire que les minimums sont à choisir parmi

$$(x_1, y_1) = \left(0, \pm\sqrt{\frac{\mu}{6}}\right), (x_2, y_2) = \left(\pm\sqrt{\frac{\mu}{2}}, 0\right), (x_3, y_3) = \left(\pm\sqrt{\frac{\mu}{2}}, \pm\sqrt{\frac{\mu}{6}}\right)$$

- **Étude de (x_1, y_1) .** Puisque $x^2 + y^2 = 1$, on obtient $\mu = 6$ dans ce cas, et $(x_1, y_1) = (0, \pm 1)$, et $f(x_1, y_1) = 3$.
- **Étude de (x_2, y_2) .** Puisque $x^2 + y^2 = 1$, on obtient $\mu = 2$ dans ce cas, et $(x_2, y_2) = (\pm 1, 0)$, et $f(x_2, y_2) = 1$.
- **Étude de (x_3, y_3) .** Puisque $x^2 + y^2 = 1$, on obtient $\mu = \frac{3}{2}$ dans ce cas, et $(x_3, y_3) = (\pm\frac{\sqrt{3}}{2}, \pm\frac{1}{2})$, et $f(x_3, y_3) = \frac{3}{4}$.

Finalement, on en déduit que $\inf_{(x, y) \in C} f(x, y) = f(x_3, y_3) = \frac{3}{4}$.

Chapitre 7

Algorithme du simplexe (contraintes d'égalité)

Soit le programme linéaire avec n variables et m contraintes $((n, m) \in \mathbb{N}^2, n \leq m)$

$$\begin{aligned} \min \quad & f(x) = c^\top \cdot x = \sum_{i=1}^n c_i x_i \\ \text{s.c.} \quad & A \cdot x \leq b \end{aligned}$$

avec $c = [c_1 \ \cdots \ c_n]^\top$, $x = (x_1, \dots, x_n)$, $A \in \mathcal{M}_{m,n}$ et $b = (b_1, \dots, b_m)$.

On va présenter quelques méthodes pour résoudre un problème d'optimisation linéaire sous contraintes.

7.1 Solution d'optimisation linéaire (OL)

Il y a deux cas dans lesquels le problème sous la forme standard (Définition 1.1) n'a pas de solution.

1. Si l'ensemble admissible du problème est vide (par exemple, $\{x \in \mathbb{R}, x \geq 1, x \leq 0\}$). Dans ce cas, on dit que le problème est non-réalisable/infeasible/无解.
2. Si le problème d'OL est réalisable mais que sa valeur optimale vaut $-\infty$ (par exemple, $\min\{x, x \in \mathbb{R}_-\}$). Dans ce cas, on dit que le problème est non-borné/unbounded/无界.

Dans tous les autres cas, la valeur optimale du problème d'OL est finie et le problème a au moins une solution.

Définition 7.1 – Point extrémal/Extreme point/极点

Soit $C \subset \mathbb{R}^n$ un ensemble convexe non vide, $x \in C$ est un point extrémal de C si et seulement si $C \setminus \{x\}$ est encore convexe.

Autrement dire, x est un point extrémal de C si

$$\forall (x_1, x_2) \in C^2, \lambda \in]0, 1[, x = \lambda \cdot x_1 + (1 - \lambda) \cdot x_2 \quad \Rightarrow \quad x = x_1 = x_2$$

Remarque 7.1

1. Le nombre de points extrémaux d'un ensemble convexe peut être fini ou infini.
2. Si un ensemble convexe possède un nombre fini des points extrémaux, on appelle ces points sommets/vertex/顶点.

Définition 7.2 – Direction/Direction/方向 et Direction extrémale/Extreme direction/极方向

Soit $C \subset \mathbb{R}^n$ un convexe fermé non vide, $d \in \mathbb{R}^n$ un vecteur non nul. On dit que d est une direction de C si

$$\forall x \in C, \exists \lambda > 0, x + \lambda \cdot d \in C$$

Une direction de C est dite extrémale si elle ne peut pas être présentée comme une combinaison positive des autres directions de C .

Remarque 7.2

1. Deux directions u et v de C sont différentes si $\nexists \lambda > 0, u = \lambda.v$. Donc deux directions linéairement indépendantes sont différentes, mais la réciproque n'est pas toujours vraie ? Pourquoi ?
2. La direction est une définition adaptée à qui fait sens dans un ensemble non-borné. Dans un ensemble borné, il n'y a pas de direction.

7.1.1 Théorème d'existence de solutions optimales d'OL

Théorème 7.1 – Existence de solutions optimales d'OL

Soit $C = \{x \in \mathbb{R}^n, A \cdot x = b, x \geq 0\}$ un polyèdre convexe tel que $d^1, d^2, \dots, d^M$ sont les directions extrémales de C . Alors une solution optimale au problème d'optimisation linéaire sous la forme standard existe si et seulement si

$$C \neq \emptyset, c^\top \cdot d^j \geq 0, \forall j \in \llbracket 1, M \rrbracket$$

Démonstration 27

Si $C = \emptyset$, alors le problème d'OL n'a pas de solution. Donc $C \neq \emptyset$ est une condition nécessaire (mais non suffisante) pour que le problème d'OL possède une solution optimale.

Supposons donc que $C \neq \emptyset$, d'après le théorème de représentation ^a, le polyèdre convexe C peut s'écrire sous la forme :

$$C = \left\{ x \in \mathbb{R}^n, x = \sum_{i=1}^N \lambda_i \cdot x^i + \sum_{j=1}^M \mu_j \cdot d^j, \sum_{i=1}^N \lambda_i = 1, \lambda_i \geq 0, \forall i \in \llbracket 1, N \rrbracket, \mu_j \geq 0, \forall j \in \llbracket 1, M \rrbracket \right\}$$

où $x^1, x^2, \dots, x^N$ sont des points extrémaux de C .

Donc le problème d'OL est équivalente au problème :

$$\begin{aligned} \min c^\top x &= \sum_{i=1}^N \lambda_i \cdot c^\top x^i + \sum_{j=1}^M \mu_j \cdot c^\top d^j \\ \text{s.c. } \sum_{i=1}^N \lambda_i &= 1 \\ \lambda_i &\geq 0, i \in \llbracket 1, N \rrbracket \\ \mu_j &\geq 0, j \in \llbracket 1, M \rrbracket \end{aligned}$$

Comme la fonction objectif $\sum_{i=1}^N \lambda_i \cdot c^\top x^i + \sum_{j=1}^M \mu_j \cdot c^\top d^j$ est une fonction séparable ^b, alors pour les variables λ_i comme les x^i sont les points extrémaux de C , alors l'ensemble $\{c^\top \cdot x^i\}$ est borné. Alors, l'ensemble des combinaisons convexes des $\{c^\top \cdot x^i\}$ est un compact de $\mathbb{R}$. Il existe donc toujours une solution λ pour minimiser la partie $\sum_{i=1}^N \lambda_i \cdot c^\top x^i$.

Ensuite, pour la partie $\sum_{j=1}^M \mu_j \cdot c^\top d^j$, avec $\mu_j \geq 0, j \in \llbracket 1, M \rrbracket$, on peut vérifier facilement qu'il existe un minimum si et seulement si $c^\top \cdot d^j \geq 0, j = 1, \dots, M$.

$\Rightarrow$: Par contraposée, si $\exists k \in \llbracket 1, M \rrbracket$ tel que $c^\top \cdot d^k < 0$, alors pour $\mu_k \rightarrow +\infty$, on obtient $\mu_k \cdot c^\top \cdot d^k \rightarrow -\infty$, donc $\sum_{j=1}^M \mu_j \cdot c^\top d^j \rightarrow -\infty$, c'est-à-dire, il n'existe pas de minimum. Donc il existe un minimum $\Rightarrow c^\top \cdot d^j \geq 0, \forall j \in \llbracket 1, M \rrbracket$.

$\Leftarrow$: Réciproquement, si $c^\top \cdot d^j \geq 0, \mu_j \geq 0, \forall j \in \llbracket 1, M \rrbracket$, alors, $\sum_{j=1}^M \mu_j \cdot c^\top d^j \geq 0$, le minimum est clairement égale à 0 si $\mu_j = 0, j = 1, \dots, M$.

Finalement, $C \neq \emptyset, c^\top \cdot d^j \geq 0, \forall j \in \llbracket 1, M \rrbracket$ est une condition nécessaire et suffisante pour l'existence de solution optimale du problème d'OL.

a. Pour tout $x \in C$, il existe un nombre fini de points extrémaux $(x_1, \dots, x_N)$ ($N \geq 1$) et un nombre fini de directions extrémales $(d_1, \dots, d_M)$ ($M \geq 0$) tel que

$$x = \sum_{i=1}^N \lambda_i \cdot x_i + \sum_{j=1}^M \mu_j d_j$$

avec $\sum_{i=1}^N \lambda_i = 1$, $\lambda_i \geq 0$, $\forall i \in \llbracket 1, N \rrbracket$, $\mu_j \geq 0$, $\forall j \in \llbracket 1, M \rrbracket$.

b. Une fonction de 2 variables indépendantes est dite séparable si on peut l'écrire sous forme d'un produit de 2 fonctions chacune d'entre elles dépendant d'une seule variable.

Théorème 7.2 – Existence de solution-sommet

Si le problème d'OL a une solution, il a une solution en un sommet de C .

Démonstration 28

On a vu dans la démonstration du théorème d'existence de solutions optimales d'OL, que la solution optimale satisfait $\mu_j = 0$, $\forall j \in \llbracket 1, M \rrbracket$. Alors, le problème devient

$$\begin{aligned} \min \quad & \sum_{i=1}^N \lambda_i \cdot c^\top \cdot x^i \\ \text{s.c.} \quad & \sum_{i=1}^N \lambda_i = 1 \\ & \lambda_i \geq 0, i \in \llbracket 1, N \rrbracket \end{aligned}$$

Prenons $p \in \llbracket 1, N \rrbracket$ tel que

$$c^\top \cdot x^p = \min_{1 \leq i \leq N} c^\top \cdot x^i$$

Comme $\sum_{i=1}^N \lambda_i = 1$, $\lambda_i \geq 0$, $i \in \llbracket 1, N \rrbracket$, on obtient alors

$$\sum_{i=1}^N \underbrace{\lambda_i}_{\geq 0} \cdot \underbrace{c^\top \cdot x^i}_{\geq c^\top \cdot x^p} \geq \sum_{i=1}^N \lambda_i \cdot c^\top \cdot x^p = \underbrace{\left(\sum_{i=1}^N \lambda_i \right)}_{=1} \cdot c^\top \cdot x^p = c^\top \cdot x^p$$

Donc $c^\top \cdot x^p$ est la valeur optimale du problème d'OL. C'est à dire, le sommet x^p est une solution optimale.

Remarque 7.3

Lorsqu'un connaît tous les points extrémaux et toutes les directions extrémales de C , alors, le Théorème 7.2 nous permet de trouver une solution optimale en un sommet de C .

7.1.2 Solution de base

Considérons le système linéaire :

$$A \cdot x = b$$

où $A \in \mathcal{M}_{m,n}$ ($m \leq n$) et $\text{rang}(A) = m$, $b \in \mathbb{R}^m$.

Comme $\text{rang}(A) = m$, il y a donc m colonnes de A linéairement indépendantes. Par exemple, si les premières m colonnes de A sont linéairement indépendantes, on peut donc écrire A sous la forme d'une matrice par blocs :

$$A = \begin{bmatrix} B & N \end{bmatrix}$$

avec $B \in \mathcal{GL}_m$, et $N \in \mathcal{M}_{m,n-m}$.

Définition 7.3 – Matrice de base/Basic matrix/基矩阵

Comme B est une matrice inversible, elle forme une base de $\mathbb{R}^m$, on l'appelle une *matrice de base/basic matrix/基矩阵* (ou une *base*). La matrice N s'appelle une *matrice hors base/non-basic matrix/非基矩阵*.

Définition 7.4 – Variable de base/Basic variable/基变量

Étant donnée une base B , on peut également décomposer les variables x en deux parties :

$$x = \begin{bmatrix} x_B \\ x_N \end{bmatrix}$$

où $x_B \in \mathbb{R}^m$ correspond à des colonnes de B , appelées *variables de base/basic variable/基变量* ; et $x_N \in \mathbb{R}^{n-m}$ correspond à des colonnes de N , appelée *variable hors base/non-basic variable/非基变量*.

On obtient alors

$$A \cdot x = b \iff A \cdot x = [B|N] \cdot \begin{bmatrix} x_B \\ x_N \end{bmatrix} = B \cdot x_B + N \cdot x_N = b$$

Comme B est inversible, on a

$$x_B = B^{-1} \cdot b - B^{-1} \cdot N \cdot x_N$$

Particulièrement, si on prend $x_N = 0$, alors

$$x_B = B^{-1} \cdot b$$

Donc $x = \begin{bmatrix} B^{-1}b \\ 0 \end{bmatrix}$ est une solution possible de l'équation $A \cdot x = b$.

Définition 7.5 – Base réalisable/Feasible base/可行基

Soit une base B donnée, si $B^{-1} \cdot b \geq 0$, alors la matrice B appelé une *base réalisable/feasible base/可行基* pour les contraintes $\{A \cdot x = b, x \geq 0\}$. Sinon, B est une *base non-réalisable/infeasible base/非可行基*.

Définition 7.6 – Solution de base/Solution de base réalisable/Solution de base optimale

Dans un problème d'OL, soit B une matrice de base, on appelle $x = \begin{bmatrix} B^{-1} \cdot b \\ 0 \end{bmatrix}$ une solution de *base/basic solution/基本解* pour l'équation du système linéaire $Ax = b$.

1. Si de plus $B^{-1} \cdot b \geq 0$, on l'appelle une *solution de base réalisable/basic feasible solution/基本可行解*.
2. Si $x = \begin{bmatrix} B^{-1} \cdot b \\ 0 \end{bmatrix}$ est une solution optimale du problème d'OL, alors B est une *base optimale/optimal base/最优基*, et x est une *solution de base optimale/optimal basic solution/最优基本可行解*.


Définition 7.7 – Dégénération/Degeneration/退化

Soit $x = \begin{bmatrix} B^{-1} \cdot b \\ 0 \end{bmatrix}$ une solution de base réalisable du problème d'OL, si $B^{-1} \cdot b > 0$, alors la solution x est non-dégénérée, sinon x est dégénérée.

7.2 Méthode graphique

Cette méthode est uniquement applicable pour résoudre un problème d'optimisation avec une ou deux variables et peu de contraintes linéaires.

Figure 7.1 – Exemple de méthode graphique



Exemple 7.1 – Optimisation linéaire avec deux variables

Considérons le problème d'optimisation linéaire suivant

$$\begin{cases} \min & -x_1 - 3x_2 \\ \text{s.c.} & x_1 + x_2 \leq 6 \\ & -x_1 + 2x_2 \leq 8 \\ & (x_1, x_2) \geq 0 \end{cases} \quad (7.1)$$

Notons l'ensemble des contraintes linéaires par C . Nous pouvons tracer le domaine C comme dans la figure 7.1, et c'est un polytope.

La fonction objectif à minimiser est $c^\top \cdot x = -x_1 - 3x_2$ où $c = \begin{bmatrix} -1 \\ -3 \end{bmatrix}$ et $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$.

Nous pouvons facilement trouver le minimum et le maximum de la fonction objectif sur C .

Le minimum global est atteint au point $\left(\frac{4}{3}, \frac{14}{3}\right)$, le maximum global est atteint au point $(0, 0)$.

La valeur minimale est $-\frac{4}{3} - 3 \times \frac{14}{3} = -\frac{46}{3}$; la valeur maximale est $-0 - 3 \times 0 = 0$.

7.3 Algorithme du simplexe

L'algorithme du simplexe/simplex algorithm/单纯性算法 a été développé par Georg Dantzig en 1947. C'est une méthode qui permet de trouver une solution de base optimale d'un problème d'OL en nombre fini d'étapes si le problème est réalisable, ou montre que le problème est non borné ou non-réalisable (les trois uniques possibilités pour un problème d'OL).

L'idée de cet algorithme est de passer d'un sommet de l'ensemble admissible (un polyèdre convexe), le long d'une arête, vers un autre sommet qui permet de diminuer la valeur de la fonction objectif. L'algorithme s'arrête lorsque la valeur de la fonction objectif ne décroît plus.

Pour construire cet algorithme, considérons le problème d'OL sous la forme standard (Définition 1.1) :

$$\min\{f(x) = c^\top \cdot x, A \cdot x = b, x \geq 0\}$$

Les matrices que nous avons mentionnées ici sont différentes de celles que nous avons utilisées pour décrire un problème d'optimisation au début de ce chapitre. Pour être précis, nous avons ici les nouvelles matrices comme suivantes : $c = \begin{bmatrix} c_1 & \cdots & c_n & \mathbf{0} \end{bmatrix}^\top$ avec $\mathbf{0}$ un vecteur nul de m éléments, $x = (x_1, \dots, x_{n+m})$, $A = \begin{bmatrix} N & B \end{bmatrix} \in \mathcal{M}_{m, n+m}$ et $b = (b_1, \dots, b_m)$.

Question : Comment passer d'une solution de base réalisable vers une autre solution de base réalisable en diminuant la valeur de la fonction objectif f ?

Analyse : Notons B une matrice de base et N une matrice hors base, supposons que

$$x^0 = \begin{bmatrix} 0 \\ B^{-1} \cdot b \end{bmatrix}$$

est une solution de base réalisable. Alors,

$$f(x^0) = c^\top \cdot x^0 = \begin{bmatrix} c_N^\top & c_B^\top \end{bmatrix} \cdot \begin{bmatrix} 0 \\ B^{-1}b \end{bmatrix} = c_B^\top \cdot B^{-1} \cdot b$$

D'abord, on va essayer de chercher une solution réalisable x depuis x^0 qui nous permet de diminuer la valeur de la fonction objectif, soit

$$x = \begin{bmatrix} x_N \\ x_B \end{bmatrix}$$

une solution réalisable améliorée (avec $x_N \geq 0$). Alors,

$$x_B = B^{-1} \cdot b - B^{-1} \cdot N \cdot \underbrace{x_N}_{\geq 0}$$

Si on a $f(x) < f(x^0)$, il faut donc

$$f(x) = c^\top \cdot x = c_B^\top \cdot x_B + c_N^\top \cdot x_N = \underbrace{c_B^\top \cdot B^{-1} \cdot b}_{=f(x^0)} - \left(c_B^\top \cdot B^{-1} \cdot N - c_N^\top \right) \cdot x_N < f(x^0)$$

On obtient alors

$$\left(c_B^\top \cdot B^{-1} \cdot N - c_N^\top \right) \cdot x_N > 0$$

Notons J l'ensemble des indices des variables hors base. Clairement $|J| = n$. Alors, on a deux cas possibles :

Cas 1 : S'il existe un indice $j \in J$ tel que $c_B^\top \cdot B^{-1} \cdot p_j - c_j > 0$, on peut prendre une bonne valeur de $x_j > 0$ telle que $x \in C$ et fixé $x_i = 0, \forall i \in J \setminus \{j\}$, ce qui donne

$$\left(c_B^\top \cdot B^{-1} \cdot N - c_N^\top \right) \cdot x_N = \underbrace{\left(c_B^\top \cdot B^{-1} \cdot p_j - c_j \right)}_{>0} \cdot \underbrace{x_j}_{>0} > 0$$

et le vecteur x pourra diminuer la valeur objectif.

Cas 2 : Sinon, $c_B^\top \cdot B^{-1} \cdot N - c_N^\top \leq 0$, alors $\nexists x_N \geq 0$ permettant de diminuer la valeur objectif, car $\left(c_B^\top \cdot B^{-1} \cdot N - c_N^\top \right) \cdot x_N \leq 0, \forall x_N \geq 0$.

D'après la discussion de cas ci-dessous, prenons

$$k \in \arg \max \{ c_B^\top \cdot B^{-1} \cdot p_i - c_i, i \in J \}$$

Si $c_B^\top \cdot B^{-1} \cdot p_k - c_k \leq 0$, on est dans le deuxième cas, donc x est une solution de base réalisable et optimale.

Sinon, on a $c_B^\top \cdot B^{-1} \cdot p_k - c_k > 0$, et on cherche une valeur de x_k qui permet de construire une solution réalisable

$x = \begin{bmatrix} x_N \\ x_B \end{bmatrix}$ telle que

$$x_N = \begin{bmatrix} x_i \end{bmatrix}_{i \in J} \text{ où } x_i = \begin{cases} x_k, & i = k \\ 0, & i \in J \setminus \{k\} \end{cases}$$

$$x_B = B^{-1} \cdot b - B^{-1} \cdot N \cdot x_N = B^{-1} \cdot b - x_k \cdot B^{-1} \cdot p_k$$

Pour simplifier la notation, on note $\bar{b} = B^{-1} \cdot b$ et $y_k = B^{-1} \cdot p_k$. Alors,

$$x_B = \bar{b} - x_k \cdot y_k$$

Donc

$$f(x) = f(x^0) - \underbrace{x_k}_{>0} \cdot \underbrace{(c_B^\top \cdot y_k - c_k)}_{>0} < f(x^0)$$

Pour maximiser l'écart entre $f(x)$ et $f(x^0)$, on peut prendre x_k le plus grand possible en gardant la faisabilité de x . Comme $A \cdot x = b$ est toujours vrai, et $x_N \geq 0$, il reste à garantir $x_B \geq 0$.

On a deux cas possibles :

— Si $y_k \leq 0$ ($y_k \neq 0$), alors

$$\forall x_k > 0, x_B = \bar{b} - x_k \cdot y_k > \bar{b} \geq 0$$

Donc x est réalisable.

On fait tendre x_k vers $+\infty$, alors $\|x_B\| \rightarrow +\infty$, donc le problème est **non-borné**. Dans ce cas,

$$f(x) = f(x^0) - x_k \cdot \underbrace{(c_B^\top \cdot y_k - c_k)}_{>0} \xrightarrow{x_k \rightarrow +\infty} -\infty$$

Donc il n'existe pas de solution optimale.

— Sinon, $\exists i \in \{1, \dots, m\}$ tel que $(y_k)_i > 0$, comme $x_B \geq 0$, il faut donc

$$\bar{b}_i - x_k \cdot (y_k)_i \geq 0$$

Ceci implique

$$x_k \leq \frac{\bar{b}_i}{(y_k)_i}$$

Donc

$$x_k \leq \min_{i \in \llbracket 1, m \rrbracket} \left\{ \frac{\bar{b}_i}{(y_k)_i}, (y_k)_i > 0 \right\}$$

Prenons

$$r \in \arg \min_{i \in \llbracket 1, m \rrbracket} \left\{ \frac{\bar{b}_i}{(y_k)_i}, (y_k)_i > 0 \right\}$$

et on choisit $x_k = \frac{\bar{b}_r}{(y_k)_r}$ (c'est le plus grand x_k tel que $x_B \geq 0$).

Si $\bar{b}_r = 0$ (cas dégénéré car $x_B^0 = \bar{b}$ n'est pas un vecteur strictement positif), alors $x_k = 0$ et donc $x = x^0$.

On ne peut pas améliorer la valeur optimale. On a donc atteint une solution réalisable de base optimale.

Sinon, $x_k > 0$, alors x est une solution réalisable et

$$x_{B_r} = \bar{b}_r - x_k \cdot (y_k)_r = \bar{b}_r - \frac{\bar{b}_r}{(y_k)_r} \cdot (y_k)_r = 0$$

Notons $\bar{B}$ la base B en remplaçant la colonne p_{B_r} (la r -ième colonne de la base B) par p_k , c'est-à-dire, $\bar{B} = (B \setminus \{p_{B_r}\}) \cup \{p_k\}$. On peut vérifier que la nouvelle solution réalisable x est une solution de base réalisable associée à la nouvelle base $\bar{B}$.

D'abord, on va montrer que $\bar{B}$ est une base. Comme $y_k = B^{-1} \cdot p_k$, donc $p_k = B \cdot y_k$.

$\bar{B}$ est une base si et seulement si

$$\sum_{1 \leq i \neq r \leq m} \lambda_i \cdot p_{B_i} + \lambda_r \cdot p_k = 0 \Rightarrow \lambda_i = 0, \forall i \in \llbracket 1, m \rrbracket$$

On peut vérifier que pour

$$\begin{aligned} \sum_{1 \leq i \neq r \leq m} \lambda_i \cdot p_{B_i} + \lambda_r \cdot p_k &= \sum_{1 \leq i \neq r \leq m} \lambda_i \cdot p_{B_i} + \lambda_r \cdot B \cdot y_k \\ &= \sum_{1 \leq i \neq r \leq m} (\lambda_i + \lambda_r (y_k)_i) \cdot p_{B_i} + \lambda_r (y_k)_r \cdot p_{B_r} = 0 \end{aligned}$$

comme B est une base, alors

$$\begin{cases} \lambda_i + \lambda_r(y_k)_i = 0, 1 \leq i \neq r \leq m \\ \lambda_r(y_k)_r = 0 \end{cases}$$

Or $(y_k)_r > 0$ (grâce à la définition de r), ceci implique $\lambda_i = 0, \forall i \in \llbracket 1, m \rrbracket$, d'où, $\overline{B}$ est une base.

Ensuite, on peut démontrer qu'une telle solution réalisable associée à la base $\overline{B}$ est une solution de base réalisable (laissé en exercice). Donc on a bien trouvé une nouvelle solution de base réalisable x en diminuant la valeur de la fonction objectif.

On résume finalement l'algorithme du simplexe ci-dessous et on a le résultat de convergence en un nombre fini d'étapes.

Exemple 7.2

Résoudre le problème d'OL suivant via l'algorithme du simplexe :

$$\begin{cases} \max & 4x_1 + x_2 \\ s.c. & -x_1 + 2x_2 \leq 4 \\ & 2x_1 + 3x_2 \leq 12 \\ & x_1 - x_2 \leq 3 \\ & (x_1, x_2) \geq 0 \end{cases}$$

Standardisation de la forme du problème d'OL :

$$\begin{cases} \min & -4x_1 - x_2 \\ s.c. & -x_1 + 2x_2 + x_3 = 4 \\ & 2x_1 + 3x_2 + x_4 = 12 \\ & x_1 - x_2 + x_5 = 3 \\ & (x_1, x_2, x_3, x_4, x_5) \geq 0 \end{cases}$$

On l'écrit sous la forme matricielle :

$$\min\{c^\top x : Ax = b, x \geq 0\}$$

$$\text{avec } c = \begin{bmatrix} -4 \\ -1 \\ 0 \\ 0 \\ 0 \end{bmatrix}, A = [p_1|p_2|p_3|p_4|p_5] = \begin{bmatrix} -1 & 2 & 1 & 0 & 0 \\ 2 & 3 & 0 & 1 & 0 \\ 1 & -1 & 0 & 0 & 1 \end{bmatrix}, b = \begin{bmatrix} 4 \\ 12 \\ 3 \end{bmatrix}.$$

— **Initialisation :**

$B = [p_3|p_4|p_5] = I_3$ est bien une base réalisable (car $x_B = B^{-1}b = b > 0$), et iter = 1.

— **Itération 1 :**

Étape 1 : On choisit la matrice B comme une matrice identité, alors on trouve que

$$\begin{aligned} x_B &= \begin{bmatrix} x_3 \\ x_4 \\ x_5 \end{bmatrix} = B^{-1} \cdot b = b = \bar{b} \\ x_N &= \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0 \\ f(x) &= c_B^\top \cdot x_B = \begin{bmatrix} 0 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 4 \\ 12 \\ 3 \end{bmatrix} = 0 \end{aligned}$$

Algorithm 6 Algorithme du simplexe

Données : La forme standard du problème d'OL, $c \in \mathbb{R}^{n+m}$, $A \in \mathcal{M}_{m,n+m}$, $b \in \mathbb{R}^m$ et $N \in \mathbb{N}^*$

Résultat : Une solution de base optimale x^* , la valeur optimale $f(x^*)$

1: Initialiser : iter = 1

2: **Fonction** SIMPLEXE

3: **Tant que** iter $\leq$ N **faire**

4: **Étape 1 :** Résoudre le système linéaire $B \cdot x_B = b$ pour trouver

$$x_N = 0, \quad x_B = B^{-1} \cdot b = \bar{b} \quad \text{et} \quad f(x) = c_B^\top \cdot x_B$$

5: **Étape 2 :** Calculer $k \in \arg \min \left\{ c_B^\top \cdot B^{-1} \cdot p_j - c_j, j \in \{1, \dots, m\} \right\}$

6: **Si** $c_B^\top \cdot B^{-1} \cdot p_k - c_k \leq 0$ **alors**

7: La solution optimale : $x \leftarrow x^* = \begin{bmatrix} 0 \\ x_B \end{bmatrix}$, $f(x) \leftarrow f(x^*) = c_B^\top \cdot x_B$

8: **Terminé**

9: **Fin Si**

10:

11: **Étape 3 :** Résoudre le système linéaire $B \cdot y_k = p_k$ pour trouver

$$y_k = B^{-1} \cdot p_k$$

12: **Si** $y_k \leq 0$ **alors**

13: Le problème est **non-borné**, donc il n'y a pas de solution optimale

14: **Terminé**

15: **Fin Si**

16:

17: **Étape 4 :** Calculer

$$r \in \arg \min_{i \in \llbracket 1, m \rrbracket} \left\{ \frac{\bar{b}_i}{(y_k)_i} : (y_k)_i > 0 \right\}$$

18: **Si** $\bar{b}_r = 0$ (problème **dégénéré**) **alors**

19: Les techniques d'anti-cyclage (voir la Section 7.5.2)

20: **Fin Si**

21:

22: **Étape 5 :** On échange x_{B_r} (variable de base $\rightarrow$ variable hors base) avec x_k (variable hors base $\rightarrow$ variable de base) pour obtenir

$$x_k = \frac{\bar{b}_r}{(y_k)_r}, \quad x_{B_r} = 0, \quad B = (B \setminus \{p_{B_r}\}) \cup \{p_k\}, \quad \text{iter} = \text{iter} + 1$$

23: **Répéter l'Étape 1.**

24: **Fin Tant que**

25:

26: **Retourner** x^* , $f(x^*)$

27: **Fin Fonction**

Étape 2 : On calcule k avec $J \in \{1, 2\}$, alors

$$\begin{aligned} k \in \arg \max \{c_B^\top \cdot B^{-1} \cdot p_j - c_j, j \in J\} &= \arg \max \{-c_1, -c_2\} \\ &= \arg \min \{4, 1\} = 1 \end{aligned}$$

Donc $k = 1$.

On a $c_B^\top \cdot B^{-1} \cdot p_k - c_k = 4 > 0$, on passe à l'étape 3.

Étape 3 : $y_1 = B^{-1} \cdot p_1 = \begin{bmatrix} -1 \\ 2 \\ 1 \end{bmatrix} \not\leq 0$. Donc on passe à l'étape 4.

Étape 4 : On calcule ensuite r avec $y_1 = \begin{bmatrix} (y_1)_1 \\ (y_1)_2 \\ (y_1)_3 \end{bmatrix} = \begin{bmatrix} -1 \\ 2 \\ 1 \end{bmatrix}$ et $\bar{b} = \begin{bmatrix} \bar{b}_1 \\ \bar{b}_2 \\ \bar{b}_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 12 \\ 3 \end{bmatrix}$, alors

$$\begin{aligned} r \in \arg \min_{i \in \{1, 2, 3\}} \left\{ \frac{\bar{b}_i}{(y_1)_i} \right\} &= \arg \min \left\{ \frac{\bar{b}_2}{(y_1)_2}, \frac{\bar{b}_3}{(y_1)_3} \right\} \\ &= \arg \min \left\{ \frac{12}{2}, \frac{3}{1} \right\} = 3 \end{aligned}$$

Donc $r = 3$.

Comme $\bar{b}_3 = 3 \neq 0$, le problème est non-dégénéré. On passe à l'étape 5.

Étape 5 : On remplace $p_{B_3} = p_5$ par $p_k = p_1$. Donc, maintenant on a $x_1 = 3$ et $x_5 = 0$.

$$x = (x_1, x_2, x_3, x_4, x_5) = (3, 0, 4, 12, 0)$$

$$B = (B \setminus \{p_{B_r}\}) \cup \{p_k\} = (B \setminus \{p_5\}) \cup \{p_1\} = [p_3 | p_4 | p_1] = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix}$$

$$\text{iter} = 2$$

Retourner à l'étape 1.

— Itération 2 :

Étape 1 : On calcule $B^{-1} = \begin{bmatrix} 1 & 0 & -1 \\ 0 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix}^{-1} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 1 \end{bmatrix}$, alors on trouve que

$$x_B = \begin{bmatrix} x_3 \\ x_4 \\ x_1 \end{bmatrix} = B^{-1} \cdot b = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 4 \\ 12 \\ 3 \end{bmatrix} = \begin{bmatrix} 7 \\ 6 \\ 3 \end{bmatrix} = \bar{b}$$

$$x_N = \begin{bmatrix} x_2 \\ x_5 \end{bmatrix} = 0$$

$$f(x) = c_B^\top \cdot x_B = \begin{bmatrix} 0 & 0 & -4 \end{bmatrix} \cdot \begin{bmatrix} 7 \\ 6 \\ 3 \end{bmatrix} = -12$$

Étape 2 : On calcule k avec $J \in \{2, 5\}$, alors

$$k \in \arg \max_{j \in J} \{c_B^\top \cdot B^{-1} \cdot p_j - c_j\}$$

$$c_B^\top \cdot B^{-1} = \begin{bmatrix} 0 & 0 & -4 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 0 & -4 \end{bmatrix}$$

On a

$$\begin{bmatrix} 0 & 0 & -4 \end{bmatrix} \cdot p_2 - c_2 = \begin{bmatrix} 0 & 0 & -4 \end{bmatrix} \cdot \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix} + 1 = 5 > 0$$

$$\begin{bmatrix} 0 & 0 & -4 \end{bmatrix} \cdot p_5 - c_5 = \begin{bmatrix} 0 & 0 & -4 \end{bmatrix} \cdot \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} - 0 = -4 < 0$$

Donc $k = 2$.

On a $c_B^\top \cdot B^{-1} \cdot p_k - c_k = 5 > 0$, on passe à l'étape 3.

Étape 3 : $y_2 = B^{-1} \cdot p_2 = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ 5 \\ -1 \end{bmatrix} \not\leq 0$. Donc on passe à l'étape 4.

Étape 4 : On calcule ensuite r avec $y_2 = \begin{bmatrix} (y_2)_1 \\ (y_2)_2 \\ (y_2)_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 5 \\ -1 \end{bmatrix}$ et $\bar{b} = \begin{bmatrix} \bar{b}_1 \\ \bar{b}_2 \\ \bar{b}_3 \end{bmatrix} = \begin{bmatrix} 7 \\ 6 \\ 3 \end{bmatrix}$, alors

$$\begin{aligned} r \in \arg \min_{i \in \{1,2\}} \left\{ \frac{\bar{b}_i}{(y_k)_i} \right\} &= \arg \min \left\{ \frac{\bar{b}_1}{(y_2)_1}, \frac{\bar{b}_2}{(y_2)_2} \right\} \\ &= \arg \min \left\{ \frac{7}{1}, \frac{6}{5} \right\} = 2 \end{aligned}$$

Donc $r = 2$.

Comme $\bar{b}_2 = 6 \neq 0$, le problème est non-dégénéré. On passe à l'étape 5.

Étape 5 : On remplace $p_{B_2} = p_4$ par $p_k = p_2$. Donc, maintenant on a $x_2 = \frac{6}{5}$ et $x_4 = 0$.

$$x = (x_1, x_2, x_3, x_4, x_5) = \left(3, \frac{6}{5}, 4, 0, 0 \right)$$

$$B = (B \setminus \{p_{B_r}\}) \cup \{p_k\} = (B \setminus \{p_4\}) \cup \{p_2\} = [p_3 | p_2 | p_1] = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 1 & 3 \\ 0 & 0 & -1 \end{bmatrix}$$

iter = 3

Retourner à l'étape 1.

— **Itération 3 :**

Étape 1 : On calcule $B^{-1} = \begin{bmatrix} 1 & -\frac{1}{5} & \frac{7}{5} \\ 0 & \frac{1}{5} & -\frac{2}{5} \\ 0 & \frac{1}{5} & \frac{3}{5} \end{bmatrix}$, alors on trouve que

$$x_B = \begin{bmatrix} x_3 \\ x_2 \\ x_1 \end{bmatrix} = B^{-1}b = \begin{bmatrix} 1 & -\frac{1}{5} & \frac{7}{5} \\ 0 & \frac{1}{5} & -\frac{2}{5} \\ 0 & \frac{1}{5} & \frac{3}{5} \end{bmatrix} \cdot \begin{bmatrix} 4 \\ 12 \\ 3 \end{bmatrix} = \begin{bmatrix} \frac{29}{5} \\ \frac{6}{5} \\ \frac{21}{5} \end{bmatrix} = \bar{b}$$

$$x_N = \begin{bmatrix} x_4 \\ x_5 \end{bmatrix} = 0$$

$$f(x) = c_B^\top x_B = \begin{bmatrix} 0 & -1 & -4 \end{bmatrix} \cdot \begin{bmatrix} \frac{29}{5} \\ \frac{6}{5} \\ \frac{21}{5} \end{bmatrix} = -18$$

Étape 2 : On calcule k avec $J \in \{4, 5\}$, alors

$$k \in \arg \max \{c_B^\top \cdot B^{-1} \cdot p_j - c_j, j \in J\}$$

$$c_B^\top \cdot B^{-1} = \begin{bmatrix} 0 & -1 & -4 \end{bmatrix} \cdot \begin{bmatrix} 1 & -\frac{1}{5} & \frac{7}{5} \\ 0 & \frac{1}{5} & -\frac{2}{5} \\ 0 & \frac{1}{5} & \frac{3}{5} \end{bmatrix} = \begin{bmatrix} 0 & -1 & -2 \end{bmatrix}$$

On a

$$\begin{aligned} \begin{bmatrix} 0 & -1 & -2 \end{bmatrix} \cdot p_4 - c_4 &= \begin{bmatrix} 0 & -1 & -2 \end{bmatrix} \cdot \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} - 0 = -1 < 0 \\ \begin{bmatrix} 0 & -1 & -2 \end{bmatrix} \cdot p_5 - c_5 &= \begin{bmatrix} 0 & -1 & -2 \end{bmatrix} \cdot \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} - 0 = -2 < 0 \end{aligned}$$

Donc $k = 4$.

Comme $c_B^\top \cdot B^{-1} \cdot p_k - c_k = -1 < 0$, donc l'algorithme est terminé. On trouve une solution de base optimale :

$$\begin{aligned} x_B &= \begin{bmatrix} x_3 \\ x_2 \\ x_1 \end{bmatrix} = B^{-1} \cdot b = \begin{bmatrix} 29/5 \\ 6/5 \\ 21/5 \end{bmatrix} \\ x_N &= \begin{bmatrix} x_4 \\ x_5 \end{bmatrix} = 0 \\ f(x) &= c_B^\top \cdot x_B = -18 \end{aligned}$$

Conclusion :

L'algorithme du simplexe se termine en 3 itérations. On obtient une solution maximale : $x^* = (x_1^*, x_2^*) = (\frac{21}{5}, \frac{6}{5})$ et la valeur optimale : $f(x^*) = 18$.

7.4 Tableau du simplexe

Dans le but de simplifier l'utilisation de l'algorithme du simplexe, nous présentons une version «tableau» dont tous les calculs pour une itération sont dans un tableau, on l'appelle tableau du simplexe/simplex table/单纯形表.

Considérons le problème d'OL sous la forme standard pour une base B donnée

$$\begin{aligned} f &= \min \quad c_N^\top \cdot x_N + c_B^\top \cdot x_B \\ s.c. \quad & N \cdot x_N + B \cdot x_B = b \\ & x_N, x_B \geq 0 \end{aligned}$$

On peut représenter ce problème en ajoutant une contrainte linéaire $f - c_N^\top x_N - c_B^\top x_B = 0$ comme suit

$$\begin{aligned} \min \quad & f \\ s.c. \quad & f - c_N^\top \cdot x_N - c_B^\top \cdot x_B = 0 \end{aligned} \tag{1}$$

$$\begin{aligned} & N \cdot x_N + B \cdot x_B = b \\ & x_N, x_B \geq 0, f \in \mathbb{R} \end{aligned} \tag{2}$$

Comme B est inversible, en multipliant par B^{-1} à gauche dans (2), on obtient

$$B^{-1} \cdot N \cdot x_N + x_B = B^{-1} \cdot b$$

puis en multipliant par $c_B^\top$ à gauche

$$c_B^\top \cdot B^{-1} \cdot N \cdot x_N + c_B^\top \cdot x_B = c_B^\top \cdot B^{-1} \cdot b$$

et on sommant avec (1)

$$f + (c_B^\top \cdot B^{-1} \cdot N - c_N^\top) \cdot x_N = c_B^\top \cdot B^{-1} \cdot b$$

Alors, le problème d'OL devient

$$\begin{aligned} \min \quad & f \\ \text{s.c.} \quad & B^{-1} \cdot N \cdot x_N + x_B = B^{-1} \cdot b \\ & f + \left(c_B^\top \cdot B^{-1} \cdot N - c_N^\top \right) \cdot x_N = c_B^\top \cdot B^{-1} \cdot b \\ & x_N, x_B \geq 0, f \in \mathbb{R} \end{aligned}$$

Ceci peut s'écrire sous forme de tableau ci-dessous

	f	x_N	x_B	
x_B	0	$B^{-1} \cdot N$	I_m	$B^{-1} \cdot b = \bar{b}$
f	1	$\underbrace{c_B^\top \cdot B^{-1} \cdot N - c_N^\top}_{\text{les coûts réduits}}$	0	$c_B^\top \cdot B^{-1} \cdot b = c_B^\top \cdot \bar{b}$

Dans ce tableau, nous avons toutes les informations pour une itération de l'algorithme du simplexe.

— La solution de base réalisable :

$$x_N = 0, x_B = \bar{b}$$

— La valeur de la fonction objectif :

$$c^\top \cdot x = c_B^\top \cdot \bar{b}$$

— Les coûts réduits :

$$c_B^\top \cdot B^{-1} \cdot N - c_N^\top$$

On suit la procédure suivante pour le passage d'un tableau (une solution de base réalisable) au tableau suivant (une autre solution de base réalisable améliorée).

1. Tester les coûts réduits.

Si $c_B^\top \cdot B^{-1} \cdot N - c_N^\top \leq 0$, alors $(x_N, x_B) = (0, \bar{b})$ est une solution optimale.

Sinon, on trouve la plus grande coordonnée de $c_B^\top \cdot B^{-1} \cdot N - c_N^\top$

$$k \in \arg \max_{i \in J} \{ c_B^\top \cdot B^{-1} \cdot p_i - c_i \}$$

où J est l'ensemble des indices des variables hors base x_N . Et on trouve la colonne y_k .

2. Calculer $\frac{\bar{b}_r}{(y_k)_r} = \min_{i \in \llbracket 1, m \rrbracket} \left\{ \frac{\bar{b}_i}{(y_k)_i}, (y_k)_i > 0 \right\}$.

3. Si $y_k \leq 0$, alors le problème est non-borné, terminé.

4. Si $\bar{b}_r = 0$ (cas dégénéré), et si on se trompe dans un cyclage, alors l'algorithme est terminé ou continue via les techniques anti-cyclage.

5. Sinon, on échange la variable hors base x_k avec la variable de base x_{B_r} . Il suffit d'appliquer la méthode du pivot de Gauss en choisissant le pivot $(y_k)_r$ comme dans le tableau du simplexe ci-dessous.

	x_N	x_B	
x_{B_1}	$(y_1)_1 \dots (y_k)_1 \dots$	I_m	$\bar{b}$
$\vdots$	$\vdots \quad \vdots$		
x_{B_r}	$(y_1)_r \dots (y_k)_r \dots$		
$\vdots$	$\vdots \quad \vdots$		
x_{B_m}	$(y_1)_m \dots (y_k)_m \dots$		
f	$\underbrace{z_1 \dots z_k \dots}_{c_B^\top \cdot B^{-1} \cdot N - c_N^\top}$	0	$c_B^\top \cdot \bar{b}$

D'après la méthode du pivot de Gauss, l'élément de la dernière ligne et dernière colonne du tableau (valeur de la fonction objectif) devient :

$$c_B^\top \cdot \bar{b} - z_k \cdot \left(\frac{\bar{b}_r}{(y_k)_r} \right)$$

Comme $z_k \left(\frac{\bar{b}_r}{(y_k)_r} \right) > 0$, alors la valeur de la fonction objectif diminue.

7.5 Convergence de l'algorithme du simplexe

7.5.1 Convergence dans le cas non dégénéré

Théorème 7.3 – Convergence dans le cas non dégénéré de l'algorithme du simplexe

Hypothèse de non dégénérescence : toutes les variables de base sont positives à chaque itération.
Si le problème d'optimisation linéaire sous la forme standard (OL)

$$\begin{aligned} \min \quad & f(x) = c^\top \cdot x \\ \text{s.c.} \quad & A \cdot x = b \\ & x \geq 0 \end{aligned}$$

avec $(c, x) \in (\mathbb{R}^{n+m})^2$, $b \in \mathbb{R}^{n+m}$, $A \in \mathcal{M}_{m,n+m}$, est réalisable avec une base B donnée, sous l'hypothèse de non dégénérescence, l'algorithme du simplexe se termine en un nombre fini d'itérations.

Démonstration 29

En supposant que la matrice A est de rang m , chaque solution de base réalisable doit comporter m variables de base positives (selon l'hypothèse de non dégénérescence).

Il y a un nombre fini de façons de choisir m colonnes de parmi les $(n+m)$ pour former des sous matrices $m \times m$

$$\binom{n+m}{m} = \frac{(n+m)!}{m!n!}$$

Or les bases réalisables constituent un sous-ensemble de ces dernières. Donc une borne supérieure du nombre de

$$\binom{n+m}{m} = \frac{(n+m)!}{m!n!}$$

solutions de base réalisables.

En effet, dans un problème d'OL réalisable, l'algorithme du simplexe trouve une solution de base optimale ; or alors détermine que le problème est non-borné ; ou enfin se trompe dans un cyclage au cas dégénéré. Si jamais on se retrouve dans le cas dégénéré, alors l'algorithme du simplexe va s'arrêter en un nombre fini d'itérations (car l'ensemble des sommets est de cardinal fini).

7.5.2 Convergence dans le cas dégénéré

Définition 7.8 – Règle de Bland/Bland's rule/布兰德规则

On appelle également règle des plus petits indices de Bland, elle consiste à faire entrer dans la base le plus petit indice $k \in J$ tel que le coût réduit $f(x_{\text{vieux}}) - f(x_{\text{nouveau}})$ est positif et à faire sortir le plus petit indice $r \in \arg \min_{i \in \llbracket 1, m \rrbracket} \left\{ \frac{\bar{b}_i}{(y_k)_i}, (y_k)_i > 0 \right\}$. Il a été démontré que la règle de Bland permet d'éviter le cyclage.

Théorème 7.4 – Convergence dans le cas dégénéré de l'algorithme du simplexe

En utilisant les critères d'entrée et de sortie de Bland, l'algorithme du simplexe doit être complété en un nombre fini d'itérations.

Démonstration 30

(Preuve par contradiction)

Supposons que l'algorithme du simplexe ne termine jamais. Cela signifie qu'il existe une séquence infinie d'états de base $B_1, B_2, B_3, \dots$ telle que la fonction objectif continue de s'améliorer à chaque itération.


7.6 Exercices

6.1 Considérer le problème suivant :

$$\begin{cases} \max & 3x_1 + x_2 \\ \text{s.c.} & x_1 - x_2 \geq 0 \\ & x_1 + x_2 \leq 5 \\ & (x_1, x_2) \geq 0. \end{cases}$$

- Résoudre le problème en utilisant la méthode graphique.
 - Trouver toutes les solutions de base réalisables, et déterminer une solution de base optimale.
 - Résoudre le problème en utilisant l'algorithme du simplexe.
 - Résoudre le problème en utilisant le tableau du simplexe.
- 6.2 (Problème de flot maximum) L'objectif est de chercher dans un graphe pondéré (dont le poids sur chaque arc représente une capacité maximale) le flot maximal entre un sommet de départ et un sommet d'arrivé.
- Construire un modèle d'optimisation linéaire pour le problème de flot maximum allant de 0 à 6 (voir le réseau dans la figure 7.2).

Figure 7.2 – Problème de flot maximum



- Résoudre ce modèle en utilisant l'algorithme du simplexe.
- Interpréter votre résultat dans le réseau.

Chapitre 8

Autres méthodes primales

8.1 Méthodes de pénalisation

8.1.1 Méthode de pénalisation externe

On considère un problème avec contraintes d'inégalité non-linéaires ($\mathcal{PCI}$)

$$(\mathcal{PCI}) \quad \begin{cases} \inf_{x \in \mathbb{R}^n} & f(x) \\ \text{s.c.} & g(x) \leq 0 \end{cases}$$

Le but des méthodes de pénalisation est de résoudre ce problème de façon approchée de la façon suivante. On définit la fonction $\varphi(x)$ par

$$\varphi(x) = \sum_{i=1}^p (g_i^+(x))^2$$

où $(\cdot)^+$ est la fonction partie positive définie par $y^+ = \max(0, y)$. Si on note $C = \{x \in \mathbb{R}^n, g(x) \leq 0\}$, la fonction φ vérifie par construction

$$\begin{cases} \varphi(x) = 0, & \forall x \in C \\ \varphi(x) > 0, & \forall x \notin C \end{cases}$$

On introduit alors le problème ($\mathcal{P}_\varepsilon$)

$$\begin{cases} \inf_{x \in \mathbb{R}^n} & f_\varepsilon(x) \\ \text{s.c.} & f_\varepsilon(x) = f(x) + \frac{1}{\varepsilon} \varphi(x) \end{cases}$$

dont on notera x_ε la solution, vérifiant

$$\forall x \in \mathbb{R}, \quad f_\varepsilon(x_\varepsilon) \leq f_\varepsilon(x)$$

Le nom de pénalité extérieure provient du fait que x_ε est toujours à l'extérieur (au sens large) de C comme le montre le résultat suivant.

Proposition 8.1

S'il existe au moins une contrainte saturée à l'optimum $\hat{x}$ du problème ($\mathcal{PCI}$), alors le vecteur solution du problème pénalisé ($\mathcal{P}_\varepsilon$) vérifie nécessairement

$$\exists i_0, \quad g_{i_0}(x_\varepsilon) \geq 0$$

Démonstration 31

Montrons la contraposée : si $g_i(x_\varepsilon) < 0$ pour tout i , on a par définition $x_\varepsilon \in C$. Puisque

$$f_\varepsilon(x_\varepsilon) \leq f_\varepsilon(x), \quad \forall x \in \mathbb{R}^n$$

donc en particulier pour $x = \hat{x}$, on a

$$f_\varepsilon(x_\varepsilon) \leq f_\varepsilon(\hat{x})$$

mais comme $x_\varepsilon \in C$ et $\hat{x} \in C$, on a

$$\varphi(x_\varepsilon) = \varphi(\hat{x}) = 0$$

et donc

$$f(x_\varepsilon) \leq f(\hat{x})$$

D'où $x_\varepsilon = \hat{x}$. On a donc $g_i(\hat{x}) < 0$ pour tout i et aucune contrainte n'est saturée en $\hat{x}$.

En général, on a toujours $x_\varepsilon \notin C$, mais sous des hypothèses assez peu restrictives, x_ε tend vers une solution du problème (PCT) quand ε tend vers 0.

Théorème 8.1 – Méthode de pénalisation extérieure

Soit $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction de pénalisation extérieure vérifiant :

- $\varphi(x) \geq 0$,
- $\varphi(x) = 0 \Leftrightarrow x \in C$,
- φ continue.

On suppose d'autre part que f est continue, que C est fermé et que l'une des deux conditions suivantes est vérifiée :

- $f(x) \rightarrow +\infty$ quand $\|x\| \rightarrow \infty$,
- C est borné et $\varphi(x) \rightarrow +\infty$ quand $\|x\| \rightarrow \infty$,
- φ continue.

Alors, quand ε_k tend vers 0, la suite x_{ε_k} admet au moins un point d'accumulation qui est alors une solution optimale du problème (PCT).

Lorsqu'on met en œuvre cette méthode de façon pratique, on ne peut pas prendre tout de suite ε_k très petit, à cause des problèmes de conditionnement que cela peut causer. On commence donc avec une valeur du type $\varepsilon_0 = 1$, et chaque solution x_{ε_k} est prise comme vecteur initial pour résoudre le problème avec $\varepsilon_{k+1} = \varepsilon_k/100$ (par exemple). On peut bien sûr utiliser n'importe quelle méthode pour résoudre le problème $\inf_x f_{\varepsilon_k}(x)$ (BFGS, gradient conjugué, ...).

Algorithm 7 Algorithme de la méthode de pénalisation

Données :

Résultat :

- 1: Initialiser : x_0 , iter = 1, $\varepsilon_1 = 1$
 - 2: **Fonction** PÉNALISATION EXTERNE
 - 3: **Étape 1** : Trouver x_k solution du problème $\min_x f_{\varepsilon_k}(x)$ en partant de x_{k-1} .
 - 4: **Étape 2** : Poser $\varepsilon_{k+1} = \varepsilon_k/100$.
 - 5: **Étape 3** : Faire $k \leftarrow k + 1$ et retourner en 2.
 - 6: **Fin Fonction**
-

8.1.2 Méthode de pénalisation interne

Dans le cas des méthodes internes, en général, x_ε n'est jamais dans C (sauf cas particulier) : cela peut poser des problèmes si par exemple la fonction f n'est pas définie hors de C . Les méthodes internes permettent d'éviter cet inconvénient. Leur principe est le même que pour les méthodes externes : on considère une fonction

$$f_\varepsilon(x) = f(x) + \varepsilon\psi(x)$$

mais ici la fonction $\psi(x)$ est définie pour $x \in C$ et est du type

$$\psi(x) = \sum_{i=1}^m \frac{1}{g_i(x)^2}$$

Puisque l'on a $\psi(x) \rightarrow \infty$ quand on s'approche de la frontière de C , on qualifie souvent ψ de fonction barrière. Les propriétés de convergence sont les mêmes que pour les méthodes externes, mais il faut ici disposer d'un $x_0 \in C$, ce qui peut être difficile dans certains cas.

8.1.3 Estimation des multiplicateurs

Les méthodes de pénalisation ne sont en général jamais utilisées pour obtenir la solution du problème avec contraintes, car cela nécessiterait d'utiliser des paramètres de pénalisation beaucoup trop petits. En revanche, elles permettent de calculer des estimations correctes des multiplicateurs.

Pour les méthodes externes, le point x_k est solution du problème $\inf f_{\varepsilon_k}(x)$ où

$$f_{\varepsilon}(x) = f(x) + \frac{1}{\varepsilon} \sum_{i=1}^m \left(g_i^+(x)\right)^2$$

et vérifie donc les conditions d'optimalité

$$\nabla f(x_k) + \frac{2}{\varepsilon} \sum_{i=1}^m g_i^+(x_k) \nabla g_i(x_k) = 0$$

Sous les hypothèses du théorème 8.1 $x_k \rightarrow \hat{x}$ et donc pour les contraintes non saturées, puisque $g_i(\hat{x}) < 0$, il existe k_0 tel que

$$k > k_0 \Rightarrow g_i(x_k) < 0, \quad i \notin I(\hat{x})$$

Si on suppose que $\hat{x}$ est régulier, les conditions de Kuhn et Tucker sont vérifiées et on a

$$\nabla f(\hat{x}) + \sum_{i \in I} \lambda_i \nabla g_i(\hat{x}) = 0$$

Si on note maintenant que pour $k > k_0$,

$$\nabla f(x_k) + \frac{2}{\varepsilon} \sum_{i \in I} g_i^+(x_k) \nabla g_i(x_k) = 0$$

alors par continuité de ∇f et ∇g , on en déduit que pour $i \in I$

$$\lim_{k \rightarrow \infty} \frac{2}{\varepsilon} g_i^+(x_k) = \lambda_i$$

On peut bien sûr faire le même type de raisonnement pour la méthode de pénalité interne.

8.2 Méthodes par résolution des équations de Kuhn et Tucker

8.2.1 Cas des contraintes d'égalité

On cherche à résoudre le problème

$$\begin{cases} \inf_{x \in \mathbb{R}^n} & f(x) \\ \text{s.c.} & h_i(x) = 0, \quad i \in \llbracket 1, q \rrbracket \end{cases}$$

On sait que la recherche d'un point de Kuhn et Tucker revient à résoudre le système à $n + q$ inconnues et $n + q$ inconnues

$$\begin{cases} \nabla_x \mathcal{L}(x, \lambda) = 0 \\ h(x) = 0 \end{cases}$$

où on a noté $\mathcal{L}(x, \lambda) = f(x) + \sum_{i=1}^q \lambda_i \cdot h_i(x)$ le lagrangien associé à ce problème. La méthode de Newton consiste, à partir d'un point (x_k, λ_k) , à linéariser $\nabla_x \mathcal{L}(x, \lambda)$ et $h(x)$ au voisinage de ce point, et à définir (x_{k+1}, λ_{k+1}) comme la solution du système obtenu. On peut écrire les équations suivantes

$$\begin{aligned} \nabla_x \mathcal{L}(x_k, \lambda_k) + H_{\mathcal{L}}(x_k, \lambda_k) \cdot (x_{k+1} - x_k) + \nabla h(x_k) \cdot (\lambda_{k+1} - \lambda_k) &= 0 \\ h(x_k) + \nabla h(x_k)^{\top} \cdot (x_{k+1} - x_k) &= 0 \end{aligned}$$

où $\nabla_x \mathcal{L}(x_k, \lambda_k) = \nabla f(x_k) + \nabla h(x_k) \cdot \lambda_k$. Si on pose

$$J_k = \nabla h(x_k)^{\top} = \frac{\partial h}{\partial x}(x_k)$$

et $H_k = H_{\mathcal{L}}(x_k, \lambda_k)$, on obtient le système

$$\begin{bmatrix} H_k & J_k^\top \\ J_k & 0 \end{bmatrix} \cdot \begin{bmatrix} x_{k+1} - x_k \\ \lambda_{k+1} \end{bmatrix} = \begin{bmatrix} -\nabla f(x_k) \\ -h(x_k) \end{bmatrix}$$

Si l'on utilise une méthode itérative, comme la méthode de Newton, pour résoudre un problème, cela peut présenter les inconvénients habituels tels que la convergence locale. De plus, pour les maximums, les équations de Kuhn et Tucker doivent également être satisfaites. Afin de remédier à ces inconvénients, une bonne estimation initiale de (x^*, λ^*) est nécessaire, qui peut être fournie par une méthode de pénalisation, par exemple.

8.2.2 Méthode de Wilson

Dans la méthode précédente, pour éviter les points stationnaires qui ne sont pas des minimums, on peut faire l'analyse suivante : si on note $s_k = x_{k+1} - x_k$ on observe que le système s'écrit

$$H_k \cdot y_k + J_k^\top \cdot \lambda_{k+1} = -\nabla f(x_k)$$

Le vecteur y_k est la solution du problème d'optimisation quadratique suivant :

$$\begin{cases} \inf_y & \frac{1}{2} y^\top \cdot H_k \cdot y + \nabla f(x_k)^\top \cdot y \\ \text{s.c.} & J_k \cdot y + h(x_k) = 0 \end{cases}$$

et λ_{k+1} est le multiplicateur associé. Au lieu de résoudre le système ancien, on peut donc résoudre le nouveau problème, ce qui permet d'éviter les points stationnaires qui ne sont pas des minima. La résolution de ce problème peut se faire avec toute méthode adaptée aux problèmes quadratiques. Cette extension de la méthode de Newton est due à Wilson.

8.2.3 Cas des contraintes d'inégalité

La méthode de Wilson vue au grain précédent se généralise très facilement au cas des contraintes d'inégalité. Si le problème original est de la forme :

$$\begin{cases} \inf & f(x) \\ \text{s.c.} & g_i(x) \leq 0, \quad i = \llbracket 1, p \rrbracket \end{cases}$$

les contraintes linéarisées prennent la forme

$$\nabla g(x_k)^\top \cdot y + g(x_k) \leq 0$$

On peut alors utiliser une méthode consistant à résoudre itérativement le problème quadratique

$$\begin{cases} \inf_y & \frac{1}{2} y^\top \cdot H_k \cdot y + \nabla f(x_k)^\top \cdot y \\ \text{s.c.} & J_k \cdot y + g(x_k) \leq 0 \end{cases}$$

Remarque 8.1

Comme on l'a déjà dit la méthode de Wilson (pour les contraintes d'égalité et d'inégalité) ne converge que localement. La globalisation de cette méthode peut se faire en utilisant une approximation de quasi-Newton pour la matrice $H_k = H_{\mathcal{L}}(x_k, \lambda_k)$ et en faisant une recherche linéaire dans la direction s_k pour définir $x_{k+1} = x_k + \rho_k \cdot s_k$. Lors de la recherche linéaire, on cherche alors à minimiser une fonction de mérite du type

$$\theta(x) = f(x) + c \sum_{k=1}^q |h_i(x)|$$

dans le cas des contraintes d'égalité, ou

$$\sigma(x) = f(x) + c \sum_{i=1}^p g_i^+(x)$$

dans le cas des contraintes d'inégalité (dans ce dernier cas c doit être un majorant des multiplicateurs optimaux). Les fonctions $\sigma(x)$ et $\theta(x)$ sont des fonctions de pénalisation exacte : cette terminologie traduit le fait que contrairement aux fonctions de pénalisation différentiables que l'on a vu précédemment, le minimum de θ ou σ peut coïncider avec x^* pour des valeurs finies de c .

Bibliographie

- [1] A. CHILLÈS, *Topologie et calcul différentiel*. Polycopié interne à Speit, 2022.
- [2] A. CHILLÈS, 吉宏俊, 欧亚飞, V. VINOLES, A. JOSEPH, *Algèbre linéaire*, Shanghai Jiao Tong University Press, 2021.