




上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



Chapitre 4 : Méthode de gradient

孔思佳

2026年05月


—— 饮水思源 · 爱国荣校 ——

Optimisation sans contrainte


Chercher le point le plus bas de la carte topographique.

sans contrainte

$$f(x^*) = \inf_{x \in \mathbb{R}^n} f(x)$$



Descente de gradient : processus historique



1847

Le mathématicien français Augustin-Louis Cauchy propose **la méthode de la plus forte pente**, à l'origine de la descente de gradient.

1960s–1980s

La descente de gradient est utilisée en statistique classique, mais reste limitée par son faible rendement de calcul et les problèmes non convexes.

1990

Les réseaux neuronaux traversent un « hiver de l'IA » à cause de **la disparition du gradient** et de l'essor des **SVM**.

2014



Adam a publié

Les optimiseurs modernes comme Adam et RMSProp restent des améliorations de la descente de gradient.

Descente de gradient point clé de l'apprentissage automatique



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY



Le machine learning (ajustement linéaire) consiste à minimiser l'erreur, donc à résoudre un problème d'optimisation, souvent par **descente de gradient**.



Problème classique d'apprentissage automatique : Classification



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

Iris setosa





Iris versicolor



Comment distinguer les différentes variétés d'iris **sans connaissances botaniques** ?





Iris versicolor

longueur de calice (CL): 1

largeur de calice (CW): 0.3

longueur de pétale (PL): 1.5


largeur de pétale (PW): 0.1

Problème classique d'apprentissage automatique : Classification



上海交通大学
SHANGHAI JIAO TONG UNIVERSITY

Prediction




机器学习



{1, 0}

Actuel



$f(\text{CL}, \text{CW}, \text{PL}, \text{PW})$



0.67345
0.86342
0.93425
0.94564
0.98734

最小化差异

最小化:
$$L(\theta) = -\frac{1}{m} \sum_{i=1}^m (y_i \log f(x_i) + (1 - y_i) \log(1 - f(x_i)))$$






Algorithme général de descente

1


Gradient & direction de descente

Comment déterminer la direction de descente ?

Si la dérivée est **négative**, la direction de descente est **positive**.



Si la gradient est **négative**, la direction de descente est **positive**.



Algorithme général de descente

Algorithme général de descente

Un point initial $x_0 \in \mathbb{R}^n$, un seuil de tolérance $\varepsilon > 0$

Un point $x \in \mathbb{R}^n$ proche de x^*

Initialiser : $x \leftarrow x_0$

$k \leftarrow 0$

def descente général :

- Tant que $\|\nabla f(x)\| \geq \varepsilon$:
1. Déterminer une direction de descente $d_k \in \mathbb{R}^n$ → condition de résiliation
 2. Déterminer un pas de descente $\delta_k > 0$ tel que $f(x_k + \delta_k \cdot d_k) < f(x_k)$ → direction de descente
 3. Mettre à jour x : $x \leftarrow x_{k+1} = x_k + \delta_k \cdot d_k$ → pas de descente
- $k \leftarrow k + 1$

Fin tant que

Retourner : x

Condition de résiliation

1. Nombre d'itérations

$$N$$

2. Critère de tolérance

$$|f(x_{k+1}) - f(x_k)|$$


3. Objectif de précision

$$f(x_k)$$

4. Convergence de la fonction de coût

$$f(x_k) = \inf f(x)$$


5. etc.



Pas de descente

Un pas plus grand est-il préférable,
ou un pas plus petit ?

Cela dépend,
il n'y a pas de réponse absolue.



Exemple : Classification


Simplifions le problème : déterminer l'espèce d'iris uniquement à partir de la longueur des pétales.

Iris Setosa :

- Longueur moyenne des pétales : 1.5 cm
- Écart-type : 0.2 cm
- Nombre d'échantillons : 50

Iris Versicolor :

- Longueur moyenne des pétales : 4.5 cm
- Écart-type : 0.3 cm
- Nombre d'échantillons : 50



Exemple : Classification

Étape 1 : Construire le modèle mathématique

Fonction de prédiction : $f(x) = \sigma(\theta x)$, où $\sigma(z) = \frac{1}{1 + e^{-z}}$ est la fonction sigmoïde.

Fonction de perte

$$L(\theta) = -\frac{1}{m} \sum_{i=1}^m (y_i \log f(x_i) + (1 - y_i) \log(1 - f(x_i)))$$

Étape 2 : Calculer le gradient

Calculer la dérivée partielle par rapport au paramètre θ :

$$\frac{dL(\theta)}{d\theta} = \frac{1}{m} \sum_{i=1}^m (f(x_i) - y_i) x_i$$

Étape 3 : Mise à jour des paramètres

Mettre à jour les paramètres avec la règle de descente de gradient

$$\theta_{\text{new}} = \theta - \frac{dL(\theta)}{d\theta}$$



**Répéter les
étapes 2 et 3**

Exemple : Classification

$$\alpha = 0.001$$


Après 1000 itérations :

Paramètre optimal θ :

0.2733

Valeur de la fonction de perte :

0.5842



Exemple : Classification

$$\alpha = 0.01$$


Après 1000 itérations :

Paramètre optimal θ :

0.3101

Valeur de la fonction de perte :

0.5829



Exemple : Classification

$$\alpha = 0.1$$


Après 1000 itérations :

Paramètre optimal θ :

0.3101


Valeur de la fonction de perte :

0.5829



Exemple : Classification

Élevons le problème : déterminer l'espèce d'iris en utilisant **la longueur et la largeur des pétales et des sépales**.



	Id	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species	Mark
0	1	5.1	3.5	1.4	0.2	Iris-setosa	1
1	2	4.9	3.0	1.4	0.2	Iris-setosa	1
2	3	4.7	3.2	1.3	0.2	Iris-setosa	1
3	4	4.6	3.1	1.5	0.2	Iris-setosa	1
4	5	5.0	3.6	1.4	0.2	Iris-setosa	1
...	...	...	...	...	...	...	...
95	96	5.7	3.0	4.2	1.2	Iris-versicolor	0
96	97	5.7	2.9	4.2	1.3	Iris-versicolor	0
97	98	6.2	2.9	4.3	1.3	Iris-versicolor	0
98	99	5.1	2.5	3.0	1.1	Iris-versicolor	0
99	100	5.7	2.8	4.1	1.3	Iris-versicolor	0

100 rows x 7 columns

Variables (poids et bias) :

Poids de la **CL** : w_1

Poids de la **CW** : w_2

Poids de la **PL** : w_3


Poids de la **PW** : w_4

Biais : b

Fonction (différence avec l'attendu) :

$$f(w_1, w_2, w_3, w_4, b) \\ = \sum_{i=1}^{100} (M_i - \sigma(w_1 l_c + w_2 w_c + w_3 l_p + w_4 w_p + b))^2$$

Exemple : Classification



$$f(w_1, w_2, w_3, w_4) = \sum_{i=1}^{100} (M_i - \sigma(w_1 l_s + w_2 w_s + w_3 l_p + w_4 w_p + b))^2$$

Calculer le gradient

$$\frac{\partial f}{\partial w_1} \quad \frac{\partial f}{\partial w_2} \quad \frac{\partial f}{\partial w_3} \quad \frac{\partial f}{\partial w_4} \quad \frac{\partial f}{\partial b}$$

Renouveler les paramètres

$$w_i = w_i - \alpha \frac{\partial f}{\partial w_i}$$


$$b = b - \alpha \frac{\partial f}{\partial b}$$

Itération

Exemple : Classification

Après 10000 itérations

Étiquettes réelles
1
1
1
1
1
...
0
0
0
0



Sorties entraînées
0.94336646
0.94337397
0.94337882
0.94338117
0.94338336
...
0.00118106
0.00118106
0.00118106
0.00118106

Entrée

CL : 5.0 cm

CW : 3.6 cm

PL : 1.4 cm

PW : 0.2 cm


Sortie

0.94338336

→ 1

→ Iris-setosa

Exemple : Classification



Classique $\neq$ Obsolète

Dominant $\neq$ Primaire

*Les algorithmes les plus simples
soutiennent souvent les systèmes les
plus complexes.*

Se déplacer dans le sens opposé
au gradient de la fonction objectif,
pour approcher progressivement le
minimum.

— 1847, Augustin-Louis Cauchy



Convergence de la méthode de descente

Si la suite $(x_k)_{k \in \mathbb{N}} \xrightarrow[k \rightarrow \infty]{} x^*$. On rappelle que si f est fortement convexe on a

$$\|x - x^*\| \leq \frac{2}{m} \|\nabla f(x)\|$$

donc le critère d'arrêt $\|\nabla f(x)\| < \varepsilon$ implique $\|x - x^*\| \leq \frac{2\varepsilon}{m}$.

Preuve.

Vitesse de convergence. On dit que la méthode est d'ordre $r \geq 1$, s'il existe une constante $C > 0$ telle que, pour k suffisamment grand

$$\frac{\|x_{k+1} - x^*\|}{\|x_k - x^*\|^r} \leq C$$



Algorithme de recherche de pas de descente

2


Choisir le pas

Ajuster le pas

D'où provient la taille du pas ?

De l'expérience humaine


Les valeurs initiales sont données sur la base de l'expérience, 0,1 ou 0,01



L'expérience n'est pas toujours précise

Ajustée dynamiquement par l'algorithme


L'algorithme ajustera dynamiquement le pas suivant.



d'une « valeur empirique » à une « valeur adaptative ».

Choisir le pas

Pas fixée



utiliser toujours 0,1, 0.01

Choisir le pas


Fonction
objective $f(x) = x^2$

Point
initial $x_0 = 3$

Itération $x_{k+1} = x_k + \delta_k \cdot d_k$

Pas fixée

utiliser toujours 0,1, 0.01



Petit pas

Pas fixé e $\alpha = 0.1$

- initial : $x_0 = 3, f(x_0) = 9$
- étape 1 : $x_1 = 3 - 0.1 \times 6 = 2.4, f(x_1) = 2.4^2 = 5.76$
- étape 2 : $x_2 = 2.4 - 0.1 \times 4.8 = 1.92, f(x_1) = 1.92^2 = 3.686$
- ...
- étape 10 : $x_{10} = 0.50331648 - 0.1 \times 2 \times 0.50331648 = 0.402653184$

Choisir le pas


Fonction
objective $f(x) = x^2$

Point
initial $x_0 = 3$


Itération $x_{k+1} = x_k + \delta_k \cdot d_k$

Pas fixée

utiliser toujours 0,1, 0.01



Petit pas



Grand pas

Choisir le pas

Fonction
objective $f(x) = x^2$

Point
initial $x_0 = 3$

Itération $x_{k+1} = x_k + \delta_k \cdot d_k$

Pas fixée

utiliser toujours 0,1, 0.01

Faible efficacité

Recherche précise

déterminer le pas optimal dans
la direction actuelle.

Méthode de pas de descente optimale

Méthode de pas de descente optimale

Pour f une fonction fortement convexe, $x \in \mathbb{R}^n$ et $d \in \mathbb{R}^n$ une direction de descente pour f en x , pour minimiser $f(x + \delta.d)$, la méthode optimale donne le pas de descente comme^a

$$\delta^* = \arg \min_{\delta > 0} f(x + \delta.d)$$

^a $\arg \min f$ est l'ensemble des valeurs x pour lesquelles f atteint son minimum

$$\arg \min f \stackrel{\text{déf}}{=} \{x \in \mathbb{R}^n \mid \forall x' \in \mathbb{R}^n, f(x') \leq f(x)\}$$

Choisir le pas

Fonction
objective $f(x) = x^2$

Point
initial $x_0 = 3$

Itération $x_{k+1} = x_k + \delta_k \cdot d_k$

Pas fixée

utiliser toujours 0,1, 0.01

Faible efficacité

Recherche précise

déterminer le pas optimal dans
la direction actuelle.

Recherche $\alpha^* = \arg \min_{\alpha > 0} f(x + \alpha \cdot d)$



- initial : $x_0 = 3, f(x_0) = 9$
 - essai 1 : $\alpha_1 = 0 + (1 - 0.618) \times 5 = 1.91$
 - essai 2 : $\alpha_2 = 0 + 0.618 \times 5 = 3.09$
 - ...
- étape 1 : $x_1 = 3 - 3 = 0, f(x_1) = 0$

Choisir le pas

Fonction
objective $f(x) = x^2$

Point
initial $x_0 = 3$

Itération $x_{k+1} = x_k + \delta_k \cdot d_k$

Pas fixée

utiliser toujours 0,1, 0.01

Faible efficacité

Recherche précise

déterminer le pas optimal dans
la direction actuelle.

Coût de calcul élevé

Recherche inexacte

trouver un pas « suffisamment
bon » est suffisant.

Choisir le pas

Fonction
objective $f(x) = x^2$

Point
initial $x_0 = 3$

Itération $x_{k+1} = x_k + \delta_k \cdot d_k$

Pas fixée

utiliser toujours 0,1, 0.01

Faible efficacité

Recherche précise


déterminer le pas optimal dans
la direction actuelle.

Coût de calcul élevé

Recherche inexacte

trouver un pas « suffisamment
bon » est suffisant.

Satisfait $f(x_k + \alpha \cdot d) \geq f(x_k) + c \cdot \alpha \cdot \nabla f(x_k)^\top d$



- initial : $x_0 = 3, f(x_0) = 9$
- étape 1 : $\alpha = 1, f(2) = 4$
- étape 2 : $\alpha = 1, f(1) = 1$
- étape 3 : $\alpha = 1, f(0) = 0$

Choisir le pas

Fonction
objective $f(x) = x^2$

Point
initial $x_0 = 3$

Itération $x_{k+1} = x_k + \delta_k \cdot d_k$

Pas fixée

utiliser toujours 0,1, 0.01

Faible efficacité

Recherche précise

déterminer le pas optimal dans
la direction actuelle.

Coût de calcul élevé

Recherche inexacte

trouver un pas « suffisamment
bon » est suffisant.

**Complexité de calcul
plus petit que celle de la
recherche exacte.**

**Convient à la plupart des
situations réelles.**

Méthode de pas de descente par rebroussement


Pour f une fonction fortement convexe, $x \in \mathbb{R}^n$ et $d \in \mathbb{R}^n$ une direction de descente pour f en x , il existe, un entier $N \in \mathbb{N}$, deux réels $\alpha \in]0, 1[$ et $\beta \in]0, 1[$ tels que si $n \geq N$, on a

$$f(x + \beta^n \cdot d) \leq f(x) + \alpha \beta^n \langle \nabla f(x), d \rangle$$


La méthode de rebroussement donne le pas de descente comme

$$\delta^* = \beta^N$$


Example : $d = 10$ $\alpha = 0,3$ $\beta = 0,8$




Example : $d = 10$ $\alpha = 0,3$ $\beta = 0,8$



Example : $d = 10$ $\alpha = 0,3$ $\beta = 0,8$



Example : $d = 10$ $\alpha = 0,3$ $\beta = 0,8$





Choisir le pas


Règle d'Armijo

On dit que α_k satisfait la règle d'Armijo pour le paramètre $c_1 \in]0, 1[$ si on a

$$f(x_k + \alpha d_k) \leq f(x_k) + c_1 \alpha \langle \nabla f(x_k), d_k \rangle$$



Choisir le pas



Recherche avec retour arrière / Backtracking / 回退法

Étape :

1. **Commencez par un grand pas** : par exemple, $= 1$.
2. **Vérification** : Ce pas est-il satisfaisant ?
3. **Si oui** : Utilisez cette longueur de pas.
4. **Si non** : Le pas était trop grand, **revenez en arrière** (par exemple, longueur du pas $\times 0,5$) et retournez à l'étape 2 pour vérifier à nouveau.

Point clé :

- Le taux de réduction (généralement 0,5 ou 0,8) correspond ici à un simple taux de compression.
- Une valeur précise de 0,618 ne soit pas nécessaire, la logique « essais – compression – essais » .

Choisir le pas



Recherche avec retour arrière / Backtracking / 回退法

Étape :

1. **Commencez par un grand pas** : par exemple, $\alpha = 1$.
2. **Vérification** : Ce pas est-il satisfaisant ?
3. **Si oui** : Utilisez cette longueur de pas.
4. **Si non** : Le pas était trop grand, **revenez en arrière** (par exemple, longueur du pas $\times 0,5$) et retournez à l'étape 2 pour vérifier à nouveau.

Point clé :

- Le taux de réduction (généralement 0,5 ou 0,8) correspond ici à un simple taux de compression.
- Une valeur précise de 0,618 ne soit pas nécessaire, la logique « essais – compression – essais ».





Algorithme de descente de gradient

3

Algorithme de descente de gradient

Algorithme de descente de gradient

Un point initial $x_0 \in \mathbb{R}^n$, un seuil de tolérance $\varepsilon > 0$

Un point $x \in \mathbb{R}^n$ proche de x^*

Initialiser : $x \leftarrow x_0$

$k \leftarrow 0$

def descente général :

Tant que $\|\nabla f(x)\| \geq \varepsilon$:

1. Calculer $d_0 = -\nabla f(x)$ ($d_k = -\nabla f(x_k)$)

2. Déterminer un pas de descente $\delta_k > 0$ par la méthode optimale ou par la méthode de remboursement

3. Mettre à jour x : $x \leftarrow x_{k+1} = x_k + \delta_k \cdot d_k$

$k \leftarrow k + 1$

Fin tant que

Retourner : x



Convergence de la méthode (de descente) de gradient

Soient $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction fortement convexe telle que

$$\forall (x, h) \in (\mathbb{R}^n)^2, m\|h\|^2 \leq \langle H_f(x) \cdot h, h \rangle \leq M\|h\|^2$$

avec $0 < m \leq M$ et x_0 un point quelconque de $\mathbb{R}^n$. Alors l'algorithme de descente de gradient converge et on a une vitesse de convergence linéaire


$$\forall k \in \mathbb{N}, f(x_k) - f(x^*) \leq c^k (f(x_0) - f(x^*))$$

où $c \in [0, 1[$ dépend de la méthode de recherche de pas de descente et est donnée par

- $c = 1 - \frac{m}{M}$ pour la méthode exacte/optimale,
- $c = 1 - \min(2m\alpha, 2\beta\alpha\frac{m}{M})$ pour la méthode de rebroussement utilisant les constantes $\alpha \in]0, \frac{1}{2}[$ et $\beta \in]0, 1[$.

Example : Curve-fitting

Objectif : Ajuster une ligne droite $y = mx + b$ aux points de données donnés.




La fonction objectif

$$E(m, b) = \sum_{i=1}^n (y_i - (mx_i + b))^2$$

est définie pour mesurer la qualité de l'ajustement, et les paramètres m et b sont optimisés de manière itérative via la méthode de descente de gradient pour minimiser la valeur de la fonction de perte.

Example : Curve-fitting



$$E(m, b) = \sum_{i=1}^n (y_i - (m \cdot x_i + b))^2$$

Calculer le gradient

$$\frac{\partial E}{\partial m} = -\frac{2}{n} \sum_{i=1}^n x_i (y_i - (m x_i + b))$$


$$\frac{\partial E}{\partial b} = -\frac{2}{n} \sum_{i=1}^n (y_i - (m x_i + b))$$

Renouveler les paramètres

$$m = m - \alpha \frac{\partial E}{\partial m}$$

$$b = b - \alpha \frac{\partial E}{\partial b}$$

Itération





上海交通大學

SHANGHAI JIAO TONG UNIVERSITY

Thank You

飲水思源 愛國榮校