

S10_Td 知识点详解

最优化理论 TD1 整理

2025–2026

1 整体主线

这份 TD 的核心不是单独考某一道题，而是在把优化课常用的基础工具串起来：

线性代数 $\implies$ 多元微分 $\implies$ 二次函数 $\implies$ 凸性与强凸性 $\implies$ 优化建模.

最重要的一条逻辑链是：

A 正定 $\implies x^\top Ax > 0 \implies$ 二次函数强凸 $\implies$ 极小点存在且唯一.

2 矩阵范数

矩阵范数用来衡量矩阵的大小，也可以理解为矩阵对向量的最大放大能力。常见范数有四种。

2.1 矩阵 1 范数

$$\|A\|_1 = \max_j \sum_i |a_{ij}|.$$

也就是每一列绝对值之和的最大值，所以又叫列和范数。

2.2 矩阵无穷范数

$$\|A\|_\infty = \max_i \sum_j |a_{ij}|.$$

也就是每一行绝对值之和的最大值，所以又叫行和范数。

2.3 矩阵 2 范数

$$\|A\|_2 = \sigma_{\max}(A),$$

其中 $\sigma_{\max}(A)$ 是 A 的最大奇异值。

如果 A 是实对称矩阵，那么奇异值等于特征值绝对值，因此

$$\|A\|_2 = \max_i |\lambda_i(A)|.$$

2.4 Frobenius 范数

标准定义是

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \sqrt{\text{Tr}(A^\top A)}.$$

如果题目写成 $\text{Tr}(A^\top A)$ ，那其实是 Frobenius 范数的平方。

3 可逆性、特征值与线性方程

对方阵 $A \in \mathbb{R}^{n \times n}$ ，以下条件等价：

$$A \text{ 可逆} \iff \det(A) \neq 0 \iff 0 \text{ 不是 } A \text{ 的特征值} \iff \text{Ker}(A) = \{0\} \iff \text{rank}(A) = n.$$

在优化中，如果一阶条件给出

$$Ax = b,$$

并且 A 可逆，那么驻点唯一：

$$x^* = A^{-1}b.$$

4 二次函数

优化中最重要的函数之一是二次函数：

$$f(x) = \frac{1}{2}x^\top Ax + b^\top x + c.$$

这里：

- A 控制函数的曲率；
- b 控制线性倾斜；
- c 只负责整体上下平移，不影响最优点位置。

4.1 梯度与 Hessian

如果 A 不一定对称, 则

$$\nabla f(x) = \frac{1}{2}(A + A^T)x + b,$$

$$H_f(x) = \frac{1}{2}(A + A^T).$$

如果 A 是对称矩阵, 则公式简化为

$$\nabla f(x) = Ax + b, \quad H_f(x) = A.$$

另一种常见写法是

$$f(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle + c.$$

当 A 对称时,

$$\nabla f(x) = Ax - b, \quad H_f(x) = A.$$

5 梯度、Jacobian 与微分

5.1 梯度

若 $f: \mathbb{R}^n \rightarrow \mathbb{R}$, 梯度为

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}.$$

梯度的核心意义是:

$$df_x(h) = \langle \nabla f(x), h \rangle.$$

也就是说, 沿方向 h 的一阶变化量由梯度与方向的内积给出。

5.2 Jacobian 矩阵

若 $F: \mathbb{R}^n \rightarrow \mathbb{R}^m$, 则导数用 Jacobian 矩阵表示:

$$J_F(x) = \left(\frac{\partial F_i}{\partial x_j} \right)_{1 \leq i \leq m, 1 \leq j \leq n}.$$

它给出一阶近似:

$$F(x+h) = F(x) + J_F(x)h + o(\|h\|).$$

5.3 链式法则

如果

$$h = f \circ u, \quad h(x) = f(u(x)),$$

那么

$$J_h(x) = J_f(u(x))J_u(x).$$

注意矩阵乘法顺序不能反。做题时先看维度最稳。

6 log-sum-exp 函数

题中函数为

$$f(x) = \ln \left(\sum_{i=1}^m \exp(a_i^\top x + b_i) \right).$$

这是优化和机器学习里非常常见的 log-sum-exp 函数。它可以看成最大值的光滑近似：

$$\ln \left(\sum_{i=1}^m e^{z_i} \right) \approx \max_i z_i.$$

令

$$w_i(x) = \frac{\exp(a_i^\top x + b_i)}{\sum_{k=1}^m \exp(a_k^\top x + b_k)}.$$

则

$$w_i(x) > 0, \quad \sum_{i=1}^m w_i(x) = 1.$$

梯度为

$$\nabla f(x) = \sum_{i=1}^m w_i(x) a_i.$$

也就是说，log-sum-exp 的梯度是向量 a_i 的 softmax 加权平均。

7 欧几里得范数的微分

欧几里得范数为

$$\|x\| = \sqrt{\langle x, x \rangle}.$$

当 $x \neq 0$ 时，范数可微：

$$d\|\cdot\|_x(h) = \frac{\langle x, h \rangle}{\|x\|}.$$

对应的梯度是

$$\nabla \|x\| = \frac{x}{\|x\|}.$$

但是在 $x = 0$ 处, 函数 $\|x\|$ 不可微。因此很多证明需要先在

$$\mathbb{R}^n \setminus \{0\}$$

上讨论, 再单独处理原点。

8 凸函数

函数 f 是凸函数, 意思是对任意 x, y 和 $t \in [0, 1]$,

$$f(tx + (1-t)y) \leq tf(x) + (1-t)f(y).$$

几何直觉: 函数图像上任意两点之间的连线都在函数图像上方。

可微凸函数有一个非常重要的一阶判别式:

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle.$$

意思是: 凸函数总在任一点切平面的上方。

如果 f 二阶可微, 那么

$$f \text{ 凸} \iff H_f(x) \succeq 0 \quad \text{对所有 } x.$$

9 严格凸与强凸

9.1 严格凸

严格凸要求当 $x \neq y$ 且 $t \in (0, 1)$ 时,

$$f(tx + (1-t)y) < tf(x) + (1-t)f(y).$$

严格凸的重要结论是:

如果最小值存在, 则最小点唯一。

但严格凸本身不保证最小值一定存在。例如 $f(x) = e^x$ 在 $\mathbb{R}$ 上严格凸, 但没有最小值。

9.2 强凸

f 是 α -强凸函数, 意思是存在 $\alpha > 0$, 使得

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\alpha}{2} \|y - x\|^2.$$

直觉: 强凸函数至少像一个二次函数那样向上弯。

如果 f 二阶可微, 则

$$f \text{ 是 } \alpha\text{-强凸} \iff H_f(x) \succeq \alpha I \quad \text{对所有 } x.$$

对二次函数

$$J(x) = \frac{1}{2}x^\top Ax - b^\top x,$$

若 A 对称正定, 则 J 强凸, 并且最佳强凸常数是

$$\alpha = \lambda_{\min}(A).$$

10 正定、半正定与谱不等式

设 A 是实对称矩阵。

10.1 半正定

$$A \succeq 0 \iff x^\top Ax \geq 0, \quad \forall x.$$

10.2 正定

$$A \succ 0 \iff x^\top Ax > 0, \quad \forall x \neq 0.$$

10.3 用特征值判断

$$A \succeq 0 \iff \lambda_i(A) \geq 0, \quad \forall i.$$

$$A \succ 0 \iff \lambda_i(A) > 0, \quad \forall i.$$

10.4 谱不等式

若 $\lambda_{\min}$ 和 $\lambda_{\max}$ 分别是 A 的最小、最大特征值, 则

$$\lambda_{\min} \|x\|_2^2 \leq x^\top Ax \leq \lambda_{\max} \|x\|_2^2.$$

这个不等式在证明函数增长、凸性和强凸性时非常常用。

11 无穷远处趋于无穷

法语中的

infinie à l'infini

意思是

$$\|x\| \rightarrow \infty \implies f(x) \rightarrow +\infty.$$

这个性质也叫 coercive。

如果 f 连续并且 coercive, 那么 f 在 $\mathbb{R}^n$ 上能取到最小值。

对二次函数

$$f(x) = \frac{1}{2}x^\top Ax - b^\top x + c,$$

如果 $A \succ 0$, 则二次项最终压过线性项, 因此

$$f(x) \rightarrow +\infty \quad \text{当} \quad \|x\| \rightarrow \infty.$$

12 线性规划建模

生产计划问题可以建模为线性规划。

设

x_i = 第 i 类产品的生产数量.

目标函数是最大化总利润:

$$\max_{x_1, \dots, x_n} \sum_{i=1}^n p_i x_i.$$

资源约束为

$$\sum_{i=1}^n a_{ij} x_i \leq b_j, \quad j = 1, \dots, m.$$

需求上限约束为

$$0 \leq x_i \leq d_i, \quad i = 1, \dots, n.$$

如果产品数量必须是整数, 则还需要加上

$$x_i \in \mathbb{N}.$$

13 最小二乘

最小二乘函数为

$$f(x) = \frac{1}{2} \|Ax - b\|^2.$$

展开得

$$f(x) = \frac{1}{2} x^\top A^\top A x - x^\top A^\top b + \frac{1}{2} b^\top b.$$

因此它是二次函数，其中

$$A_0 = A^\top A, \quad b_0 = A^\top b, \quad c_0 = \frac{1}{2} \|b\|^2.$$

梯度和 Hessian 为

$$\nabla f(x) = A^\top (Ax - b),$$

$$H_f(x) = A^\top A.$$

由于

$$x^\top A^\top A x = \|Ax\|^2 \geq 0,$$

所以 $A^\top A$ 一定半正定，故最小二乘函数一定凸。

它强凸当且仅当

$$A^\top A \succ 0.$$

这又等价于

$$\text{Ker}(A) = \{0\}.$$

直觉上，如果存在非零方向 h 使得 $Ah = 0$ ，那么沿着 h 移动不会改变 Ax ，也就不会改变目标函数值，因此不可能强凸。

14 各题对应的核心方法

1. Exercice 1: 计算矩阵范数，判断可逆性，必要时使用特征值或矩阵分解。
2. Exercice 2: 计算二次函数梯度和 Hessian，使用 Jacobian 链式法则，掌握 log-sum-exp 梯度。
3. Exercice 3: 练习 Fréchet 微分，尤其是 $\|x\|$ 在 $x = 0$ 与 $x \neq 0$ 的区别。
4. Exercice 4: 把生产计划写成线性规划。
5. Exercice 5: 用矩阵正定性研究二次函数的存在唯一性。
6. Exercice 6: 证明凸函数的基本封闭性质，联系二次函数与正定矩阵。
7. Exercice 7: 理解最小二乘函数的二次结构、梯度、Hessian、凸性与强凸条件。