

Chapitre 3-3

Distribution d'une fonction d'une variable aléatoire multidimensionnelle

Semaine 6

1 Distribution d'une fonction d'une variable aléatoire multidimensionnelle

Soit $(X_1, X_2, \dots, X_n)$ une variable aléatoire n -dimensionnelle. Alors la fonction $Y = g(X_1, X_2, \dots, X_n)$ de $(X_1, X_2, \dots, X_n)$ est une variable aléatoire unidimensionnelle. Le problème est le suivant : comment déterminer la distribution de Y à partir de la distribution conjointe de $(X_1, X_2, \dots, X_n)$? C'est un travail qui requiert beaucoup d'astuce. Il existe des méthodes différentes selon que le cas est discret ou continu, et selon la forme de la fonction $g(X_1, X_2, \dots, X_n)$. Certaines méthodes ne s'appliquent qu'à des formes particulières de $g(\cdot)$. Nous présentons ci-dessous quelques méthodes courantes.

1.1 Distribution d'une fonction d'une variable aléatoire multidimensionnelle discrète

Soit $(X_1, X_2, \dots, X_n)$ une variable aléatoire n -dimensionnelle discrète. Alors une certaine fonction $Y = g(X_1, X_2, \dots, X_n)$ est une variable aléatoire unidimensionnelle discrète. Lorsque l'ensemble des valeurs possibles de $(X_1, X_2, \dots, X_n)$ est petit, on peut lister une à une les valeurs de Y puis les regrouper pour obtenir le résultat, comme dans l'exemple suivant.

Exemple 1.1. Soit (X, Y) une variable aléatoire bidimensionnelle dont la distribution conjointe est donnée par le tableau suivant :

$2 \times X$	Y		
	-1	1	2
-1	5/20	2/20	6/20
2	3/20	3/20	1/20

Déterminer les distributions de : (1) $Z_1 = X + Y$; (2) $Z_2 = X - Y$; (3) $Z_3 = \max\{X, Y\}$.

Solution. On place dans le même tableau les valeurs de (X, Y) et des différentes fonctions :

P	5/20	2/20	6/20	3/20	3/20	1/20
(X, Y)	$(-1, -1)$	$(-1, 1)$	$(-1, 2)$	$(2, -1)$	$(2, 1)$	$(2, 2)$
$Z_1 = X + Y$	-2	0	1	1	3	4
$Z_2 = X - Y$	0	-2	-3	3	1	0
$Z_3 = \max\{X, Y\}$	-1	1	2	2	2	2

Après regroupement, on obtient les résultats finaux :

$Z_1 = X + Y$	-2	0	1	3	4
P	5/20	2/20	9/20	3/20	1/20
$Z_2 = X - Y$	-3	-2	0	1	3
P	6/20	2/20	6/20	3/20	3/20
$Z_3 = \max\{X, Y\}$	-1	1	2		
P	5/20	2/20	13/20		

Exemple 1.2. (Additivité de la loi de Poisson) Soient $X \sim P(\lambda_1)$, $Y \sim P(\lambda_2)$ indépendantes. Montrer que $Z = X + Y \sim P(\lambda_1 + \lambda_2)$.

Preuve. Remarquons d'abord que $Z = X + Y$ peut prendre toutes les valeurs entières non négatives $0, 1, 2, \dots$. L'événement $\{Z = k\}$ est la réunion des événements incompatibles

$$\{X = i, Y = k - i\}, \quad i = 0, 1, \dots, k.$$

Compte tenu de l'indépendance, pour tout entier non négatif k ,

$$P(Z = k) = \sum_{i=0}^k P(X = i)P(Y = k - i).$$

Cette égalité est appelée formule de convolution dans le cadre discret. En l'utilisant,

$$\begin{aligned} P(Z = k) &= \sum_{i=0}^k \frac{\lambda_1^i}{i!} e^{-\lambda_1} \cdot \frac{\lambda_2^{k-i}}{(k-i)!} e^{-\lambda_2} \\ &= e^{-(\lambda_1 + \lambda_2)} \frac{1}{k!} \sum_{i=0}^k \frac{k!}{i!(k-i)!} \lambda_1^i \lambda_2^{k-i} \\ &= e^{-(\lambda_1 + \lambda_2)} \frac{(\lambda_1 + \lambda_2)^k}{k!}. \end{aligned}$$

Cela montre que $X + Y \sim P(\lambda_1 + \lambda_2)$. Notons que $X - Y$ ne suit pas une loi de Poisson.

Cette propriété de la loi de Poisson peut s'énoncer : le produit de convolution de lois de Poisson est encore une loi de Poisson, et on note

$$P(\lambda_1) * P(\lambda_2) = P(\lambda_1 + \lambda_2).$$

Ici, la convolution désigne l'opération qui consiste à chercher la distribution de la somme de deux variables aléatoires indépendantes. Cette propriété se généralise à la somme d'un nombre fini de variables de Poisson indépendantes :

$$P(\lambda_1) * P(\lambda_2) * \dots * P(\lambda_n) = P(\lambda_1 + \lambda_2 + \dots + \lambda_n).$$

En particulier, si $\lambda_1 = \lambda_2 = \dots = \lambda_n = \lambda$,

$$P(\lambda) * P(\lambda) * \dots * P(\lambda) = P(n\lambda).$$

Ces conclusions sont importantes tant en théorie qu'en pratique.

Nous appellerons désormais propriété d'additivité le fait que la distribution de la somme de variables indépendantes appartenant à une même famille appartient encore à cette famille. L'exemple ci-dessus montre que la loi de Poisson est additive ; l'exemple suivant montre que la loi binomiale est également additive.

Exemple 1.3. (Additivité de la loi binomiale) Soient $X \sim b(n, p)$, $Y \sim b(m, p)$ indépendantes. Montrer que $Z = X + Y \sim b(n + m, p)$.

Preuve. $Z = X + Y$ peut prendre les valeurs $0, 1, 2, \dots, n + m$. En utilisant la formule de convolution discrète,

$$P(Z = k) = \sum_{i=0}^k P(X = i)P(Y = k - i).$$

Puisque $X \sim b(n, p)$ et $Y \sim b(m, p)$, on doit avoir $i \leq n$ et $k - i \leq m$, soit $i \leq n$ et $i \geq k - m$. Posons

$$a = \max\{0, k - m\}, \quad b = \min\{n, k\}.$$

Alors

$$\begin{aligned} P(Z = k) &= \sum_{i=a}^b \binom{n}{i} p^i (1-p)^{n-i} \cdot \binom{m}{k-i} p^{k-i} (1-p)^{m-(k-i)} \\ &= p^k (1-p)^{n+m-k} \sum_{i=a}^b \binom{n}{i} \binom{m}{k-i}. \end{aligned}$$

D'après la distribution hypergéométrique, on a

$$\sum_{i=a}^b \frac{\binom{n}{i} \binom{m}{k-i}}{\binom{n+m}{k}} = 1 \quad \text{soit} \quad \sum_{i=a}^b \binom{n}{i} \binom{m}{k-i} = \binom{n+m}{k}.$$

Ainsi,

$$P(Z = k) = \binom{n+m}{k} p^k (1-p)^{n+m-k}, \quad k = 0, 1, \dots, n+m.$$

Cela montre que $Z = X + Y \sim b(n + m, p)$. Ainsi, pour un même paramètre p , le produit de convolution de lois binomiales est encore une loi binomiale : $b(n, p) * b(m, p) = b(n + m, p)$. Cette propriété se généralise :

$$b(n_1, p) * b(n_2, p) * \dots * b(n_k, p) = b(n_1 + n_2 + \dots + n_k, p).$$

En particulier, si $n_1 = n_2 = \dots = n_k = 1$,

$$b(1, p) * b(1, p) * \dots * b(1, p) = b(k, p),$$

ce qui signifie que si $X_1, X_2, \dots, X_n$ sont indépendantes et identiquement distribuées selon une loi $b(1, p)$ (loi de Bernoulli), alors leur somme $\sum_{i=1}^n X_i$ suit une loi $b(n, p)$. Autrement dit, une variable binomiale $b(n, p)$ peut être décomposée en somme de n variables de Bernoulli indépendantes.

1.2 Distribution du maximum et du minimum

Considérons la pluie annuelle X d'une région ; c'est une variable aléatoire de fonction de répartition $F(x)$. Pour étudier la possibilité d'inondations ou de sécheresses dans cette région au cours des cinquante prochaines années, on a besoin des pluies annuelles maximale et minimale sur ces cinquante années, qui s'écrivent

$$Y = \max\{X_1, X_2, \dots, X_{50}\}, \quad Z = \min\{X_1, X_2, \dots, X_{50}\},$$

où X_i est la pluie de la i -ième année. La région étant la même, les X_i peuvent être considérées comme indépendantes et identiquement distribuées.

Il est donc intéressant d'étudier les distributions du maximum Y et du minimum Z d'un échantillon de variables indépendantes et identiquement distribuées. Nous allons traiter ces problèmes par des exemples.

Exemple 1.4. (Distribution du maximum) Soient $X_1, X_2, \dots, X_n$ des variables aléatoires indépendantes. Soit $Y = \max\{X_1, X_2, \dots, X_n\}$. Déterminer la distribution de Y dans les cas suivants : (1) $X_i \sim F_i(x), i = 1, 2, \dots, n$; (2) les X_i sont identiquement distribuées : $X_i \sim F(x), i = 1, 2, \dots, n$; (3) les X_i sont continues et identiquement distribuées, de densité $p(x)$; (4) $X_i \sim \text{Exp}(\lambda), i = 1, 2, \dots, n$.

Solution. (1) La fonction de répartition de Y est

$$\begin{aligned} F_Y(y) &= P(\max\{X_1, \dots, X_n\} \leq y) = P(X_1 \leq y, \dots, X_n \leq y) \\ &= P(X_1 \leq y) \cdots P(X_n \leq y) = \prod_{i=1}^n F_i(y). \end{aligned} \quad (3.3.7)$$

(2) En substituant la fonction de répartition commune $F(x)$,

$$F_Y(y) = [F(y)]^n.$$

(3) La densité de Y s'obtient en dérivant :

$$p_Y(y) = F'_Y(y) = n[F(y)]^{n-1}p(y).$$

(4) Pour la loi exponentielle $\text{Exp}(\lambda)$: $F(y) = 1 - e^{-\lambda y}$, $p(y) = \lambda e^{-\lambda y}$ pour $y > 0$. Alors

$$\begin{aligned} F_Y(y) &= (1 - e^{-\lambda y})^n, \quad y > 0, \\ p_Y(y) &= n(1 - e^{-\lambda y})^{n-1} \lambda e^{-\lambda y}, \quad y > 0. \end{aligned}$$

Exemple 1.5. (Distribution du minimum) Soient $X_1, X_2, \dots, X_n$ des variables aléatoires indépendantes. Soit $Z = \min\{X_1, X_2, \dots, X_n\}$. Déterminer la distribution de Z dans les cas suivants : (1) $X_i \sim F_i(x), i = 1, 2, \dots, n$; (2) les X_i sont identiquement distribuées : $X_i \sim F(x), i = 1, 2, \dots, n$; (3) les X_i sont continues et identiquement distribuées, de densité $p(x)$; (4) $X_i \sim \text{Exp}(\lambda), i = 1, 2, \dots, n$.

Solution. (1) La fonction de répartition de Z est

$$\begin{aligned} F_Z(z) &= P(\min\{X_1, \dots, X_n\} \leq z) = 1 - P(\min\{X_1, \dots, X_n\} > z) \\ &= 1 - P(X_1 > z, \dots, X_n > z) = 1 - \prod_{i=1}^n P(X_i > z) \\ &= 1 - \prod_{i=1}^n [1 - F_i(z)]. \end{aligned}$$

(2) Avec une distribution commune F ,

$$F_Z(z) = 1 - [1 - F(z)]^n.$$

(3) La densité de Z est

$$p_Z(z) = F'_Z(z) = n[1 - F(z)]^{n-1}p(z).$$

(4) Pour la loi exponentielle $\text{Exp}(\lambda)$: $F(z) = 1 - e^{-\lambda z}$, $p(z) = \lambda e^{-\lambda z}$ pour $z > 0$. Alors

$$F_Z(z) = 1 - e^{-n\lambda z}, \quad p_Z(z) = n\lambda e^{-n\lambda z}, \quad z > 0.$$

D'après les exemples, si $X_1, \dots, X_n$ sont i.i.d. de loi exponentielle de paramètre λ , alors $\max\{X_1, \dots, X_n\}$ ne suit pas une loi exponentielle, tandis que $\min\{X_1, \dots, X_n\}$ suit encore une loi exponentielle, de paramètre $n\lambda$.

Exemple 1.6. Un tronçon de route était initialement équipé de 5 lampadaires. Après réfection, il est équipé de 20 lampadaires pour l'éclairage nocturne. Après les travaux, les gestionnaires de la route estiment que les ampoules sont plus fragiles. Expliquer pourquoi.

Solution. Supposons que les durées de vie des ampoules sont indépendantes et identiquement distribuées selon une loi exponentielle $\text{Exp}(\lambda)$, de durée de vie moyenne (espérance) $\lambda^{-1} = 2000$ heures. D'après l'exemple 3.3.5, avant réfection, le temps de panne de la première ampoule parmi les 5 est $T_1 = \min\{X_1, \dots, X_5\}$ et $T_1 \sim \text{Exp}(5\lambda)$. Si chaque ampoule est utilisée 10 heures par jour, la probabilité de devoir remplacer une ampoule dans les 30 jours est

$$P(T_1 \leq 300) = 1 - \exp\{-5\lambda \cdot 300\} = 1 - \exp\left\{-\frac{1500}{2000}\right\} = 0,5276.$$

Après réfection, le temps de panne de la première ampoule parmi les 20 est $T_2 = \min\{X_1, \dots, X_{20}\}$ et $T_2 \sim \text{Exp}(20\lambda)$. Alors

$$P(T_2 \leq 300) = 1 - \exp\{-20\lambda \cdot 300\} = 1 - \exp\left\{-\frac{6000}{2000}\right\} = 0,9502.$$

Cela montre qu'après réfection, la probabilité de devoir remplacer une ampoule dans les 30 jours a considérablement augmenté. C'est pourquoi les gestionnaires trouvent les ampoules plus fragiles.

Si une route comporte 100 lampadaires, la probabilité est encore plus grande. Il faut donc utiliser des ampoules à longue durée de vie (économie d'énergie) pour réduire la fréquence de remplacement.

1.3 Formule de convolution dans le cadre continu

Théorème 1.1. Soient X et Y deux variables aléatoires continues indépendantes de densités respectives $p_X(x)$ et $p_Y(y)$. Alors la densité de leur somme $Z = X + Y$ est

$$p_Z(z) = \int_{-\infty}^{+\infty} p_X(z-y)p_Y(y) dy = \int_{-\infty}^{+\infty} p_X(x)p_Y(z-x) dx.$$

Preuve. La fonction de répartition de $Z = X + Y$ est

$$\begin{aligned}
F_Z(z) &= P(X + Y \leq z) = \iint_{x+y \leq z} p_X(x)p_Y(y) dx dy \\
&= \int_{-\infty}^{+\infty} \left(\int_{-\infty}^{z-y} p_X(x) dx \right) p_Y(y) dy \\
&= \int_{-\infty}^{+\infty} \int_{-\infty}^z p_X(t-y)p_Y(y) dt dy \\
&= \int_{-\infty}^z \left(\int_{-\infty}^{+\infty} p_X(t-y)p_Y(y) dy \right) dt.
\end{aligned}$$

En dérivant, on obtient la densité :

$$p_Z(z) = \int_{-\infty}^{+\infty} p_X(z-y)p_Y(y) dy.$$

Le changement de variable $x = z - y$ donne la seconde expression.

Remarque : La formule de convolution peut aussi être utilisée lorsque X et Y ne sont pas indépendantes, en remplaçant le produit des densités marginales par la densité conjointe.

Les exemples suivants appliquent la formule de convolution aux lois normale et gamma.

Exemple 1.7. (Additivité de la loi normale) Soient $X \sim N(\mu_1, \sigma_1^2)$ et $Y \sim N(\mu_2, \sigma_2^2)$ indépendantes. Montrer que $Z = X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

Preuve. Z prend ses valeurs dans $\mathbb{R}$. Par la formule de convolution,

$$p_Z(z) = \frac{1}{2\pi\sigma_1\sigma_2} \int_{-\infty}^{+\infty} \exp \left\{ -\frac{1}{2} \left[\frac{(z-y-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\} dy.$$

Développons l'exposant en puissances de y :

$$\frac{(z-y-\mu_1)^2}{\sigma_1^2} + \frac{(y-\mu_2)^2}{\sigma_2^2} = A \left(y - \frac{B}{A} \right)^2 + \frac{(z-\mu_1-\mu_2)^2}{\sigma_1^2 + \sigma_2^2},$$

où

$$A = \frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2}, \quad B = \frac{z-\mu_1}{\sigma_1^2} + \frac{\mu_2}{\sigma_2^2}.$$

En reportant,

$$p_Z(z) = \frac{1}{2\pi\sigma_1\sigma_2} \exp \left\{ -\frac{1}{2} \frac{(z-\mu_1-\mu_2)^2}{\sigma_1^2 + \sigma_2^2} \right\} \int_{-\infty}^{+\infty} \exp \left\{ -\frac{A}{2} \left(y - \frac{B}{A} \right)^2 \right\} dy.$$

L'intégrale vaut $\sqrt{2\pi}/\sqrt{A}$ par normalité de la loi normale. Ainsi,

$$p_Z(z) = \frac{1}{\sqrt{2\pi(\sigma_1^2 + \sigma_2^2)}} \exp \left\{ -\frac{1}{2} \frac{(z-\mu_1-\mu_2)^2}{\sigma_1^2 + \sigma_2^2} \right\},$$

qui est la densité normale $N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

Ce résultat montre que la somme de deux normales indépendantes est encore normale, avec des paramètres qui s'ajoutent :

$$N(\mu_1, \sigma_1^2) * N(\mu_2, \sigma_2^2) = N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

Cette propriété se généralise à un nombre fini de variables normales indépendantes.

De plus, si $X \sim N(\mu, \sigma^2)$, alors pour tout réel non nul a , $aX \sim N(a\mu, a^2\sigma^2)$. On en déduit une autre conséquence importante : toute combinaison linéaire de variables normales indépendantes est normale, c'est-à-dire

$$a_1X_1 + a_2X_2 + \cdots + a_nX_n \sim N(\mu_0, \sigma_0^2),$$

avec $X_i \sim N(\mu_i, \sigma_i^2)$ indépendantes, et

$$\mu_0 = \sum_{i=1}^n a_i \mu_i, \quad \sigma_0^2 = \sum_{i=1}^n a_i^2 \sigma_i^2.$$

1.4 Méthode du changement de variables

Soit (X, Y) un couple de variables aléatoires de densité conjointe $p(x, y)$. Si les fonctions

$$u = u(x, y), \quad v = v(x, y)$$

admettent des dérivées partielles continues et une transformation inverse unique

$$x = x(u, v), \quad y = y(u, v),$$

et si le jacobien de la transformation est

$$J = \frac{\partial(x, y)}{\partial(u, v)} \neq 0,$$

alors la densité conjointe de (U, V) est

$$p_{U,V}(u, v) = p_{X,Y}(x(u, v), y(u, v)) |J|.$$

Cette méthode est en fait la formule du changement de variables dans les intégrales doubles.

Exemple 1.8. Soient X et Y indépendantes et identiquement distribuées selon $N(\mu, \sigma^2)$. Posons

$$U = X + Y, \quad V = X - Y.$$

Déterminer la densité conjointe de (U, V) et dire si U et V sont indépendantes.

Solution. La transformation inverse est

$$x = \frac{u + v}{2}, \quad y = \frac{u - v}{2}.$$

Le jacobien vaut

$$J = \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{pmatrix} = \det \begin{pmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{pmatrix} = -\frac{1}{2}.$$

Donc $|J| = 1/2$. La densité conjointe de (U, V) est

$$\begin{aligned} p_{U,V}(u, v) &= p_X\left(\frac{u+v}{2}\right) p_Y\left(\frac{u-v}{2}\right) \cdot \frac{1}{2} \\ &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}\left(\frac{u+v}{2}-\mu\right)^2} \cdot \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}\left(\frac{u-v}{2}-\mu\right)^2} \cdot \frac{1}{2}. \end{aligned}$$

En simplifiant l'exposant :

$$\left(\frac{u+v}{2}-\mu\right)^2 + \left(\frac{u-v}{2}-\mu\right)^2 = \frac{1}{2}(u-2\mu)^2 + \frac{1}{2}v^2.$$

Ainsi,

$$p_{U,V}(u, v) = \frac{1}{2\pi\sigma^2} e^{-\frac{1}{4\sigma^2}[(u-2\mu)^2+v^2]} \cdot \frac{1}{2} = \frac{1}{4\pi\sigma^2} e^{-\frac{(u-2\mu)^2}{4\sigma^2}} e^{-\frac{v^2}{4\sigma^2}}.$$

On reconnaît le produit d'une densité normale $N(2\mu, 2\sigma^2)$ pour U et d'une densité normale $N(0, 2\sigma^2)$ pour V , donc U et V sont indépendantes.

Remarque : Dans la méthode du changement de variables, l'indépendance de X et Y n'est pas nécessaire. Si (X, Y) suit une loi normale bivariée, on obtient encore que (U, V) est normal bivarié. De façon générale, une transformation linéaire d'un vecteur normal multivarié reste normale.

1.5 Méthode de la variable auxiliaire

La méthode de la variable auxiliaire est une application de la méthode du changement de variables : pour obtenir la densité d'une fonction $U = g(X, Y)$ d'un couple (X, Y) continu, on introduit une nouvelle variable auxiliaire $V = h(X, Y)$ (par exemple $V = X$ ou $V = Y$), on détermine la densité conjointe de (U, V) par changement de variables, puis on intègre par rapport à v pour obtenir la densité marginale de U .

On donne ci-dessous les formules pour le produit et le quotient de deux variables indépendantes.

Exemple 1.9. 3.3.11 (Formule du produit) Soient X et Y indépendantes de densités p_X et p_Y . Alors la densité de $U = XY$ est

$$p_U(u) = \int_{-\infty}^{+\infty} p_X\left(\frac{u}{v}\right) p_Y(v) \frac{1}{|v|} dv. \quad (f1)$$

Preuve. Posons $V = Y$. La transformation inverse est $x = u/v$, $y = v$. Le jacobien est

$$J = \det \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{pmatrix} = \det \begin{pmatrix} 1/v & -u/v^2 \\ 0 & 1 \end{pmatrix} = \frac{1}{v}.$$

Donc $|J| = 1/|v|$. La densité conjointe de (U, V) est

$$p_{U,V}(u, v) = p_X\left(\frac{u}{v}\right) p_Y(v) \frac{1}{|v|}.$$

En intégrant par rapport à v , on obtient (f1).

Exemple 1.10. 3.3.12 (Formule du quotient) Soient X et Y indépendantes de densités p_X et p_Y . Alors la densité de $U = X/Y$ est

$$p_U(u) = \int_{-\infty}^{+\infty} p_X(uv)p_Y(v) |v| dv. \quad (f2)$$

Preuve. Posons $V = Y$. La transformation inverse est $x = uv$, $y = v$. Le jacobien est

$$J = \det \begin{pmatrix} v & u \\ 0 & 1 \end{pmatrix} = v.$$

D'où $|J| = |v|$. La densité conjointe est

$$p_{U,V}(u, v) = p_X(uv)p_Y(v) |v|.$$

En intégrant par rapport à v , on obtient (f2).