

Caractéristiques numériques

Semaine 8-9

1 Espérance mathématique d'une variable aléatoire

Nous savons déjà que chaque variable aléatoire a une distribution (loi de probabilité, fonction de densité ou fonction de distribution). Différentes variables aléatoires peuvent avoir des distributions différentes, mais peuvent aussi avoir la même distribution. La distribution décrit de manière exhaustive la loi statistique des valeurs prises par la variable aléatoire, et à partir de la distribution, on peut calculer les probabilités des événements aléatoires associés. En outre, à partir de la distribution, on peut également calculer les caractéristiques numériques correspondantes de la variable aléatoire, telles que la moyenne, la variance, les quantiles, etc. Ces caractéristiques décrivent chacune un aspect de la distribution. Par exemple, le poids d'un nouveau-né est une variable aléatoire, et sa valeur moyenne décrit un aspect des caractéristiques du poids. Comment calculer la moyenne à partir de la distribution d'une variable aléatoire est la question que nous devons étudier dans cette section.

Cette section présente la caractéristique numérique la plus importante d'une variable aléatoire : l'espérance mathématique.

1.1 Concept d'espérance mathématique

Espérance désigne souvent dans la vie courante un souhait que l'on espère, mais en théorie des probabilités, l'espérance mathématique provient d'un problème historique célèbre de partage de mise.

Exemple 1.1 ((Problème du partage de la mise)). Au milieu du 17^{ème} siècle, un joueur posa au mathématicien français Pascal (1623-1662) un problème de partage de mise qui le tourmentait depuis longtemps : Deux joueurs, A et B, ayant des compétences égales, misent chacun 50 francs, et il n'y a pas de match nul dans chaque partie. Ils conviennent que celui qui gagne trois parties en premier remporte la totalité de la mise de 100 francs. Lorsque A a gagné deux parties et B en a gagné une, ils doivent interrompre le jeu pour une raison (convocation par le roi). Comment partager équitablement les 100 francs ?

Ce problème a suscité l'intérêt de nombreuses personnes. Tout d'abord, tout le monde a reconnu qu'un partage égal est injuste pour A, et qu'attribuer la totalité à A est injuste pour B. Une méthode de partage raisonnable est de partager selon une certaine proportion, A recevant plus et B recevant moins. Le point crucial est donc : selon quelle proportion partager ? Voici deux méthodes de partage :

(1) A reçoit 2/3 des 100 francs, B reçoit 1/3 des 100 francs. Cette méthode est basée sur le nombre de parties déjà jouées : A a gagné deux parties, B en a gagné une.

(2) En 1654, Pascal proposa la méthode de partage suivante : Imaginez que le jeu continue. Alors le gain final X de A est une variable aléatoire pouvant prendre les valeurs 0 ou 100. Deux parties supplémentaires suffisent à terminer le jeu, et les résultats possibles sont les quatre situations suivantes : AA, AB, BA, BB où AB signifie que A gagne la première partie et B gagne la deuxième. Dans trois de ces quatre situations, A obtient 100 francs ; il n'y a qu'une seule situation (BB) où A obtient 0 franc. Comme les compétences sont égales, la probabilité que A obtienne 100 francs est de 3/4 et celle qu'il obtienne 0 franc est de 1/4, c'est-à-dire que la loi de probabilité de X est

X	0	100
P	0,25	0,75

Après cette analyse, Pascal estima que le gain espéré de A devrait être : $0 \times 0,25 + 100 \times 0,75 = 75$ francs. Autrement dit, A reçoit 75 francs, B reçoit 25 francs. Cette méthode de partage prend en compte non seulement les parties déjà jouées, mais inclut également une espérance sur la poursuite du jeu. Elle est plus raisonnable que la méthode (1).

C'est de là que vient le nom espérance mathématique. En réalité, le terme moyenne serait plus imagé et plus facile à comprendre. Dans l'exemple ci-dessus, si le jeu continue, A peut en moyenne gagner 75 francs.

Analysons maintenant progressivement comment calculer la moyenne à partir de la distribution.

1.2 Définition de l'espérance mathématique

Définition 1.1. Soit X une variable aléatoire discrète de loi de probabilité

$$p(x_i) = P(X = x_i), \quad i = 1, 2, \dots, n, \dots$$

Si

$$\sum_{i=1}^{\infty} |x_i| p(x_i) < \infty,$$

on appelle

$$E(X) = \sum_{i=1}^{\infty} x_i p(x_i)$$

l'espérance mathématique de la variable aléatoire X , ou l'espérance mathématique de cette distribution, ou simplement espérance ou moyenne. Si la série $\sum_{i=1}^{\infty} |x_i| p(x_i)$ diverge, on dit que l'espérance mathématique de X n'existe pas.

Dans la définition ci-dessus, l'exigence de convergence absolue de la série vise à garantir l'unicité de l'espérance mathématique. Comme les valeurs d'une variable aléatoire peuvent être positives ou négatives, et que l'ordre des termes peut être modifié, la théorie des séries infinies nous indique que si cette série infinie converge absolument, sa somme n'est pas affectée par un changement d'ordre. Comme la

somme d'un nombre fini de termes n'est pas affectée par un changement d'ordre, l'espérance mathématique d'une variable aléatoire prenant un nombre fini de valeurs existe toujours.

La définition de l'espérance mathématique pour une variable aléatoire continue est similaire à celle du cas discret, en remplaçant la somme par une intégrale.

Définition 1.2. Soit X une variable aléatoire continue de fonction de densité $p(x)$. Si

$$\int_{-\infty}^{\infty} |x|p(x)dx < \infty,$$

on appelle

$$E(X) = \int_{-\infty}^{\infty} xp(x)dx$$

l'espérance mathématique de X , ou l'espérance mathématique de la distribution $p(x)$, ou simplement espérance ou moyenne. Si $\int_{-\infty}^{\infty} |x|p(x)dx$ diverge, on dit que l'espérance mathématique de X n'existe pas.

L'interprétation physique de l'espérance mathématique $E(X)$ est le centre de gravité. Si on considère la probabilité $p(x_i) = P(X = x_i)$ comme une masse au point x_i , et la distribution de probabilité comme la répartition de la masse sur l'axe des x , alors l'espérance mathématique $E(X)$ est la position du centre de gravité de cette répartition de masse.

La signification théorique de l'espérance mathématique est profonde ; c'est un moyen essentiel d'éliminer le caractère aléatoire, ce qui sera clairement démontré dans les chapitres suivants de ce livre.

L'espérance mathématique a des applications pratiques étendues. $E(X)$ est souvent utilisée comme représentant de la distribution de X (un indicateur statistique) pour comparer des indicateurs de même nature. Par exemple, le nombre de défauts sur une bande magnétique est aléatoire et difficile à comparer, mais le nombre moyen de défauts sur plusieurs bandes (valeur espérée) peut être comparé ; plus il est petit, mieux c'est. L'exemple pratique suivant illustre l'étendue des applications de l'espérance mathématique.

Exemple 1.2. Dans une population de taille N , on procède à un dépistage de groupe pour une certaine maladie. Pour cela, il faut prélever du sang à N personnes. Si on analyse le sang de chaque personne individuellement, cela nécessite N analyses. Pour réduire la charge de travail, un statisticien propose une méthode : diviser les personnes en groupes de k personnes. Mélanger les échantillons de sang des k personnes du même groupe, puis analyser ce mélange. Si le mélange est négatif, cela signifie que les k personnes sont toutes négatives, donc toutes exemptes de la maladie. Ainsi, il suffit d'une seule analyse pour ces k personnes, ce qui équivaut à $1/k$ analyse par personne, réduisant ainsi considérablement la charge de travail. Si le mélange est positif, cela signifie qu'au moins une personne parmi les k est positive, et il faut alors analyser individuellement les échantillons de ces k personnes. Ainsi, pour ce groupe de k personnes, il faut effectuer $1 + k$ analyses, ce qui équivaut à $1 + 1/k$ analyses par personne, ce qui augmente le nombre d'analyses. Supposons que le taux d'incidence de la maladie soit p et que les personnes soient indépendantes. Cette méthode permet-elle de réduire le nombre moyen d'analyses ?

Correction 1. Soit X le nombre d'analyses par personne dans cette population. La loi de probabilité de X est :

X	$1/k$	$1 + 1/k$
P	$(1-p)^k$	$1 - (1-p)^k$

Le nombre moyen d'analyses par personne est donc

$$E(X) = \frac{1}{k}(1-p)^k + \left(1 + \frac{1}{k}\right) [1 - (1-p)^k] = 1 - (1-p)^k + \frac{1}{k}.$$

Ainsi, si on choisit k tel que

$$1 - (1-p)^k + \frac{1}{k} < 1 \quad \text{ou} \quad (1-p)^k > \frac{1}{k},$$

on peut réduire le nombre d'analyses. De plus, on peut choisir k de manière à minimiser $E(X)$. Par exemple, pour $p = 0,1$, les valeurs de $E(X)$ pour différents k sont données dans le tableau 2.2.1. On voit que pour $k \geq 34$, le nombre moyen d'analyses dépasse 1, ce qui est plus élevé que l'analyse individuelle. Pour $k \leq 33$, le nombre moyen d'analyses est réduit à des degrés divers, notamment pour $k = 4$, le nombre moyen d'analyses est minimal, réduisant la charge de travail de 40%.

Exemple 1.3. Chaque billet de loterie coûte 5 yuans et porte un numéro de tirage. Pour chaque tirage de 1 million de billets, un numéro gagnant à 6 chiffres est tiré au sort (on suppose que chaque numéro de 000000 à 999999 est équiprobable). Les règles de loterie sont les suivantes :

1. Si le numéro du billet correspond au dernier chiffre du numéro gagnant, on obtient un sixième prix de 10 yuans.
2. Si le numéro du billet correspond aux deux derniers chiffres du numéro gagnant, on obtient un cinquième prix de 50 yuans.
3. Si le numéro du billet correspond aux trois derniers chiffres du numéro gagnant, on obtient un quatrième prix de 500 yuans.
4. Si le numéro du billet correspond aux quatre derniers chiffres du numéro gagnant, on obtient un troisième prix de 5000 yuans.
5. Si le numéro du billet correspond aux cinq derniers chiffres du numéro gagnant, on obtient un deuxième prix de 50000 yuans.
6. Si le numéro du billet correspond à la totalité des six chiffres du numéro gagnant, on obtient un premier prix de 500000 yuans.

De plus, on ne reçoit que le prix le plus élevé. Trouver le gain moyen par billet de loterie.

Correction 2. Soit X le gain d'un billet de loterie. La loi de probabilité de X est :

X (yuans)	500000	50000	5000	500	50	10	0
P	0,000001	0,000009	0,00009	0,0009	0,009	0,09	0,9

Le gain moyen par billet est donc

$$E(X) = 0,5 + 0,45 + 0,45 + 0,45 + 0,9 + 0 = 3,2 \text{ yuans.}$$

Cela signifie que pour chaque tirage, sur les 5 millions de yuans collectés, 3,2 millions de yuans sont redistribués aux acheteurs sous forme de prix, les 1,8 million restants servant aux œuvres sociales et aux frais de gestion.

Exemple 1.4. Soit X une variable aléatoire suivant la distribution uniforme sur l'intervalle (a, b) . Trouver $E(X)$.

Correction 3. D'après l'exemple 2.1.7, la fonction de densité de X est

$$p(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{ailleurs} \end{cases}$$

Ainsi,

$$E(X) = \int_a^b x \cdot \frac{1}{b-a} dx = \frac{1}{b-a} \cdot \frac{x^2}{2} \Big|_a^b = \frac{a+b}{2}.$$

Ce résultat est compréhensible, car X prend des valeurs uniformément sur (a, b) , sa valeur moyenne est donc naturellement le milieu de (a, b) , c'est-à-dire $(a+b)/2$.

Exemple 1.5. L'espérance mathématique de la distribution de Cauchy n'existe pas. En effet, la fonction de densité de la distribution de Cauchy est

$$p(x) = \frac{1}{\pi} \frac{1}{1+x^2}, \quad -\infty < x < \infty.$$

Comme

$$\int_{-\infty}^{\infty} |x| \cdot \frac{1}{\pi} \frac{1}{1+x^2} dx = \infty,$$

$E(X)$ n'existe pas.

1.3 Propriétés de l'espérance mathématique

Selon la définition de l'espérance mathématique $E(X)$, $E(X)$ est uniquement déterminée par sa distribution. Si l'on souhaite calculer l'espérance mathématique d'une fonction $g(X)$ de la variable aléatoire X (qui est elle-même une variable aléatoire), on pourrait d'abord déterminer la distribution de $Y = g(X)$, puis utiliser cette distribution pour calculer $E(Y)$. Ce processus peut être illustré par l'exemple suivant.

Exemple 1.6. Soit X une variable aléatoire discrète de loi de probabilité :

X	-2	-1	0	1	2
P	0,2	0,1	0,1	0,3	0,3

On souhaite calculer l'espérance mathématique de $Y = X^2$. Pour cela, deux étapes sont nécessaires : Première étape, trouver la distribution de $Y = X^2$, dérivée de la distribution de X :

X^2	$(-2)^2$	$(-1)^2$	0^2	1^2	2^2
P	0,2	0,1	0,1	0,3	0,3

En regroupant les valeurs identiques et en additionnant les probabilités correspondantes, on obtient :

X^2	0	1	4
P	0,1	0,4	0,5

Deuxième étape, utiliser la distribution de X^2 pour calculer $E(X^2)$:

$$E(X^2) = 0 \times 0,1 + 1 \times 0,4 + 4 \times 0,5 = 2,4.$$

Si on utilise la distribution avant regroupement pour calculer $E(X^2)$, on obtient le même résultat :

$$E(X^2) = (-2)^2 \times 0,2 + (-1)^2 \times 0,1 + 0^2 \times 0,1 + 1^2 \times 0,3 + 2^2 \times 0,3 = 2,4.$$

Ces deux méthodes de calcul sont essentiellement identiques, mais cette dernière consiste essentiellement à calculer $E(X^2)$ directement à partir de la distribution de X en remplaçant les valeurs par leurs carrés. Cela suggère que pour calculer $E(X^3)$ et $E(X^4)$, il n'est pas nécessaire de déterminer d'abord la distribution de X^3 et X^4 ; on peut utiliser directement la distribution de X :

$$E(X^3) = (-2)^3 \times 0,2 + (-1)^3 \times 0,1 + 0^3 \times 0,1 + 1^3 \times 0,3 + 2^3 \times 0,3 = 1.$$

$$E(X^4) = (-2)^4 \times 0,2 + (-1)^4 \times 0,1 + 0^4 \times 0,1 + 1^4 \times 0,3 + 2^4 \times 0,3 = 8,4.$$

En général, on a le théorème suivant.

Théorème 1.1. *Si la distribution de la variable aléatoire X est donnée par la loi de probabilité $p(x_i)$ ou par la fonction de densité $p(x)$, alors l'espérance mathématique d'une fonction $g(X)$ de X est*

$$E[g(X)] = \begin{cases} \sum_i g(x_i)p(x_i), & \text{pour une variable aléatoire discrète,} \\ \int_{-\infty}^{\infty} g(x)p(x)dx, & \text{pour une variable aléatoire continue.} \end{cases}$$

On suppose que les espérances mathématiques mentionnées existent.

La démonstration de ce théorème nécessite des outils plus avancés, nous l'omettons ici. Basons-nous maintenant sur ce théorème pour démontrer plusieurs propriétés couramment utilisées de l'espérance mathématique. Nous supposons que toutes les espérances mathématiques mentionnées existent.

Propriété 1.1. Si c est une constante, alors $E(c) = c$.

Proof. Considérons la constante c comme une variable aléatoire X ne prenant qu'une seule valeur, alors $P(X = c) = 1$, donc son espérance mathématique est $E(c) = E(X) = c \times 1 = c$. $\square$

Propriété 1.2. Pour toute constante a ,

$$E(aX) = aE(X).$$

Proof. posons $g(x) = ax$, puis extrayons a du signe somme ou intégrale. $\square$

Propriété 1.3. Pour deux fonctions quelconques $g_1(x)$ et $g_2(x)$,

$$E[g_1(X) \pm g_2(X)] = E[g_1(X)] \pm E[g_2(X)].$$

Proof. posons $g(x) = g_1(x) \pm g_2(x)$, puis décomposons la somme en deux sommes ou l'intégrale en deux intégrales. $\square$

Exemple 1.7. Une société vend une certaine matière première. Selon les données historiques, la demande du marché X (en tonnes) pour cette matière première suit une distribution uniforme sur $(300, 500)$. Pour chaque tonne vendue, la société réalise un bénéfice de 1,5 (millier de yuans) ; pour chaque tonne invendue, elle subit une perte de 0,5 (millier de yuans). Quelle quantité de matière première la société doit-elle approvisionner pour maximiser son bénéfice moyen ?

Correction 4. Supposons que la société approvisionne a tonnes. On doit avoir $300 \leq a \leq 500$. Soit Y le bénéfice (en milliers de yuans) sous la condition d'un approvisionnement de a tonnes. Le bénéfice Y est fonction de la demande X , soit $Y = g(X)$. D'après l'énoncé, si $X \geq a$, alors les a tonnes sont entièrement vendues, réalisant un bénéfice de $1,5a$. Si $X < a$, alors X tonnes sont vendues (bénéfice de $1,5X$), et il reste $a - X$ tonnes invendues (perte de $-0,5(a - X)$), donc le bénéfice total est $1,5X - 0,5(a - X) = 2X - 0,5a$. Ainsi,

$$g(x) = \begin{cases} 2x - 0,5a, & x < a \\ 1,5a, & x \geq a \end{cases}$$

D'après le théorème et la distribution uniforme,

$$E(Y) = \int_{-\infty}^{\infty} g(x)p_X(x)dx = \int_{300}^{500} g(x)\frac{1}{200}dx$$

2 Variance et écart type d'une variable aléatoire

L'espérance mathématique $E(X)$ d'une variable aléatoire X est une caractéristique de position de la distribution. Elle indique que les valeurs de X fluctuent autour de $E(X)$. Cependant, cette caractéristique de position ne peut pas refléter l'ampleur de la fluctuation des valeurs de la variable aléatoire. Par exemple, les lois de probabilité de X et Y sont :

X	-1	0	1
P	1/3	1/3	1/3

Y	-100	0	100
P	1/3	1/3	1/3

Bien que leurs espérances mathématiques soient toutes deux nulles, il est évident que la fluctuation des valeurs de Y est plus grande que celle des valeurs de X . Comment représenter numériquement l'ampleur de la fluctuation des valeurs d'une variable aléatoire ? C'est la question que nous étudions dans cette section. La variance et l'écart type, définis ci-dessous, sont les deux caractéristiques les plus importantes pour mesurer cette ampleur de fluctuation.

2.1 Définitions de la variance et de l'écart type

Soit $a = E(X)$ la moyenne de la variable aléatoire X . Les valeurs de X ne sont bien sûr pas nécessairement exactement égales à a , elles s'en écartent. L'écart $X - a$ peut être positif ou négatif. Pour éviter que les écarts positifs et négatifs ne s'annulent mutuellement, on considère généralement $(X - a)^2$, plutôt que la valeur absolue $|X - a|$ qui est mathématiquement plus difficile à traiter. Comme $(X - a)^2$ est également une variable aléatoire, prendre sa moyenne $E(X - a)^2$ permet de caractériser le degré de fluctuation de X . Cette quantité est appelée la variance de X , définie comme suit :

Définition 2.1. Si l'espérance mathématique $E(X^2)$ de X^2 existe, on appelle variance de la variable aléatoire X (ou de la distribution correspondante) l'espérance mathématique du carré de l'écart $(X - E(X))^2$, notée

$$\text{Var}(X) = E(X - E(X))^2.$$

On note souvent $\sigma^2(X) = \text{Var}(X)$, et on appelle $\sigma(X) = \sqrt{\text{Var}(X)}$ l'écart type de X .

Exemple 2.1. Calculer la variance de la variable aléatoire X dans l'exemple 2.2.6.

Correction 5. On a $E(X) = (-2) \times 0,2 + (-1) \times 0,1 + 0 \times 0,1 + 1 \times 0,3 + 2 \times 0,3 = 0,4$.

$$\text{Var}(X) = E(X - E(X))^2 = (-2 - 0,4)^2 \times 0,2 + (-1 - 0,4)^2 \times 0,1 + (0 - 0,4)^2 \times 0,1 + (1 - 0,4)^2 \times 0,3 + (2 - 0,4)^2 \times 0,3 = 2,44$$

On peut aussi utiliser la formule $\text{Var}(X) = E(X^2) - [E(X)]^2$. On a $E(X^2) = 4 \times 0,2 + 1 \times 0,1 + 0 \times 0,1 + 1 \times 0,3 + 4 \times 0,3 = 2,6$. D'où $\text{Var}(X) = 2,6 - (0,4)^2 = 2,44$.

Exemple 2.2. Une personne dispose d'un capital à investir dans deux projets : l'immobilier et le commerce. Les rendements dépendent de l'état du marché. On divise le marché futur en trois niveaux : bon, moyen, mauvais, avec des probabilités respectives de 0,2, 0,7, 0,1. L'investisseur estime que les rendements (en milliers de yuans) de l'investissement immobilier X et commercial Y ont les distributions suivantes :

X	11	3	-3
P	0,2	0,7	0,1

Y	6	4	-1
P	0,2	0,7	0,1

Comment l'investisseur doit-il choisir ?

Correction 6. Examinons d'abord l'espérance mathématique (rendement moyen) :

$$E(X) = 11 \times 0,2 + 3 \times 0,7 + (-3) \times 0,1 = 4,0 \text{ (milliers de yuans),}$$

$$E(Y) = 6 \times 0,2 + 4 \times 0,7 + (-1) \times 0,1 = 3,9 \text{ (milliers de yuans).}$$

Du point de vue du rendement moyen, l'investissement immobilier est plus rentable, avec un rendement moyen supérieur de 0,1 millier de yuans à celui du commerce. Calculons maintenant leurs variances respectives :

$$\text{Var}(X) = (11 - 4)^2 \times 0,2 + (3 - 4)^2 \times 0,7 + (-3 - 4)^2 \times 0,1 = 15,4,$$

$$\text{Var}(Y) = (6 - 3,9)^2 \times 0,2 + (4 - 3,9)^2 \times 0,7 + (-1 - 3,9)^2 \times 0,1 = 3,29,$$

et leurs écarts types :

$$\sigma(X) = \sqrt{15,4} \approx 3,92, \quad \sigma(Y) = \sqrt{3,29} \approx 1,81.$$

Plus l'écart type (ou la variance) est grand, plus le rendement est volatil, donc plus le risque est élevé. Le choix d'investissement ne dépend pas seulement du rendement moyen, mais aussi du risque. Ici, du point de vue de l'écart type, le risque de l'investissement immobilier est plus du double de celui de l'investissement commercial. En considérant à la fois le rendement et le risque, l'investisseur ferait mieux de choisir le commerce, bien que le rendement moyen soit inférieur de 0,1 millier de yuans, le risque est plus de deux fois moindre.

2.2 Propriétés de la variance

Propriété 2.1. $\text{Var}(X) = E(X^2) - [E(X)]^2$.

Proof. Comme

$$\text{Var}(X) = E(X - E(X))^2 = E(X^2 - 2XE(X) + (E(X))^2),$$

par les propriétés de l'espérance mathématique (Propriété 2.2.3),

$$\text{Var}(X) = E(X^2) - 2E(X)E(X) + (E(X))^2 = E(X^2) - (E(X))^2.$$

□

En pratique, cette propriété est souvent plus utile que la définition $\text{Var}(X) = E(X - E(X))^2$ pour le calcul de la variance.

Propriété 2.2. La variance d'une constante est nulle, c'est-à-dire $\text{Var}(c) = 0$, où c est une constante.

Proof. Si c est une constante, alors

$$\text{Var}(c) = E(c - E(c))^2 = E(c - c)^2 = 0.$$

□

Propriété 2.3. Si a et b sont des constantes, alors $\text{Var}(aX + b) = a^2\text{Var}(X)$.

Proof. Comme a et b sont des constantes,

$$\text{Var}(aX + b) = E(aX + b - E(aX + b))^2 = E(a(X - E(X)))^2 = a^2\text{Var}(X).$$

□

De plus, de $\text{Var}(X) = E(X^2) - [E(X)]^2 \geq 0$, il est facile de voir que si $E(X^2) = 0$, alors $E(X) = 0$ et $\text{Var}(X) = 0$.

Exemple 2.3. Soit X le nombre de points obtenu en lançant un dé. Calculer $\text{Var}(X)$.

Correction 7.

$$\begin{aligned} E(X) &= \frac{1}{6}(1 + 2 + 3 + 4 + 5 + 6) = \frac{7}{2}, \\ E(X^2) &= \frac{1}{6}(1^2 + 2^2 + 3^2 + 4^2 + 5^2 + 6^2) = \frac{91}{6}, \\ \text{Var}(X) &= \frac{91}{6} - \left(\frac{7}{2}\right)^2 = \frac{91}{6} - \frac{49}{4} = \frac{35}{12} \approx 2,917. \end{aligned}$$

2.3 Inégalité de Chebyshev

Voici une inégalité fondamentale importante en théorie des probabilités.

Théorème 2.1 (Inégalité de Chebyshev). *Soit X une variable aléatoire dont l'espérance mathématique et la variance existent. Alors, pour toute constante $\epsilon > 0$,*

$$P(|X - E(X)| \geq \epsilon) \leq \frac{\text{Var}(X)}{\epsilon^2},$$

ou

$$P(|X - E(X)| < \epsilon) \geq 1 - \frac{\text{Var}(X)}{\epsilon^2}.$$

Proof. Supposons que X soit une variable aléatoire continue de fonction de densité $p(x)$. Notons $a = E(X)$. On a

$$P(|X - a| \geq \epsilon) = \int_{\{x: |x-a| \geq \epsilon\}} p(x) dx \leq \int_{\{x: |x-a| \geq \epsilon\}} \frac{(x-a)^2}{\epsilon^2} p(x) dx \leq \frac{1}{\epsilon^2} \int_{-\infty}^{\infty} (x-a)^2 p(x) dx = \frac{\text{Var}(X)}{\epsilon^2}.$$

Ainsi, est démontrée pour une variable aléatoire continue. La démonstration pour une variable aléatoire discrète est similaire. $\square$

En théorie des probabilités, l'événement $\{|X - E(X)| \geq \epsilon\}$ est appelé grand écart, et sa probabilité $P(|X - E(X)| \geq \epsilon)$ est appelée probabilité de grand écart. L'inégalité de Chebyshev donne une borne supérieure pour la probabilité de grand écart, cette borne étant proportionnelle à la variance ; plus la variance est grande, plus la borne supérieure est grande.

Le théorème suivant montre que si la variance est nulle, les valeurs de la variable aléatoire sont presque concentrées en un point.

3 Espérance mathématique d'une fonction d'un vecteur aléatoire multidimensionnel

Théorème 3.1. *Si la distribution du couple de variables aléatoires (X, Y) est donnée par la distribution jointe $P(X = x_i, Y = y_j)$ ou par la densité jointe $p(x, y)$, alors l'espérance mathématique de $Z = g(X, Y)$ est*

$$E(Z) = \begin{cases} \sum_i \sum_j g(x_i, y_j) P(X = x_i, Y = y_j), & \text{en discret,} \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) p(x, y) dx dy, & \text{en continu.} \end{cases}$$

On suppose que les espérances mathématiques mentionnées existent.

Il faut également souligner que dans le cas continu (et de manière analogue dans le cas discret) :

Lorsque $g(X, Y) = X$, on obtient l'espérance mathématique de X comme

$$\overbrace{E(X)}^{E(X)} = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xp(x, y) dx dy = \int_{-\infty}^{\infty} xp_X(x) dx.$$

Lorsque $g(X, Y) = (X - E(X))^2$, on obtient la variance de X comme

$$\begin{aligned} \text{Var}(X) &= E(X - E(X))^2 = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - E(X))^2 p(x, y) dx dy \\ &= \int_{-\infty}^{\infty} (x - E(X))^2 p_X(x) dx. \end{aligned}$$

On peut donner de manière analogue les formules de l'espérance mathématique et de la variance de Y .

Exemple 3.1. Soient X et Y deux points choisis au hasard sur un segment de longueur a . Trouver la longueur moyenne entre ces deux points.

Solution Comme X et Y suivent toutes deux une loi uniforme sur $(0, a)$, et que X et Y sont indépendants, la densité jointe de (X, Y) est

$$p(x, y) = \frac{1}{a^2}, \quad 0 < x < a, \quad 0 < y < a.$$

En utilisant le théorème, la longueur moyenne entre les deux points est

$$\begin{aligned} E(|X - Y|) &= \int_0^a \int_0^a |x - y| \frac{1}{a^2} dx dy \\ &= \frac{1}{a^2} \left\{ \int_0^a \int_0^x (x - y) dy dx + \int_0^a \int_x^a (y - x) dy dx \right\} \\ &= \frac{1}{a^2} \left\{ \int_0^a \left(x^2 - ax + \frac{a^2}{2} \right) dx \right\} = \frac{a}{3}. \end{aligned}$$

Notez que, bien que le théorème 3.4.1 permette d'éviter de trouver la distribution de la fonction de la variable aléatoire, dans certains cas, la somme ou l'intégrale impliquée est difficile à calculer.

4 Propriétés de calcul de l'espérance mathématique et de la variance

Au chapitre 2, nous avons donné quelques propriétés simples de l'espérance mathématique et de la variance. En utilisant le théorème 3.4.1, nous pouvons donner quelques propriétés de calcul de l'espérance mathématique et de la variance. Dans ce qui suit, on suppose que les espérances et variances concernées existent.

Propriété 4.1. Soit (X, Y) un couple de variables aléatoires. Alors

$$E(X + Y) = E(X) + E(Y).$$

Démonstration Supposons que (X, Y) est continu (la démonstration pour le cas discret est analogue). Soit $p(x, y)$ sa densité jointe. En posant $g(X, Y) = X + Y$, d'après le théorème, on obtient

$$\begin{aligned} E(X + Y) &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x + y)p(x, y)dx dy \\ &= \int_{-\infty}^{\infty} x \left[\int_{-\infty}^{\infty} p(x, y)dy \right] dx + \int_{-\infty}^{\infty} y \left[\int_{-\infty}^{\infty} p(x, y)dx \right] dy \\ &= \int_{-\infty}^{\infty} xp_X(x)dx + \int_{-\infty}^{\infty} yp_Y(y)dy \\ &= E(X) + E(Y). \end{aligned}$$

Cette propriété peut être simplement énoncée comme : l'espérance de la somme est égale à la somme des espérances. Cette propriété peut être étendue au cas d'un vecteur aléatoire de dimension n , c'est-à-dire

$$E(X_1 + X_2 + \dots + X_n) = E(X_1) + E(X_2) + \dots + E(X_n). \quad (3.4.3)$$

Propriété 4.2. Si les variables aléatoires X et Y sont indépendantes, alors

$$E(XY) = E(X)E(Y).$$

Démonstration Supposons que (X, Y) est continu (la démonstration pour le cas discret est analogue). Sa densité jointe est $p(x, y)$. Par indépendance de X et Y , on a $p(x, y) = p_X(x)p_Y(y)$. En posant $g(X, Y) = XY$, d'après le théorème 3.4.1, on obtient

$$E(XY) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xyp_X(x)p_Y(y)dx dy = \int_{-\infty}^{\infty} xp_X(x)dx \int_{-\infty}^{\infty} yp_Y(y)dy = E(X)E(Y).$$

Cette propriété peut être simplement énoncée comme : dans le cas indépendant, l'espérance mathématique du produit de variables aléatoires est égale au produit des espérances mathématiques.

la somme ou l'intégrale est difficile à calculer. Dans ce cas, on peut procéder en deux étapes : d'abord trouver la distribution de la fonction $Z = g(X_1, X_2, \dots, X_n)$, puis utiliser cette distribution pour trouver $E(Z)$, comme dans l'exemple suivant.

Exemple 4.1. Soient X_1 et X_2 deux variables aléatoires indépendantes et identiquement distribuées selon une loi exponentielle $Exp(\lambda)$. Trouver l'espérance mathématique de $Y = \max\{X_1, X_2\}$.

Solution nous avons déjà trouvé la densité de $Y = \max\{X_1, X_2\}$:

$$p_Y(y) = 2(1 - e^{-\lambda y})\lambda e^{-\lambda y}, \quad y > 0.$$

Alors l'espérance mathématique de $Y = \max\{X_1, X_2\}$ est

$$E[\max\{X_1, X_2\}] = \int_0^{\infty} 2\lambda y(1 - e^{-\lambda y})e^{-\lambda y}dy$$

$$\begin{aligned}
&= 2 \int_0^\infty y e^{-\lambda y} d(\lambda y) - \int_0^\infty y e^{-2\lambda y} d(2\lambda y) \\
&= \frac{2}{\lambda} \int_0^\infty u e^{-u} du - \frac{1}{2\lambda} \int_0^\infty v e^{-v} dv \\
&= \frac{2}{\lambda} \Gamma(2) - \frac{1}{2\lambda} \Gamma(2) = \frac{3}{2\lambda}.
\end{aligned}$$

5 Propriétés de calcul de l'espérance mathématique et de la variance

Dans ce qui suit, on suppose que les espérances et variances concernées existent.

Propriété 5.1. Soit (X, Y) un couple de variables aléatoires. Alors

$$E(X + Y) = E(X) + E(Y). \quad (3.4.2)$$

Démonstration Supposons que (X, Y) est continu (la démonstration pour le cas discret est analogue). Soit $p(x, y)$ sa densité jointe. En posant $g(X, Y) = X + Y$, d'après le théorème, on obtient

$$\begin{aligned}
E(X + Y) &= \int_{-\infty}^\infty \int_{-\infty}^\infty (x + y) p(x, y) dx dy \\
&= \int_{-\infty}^\infty x \left[\int_{-\infty}^\infty p(x, y) dy \right] dx + \int_{-\infty}^\infty y \left[\int_{-\infty}^\infty p(x, y) dx \right] dy \\
&= \int_{-\infty}^\infty x p_X(x) dx + \int_{-\infty}^\infty y p_Y(y) dy \\
&= E(X) + E(Y).
\end{aligned}$$

Cette propriété peut être simplement énoncée comme : l'espérance de la somme est égale à la somme des espérances. Cette propriété peut être étendue au cas d'un vecteur aléatoire de dimension n , c'est-à-dire

$$E(X_1 + X_2 + \cdots + X_n) = E(X_1) + E(X_2) + \cdots + E(X_n).$$

Propriété 5.2. Si les variables aléatoires X et Y sont indépendantes, alors

$$E(XY) = E(X)E(Y). \quad (3.4.4)$$

Démonstration Supposons que (X, Y) est continu (la démonstration pour le cas discret est analogue). Sa densité jointe est $p(x, y)$. Par indépendance de X et Y , on a $p(x, y) = p_X(x)p_Y(y)$. En posant $g(X, Y) = XY$, d'après le théorème 3.4.1, on obtient

$$E(XY) = \int_{-\infty}^\infty \int_{-\infty}^\infty xy p_X(x) p_Y(y) dx dy = \int_{-\infty}^\infty x p_X(x) dx \int_{-\infty}^\infty y p_Y(y) dy = E(X)E(Y).$$

Cette propriété peut être simplement énoncée comme : dans le cas indépendant, l'espérance mathématique du produit de variables aléatoires est égale au produit

des espérances mathématiques. Cette propriété peut être étendue au cas d'un vecteur aléatoire de dimension n , c'est-à-dire si $X_1, X_2, \dots, X_n$ sont mutuellement indépendants, alors

$$E(X_1 X_2 \dots X_n) = E(X_1) E(X_2) \dots E(X_n).$$

Propriété 5.3. Si les variables aléatoires X et Y sont indépendantes, alors

$$\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y).$$

Démonstration D'après les propriétés, on a

$$\begin{aligned} \text{Var}(X \pm Y) &= E(X \pm Y - E(X \pm Y))^2 = E((X - E(X)) \pm (Y - E(Y)))^2 \\ &= \text{Var}(X) + \text{Var}(Y) \pm 2E(X - E(X))(Y - E(Y)), \end{aligned}$$

le dernier terme est nul à cause de l'indépendance, ce qui démontre la propriété.

Cette propriété montre que la variance de la somme algébrique de variables indépendantes est égale à la somme des variances. Mais il faut noter que cette propriété ne tient pas pour l'écart type, c'est-à-dire $\sigma(X \pm Y) \neq \sigma(X) + \sigma(Y)$. L'écart type de la somme algébrique de variables indépendantes ne peut être obtenu que par "d'abord la variance, puis l'écart type", c'est-à-dire

$$\sigma(X \pm Y) = \sqrt{\text{Var}(X) + \text{Var}(Y)}$$

Cette propriété peut être étendue au cas d'un vecteur aléatoire de dimension n , c'est-à-dire si $X_1, X_2, \dots, X_n$ sont mutuellement indépendants, alors

$$\text{Var}(X_1 \pm X_2 \pm \dots \pm X_n) = \text{Var}(X_1) + \text{Var}(X_2) + \dots + \text{Var}(X_n). \quad (3.4.6)$$

Ceci montre que, pour des variables aléatoires indépendantes, qu'elles soient ajoutées ou soustraites, leur variance s'accumule toujours, elle ne fait qu'augmenter, jamais diminuer.

En particulier, la variance de la moyenne arithmétique de n variables aléatoires indépendantes et identiquement distribuées (de variance σ^2) $X_1, X_2, \dots, X_n$ est

$$\text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{\sigma^2}{n}.$$

Ceci indique que, lors de la mesure d'une grandeur physique μ (comme une pesée), on peut utiliser la moyenne de n mesures indépendantes répétées pour améliorer la précision de la mesure.

Exemple 5.1. Soient des variables aléatoires indépendantes X_1, X_2, X_3 avec $X_1 \sim U(0, 6)$, $X_2 \sim N(1, 3)$, $X_3 \sim E$. Trouver l'espérance mathématique, la variance et l'écart type de $Y = X_1 - 2X_2 + 3X_3$.

Solution D'après les propriétés de calcul de l'espérance et de la variance, on obtient

$$E(X_1 - 2X_2 + 3X_3) = 3 - 2 \times 1 + 3 \times \frac{1}{3} = 2.$$

$$\text{Var}(X_1 - 2X_2 + 3X_3) = \frac{6^2}{12} + 4 \times 3 + 9 \times \frac{1}{9} = 16.$$

$$\sigma(X_1 - 2X_2 + 3X_3) = \sqrt{\text{Var}(X_1 - 2X_2 + 3X_3)} = \sqrt{16} = 4.$$

Écrire une variable aléatoire comme la somme de plusieurs variables aléatoires, puis utiliser les propriétés de l'espérance mathématique pour effectuer les calculs peut simplifier des calculs complexes, comme le montre l'exemple suivant.

Exemple 5.2. Une urne contient m boules de couleurs toutes différentes. On prélève une boule au hasard à chaque tirage, avec remise, et on effectue n tirages. Soit X le nombre de couleurs différentes obtenues dans les n tirages. Trouver $E(X)$.

Solution Il est difficile d'écrire directement la distribution de X car, si la boule de couleur i a été tirée, elle peut l'avoir été une fois, deux fois, ..., n fois, ce qui est complexe. La probabilité de l'événement contraire "la boule de couleur i n'a jamais été tirée en n tirages" est facile à écrire :

$$P(\text{la boule de couleur } i \text{ n'est jamais tirée en } n \text{ tirages}) = \left(1 - \frac{1}{m}\right)^n.$$

Pour cela, définissons

$$X_i = \begin{cases} 1, & \text{la boule de couleur } i \text{ est tirée au moins une fois en } n \text{ tirages,} \\ 0, & \text{la boule de couleur } i \text{ n'est jamais tirée en } n \text{ tirages,} \end{cases} \quad i = 1, 2, \dots, m.$$

Ces X_i sont des compteurs indiquant si la boule de couleur i a été tirée ou non, et X est le nombre total de couleurs différentes tirées, donc $X = \sum_{i=1}^m X_i$. Comme

$$P(X_i = 0) = \left(1 - \frac{1}{m}\right)^n,$$

on a

$$E(X_i) = P(X_i = 1) = 1 - P(X_i = 0) = 1 - \left(1 - \frac{1}{m}\right)^n,$$

donc

$$E(X) = mE(X_i) = m \left[1 - \left(1 - \frac{1}{m}\right)^n\right].$$

Par exemple, pour $m = n = 6$,

$$E(X) = 6 \left[1 - \left(\frac{5}{6}\right)^6\right] = 3.99 \approx 4,$$

ce qui montre que pour 6 boules de couleurs différentes dans l'urne, en effectuant 6 tirages avec remise, on n'obtient en moyenne que 4 couleurs différentes.

Exemple 5.3. Soit une variable aléatoire $X \sim b(n, p)$. Trouver son espérance mathématique et sa variance.

Solution L'espérance et la variance de la loi binomiale ont été trouvées au chapitre 2, mais le calcul était complexe. Utilisons ici une autre méthode plus simple. Soient $X_1, X_2, \dots, X_n$ indépendantes, chaque X_i suivant une loi de Bernoulli $b(1, p)$. Alors

$$E(X_i) = p, \quad \text{Var}(X_i) = p(1 - p),$$

et $X = X_1 + X_2 + \dots + X_n \sim b(n, p)$. D'où

$$E(X) = E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n E(X_i) = np.$$

$$\text{Var}(X) = \text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i) = \sum_{i=1}^n p(1 - p) = np(1 - p).$$

Par exemple, pour 72 lancers de dé, le nombre d'apparitions du 6, $X \sim b(72, 1/6)$, a pour moyenne $E(X) = 72/6 = 12$, pour variance $\text{Var}(X) = (72/6) \times (5/6) = 10$, et pour écart type $\sigma(X) = \sqrt{10} = 3.16$.

6 Covariance

La distribution jointe bidimensionnelle contient non seulement les distributions marginales de chaque composante, mais aussi des informations sur la relation de dépendance entre les deux composantes. Une caractéristique décrivant ce degré d'association est la covariance, définie comme suit :

Définition 6.1. Soit (X, Y) un couple de variables aléatoires. Si $E[(X - E(X))(Y - E(Y))]$ existe, on appelle cette espérance mathématique la covariance de X et Y , ou le moment centré croisé de X et Y , et on la note

$$\text{Cov}(X, Y) = E[(X - E(X))(Y - E(Y))].$$

En particulier, $\text{Cov}(X, X) = \text{Var}(X)$.

De la définition de la covariance, on voit qu'il s'agit de l'espérance du produit de l'écart $X - E(X)$ de X et de l'écart $Y - E(Y)$ de Y .

Comme les écarts peuvent être positifs ou négatifs, la covariance peut être positive, négative ou nulle, avec les interprétations suivantes :

- Lorsque $\text{Cov}(X, Y) > 0$, on dit que X et Y sont positivement corrélés. Les deux écarts $(X - E(X))$ et $(Y - E(Y))$ ont tendance à augmenter ou diminuer simultanément. Comme $E(X)$ et $E(Y)$ sont des constantes, cela équivaut à dire que X et Y ont tendance à augmenter ou diminuer ensemble. C'est le sens de la corrélation positive.
- Lorsque $\text{Cov}(X, Y) < 0$, on dit que X et Y sont négativement corrélés. Alors, quand X augmente, Y a tendance à diminuer, ou quand Y augmente, X a tendance à diminuer. C'est le sens de la corrélation négative.

- Lorsque $\text{Cov}(X, Y) = 0$, on dit que X et Y sont non corrélés. Cela peut provenir de deux types de situations : l'une où les valeurs de X et Y sont sans aucune relation, l'autre où il existe une relation non linéaire entre X et Y .

La propriété suivante est très utile pour le calcul de la covariance.

Propriété 6.1. $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$.

Démonstration Par définition de la covariance et par les propriétés de l'espérance mathématique, on a

$$\begin{aligned}\text{Cov}(X, Y) &= E[XY - XE(Y) - YE(X) + E(X)E(Y)] \\ &= E(XY) - E(X)E(Y).\end{aligned}$$

Nous utilisons maintenant la propriété suivante pour illustrer que "non corrélé" est une notion plus faible qu'"indépendant".

Propriété 6.2. Si les variables aléatoires X et Y sont indépendantes, alors $\text{Cov}(X, Y) = 0$. La réciproque est fausse.

Démonstration En effet, dans le cas indépendant, on a $E(XY) = E(X)E(Y)$, et la covariance est nulle. La réciproque est fausse, comme le montre le contre-exemple suivant.

Exemple 6.1. Soit une variable aléatoire $X \sim N(0, \sigma^2)$, et posons $Y = X^2$. Alors X et Y ne sont pas indépendants. La covariance de X et Y est

$$\text{Cov}(X, Y) = \text{Cov}(X, X^2) = E(X \cdot X^2) - E(X)E(X^2) = 0.$$

La dernière égalité vient du fait que tous les moments impairs de la loi normale $N(0, \sigma^2)$ sont nuls, c'est-à-dire $E(X) = E(X^3) = 0$.

Cet exemple montre que "indépendant" implique "non corrélé", mais "non corrélé" n'implique pas forcément "indépendant". L'indépendance est une condition plus forte, la non-corrélation est plus faible. L'indépendance est définie par la distribution, tandis que la non-corrélation n'est définie que par des moments. Il faut bien reconnaître la différence entre les deux.

On peut remarquer que la propriété sur l'espérance mathématique : si X et Y sont indépendants, alors $E(XY) = E(X)E(Y)$, ne peut pas être affaiblie en remplaçant "indépendant" par "non corrélé".

L'introduction de la covariance permet de compléter le calcul de la variance d'une somme de variables aléatoires, comme le montre la propriété suivante.

Propriété 6.3. Pour tout couple de variables aléatoires (X, Y) , on a

$$\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y) \pm 2 \text{Cov}(X, Y).$$

Démonstration Par définition de la variance,

$$\begin{aligned}\text{Var}(X \pm Y) &= E[(X \pm Y) - E(X \pm Y)]^2 \\ &= E[(X - E(X))^2 \pm [Y - E(Y)]^2] \\ &= E[(X - E(X))^2 + [Y - E(Y)]^2 \pm 2[X - E(X)][Y - E(Y)]] \\ &= \text{Var}(X) + \text{Var}(Y) \pm 2 \text{Cov}(X, Y).\end{aligned}$$

Cette propriété montre que, dans le cas où X et Y sont corrélés, la variance de la somme n'est pas égale à la somme des variances. Une corrélation positive entre X et Y augmente la variance de la somme, une corrélation négative la diminue. Dans le cas où X et Y sont non corrélés, la variance de la somme est égale à la somme des variances.

Ceci permet de modifier la propriété sur la variance comme suit :

La propriété peut également être étendue au cas de plus de deux variables aléatoires : pour n variables aléatoires $X_1, X_2, \dots, X_n$, on a

$$\text{Var} \left(\sum_{i=1}^n X_i \right) = \sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i=1}^n \sum_{j=1}^{i-1} \text{Cov}(X_i, X_j).$$

Pour le calcul de la covariance, on dispose également des quatre propriétés utiles suivantes.

Propriété 6.4. Le calcul de la covariance $\text{Cov}(X, Y)$ est indépendant de l'ordre de X et Y , c'est-à-dire

$$\text{Cov}(X, Y) = \text{Cov}(Y, X).$$

Démonstration Cela découle directement de la définition de la covariance.

Propriété 6.5. La covariance d'une variable aléatoire quelconque X avec une constante a est nulle, c'est-à-dire

$$\text{Cov}(X, a) = 0.$$

Démonstration Il suffit de calculer avec la définition de la covariance.

Propriété 6.6. Pour toutes constantes a, b , on a

$$\text{Cov}(aX, bY) = ab \text{Cov}(X, Y).$$

Démonstration Par définition de la covariance,

$$\text{Cov}(aX, bY) = E[(aX - E(aX))(bY - E(bY))].$$

En factorisant a et b , on obtient $ab \text{Cov}(X, Y)$.

Propriété 6.7. Soient X, Y, Z trois variables aléatoires quelconques. Alors

$$\text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z).$$

Démonstration D'après la propriété 3.4.4 de la covariance,

$$\begin{aligned} \text{Cov}(X + Y, Z) &= E[(X + Y)Z] - E(X + Y)E(Z) \\ &= E(XZ) + E(YZ) - E(X)E(Z) - E(Y)E(Z) \\ &= [E(XZ) - E(X)E(Z)] + [E(YZ) - E(Y)E(Z)] \\ &= \text{Cov}(X, Z) + \text{Cov}(Y, Z). \end{aligned}$$

Exemple 6.2. Soit un couple de variables aléatoires (X, Y) de densité jointe

$$p(x, y) = 3x, \quad 0 < y < x < 1.$$

Trouver $\text{Cov}(X, Y)$.

Solution En utilisant la formule de calcul de la covariance, nous devons d'abord calculer $E(X), E(Y), E(XY)$. On les obtient directement à partir de $p(x, y)$, en faisant attention aux bornes d'intégration :

$$E(X) = \int_0^1 \int_0^x x \cdot 3x dy dx = \int_0^1 3x^3 dx = \frac{3}{4}.$$

$$E(Y) = \int_0^1 \int_0^x y \cdot 3x dy dx = \int_0^1 \frac{3x^3}{2} dx = \frac{3}{8}.$$

$$E(XY) = \int_0^1 \int_0^x xy \cdot 3x dy dx = \int_0^1 \frac{3x^4}{2} dx = \frac{3}{10}.$$

Donc

$$\text{Cov}(X, Y) = \frac{3}{10} - \frac{3}{4} \times \frac{3}{8} = \frac{3}{160} > 0.$$

On peut en conclure que X et Y ne sont pas indépendants.

Exemple 6.3. Soit un couple de variables aléatoires (X, Y) de densité jointe

$$p(x, y) = \frac{1}{3}(x + y), \quad 0 < x < 1, \quad 0 < y < 2.$$

Trouver $\text{Var}(2X - 3Y + 8)$.

Solution Comme

$$\begin{aligned} \text{Var}(2X - 3Y + 8) &= \text{Var}(2X) + \text{Var}(3Y) - 2\text{Cov}(2X, 3Y) \\ &= 4\text{Var}(X) + 9\text{Var}(Y) - 12\text{Cov}(X, Y), \end{aligned}$$

nous devons d'abord calculer $E(X), E(X^2), E(Y), E(Y^2), E(XY)$. Pour cela, calculons d'abord les densités marginales.

$$p_X(x) = \int_0^2 \frac{1}{3}(x + y) dy = \frac{2}{3}(x + 1), \quad 0 < x < 1,$$

$$p_Y(y) = \int_0^1 \frac{1}{3}(x + y) dx = \frac{1}{3}\left(\frac{1}{2} + y\right), \quad 0 < y < 2.$$

Calculons ensuite les moments d'ordre 1 et 2.

$$E(X) = \int_0^1 \frac{2}{3}x(x + 1) dx = \frac{5}{9},$$

$$E(X^2) = \int_0^1 \frac{2}{3}x^2(x + 1) dx = \frac{7}{18},$$

$$E(Y) = \int_0^2 \frac{1}{3}y\left(\frac{1}{2} + y\right)dy = \frac{11}{9},$$

$$E(Y^2) = \int_0^2 \frac{1}{3}y^2\left(\frac{1}{2} + y\right)dy = \frac{16}{9}.$$

On en déduit

$$\text{Var}(X) = \frac{7}{18} - \left(\frac{5}{9}\right)^2 = \frac{13}{162}, \quad \text{Var}(Y) = \frac{16}{9} - \left(\frac{11}{9}\right)^2 = \frac{23}{81}.$$

Enfin, il faut calculer $E(XY)$ à partir de la densité jointe.

$$E(XY) = \frac{1}{3} \int_0^1 \int_0^2 xy(x+y)dydx = \frac{1}{3} \int_0^1 \left(2x^2 + \frac{8}{3}x\right)dx = \frac{2}{3}.$$

On obtient alors la covariance

$$\text{Cov}(X, Y) = \frac{2}{3} - \frac{5}{9} \times \frac{11}{9} = -\frac{1}{81}.$$

En substituant, on trouve

$$\text{Var}(2X - 3Y + 8) = 4 \times \frac{13}{162} + 9 \times \frac{23}{81} - 12 \times \left(-\frac{1}{81}\right) = \frac{245}{81}.$$

7 Coefficient de corrélation

La covariance $\text{Cov}(X, Y)$ est une grandeur dimensionnée. Par exemple, si X représente la taille d'une personne en mètres (m) et Y son poids en kilogrammes (kg), alors $\text{Cov}(X, Y)$ a la dimension (m · kg). Pour éliminer l'influence des dimensions, on divise la covariance par une grandeur de même dimension, ce qui donne un nouveau concept : le coefficient de corrélation, défini comme suit.

Définition 7.1. Soit (X, Y) un couple de variables aléatoires avec $\text{Var}(X) = \sigma_X^2 > 0$ et $\text{Var}(Y) = \sigma_Y^2 > 0$. On appelle

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)}} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

le coefficient de corrélation (linéaire) de X et Y .

D'après cette définition, le coefficient de corrélation $\text{Corr}(X, Y)$ a le même signe que la covariance $\text{Cov}(X, Y)$, c'est-à-dire positif, négatif ou nul. Ainsi, le signe du coefficient de corrélation indique également une corrélation positive, négative ou une non-corrélation entre X et Y .

Une autre interprétation du coefficient de corrélation est qu'il s'agit de la covariance des variables standardisées correspondantes. Si l'on note μ_X, μ_Y les espérances mathématiques de X et Y , leurs variables standardisées sont

$$X^\star = \frac{X - \mu_X}{\sigma_X}, \quad Y^\star = \frac{Y - \mu_Y}{\sigma_Y},$$

et l'on a

$$\text{Cov}(X^*, Y^*) = \text{Cov}\left(\frac{X - \mu_X}{\sigma_X}, \frac{Y - \mu_Y}{\sigma_Y}\right) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \text{Corr}(X, Y).$$

Exemple 7.1. Pour une loi normale bidimensionnelle $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, le coefficient de corrélation est ρ .

Solution Calculons d'abord $\text{Cov}(X, Y)$.

$$\begin{aligned} \text{Cov}(X, Y) &= E[(X - E(X))(Y - E(Y))] \\ &= \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mu_1)(y - \mu_2) \cdot \\ &\quad \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\frac{(x - \mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x - \mu_1)(y - \mu_2)}{\sigma_1\sigma_2} + \frac{(y - \mu_2)^2}{\sigma_2^2}\right]\right\} dx dy. \end{aligned}$$

Transformons d'abord l'expression entre crochets en

$$\left(\frac{x - \mu_1}{\sigma_1} - \rho\frac{y - \mu_2}{\sigma_2}\right)^2 + \left(\sqrt{1-\rho^2}\frac{y - \mu_2}{\sigma_2}\right)^2,$$

puis effectuons le changement de variables

$$u = \frac{1}{\sqrt{1-\rho^2}}\left(\frac{x - \mu_1}{\sigma_1} - \rho\frac{y - \mu_2}{\sigma_2}\right), \quad v = \frac{y - \mu_2}{\sigma_2}.$$

Alors

$$\begin{aligned} &\begin{cases} x - \mu_1 = \sigma_1(u\sqrt{1-\rho^2} + \rho v), \\ y - \mu_2 = \sigma_2 v, \end{cases} \\ &dx dy = |J| du dv = \sigma_1 \sigma_2 \sqrt{1-\rho^2} du dv. \end{aligned}$$

On obtient ainsi

$$\text{Cov}(X, Y) = \frac{\sigma_1 \sigma_2}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (uv\sqrt{1-\rho^2} + \rho v^2) \exp\left\{-\frac{1}{2}(u^2 + v^2)\right\} du dv.$$

L'intégrale de droite peut être décomposée en deux intégrales, dont

$$\begin{aligned} &\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} uv \exp\left\{-\frac{1}{2}(u^2 + v^2)\right\} du dv = 0, \\ &\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} v^2 \exp\left\{-\frac{1}{2}(u^2 + v^2)\right\} du dv = 2\pi. \end{aligned}$$

Par conséquent,

$$\text{Cov}(X, Y) = \frac{\sigma_1 \sigma_2}{2\pi} \cdot \rho \cdot 2\pi = \rho \sigma_1 \sigma_2,$$

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_1 \sigma_2} = \rho.$$

Pour étudier les propriétés du coefficient de corrélation, nous avons besoin du lemme suivant.

Lemme 3.4.1 (Inégalité de Schwarz) Pour tout couple de variables aléatoires (X, Y) dont les variances existent, en notant $\sigma_X^2 = \text{Var}(X)$ et $\sigma_Y^2 = \text{Var}(Y)$, on a

$$[\text{Cov}(X, Y)]^2 \leq \sigma_X^2 \sigma_Y^2.$$

Démonstration Supposons $\sigma_X^2 > 0$ (car si $\sigma_X^2 = 0$, alors X est presque sûrement constant, sa covariance avec Y est nulle, et les deux membres sont nuls, la conclusion est vérifiée). Si $\sigma_X^2 > 0$, considérons la fonction quadratique en t suivante :

$$E[t(X - E(X)) + (Y - E(Y))]^2 = t^2 \sigma_X^2 + 2t \text{Cov}(X, Y) + \sigma_Y^2.$$

Comme cette expression quadratique est non négative et que le coefficient de t^2 est $\sigma_X^2 > 0$, son discriminant est inférieur ou égal à zéro, c'est-à-dire

$$[2\text{Cov}(X, Y)]^2 - 4\sigma_X^2 \sigma_Y^2 \leq 0.$$

En réarrangeant, on obtient l'inégalité de Schwarz.

En utilisant l'inégalité de Schwarz, on obtient immédiatement une propriété importante du coefficient de corrélation.

Propriété 7.1. $-1 \leq \text{Corr}(X, Y) \leq 1$, ou $|\text{Corr}(X, Y)| \leq 1$.

Cette propriété montre que le coefficient de corrélation est compris entre -1 et 1. Lorsque le coefficient de corrélation vaut ± 1 , on a une autre propriété importante.

Propriété 7.2. $\text{Corr}(X, Y) = \pm 1$ si et seulement si X et Y sont presque sûrement liés par une relation linéaire, c'est-à-dire qu'il existe des constantes $a(\neq 0)$ et b telles que

$$P(Y = aX + b) = 1.$$

Lorsque $\text{Corr}(X, Y) = 1$, on a $a > 0$; lorsque $\text{Corr}(X, Y) = -1$, on a $a < 0$.

Démonstration (Suffisance) Si $Y = aX + b$ (ou $X = cY + d$), alors

$$\text{Var}(Y) = a^2 \text{Var}(X), \quad \text{Cov}(X, Y) = a \text{Cov}(X, X) = a \text{Var}(X).$$

En substituant dans la définition du coefficient de corrélation, on obtient

$$\text{Corr}(X, Y) = \frac{a \text{Var}(X)}{\sqrt{\text{Var}(X)} \sqrt{a^2 \text{Var}(X)}} = \frac{a}{|a|} = \pm 1.$$

(Nécessité) Comme

$$\text{Var}\left(\frac{X}{\sigma_X} \pm \frac{Y}{\sigma_Y}\right) = 2[1 \pm \text{Corr}(X, Y)],$$

lorsque $\text{Corr}(X, Y) = 1$, on a

$$\text{Var}\left(\frac{X}{\sigma_X} - \frac{Y}{\sigma_Y}\right) = 0,$$

d'où

$$P\left(\frac{X}{\sigma_X} - \frac{Y}{\sigma_Y} = c\right) = 1,$$

ou

$$P\left(Y = \frac{\sigma_Y}{\sigma_X}X - c\sigma_Y\right) = 1.$$

Ceci démontre que, lorsque $\text{Corr}(X, Y) = 1$, Y est presque sûrement une fonction linéaire croissante de X .

Lorsque $\text{Corr}(X, Y) = -1$, on a

$$\text{Var}\left(\frac{X}{\sigma_X} + \frac{Y}{\sigma_Y}\right) = 0,$$

d'où

$$P\left(\frac{X}{\sigma_X} + \frac{Y}{\sigma_Y} = c\right) = 1,$$

ou

$$P\left(Y = -\frac{\sigma_Y}{\sigma_X}X + c\sigma_Y\right) = 1.$$

Ceci démontre que, lorsque $\text{Corr}(X, Y) = -1$, Y est presque sûrement une fonction linéaire décroissante de X .

Plusieurs remarques sur cette propriété :

- Le coefficient de corrélation $\text{Corr}(X, Y)$ mesure l'intensité de la relation linéaire entre X et Y . C'est pourquoi on l'appelle souvent "coefficient de corrélation linéaire".
- Si $\text{Corr}(X, Y) = 0$, on dit que X et Y sont non corrélés. La non-corrélation signifie qu'il n'y a pas de relation linéaire entre X et Y , mais il peut exister d'autres relations fonctionnelles, comme une relation quadratique, logarithmique, etc.
- Si $\text{Corr}(X, Y) = 1$, on dit que X et Y sont totalement positivement corrélés ; si $\text{Corr}(X, Y) = -1$, on dit qu'ils sont totalement négativement corrélés.
- Si $0 < |\text{Corr}(X, Y)| < 1$, on dit que X et Y ont un certain degré de relation linéaire. Plus $\text{Corr}(X, Y)$ est proche de 1, plus la corrélation linéaire est forte ; plus il est proche de 0, plus la corrélation linéaire est faible. La covariance ne permet pas de voir cela. Si la covariance est très petite, mais que les deux écarts types σ_X et σ_Y sont également très petits, leur rapport peut ne pas être petit, comme le montre l'exemple ci-dessous.

Exemple 7.2. On donne la densité jointe d'un couple aléatoire (X, Y) :

$$p(x, y) = \frac{8}{3}, \quad 0 < x - y < 0.5, \quad 0 < x < 1, \quad 0 < y < 1; = 0, \text{ sinon}$$

Trouver le coefficient de corrélation $\text{Corr}(X, Y)$.

Solution Calculons d'abord les densités marginales.

Pour $0 < x < 0.5$,

$$p_X(x) = \int_{-\infty}^{\infty} p(x, y) dy = \int_0^x \frac{8}{3} dy = \frac{8}{3}x,$$

Pour $0.5 < x < 1$,

$$p_X(x) = \int_{-\infty}^{\infty} p(x, y) dy = \int_{x-0.5}^x \frac{8}{3} dy = \frac{4}{3},$$

Donc la densité marginale de X est

$$p_X(x) = \begin{cases} \frac{8}{3}x, & 0 < x < 0.5, \\ \frac{4}{3}, & 0.5 \leq x < 1. \end{cases}$$

Pour $0 < y < 0.5$,

$$p_Y(y) = \int_{-\infty}^{\infty} p(x, y) dx = \int_y^{y+0.5} \frac{8}{3} dx = \frac{4}{3},$$

Pour $0.5 < y < 1$,

$$p_Y(y) = \int_{-\infty}^{\infty} p(x, y) dx = \int_y^1 \frac{8}{3} dx = \frac{8}{3}(1 - y),$$

Donc la densité marginale de Y est

$$p_Y(y) = \begin{cases} \frac{4}{3}, & 0 < y < 0.5, \\ \frac{8}{3}(1 - y), & 0.5 \leq y < 1. \end{cases}$$

Calculons ensuite les moments d'ordre 1 et 2 de X et Y .

$$E(X) = \int_0^{0.5} \frac{8}{3}x^2 dx + \int_{0.5}^1 \frac{4}{3}x dx = \frac{11}{18},$$

$$E(Y) = \int_0^{0.5} \frac{4}{3}y dy + \int_{0.5}^1 \frac{8}{3}y(1 - y) dy = \frac{7}{18},$$

$$E(X^2) = \int_0^{0.5} \frac{8}{3}x^3 dx + \int_{0.5}^1 \frac{4}{3}x^2 dx = \frac{31}{72},$$

$$E(Y^2) = \int_0^{0.5} \frac{4}{3}y^2 dy + \int_{0.5}^1 \frac{8}{3}y^2(1 - y) dy = \frac{5}{24}.$$

On en déduit les variances

$$\text{Var}(X) = \frac{31}{72} - \left(\frac{11}{18}\right)^2 = \frac{37}{648},$$

$$\text{Var}(Y) = \frac{5}{24} - \left(\frac{7}{18}\right)^2 = \frac{37}{648}.$$

Enfin, il faut calculer $E(XY)$ à partir de la densité jointe.

$$\begin{aligned}
E(XY) &= \int_0^{0.5} \int_0^x \frac{8}{3} xy dy dx + \int_{0.5}^1 \int_{x-0.5}^x \frac{8}{3} xy dy dx \\
&= \int_0^{0.5} \frac{4}{3} x^3 dx + \int_{0.5}^1 \frac{4}{3} x \left(x - \frac{1}{4} \right) dx \\
&= \frac{1}{48} + \frac{7}{18} - \frac{1}{8} = \frac{41}{144}.
\end{aligned}$$

On obtient finalement la covariance et le coefficient de corrélation :

$$\text{Cov}(X, Y) = \frac{41}{144} - \frac{11}{18} \times \frac{7}{18} = \frac{61}{1296} = 0.0471.$$

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{61}{1296} \times \frac{648}{37} = \frac{61}{74} = 0.8243.$$

Ici, la covariance est très petite, mais le coefficient de corrélation ne l'est pas.

Dans l'exemple ci-dessus, le coefficient de corrélation $\text{Corr}(X, Y) = 0.8243$ indique une corrélation positive assez forte entre X et Y ; mais la covariance correspondante $\text{Cov}(X, Y) = 0.0471$ semble très faible, presque négligeable. Cette illusion est due au fait qu'on n'a pas tenu compte des écarts types. Si les deux écarts types sont très petits, même une covariance petite peut correspondre à un coefficient de corrélation élevé. Ainsi, le coefficient de corrélation, construit à partir de la covariance, est une caractéristique de corrélation plus importante.

En général, l'indépendance implique la non-corrélation, mais la non-corrélation n'implique pas l'indépendance. Il y a cependant des exceptions, comme le montre la propriété suivante.

Propriété 7.3. Dans le cas d'une loi normale bidimensionnelle $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, la non-corrélation et l'indépendance sont équivalentes.

Démonstration D'après l'exemple, le coefficient de corrélation d'une loi normale bidimensionnelle $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ est ρ . Il suffit donc de montrer que $\rho = 0$ est équivalent à l'indépendance. Les lois marginales sont $N(\mu_1, \sigma_1^2)$ et $N(\mu_2, \sigma_2^2)$. Notons $p(x, y)$ la densité jointe, $p_X(x)$ et $p_Y(y)$ les densités marginales.

Lorsque $\rho = 0$, on peut voir directement dans l'expression de la densité normale que

$$p(x, y) = p_X(x)p_Y(y),$$

c'est-à-dire que X et Y sont indépendants.

Réciproquement, si X et Y sont indépendants, alors ils sont non corrélés, donc $\rho = 0$. La conclusion est démontrée.

Exemple 7.3 (Risque d'un portefeuille d'investissement). Supposons qu'un capital total, noté 1 (pouvant être 10 000 yuans, 1 million de yuans, etc.), doive être investi dans deux titres, A et B. On investit une fraction x_1 du capital dans le titre A, et le reste $1 - x_1 = x_2$ dans le titre B. Le couple (x_1, x_2) forme un portefeuille. Soit X le rendement du titre A et Y celui du titre B, ce sont des variables aléatoires. Si les espérances (représentant le rendement moyen) de X et Y sont respectivement μ_1 et μ_2 , leurs variances (représentant le risque) sont σ_1^2 et σ_2^2 , et leur coefficient de corrélation

est ρ . Trouver le rendement moyen et le risque (variance) de ce portefeuille, ainsi que la valeur de x_1 qui minimise le risque.

Solution Le rendement du portefeuille est

$$Z = x_1X + x_2Y = x_1X + (1 - x_1)Y,$$

donc son rendement moyen est

$$E(Z) = x_1E(X) + (1 - x_1)E(Y) = x_1\mu_1 + (1 - x_1)\mu_2.$$

Le risque (variance) du portefeuille est

$$\begin{aligned} \text{Var}(Z) &= \text{Var}[x_1X + (1 - x_1)Y] \\ &= x_1^2\text{Var}(X) + (1 - x_1)^2\text{Var}(Y) + 2x_1(1 - x_1)\text{Cov}(X, Y) \\ &= x_1^2\sigma_1^2 + (1 - x_1)^2\sigma_2^2 + 2x_1(1 - x_1)\rho\sigma_1\sigma_2. \end{aligned}$$

Pour minimiser le risque, on cherche le minimum de $\text{Var}(Z)$ en fonction de x_1 . Pour cela, on pose

$$\frac{d(\text{Var}(Z))}{dx_1} = 2x_1\sigma_1^2 - 2(1 - x_1)\sigma_2^2 + 2\rho\sigma_1\sigma_2 - 4x_1\rho\sigma_1\sigma_2 = 0,$$

d'où on tire

$$x_1^* = \frac{\sigma_2^2 - \rho\sigma_1\sigma_2}{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}.$$

Cette valeur ne dépend ni de μ_1 ni de μ_2 . Comme le coefficient de x_1^2 dans $\text{Var}(Z)$ est positif, ce x_1^* minimise bien le risque.

Par exemple, si $\sigma_1^2 = 0.3$, $\sigma_2^2 = 0.5$, $\rho = 0.4$, alors

$$x_1^* = \frac{0.5 - 0.4\sqrt{0.3 \times 0.5}}{0.3 + 0.5 - 2 \times 0.4\sqrt{0.3 \times 0.5}} = 0.704.$$

Cela signifie qu'il faut investir environ 70% du capital dans le titre A et les 30% restants dans le titre B pour minimiser le risque du portefeuille.

8 Vecteur d'espérance mathématique et matrice de covariance d'un vecteur aléatoire

Nous donnons ci-dessous, sous forme matricielle, l'espérance mathématique et la variance d'un vecteur aléatoire de dimension n .

Définition 8.1. Soit $X = (X_1, X_2, \dots, X_n)'$ un vecteur aléatoire de dimension n . Si l'espérance mathématique de chaque composante existe, on appelle

$$E(X) = (E(X_1), E(X_2), \dots, E(X_n))'$$

le vecteur d'espérance mathématique du vecteur aléatoire X , ou simplement l'espérance de X . On appelle

$$E[(X - E(X))(X - E(X))']$$

la matrice de variance-covariance de ce vecteur aléatoire, ou simplement matrice de covariance, notée $\text{Cov}(X)$.

Ainsi, l'espérance mathématique d'un vecteur aléatoire de dimension n est le vecteur des espérances de ses composantes. Sa variance est la matrice formée par les variances et covariances des composantes : les éléments diagonaux sont les variances, les éléments non diagonaux sont les covariances.

Donnons ci-dessous une propriété importante de la matrice de covariance.

Théorème 8.1. *La matrice de covariance $\text{Cov}(X) = (\text{Cov}(X_i, X_j))_{n \times n}$ d'un vecteur aléatoire de dimension n est une matrice symétrique semi-définie positive.*

Démonstration La symétrie vient de ce que $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$. Montrons la semi-définition positive. Pour tout vecteur réel $c = (c_1, c_2, \dots, c_n)'$ de dimension n , on a

$$\begin{aligned} c' \text{Cov}(\mathbf{X}) c &= (c_1 \quad c_2 \quad \dots \quad c_n) \begin{pmatrix} \text{Var}(X_1) & \dots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \dots & \text{Cov}(X_2, X_n) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \dots & \text{Var}(X_n) \end{pmatrix} \begin{pmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{pmatrix} \\ &= \sum_{i=1}^n \sum_{j=1}^n c_i c_j \text{Cov}(X_i, X_j) \\ &= \sum_{i=1}^n \sum_{j=1}^n E[c_i(X_i - E(X_i))][c_j(X_j - E(X_j))] \\ &= E \left\{ \sum_{i=1}^n \sum_{j=1}^n [c_i(X_i - E(X_i))][c_j(X_j - E(X_j))] \right\} \\ &= E \left\{ \left[\sum_{i=1}^n c_i(X_i - E(X_i)) \right] \left[\sum_{j=1}^n c_j(X_j - E(X_j)) \right] \right\} \\ &= E \left[\sum_{i=1}^n c_i(X_i - E(X_i)) \right]^2 \geq 0. \end{aligned}$$

Par conséquent, la matrice $\text{Cov}(\mathbf{X})$ est semi-définie positive, et le théorème est démontré.

Exemple 8.1 (Distribution normale multivariée). Soit $\mathbf{X} = (X_1, X_2, \dots, X_n)'$ un vecteur aléatoire de dimension n dont la matrice de covariance $\mathbf{B} = \text{Cov}(\mathbf{X})$ est définie positive. Le vecteur de l'espérance mathématique est $\mathbf{a} = (a_1, a_2, \dots, a_n)'$. Soit également $\mathbf{x} = (x_1, x_2, \dots, x_n)'$. Alors, la fonction de densité est définie par :

$$p(x_1, x_2, \dots, x_n) = p(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}} |\mathbf{B}|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \mathbf{a})' \mathbf{B}^{-1} (\mathbf{x} - \mathbf{a}) \right\} \quad (8.1)$$

Cette distribution est appelée distribution normale à n variables (ou normale multivariée), notée $\mathbf{X} \sim N(\mathbf{a}, \mathbf{B})$. Ici, $|\mathbf{B}|$ représente le déterminant de $\mathbf{B}$, $\mathbf{B}^{-1}$ représente l'inverse de $\mathbf{B}$, et $(\mathbf{x} - \mathbf{a})'$ représente la transposée du vecteur $(\mathbf{x} - \mathbf{a})$.

Si l'on note $\mathbf{B}^{-1} = (r_{ij})$, alors l'équation peut s'écrire :

$$p(x_1, x_2, \dots, x_n) = \frac{1}{(2\pi)^{\frac{n}{2}} |\mathbf{B}|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} \sum_{i,j=1}^n r_{ij} (x_i - a_i)(x_j - a_j) \right\} \quad (8.2)$$

Dans le cas où $n = 2$, si l'on prend respectivement le vecteur d'espérance et la matrice de covariance comme :

$$\mathbf{a} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \mathbf{B} = \begin{pmatrix} \sigma_1^2 & \sigma_1 \sigma_2 \rho \\ \sigma_1 \sigma_2 \rho & \sigma_2^2 \end{pmatrix}$$

En remplaçant dans l'équation, on peut obtenir la fonction de densité normale bivariée donnée par l'équation.

La distribution normale multivariée est l'une des distributions multidimensionnelles les plus importantes ; elle occupe une place prépondérante en théorie des probabilités, en statistique mathématique et dans l'étude des processus aléatoires.

9 Distribution conditionnelle et espérance conditionnelle

Les relations entre les composantes d'un couple de variables aléatoires (X, Y) sont principalement de deux types : indépendance ou dépendance. Dans de nombreux problèmes, les variables aléatoires concernées ont souvent des influences mutuelles, ce qui fait de la distribution conditionnelle un outil puissant pour étudier les relations de dépendance entre variables.

9.1 Distribution conditionnelle

Pour un couple de variables aléatoires (X, Y) , la distribution conditionnelle de X sachant Y est la distribution de X étant donné que Y prend une certaine valeur. Par exemple, soit X le poids d'une personne et Y sa taille. En général, X et Y sont dépendants. Si on fixe $Y = 1.7\text{m}$, la distribution conditionnelle de X sachant $Y = 1.7$ est très différente de sa distribution marginale (sans cette condition). Cette section donne la définition de la distribution conditionnelle, puis celle de l'espérance conditionnelle.

I. Distribution conditionnelle pour des variables aléatoires discrètes

Soit (X, Y) un couple de variables aléatoires discrètes de distribution jointe

$$p_{ij} = P(X = x_i, Y = y_j), \quad i = 1, 2, \dots, \quad j = 1, 2, \dots$$

Par analogie avec la probabilité conditionnelle, on définit facilement la distribution conditionnelle discrète.

Définition 9.1. Pour tout y_j tel que $P(Y = y_j) = p_{\cdot j} = \sum_i p_{ij} > 0$, on appelle

$$p_{i|j} = P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{p_{ij}}{p_{\cdot j}}, \quad i = 1, 2,$$

la distribution conditionnelle de X sachant $Y = y_j$.

De même, pour tout x_i tel que $P(X = x_i) = p_{i\cdot} = \sum_j p_{ij} > 0$, on appelle

$$p_{j|i} = P(Y = y_j | X = x_i) = \frac{P(X = x_i, Y = y_j)}{P(X = x_i)} = \frac{p_{ij}}{p_{i\cdot}}, \quad j = 1, 2,$$

la distribution conditionnelle de Y sachant $X = x_i$.

Ayant défini les distributions conditionnelles, on peut donner les fonctions de répartition conditionnelles.

Définition 9.2. La fonction de répartition conditionnelle de X sachant $Y = y_j$ est

$$F(x | y_j) = \sum_{x_i \leq x} P(X = x_i | Y = y_j) = \sum_{x_i \leq x} p_{i|j},$$

et celle de Y sachant $X = x_i$ est

$$F(y | x_i) = \sum_{y_j \leq y} P(Y = y_j | X = x_i) = \sum_{y_j \leq y} p_{j|i},$$

Exemple 9.1. Soit la distribution jointe d'un couple discret (X, Y) :

X	Y			$p_{i\cdot}$
	1	2	3	
1	0.1	0.3	0.2	0.6
2	0.2	0.05	0.15	0.4
$p_{\cdot j}$	0.3	0.35	0.35	1.0

Comme $P(X = 1) = p_{1\cdot} = 0.6$, en divisant les éléments de la première ligne par 0.6, on obtient la distribution conditionnelle de Y sachant $X = 1$:

$Y X = 1$	1	2	3
P	1/6	1/2	1/3

En divisant les éléments de la seconde ligne par 0.4, on obtient la distribution conditionnelle de Y sachant $X = 2$:

$Y X = 2$	1	2	3
P	1/2	1/8	3/8

En divisant les éléments de la première colonne par 0.3, on obtient la distribution conditionnelle de X sachant $Y = 1$:

$X Y = 1$	1	2
P	1/3	2/3

En divisant les éléments de la seconde colonne par 0.35, on obtient la distribution conditionnelle de X sachant $Y = 2$:

$X \mid Y = 2$	1	2
P	6/7	1/7

En divisant les éléments de la troisième colonne par 0.35, on obtient la distribution conditionnelle de X sachant $Y = 3$:

$X \mid Y = 3$	1	2
P	4/7	3/7

Cet exemple montre qu'il n'y a qu'une seule distribution jointe, mais plusieurs distributions conditionnelles. Plus les valeurs de X et Y sont nombreuses, plus il y a de distributions conditionnelles. Chaque distribution conditionnelle décrit, sous un angle particulier, la distribution spécifique dans un état donné. On voit que le contenu des distributions conditionnelles est riche et leurs applications plus larges.

Exemple 9.2. Soient X et Y indépendantes, avec $X \sim P(\lambda_1)$ et $Y \sim P(\lambda_2)$. Trouver la distribution conditionnelle de X sachant $X + Y = n$.

Solution Comme la somme de deux Poisson indépendantes suit une loi de Poisson, $X + Y \sim P(\lambda_1 + \lambda_2)$, on a

$$\begin{aligned}
 P(X = k \mid X + Y = n) &= \frac{P(X = k, X + Y = n)}{P(X + Y = n)} \\
 &= \frac{P(X = k)P(Y = n - k)}{P(X + Y = n)} \\
 &= \frac{\frac{\lambda_1^k e^{-\lambda_1}}{k!} \cdot \frac{\lambda_2^{n-k} e^{-\lambda_2}}{(n-k)!}}{\frac{(\lambda_1 + \lambda_2)^n e^{-(\lambda_1 + \lambda_2)}}{n!}} \\
 &= \frac{n!}{k!(n-k)!} \frac{\lambda_1^k \lambda_2^{n-k}}{(\lambda_1 + \lambda_2)^n} \\
 &= \binom{n}{k} \left(\frac{\lambda_1}{\lambda_1 + \lambda_2} \right)^k \left(\frac{\lambda_2}{\lambda_1 + \lambda_2} \right)^{n-k}, \quad k = 0, 1, \dots, n.
 \end{aligned}$$

Ainsi, sachant $X + Y = n$, X suit une loi binomiale $b(n, p)$ avec $p = \lambda_1 / (\lambda_1 + \lambda_2)$.

Exemple 9.3. Soit X le nombre de clients entrant dans un magasin pendant une période donnée, suivant une loi de Poisson $P(\lambda)$. Chaque client achète un certain produit avec une probabilité p , et les achats des clients sont indépendants. Trouver la distribution du nombre Y de clients qui achètent ce produit.

Solution Par hypothèse,

$$P(X = m) = \frac{\lambda^m}{m!} e^{-\lambda}, \quad m = 0, 1, 2, \dots$$

Sachant que $X = m$ clients sont entrés, le nombre Y d'acheteurs suit une loi binomiale $b(m, p)$:

$$P(Y = k | X = m) = \binom{m}{k} p^k (1-p)^{m-k}, \quad k = 0, 1, \dots, m.$$

Par la formule des probabilités totales,

$$\begin{aligned} P(Y = k) &= \sum_{m=k}^{\infty} P(X = m) P(Y = k | X = m) \\ &= \sum_{m=k}^{\infty} \frac{\lambda^m}{m!} e^{-\lambda} \cdot \frac{m!}{k!(m-k)!} p^k (1-p)^{m-k} \\ &= e^{-\lambda} \sum_{m=k}^{\infty} \frac{\lambda^m}{k!(m-k)!} p^k (1-p)^{m-k} \\ &= e^{-\lambda} \frac{(\lambda p)^k}{k!} \sum_{m=k}^{\infty} \frac{[(1-p)\lambda]^{m-k}}{(m-k)!} \\ &= e^{-\lambda} \frac{(\lambda p)^k}{k!} e^{(1-p)\lambda} \\ &= \frac{(\lambda p)^k}{k!} e^{-\lambda p}, \quad k = 0, 1, 2, \dots \end{aligned}$$

Ainsi, Y suit une loi de Poisson de paramètre λp .

Cet exemple montre que, lorsqu'il est difficile de trouver directement la distribution de Y , on peut parfois utiliser les distributions conditionnelles pour surmonter la difficulté.

Distribution conditionnelle pour des variables aléatoires continues

Soit (X, Y) un couple de variables aléatoires continues de densité jointe $p(x, y)$ et de densités marginales $p_X(x), p_Y(y)$.

Dans le cas discret, la fonction de répartition conditionnelle est $P(X \leq x | Y = y)$. Mais pour une variable continue, la probabilité d'une valeur ponctuelle est nulle, $P(Y = y) = 0$, donc on ne peut pas calculer directement $P(X \leq x | Y = y)$. Une idée naturelle est de considérer la limite de $P(X \leq x | y \leq Y \leq y + h)$ quand $h \rightarrow 0$:

$$\begin{aligned} P(X \leq x | Y = y) &= \lim_{h \rightarrow 0} P(X \leq x | y \leq Y \leq y + h) \\ &= \lim_{h \rightarrow 0} \frac{P(X \leq x, y \leq Y \leq y + h)}{P(y \leq Y \leq y + h)} \\ &= \lim_{h \rightarrow 0} \frac{\int_{-\infty}^x \int_y^{y+h} p(u, v) dv du}{\int_y^{y+h} p_Y(v) dv} \\ &= \lim_{h \rightarrow 0} \frac{\int_{-\infty}^x \left\{ \frac{1}{h} \int_y^{y+h} p(u, v) dv \right\} du}{\frac{1}{h} \int_y^{y+h} p_Y(v) dv}, \end{aligned}$$

Si $p_Y(y)$ et $p(x, y)$ sont continues en y , par le théorème de la moyenne, on a

$$\lim_{h \rightarrow 0} \frac{1}{h} \int_y^{y+h} p_Y(v) dv = p_Y(y),$$

$$\lim_{h \rightarrow 0} \frac{1}{h} \int_y^{y+h} p(u, v) dv = p(u, y).$$

Donc

$$P(X \leq x \mid Y = y) = \int_{-\infty}^x \frac{p(u, y)}{p_Y(y)} du.$$

Le membre de gauche est la fonction de répartition conditionnelle de X sachant $Y = y$, notée $F(x \mid y)$. Par définition de la densité, l'intégrande dans le membre de droite est la densité conditionnelle de X sachant $Y = y$, notée $p(x \mid y)$. On peut donc définir la fonction de répartition conditionnelle et la densité conditionnelle pour les variables continues comme suit.

Définition 9.3. Pour tout y tel que $p_Y(y) > 0$, la fonction de répartition conditionnelle et la densité conditionnelle de X sachant $Y = y$ sont respectivement

$$F(x \mid y) = \int_{-\infty}^x \frac{p(u, y)}{p_Y(y)} du,$$

$$p(x \mid y) = \frac{p(x, y)}{p_Y(y)}.$$

De même, pour tout x tel que $p_X(x) > 0$, la fonction de répartition conditionnelle et la densité conditionnelle de Y sachant $X = x$ sont respectivement

$$F(y \mid x) = \int_{-\infty}^y \frac{p(x, v)}{p_X(x)} dv,$$

$$p(y \mid x) = \frac{p(x, y)}{p_X(x)}.$$

Il faut noter que la fonction de répartition conditionnelle $F(x \mid y)$ et la densité conditionnelle $p(x \mid y)$ dépendent de la condition $Y = y$. Elles sont différentes selon la valeur de y . Ainsi, $F(x \mid y)$ (ou $p(x \mid y)$) représente une famille de fonctions de répartition (ou densités). Il en va de même pour $F(y \mid x)$ et $p(y \mid x)$. Ces aspects peuvent être observés dans l'exemple suivant.

Exemple 9.4. Soit (X, Y) suivant une loi normale bidimensionnelle $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. Les lois marginales sont $X \sim N(\mu_1, \sigma_1^2)$ et $Y \sim N(\mu_2, \sigma_2^2)$. Trouvons les distributions conditionnelles.

$$p(x \mid y) = \frac{p(x, y)}{p_Y(y)}$$

$$= \frac{\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2} \right] \right\}}{\frac{1}{\sqrt{2\pi}\sigma_2} \exp \left\{ -\frac{(y-\mu_2)^2}{2\sigma_2^2} \right\}}$$

$$= \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2\sigma_1^2(1-\rho^2)} \left[x - \left(\mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2) \right) \right]^2 \right\},$$

qui est la densité d'une loi normale. Sa moyenne μ_3 et sa variance σ_3^2 sont

$$\mu_3 = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2), \quad \sigma_3^2 = \sigma_1^2(1 - \rho^2).$$

De même, sachant $X = x$, la distribution conditionnelle de Y est normale $N(\mu_4, \sigma_4^2)$ avec

$$\mu_4 = \mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), \quad \sigma_4^2 = \sigma_2^2(1 - \rho^2).$$

Ainsi, pour une loi normale bidimensionnelle, les lois marginales et conditionnelles sont toutes normales. C'est une propriété importante.

Exemple 9.5. Soit (X, Y) uniforme sur le disque $G = \{(x, y) \mid x^2 + y^2 \leq 1\}$. Trouver la densité conditionnelle de X sachant $Y = y$.

Solution La densité jointe est

$$p(x, y) = \frac{1}{\pi}, \quad x^2 + y^2 \leq 1.$$

La densité marginale de Y est

$$p_Y(y) = \int_{-\sqrt{1-y^2}}^{\sqrt{1-y^2}} \frac{1}{\pi} dx = \frac{2\sqrt{1-y^2}}{\pi}, \quad -1 < y < 1.$$

Donc pour $-1 < y < 1$,

$$p(x \mid y) = \frac{p(x, y)}{p_Y(y)} = \frac{1/\pi}{2\sqrt{1-y^2}/\pi} = \frac{1}{2\sqrt{1-y^2}}, \quad -\sqrt{1-y^2} < x < \sqrt{1-y^2}.$$

Pour $y = 0$ et $y = 0.5$, on obtient respectivement

$$p(x \mid 0) = \frac{1}{2}, \quad -1 < x < 1,$$

$$p(x \mid 0.5) = \frac{1}{2\sqrt{1-0.25}} = \frac{1}{\sqrt{3}}, \quad -\sqrt{0.75} < x < \sqrt{0.75}.$$

Ainsi, pour $-1 < y < 1$, sachant $Y = y$, X est uniforme sur $(-\sqrt{1-y^2}, \sqrt{1-y^2})$. De même, pour $-1 < x < 1$, sachant $X = x$, Y est uniforme sur $(-\sqrt{1-x^2}, \sqrt{1-x^2})$.

9.1.1 Formules de probabilité totale et de Bayes en continu

Ayant défini les densités conditionnelles, on peut donner les formules de la probabilité totale et de Bayes pour les variables continues. Les équations peuvent être réécrites comme

$$p(x, y) = p_X(x)p(y \mid x),$$

$$p(x, y) = p_Y(y)p(x | y).$$

En intégrant $p(x, y)$ par rapport à x ou y , on obtient les formules de probabilité totale pour les densités :

$$\begin{cases} p_Y(y) = \int_{-\infty}^{\infty} p_X(x)p(y | x) dx, \\ p_X(x) = \int_{-\infty}^{\infty} p_Y(y)p(x | y) dy. \end{cases}$$

on obtient la formule de Bayes pour les densités :

$$p(x | y) = \frac{p_X(x)p(y | x)}{\int_{-\infty}^{\infty} p_X(x)p(y | x) dx},$$

ou

$$p(y | x) = \frac{p_Y(y)p(x | y)}{\int_{-\infty}^{\infty} p_Y(y)p(x | y) dy}.$$

Notez que, bien qu'on ne puisse pas obtenir la distribution jointe à partir des seules marginales, les équations montrent qu'avec une marginale et une conditionnelle, on peut obtenir la jointe.

Exemple 9.6. Soit $X \sim N(\mu, \sigma_1^2)$. Sachant $X = x$, la distribution conditionnelle de Y est $N(x, \sigma_2^2)$. Trouver la densité (marginale) de Y , $p_Y(y)$.

Solution Par hypothèse,

$$\begin{aligned} p_X(x) &= \frac{1}{\sqrt{2\pi}\sigma_1} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma_1^2} \right\}, \\ p(y | x) &= \frac{1}{\sqrt{2\pi}\sigma_2} \exp \left\{ -\frac{(y - x)^2}{2\sigma_2^2} \right\}, \end{aligned}$$

Donc,

$$\begin{aligned} p_Y(y) &= \int_{-\infty}^{\infty} p_X(x)p(y | x) dx \\ &= \frac{1}{2\pi\sigma_1\sigma_2} \int_{-\infty}^{\infty} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma_1^2} - \frac{(y - x)^2}{2\sigma_2^2} \right\} dx \\ &= \frac{1}{2\pi\sigma_1\sigma_2} \int_{-\infty}^{\infty} \exp \left\{ -\frac{1}{2} \left[\left(\frac{1}{\sigma_1^2} + \frac{1}{\sigma_2^2} \right) x^2 - 2 \left(\frac{y}{\sigma_2^2} + \frac{\mu}{\sigma_1^2} \right) x + \frac{y^2}{\sigma_2^2} + \frac{\mu^2}{\sigma_1^2} \right] \right\} dx. \end{aligned}$$

Soit $c = \frac{\sigma_1^2\sigma_2^2}{\sigma_1^2 + \sigma_2^2}$. Alors l'expression devient

$$\begin{aligned} p_Y(y) &= \frac{1}{2\pi\sigma_1\sigma_2} \int_{-\infty}^{\infty} \exp \left\{ -\frac{1}{2}c^{-1} \left[x - c \left(\frac{\mu}{\sigma_1^2} + \frac{y}{\sigma_2^2} \right) \right]^2 - \frac{1}{2} \frac{(y - \mu)^2}{\sigma_1^2 + \sigma_2^2} \right\} dx \\ &= \frac{1}{2\pi\sigma_1\sigma_2} \sqrt{2\pi c} \exp \left\{ -\frac{(y - \mu)^2}{2(\sigma_1^2 + \sigma_2^2)} \right\} \\ &= \frac{1}{\sqrt{2\pi} \sqrt{\sigma_1^2 + \sigma_2^2}} \exp \left\{ -\frac{(y - \mu)^2}{2(\sigma_1^2 + \sigma_2^2)} \right\}. \end{aligned}$$

Ainsi, Y suit une loi normale $N(\mu, \sigma_1^2 + \sigma_2^2)$.

9.2 Espérance mathématique conditionnelle

L'espérance mathématique d'une distribution conditionnelle est appelée espérance conditionnelle. Sa définition est la suivante.

Définition 9.4. L'espérance mathématique de la distribution conditionnelle (si elle existe) est appelée espérance conditionnelle. Elle est définie par

$$E(X | Y = y) = \begin{cases} \sum_i x_i P(X = x_i | Y = y), & \text{pour un couple discret,} \\ \int_{-\infty}^{\infty} xp(x | y) dx, & \text{pour un couple continu.} \end{cases} \quad (3.5.15)$$

Il est important de noter que l'espérance conditionnelle $E(X | Y = y)$ est une fonction de y , différente de l'espérance marginale $E(X)$, non seulement par sa formule de calcul mais aussi par son sens.

Cette formule joue un rôle important dans les enquêtes criminelles. Par exemple, si la longueur d'une empreinte de pas laissée par un suspect est de 25.3cm, cette formule estime sa taille à environ 174cm.

Cette formule n'est pas complexe à obtenir. On considère généralement que la taille et la longueur du pied (X, Y) suivent une loi normale bidimensionnelle $N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$. D'après l'exemple 3.5.4, sachant $Y = y$, X suit une loi normale

$$N\left(\mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2), \sigma_1^2(1 - \rho^2)\right).$$

Ainsi,

$$E(X | Y = y) = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2),$$

qui est une fonction linéaire de y . En utilisant des méthodes statistiques pour estimer $\mu_1, \mu_2, \sigma_1, \sigma_2, \rho$ à partir de nombreuses données réelles, on obtient la formule ci-dessus.

Comme l'espérance conditionnelle est l'espérance mathématique d'une distribution conditionnelle, elle possède toutes les propriétés de l'espérance mathématique, par exemple

$$E(a_1 X_1 + a_2 X_2 | Y = y) = a_1 E(X_1 | Y = y) + a_2 E(X_2 | Y = y).$$

Nous ne listons pas toutes les autres propriétés, le lecteur peut les écrire lui-même.

Il faut particulièrement souligner que $E(X | Y = y)$ est une fonction de y . Pour différentes valeurs de y , l'espérance conditionnelle $E(X | Y = y)$ prend différentes valeurs. On peut donc noter

$$g(y) = E(X | Y = y).$$

On peut également considérer l'espérance conditionnelle comme une fonction de la variable aléatoire Y , notée $E(X | Y) = g(Y)$, et $E(X | Y = y)$ est la valeur de $E(X | Y)$ lorsque $Y = y$. Ainsi, $E(X | Y)$ est elle-même une variable aléatoire.

Théorème 9.1 (Formule de l'espérance totale). *Soit (X, Y) un couple de variables aléatoires tel que $E(X)$ existe. Alors*

$$E(X) = E(E(X | Y)).$$

Démonstration Nous démontrons pour le cas continu, le cas discret est analogue. Soit $p(x, y)$ la densité jointe. Posons $g(y) = E(X | Y = y)$, alors $g(Y) = E(X | Y)$. En utilisant $p(x, y) = p(x | y)p_Y(y)$, on a

$$E(X) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xp(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} xp(x | y)p_Y(y) dx dy$$

L'intégrale entre accolades n'est autre que l'espérance conditionnelle $E(X | Y = y)$. Donc

$$E(X) = \int_{-\infty}^{\infty} E(X | Y = y)p_Y(y) dy = \int_{-\infty}^{\infty} g(y)p_Y(y) dy = E(g(Y)) = E(E(X | Y)).$$

La formule de l'espérance totale est un résultat profond en probabilités, très utile en pratique. Par exemple, pour calculer la moyenne d'une variable X prenant des valeurs dans un très grand domaine, on peut rencontrer des difficultés de calcul. On peut alors chercher une variable Y liée à X , partitionner le grand domaine en petites régions selon les valeurs de Y , calculer d'abord la moyenne de X dans chaque petite région, puis faire la moyenne pondérée de ces moyennes conditionnelles, le poids étant la probabilité de chaque région. C'est comme pour calculer la taille moyenne des étudiants d'une université : on peut d'abord calculer la taille moyenne par classe, puis faire la moyenne pondérée de ces moyennes par l'effectif de chaque classe.

L'utilisation pratique de la formule de l'espérance totale est la suivante :

(1) Si Y est une variable aléatoire discrète,

$$E(X) = \sum_j E(X | Y = y_j)P(Y = y_j).$$

(2) Si Y est une variable aléatoire continue,

$$E(X) = \int_{-\infty}^{\infty} E(X | Y = y)p_Y(y) dy.$$

Exemple 9.7. Un mineur est coincé dans un puits avec trois portes. La première porte mène à un tunnel qui le conduit à la zone de sécurité en 3 heures. La deuxième porte mène à un tunnel qui le ramène au point de départ après 5 heures. La troisième porte mène à un tunnel qui le ramène au point de départ après 7 heures. Le mineur choisit une porte au hasard, de manière équiprobable. Trouver le temps moyen pour qu'il atteigne la zone de sécurité.

Solution Soit X le temps (en heures) pour atteindre la sécurité. Les valeurs possibles de X sont $3, 5 + 3, 7 + 3, 5 + 5 + 3, 5 + 7 + 3, 7 + 5 + 3, \dots$. Il est difficile d'écrire la distribution de X . Soit Y la porte choisie la première fois. Par hypothèse,

$$P(Y = 1) = P(Y = 2) = P(Y = 3) = \frac{1}{3}.$$

S'il choisit la porte 1, il atteint la sécurité en 3 heures, donc $E(X | Y = 1) = 3$. S'il choisit la porte 2, il revient au point de départ après 5 heures, puis le processus recommence, donc $E(X | Y = 2) = 5 + E(X)$. S'il choisit la porte 3, il revient au point de départ après 7 heures, donc $E(X | Y = 3) = 7 + E(X)$.

$$E(X) = \frac{1}{3}[3 + (5 + E(X)) + (7 + E(X))] = 5 + \frac{2}{3}E(X),$$

d'où $E(X) = 15$. Le mineur mettra en moyenne 15 heures pour atteindre la sécurité.

La méthode de résolution de cet exemple a un caractère général. Le lecteur pourra la retrouver dans l'exemple suivant.

Exemple 9.8. Une urne contient n boules numérotées $1, 2, \dots, n$. On tire une boule au hasard. Si on tire la boule numéro 1, on gagne 1 point et on s'arrête. Si on tire la boule numéro i ($i \geq 2$), on gagne i points, on remet la boule dans l'urne, et on recommence. Trouver le nombre moyen total de points gagnés.

Solution Soit X le nombre total de points, et Y le numéro de la boule tirée au premier tirage. Alors

$$E(X | Y = 1) = 1, \quad E(X | Y = i) = i + E(X) \text{ pour } i \geq 2.$$

Donc

$$E(X) = \sum_{i=1}^n E(X | Y = i)P(Y = i) = \frac{1}{n} [1 + 2 + \dots + n + (n-1)E(X)].$$

On en déduit

$$E(X) = \frac{n(n+1)}{2}.$$

Exemple 9.9. La compagnie d'électricité peut fournir à une usine une puissance X (en 10^4 kW) uniforme sur $(10, 30)$. L'usine a besoin réellement d'une puissance Y uniforme sur $(10, 20)$. Si l'usine reçoit suffisamment d'électricité, chaque 10^4 kW crée un profit de 300 000 yuans. Sinon, elle doit compléter par d'autres moyens, qui ne rapportent que 100 000 yuans par 10^4 kW. Trouver le profit mensuel moyen de l'usine.

Solution Le profit Z (en dizaines de milliers de yuans) est

$$Z = \begin{cases} 30Y, & \text{si } Y \leq X, \\ 10Y + 20X, & \text{si } Y > X. \end{cases}$$

Sachant $X = x$, l'espérance conditionnelle de Z est, pour $10 \leq x < 20$,

$$\begin{aligned} E(Z | X = x) &= \int_{10}^x 30y \cdot \frac{1}{10} dy + \int_x^{20} (10y + 20x) \cdot \frac{1}{10} dy \\ &= \frac{3}{2}(x^2 - 100) + \frac{1}{2}(400 - x^2) + 2x(20 - x) = 50 + 40x - x^2. \end{aligned}$$

Pour $20 \leq x \leq 30$,

$$E(Z | X = x) = \int_{10}^{20} 30y \cdot \frac{1}{10} dy = 450.$$

Ensuite, on moyenne par rapport à X (uniforme sur $(10, 30)$) :

$$\begin{aligned} E(Z) &= E(E(Z | X)) \\ &= \frac{1}{20} \int_{10}^{20} (50 + 40x - x^2) dx + \frac{1}{20} \int_{20}^{30} 450 dx \\ &= 25 + 300 - \frac{700}{6} + 225 = 433.\bar{3}. \end{aligned}$$

Le profit mensuel moyen est donc d'environ 4,333 millions de yuans.

Exemple 9.10 (Espérance d'une somme d'un nombre aléatoire de variables). Soit $X_1, X_2, \dots$ une suite de variables aléatoires indépendantes et identiquement distribuées. Soit N une variable aléatoire prenant des valeurs entières positives, indépendante des $\{X_n\}$. Montrer que

$$E\left(\sum_{i=1}^N X_i\right) = E(X_1)E(N).$$

Démonstration

$$\begin{aligned} E\left(\sum_{i=1}^N X_i\right) &= E\left[E\left(\sum_{i=1}^N X_i \mid N\right)\right] = \sum_{n=1}^{\infty} E\left(\sum_{i=1}^N X_i \mid N=n\right) P(N=n) \\ &= \sum_{n=1}^{\infty} E\left(\sum_{i=1}^n X_i\right) P(N=n) = \sum_{n=1}^{\infty} nE(X_1)P(N=n) \\ &= E(X_1) \sum_{n=1}^{\infty} nP(N=n) = E(X_1)E(N). \end{aligned}$$

La conclusion est démontrée.

En utilisant ce résultat, on peut résoudre de nombreux problèmes pratiques, par exemple :

(1) Soit N le nombre de clients entrant dans un grand magasin en un jour, avec $E(N) = 35000$. Soit X_i le montant des achats du i -ème client. On suppose que les X_i sont i.i.d. avec $E(X_i) = 82$ yuans, et que N est indépendant des X_i . Alors le chiffre d'affaires moyen journalier est

$$E\left(\sum_{i=1}^N X_i\right) = E(X_1)E(N) = 82 \times 35000 = 2\,870\,000 \text{ yuans} = 2.87 \text{ millions.}$$

(2) Le nombre d'œufs pondus par un insecte en une fois, N , suit une loi de Poisson $P(\lambda)$. Chaque œuf a une probabilité p de survivre. On peut définir X_i comme une indicatrice (1 si l'œuf i survit, 0 sinon). Alors le nombre moyen d'œufs survivants après une ponte est

$$E\left(\sum_{i=1}^N X_i\right) = E(X_1)E(N) = \lambda p.$$