

Chapitre 5 : Lois des grands nombres et théorème central limite

1 Convergence

Il existe plusieurs types de convergence pour les suites de variables aléatoires, parmi lesquels deux sont couramment utilisés : la convergence en probabilité et la convergence en loi. La loi des grands nombres, abordée dans ce chapitre, concerne la convergence en probabilité, tandis que le théorème central limite traite de la convergence en loi. Ces théorèmes limites sont non seulement au cœur de la recherche en théorie des probabilités, mais aussi largement appliqués en statistique mathématique. Cette section présentera les définitions de ces deux types de convergence et leurs propriétés associées ; le lecteur doit en assimiler la méthodologie.

1.1 Convergence en probabilité

Dans le chapitre 1, pour déterminer une probabilité à partir d'une fréquence, nous avons avancé que la probabilité est la valeur stable de la fréquence ou que la fréquence se stabilise autour de la probabilité. Interprétons maintenant le sens de stable et son expression mathématique.

Considérons un grand lot de produits dont le taux de produits non conformes est p . On vérifie la conformité des produits un par un ; notons S_n le nombre de produits non conformes découverts lors des n premiers contrôles, et $v_n = S_n/n$ la fréquence de produits non conformes. En poursuivant les contrôles, on observe deux phénomènes pour la suite $\{v_n\}$:

(1) L'écart absolu $|v_n - p|$ a tendance à diminuer lorsque n augmente, mais on ne peut pas dire qu'il converge vers zéro.

(2) En raison du caractère aléatoire de la fréquence, l'écart absolu $|v_n - p|$ est parfois grand, parfois petit. Bien qu'on ne puisse exclure la possibilité d'un grand écart, celle-ci devient de plus en plus faible lorsque n augmente. C'est un nouveau concept de limite.

Traduisons mathématiquement cette idée. Pour un $\epsilon > 0$ donné, l'événement $\{|v_n - p| \geq \epsilon\}$ signifie qu'un grand écart se produit. Le fait que la probabilité d'un grand écart diminue s'écrit :

$$P(|v_n - p| \geq \epsilon) \rightarrow 0, \quad (n \rightarrow \infty).$$

On dit alors que la suite des fréquences $\{v_n\}$ converge en probabilité. C'est le sens de la fréquence se stabilise autour de la probabilité.

Donnons maintenant la définition générale de la convergence en probabilité pour une suite $\{X_n\}$ de variables aléatoires vers une variable aléatoire X .

Définition 1.1. Soit $\{X_n\}$ une suite de variables aléatoires et X une variable aléatoire. Si pour tout $\epsilon > 0$,

$$P(|X_n - X| \geq \epsilon) \rightarrow 0 \quad (n \rightarrow \infty),$$

on dit que la suite $\{X_n\}$ converge en probabilité vers X , et on note $X_n \xrightarrow{P} X$.

La convergence en probabilité signifie que la probabilité que l'écart absolu entre X_n et X dépasse une valeur donnée devient de plus en plus petite lorsque n augmente. Autrement dit, la probabilité que l'écart soit inférieur à une valeur donnée tend vers 1 :

$$P(|X_n - X| < \epsilon) \rightarrow 1 \quad (n \rightarrow \infty).$$

En particulier, si X est dégénérée, c'est-à-dire $P(X = c) = 1$, on dit que $\{X_n\}$ converge en probabilité vers c : $X_n \xrightarrow{P} c$.

Donnons d'abord les propriétés des opérations arithmétiques pour la convergence en probabilité vers une constante.

Soient $\{X_n\}$ et $\{Y_n\}$ deux suites de variables aléatoires, et a, b deux constantes. Si

$$X_n \xrightarrow{P} a, \quad Y_n \xrightarrow{P} b,$$

alors : (1) $X_n \pm Y_n \xrightarrow{P} a \pm b$; (2) $X_n \times Y_n \xrightarrow{P} a \times b$; (3) $X_n \div Y_n \xrightarrow{P} a \div b$ ($b \neq 0$).

Proof. (1) car

$$|(X_n + Y_n) - (a + b)| \geq \epsilon \subset \left\{ |X_n - a| \geq \frac{\epsilon}{2} \right\} \cup \left\{ |Y_n - b| \geq \frac{\epsilon}{2} \right\},$$

donc

$$0 \leq P(|(X_n + Y_n) - (a + b)| \geq \epsilon) \leq P\left(|X_n - a| \geq \frac{\epsilon}{2}\right) + P\left(|Y_n - b| \geq \frac{\epsilon}{2}\right) \rightarrow 0.$$

Ainsi $X_n + Y_n \xrightarrow{P} a + b$. On montre de même pour la soustraction.

(2) Pour montrer $X_n Y_n \xrightarrow{P} ab$, procédons par étapes : i) Si $X_n \xrightarrow{P} 0$, alors $X_n^2 \xrightarrow{P} 0$. ii) Si $X_n \xrightarrow{P} a$, alors $cX_n \xrightarrow{P} ca$. iii) Si $X_n \xrightarrow{P} a$, alors $X_n^2 \xrightarrow{P} a^2$. iv) On a alors

$$X_n Y_n = \frac{1}{2} [(X_n + Y_n)^2 - X_n^2 - Y_n^2] \xrightarrow{P} \frac{1}{2} [(a + b)^2 - a^2 - b^2] = ab.$$

(3) On montre d'abord $1/Y_n \xrightarrow{P} 1/b$ puis on utilise (2). □

Ce théorème montre que la limite en probabilité (pour une constante) se comporte comme la limite usuelle en analyse. Des résultats analogues valent pour la convergence en probabilité vers une variable aléatoire X .

1.2 Convergence en loi, convergence faible

La fonction de répartition décrit complètement la loi d'une variable aléatoire. Il est donc intéressant d'étudier la convergence d'une suite de fonctions de répartition $F_n(x)$ vers une fonction de répartition limite $F(x)$. Naturellement, on pourrait exiger la convergence ponctuelle $\lim_{n \rightarrow \infty} F_n(x) = F(x)$ pour tout x . Hélas, l'exemple suivant montre que cette exigence est trop forte.

Soit $\{X_n\}$ une suite de variables aléatoires dégénérées :

$$P\left(X_n = \frac{1}{n}\right) = 1, \quad n = 1, 2, \dots$$

Leurs fonctions de répartition sont :

$$F_n(x) = \begin{cases} 0, & x < 1/n, \\ 1, & x \geq 1/n. \end{cases}$$

La limite ponctuelle est

$$g(x) = \lim_{n \rightarrow \infty} F_n(x) = \begin{cases} 0, & x \leq 0, \\ 1, & x > 0. \end{cases}$$

La fonction $g(x)$ n'est pas continue à droite en 0 (car $g(0) = 0$ mais $\lim_{x \rightarrow 0^+} g(x) = 1$), donc ce n'est pas une fonction de répartition.

Cela montre qu'on ne peut pas exiger la convergence ponctuelle en tout point. On remarque que le défaut de convergence se produit aux points de discontinuité de la limite. On affaiblit donc l'exigence en ne considérant que les points de continuité de F .

Définition 1.2. Soient $X, X_1, X_2, \dots$ des variables aléatoires de fonctions de répartition respectives $F, F_1, F_2, \dots$. Si pour tout point x où F est continue,

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

on dit que $\{F_n(x)\}$ converge faiblement vers $F(x)$, noté $F_n(x) \xrightarrow{W} F(x)$. On dit aussi que la suite $\{X_n\}$ converge en loi vers X , noté $X_n \xrightarrow{L} X$.

La convergence en probabilité est plus forte que la convergence en loi.

$$X_n \xrightarrow{P} X \implies X_n \xrightarrow{L} X.$$

Proof. Soient $F, F_1, F_2, \dots$ les fonctions de répartition. Pour tout x , on a

$$F(x-0) \leq \varliminf_{n \rightarrow \infty} F_n(x) \leq \varlimsup_{n \rightarrow \infty} F_n(x) \leq F(x+0).$$

Si x est point de continuité de F , alors $F(x-0) = F(x+0) = F(x)$, d'où $F_n(x) \rightarrow F(x)$. $\square$

Attention, la réciproque est fausse : la convergence en loi n'implique pas la convergence en probabilité (sauf si la limite est une constante).

Si c est une constante, alors $X_n \xrightarrow{P} c$ si et seulement si $X_n \xrightarrow{L} c$.

2 Fonction caractéristique

Soit $p(x)$ la densité d'une variable aléatoire X . La transformée de Fourier de $p(x)$ est

$$\phi(t) = \int_{-\infty}^{\infty} e^{itx} p(x) dx,$$

où $i = \sqrt{-1}$ est l'unité imaginaire.

D'après la notion d'espérance mathématique, $\phi(t)$ est précisément $E(e^{itX})$.

C'est la fonction caractéristique qui sera discutée dans cette section ; c'est un outil puissant pour traiter de nombreux problèmes de probabilités.

Elle permet de transformer l'opération de convolution (intégration) pour la somme de variables aléatoires indépendantes en une opération de multiplication, et de transformer le calcul des moments (intégration) en une opération de dérivation ; en particulier, elle permet de transformer la recherche de la limite d'une suite de distributions en un problème de limite de fonctions ordinaires.

Nous commençons par introduire la fonction caractéristique à partir de sa définition.

2.1 Définition de la fonction caractéristique

Introduisons d'abord la notion de variable aléatoire complexe.

En plus des variables aléatoires réelles, on considère également des variables aléatoires complexes, appelées variables aléatoires complexes.

Une variable aléatoire complexe est définie par $Z = Z(w) = X(w) + iY(w)$, où $X(w)$ et $Y(w)$ sont des variables aléatoires réelles définies sur Ω .

$\bar{Z}(w) = X(w) - iY(w)$ est appelée la variable aléatoire complexe conjuguée de $Z(w)$.

Le module $|Z|$ d'une variable aléatoire complexe $Z = X + iY$ est défini par $\sqrt{X^2 + Y^2}$, ou $|Z|^2 = X^2 + Y^2$, et $Z\bar{Z} = X^2 + Y^2 = |Z|^2$.

Certains concepts et définitions relatifs aux variables aléatoires réelles peuvent généralement être étendus au cas complexe.

Par exemple, si les espérances mathématiques $E(X)$ et $E(Y)$ existent, l'espérance mathématique de la variable aléatoire complexe $Z = X + iY$ est définie par $E(Z) = E(X) + iE(Y)$.

De même, deux variables aléatoires complexes $Z_1 = X_1 + iY_1$ et $Z_2 = X_2 + iY_2$ sont dites indépendantes si et seulement si (X_1, Y_1) et (X_2, Y_2) sont indépendants (la distribution jointe de (X_1, Y_1, X_2, Y_2) est le produit de leurs distributions marginales).

Dans la formule d'Euler $e^{iX} = \cos X + i \sin X$, si X est une variable aléatoire réelle, alors $E(e^{iX}) = E(\cos X) + iE(\sin X)$, et son module $|e^{iX}| = \sqrt{\cos^2 X + \sin^2 X} = 1$.

Si X et Y sont indépendantes, alors e^{iX} et e^{iY} sont également indépendantes.

Donnons maintenant la définition de la fonction caractéristique.

Définition 2.1. Soit X une variable aléatoire. On appelle fonction caractéristique de X la fonction

$$\phi(t) = E(e^{itX}), \quad -\infty < t < \infty,$$

Comme $|e^{itX}| = 1$, $E(e^{itX})$ existe toujours ; toute variable aléatoire possède donc une fonction caractéristique.

Pour une variable aléatoire discrète X de loi $p_k = P(X = x_k), k = 1, 2, \dots$, sa fonction caractéristique est

$$\phi(t) = \sum_{k=1}^{\infty} e^{itx_k} p_k, \quad -\infty < t < \infty.$$

Pour une variable aléatoire continue X de densité $p(x)$, sa fonction caractéristique est

$$\phi(t) = \int_{-\infty}^{\infty} e^{itx} p(x) dx, \quad -\infty < t < \infty.$$

Comme l'espérance mathématique, la variance et les moments, la fonction caractéristique ne dépend que de la loi de X ; deux variables ayant la même loi ont la même fonction caractéristique. On parle donc souvent de la fonction caractéristique d'une loi.

[Fonctions caractéristiques de lois usuelles (1)] (1) Loi dégénérée $P(X = a) = 1$:

$$\phi(t) = e^{ita}.$$

(2) Loi de Bernoulli $b(1, p) : P(X = x) = p^x(1-p)^{1-x}, x = 0, 1$:

$$\phi(t) = pe^{it} + q, \quad q = 1 - p.$$

(3) Loi de Poisson $P(\lambda) : P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, \dots$:

$$\phi(t) = \sum_{k=0}^{\infty} e^{itk} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} e^{\lambda e^{it}} = \exp(\lambda(e^{it} - 1)).$$

(4) Loi uniforme $U(a, b)$: densité

$$p(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{sinon} \end{cases}$$

donc

$$\phi(t) = \int_a^b \frac{e^{itx}}{b-a} dx = \frac{e^{itb} - e^{ita}}{it(b-a)}.$$

(5) Loi normale centrée réduite $N(0, 1)$: densité $p(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$.

$$\begin{aligned} \phi(t) &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{itx} e^{-x^2/2} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \sum_{n=0}^{\infty} \frac{(itx)^n}{n!} e^{-x^2/2} dx \\ &= \sum_{n=0}^{\infty} \frac{(it)^n}{n!} \left[\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x^n e^{-x^2/2} dx \right]. \end{aligned}$$

L'expression entre crochets est le moment d'ordre n de $N(0, 1)$. Pour n impair, $E(X^n) = 0$; pour n pair, $n = 2m$,

$$E(X^{2m}) = \frac{(2m)!}{2^m m!}.$$

En substituant, on obtient la fonction caractéristique de la loi normale centrée réduite

$$\phi(t) = \sum_{m=0}^{\infty} \frac{(it)^{2m}}{(2m)!} \cdot \frac{(2m)!}{2^m m!} = \sum_{m=0}^{\infty} \left(-\frac{t^2}{2}\right)^m \frac{1}{m!} = e^{-t^2/2}.$$

À partir de la fonction caractéristique de la loi normale centrée réduite et en utilisant les propriétés de la section suivante, on obtient facilement la fonction caractéristique de la loi normale générale $N(\mu, \sigma^2)$.

(6) Loi exponentielle $Exp(\lambda)$: densité

$$p(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

donc

$$\begin{aligned} \phi(t) &= \int_0^{\infty} e^{itx} \lambda e^{-\lambda x} dx = \lambda \left[\int_0^{\infty} \cos(tx) e^{-\lambda x} dx + i \int_0^{\infty} \sin(tx) e^{-\lambda x} dx \right] \\ &= \lambda \left(\frac{\lambda}{\lambda^2 + t^2} + i \frac{t}{\lambda^2 + t^2} \right) = \left(1 - \frac{it}{\lambda} \right)^{-1}. \end{aligned}$$

Dans les calculs ci-dessus, on a utilisé la formule d'Euler $e^{itx} = \cos(tx) + i \sin(tx)$.

2.2 Propriétés de la fonction caractéristique

Étudions maintenant quelques propriétés de la fonction caractéristique ; $\phi_X(t)$ désigne la fonction caractéristique de X .

Propriété 2.1. $|\phi(t)| \leq \phi(0) = 1$.

Propriété 2.2. $\phi(-t) = \overline{\phi(t)}$, où $\overline{\phi(t)}$ désigne le conjugué de $\phi(t)$.

Propriété 2.3. Si $Y = aX + b$, où a, b sont des constantes, alors

$$\phi_Y(t) = e^{itb} \phi_X(at).$$

Propriété 2.4. Si X et Y sont indépendantes, alors

$$\phi_{X+Y}(t) = \phi_X(t) \phi_Y(t).$$

Propriété 2.5. Si $E(|X|^l)$ existe, alors la fonction caractéristique $\phi(t)$ est l fois dérivable, et pour $1 \leq k \leq l$,

$$\phi^{(k)}(0) = i^k E(X^k).$$

Ceci fournit un moyen d'obtenir les moments d'une variable aléatoire ; en particulier,

$$E(X) = \frac{\phi'(0)}{i}, \quad \text{Var}(X) = -\phi''(0) + (\phi'(0))^2.$$

Proof. Nous démontrons ici uniquement pour le cas continu ; la démonstration pour le cas discret est analogue.

$$(1) |\phi(t)| = \left| \int_{-\infty}^{\infty} e^{itx} p(x) dx \right| \leq \int_{-\infty}^{\infty} |e^{itx}| p(x) dx = \int_{-\infty}^{\infty} p(x) dx = \phi(0) = 1.$$

$$(2) \phi(-t) = \int_{-\infty}^{\infty} e^{-itx} p(x) dx = \overline{\int_{-\infty}^{\infty} e^{itx} p(x) dx} = \overline{\phi(t)}.$$

$$(3) \phi_Y(t) = E(e^{it(aX+b)}) = e^{itb} E(e^{itaX}) = e^{itb} \phi_X(at).$$

(4) Comme X et Y sont indépendantes, e^{itX} et e^{itY} le sont aussi, donc

$$\phi_{X+Y}(t) = E(e^{it(X+Y)}) = E(e^{itX})E(e^{itY}) = \phi_X(t)\phi_Y(t).$$

(5) Comme $E(|X|^l) < \infty$, c'est-à-dire $\int_{-\infty}^{\infty} |x|^l p(x) dx < \infty$, l'intégrale généralisée dépendant du paramètre t , $\int_{-\infty}^{\infty} e^{itx} p(x) dx$, est dérivable l fois par rapport à t . Ainsi, pour $0 \leq k \leq l$,

$$\phi^{(k)}(t) = \int_{-\infty}^{\infty} (ix)^k e^{itx} p(x) dx = i^k E(X^k e^{itX}),$$

et en prenant $t = 0$, $\phi^{(k)}(0) = i^k E(X^k)$. □

L'exemple suivant utilise les propriétés pour obtenir les fonctions caractéristiques d'autres lois usuelles.

[Fonctions caractéristiques de lois usuelles (2)] (1) Loi binomiale $b(n, p)$: soit $Y \sim b(n, p)$. Alors $Y = X_1 + \dots + X_n$ où les X_i sont i.i.d. de loi $b(1, p)$. D'après l'exemple, $\phi_{X_i}(t) = pe^{it} + q$. Par la propriété,

$$\phi_Y(t) = (pe^{it} + q)^n.$$

(2) Loi normale $N(\mu, \sigma^2)$: soit $Y \sim N(\mu, \sigma^2)$. Alors $X = (Y - \mu)/\sigma \sim N(0, 1)$. D'après l'exemple, $\phi_X(t) = e^{-t^2/2}$. Avec $Y = \sigma X + \mu$ et la propriété,

$$\phi_Y(t) = e^{i\mu t} \phi_X(\sigma t) = \exp \left\{ i\mu t - \frac{\sigma^2 t^2}{2} \right\}.$$

(3) Loi Gamma $Ga(n, \lambda)$: soit $Y \sim Ga(n, \lambda)$. Alors $Y = X_1 + \dots + X_n$ où les X_i sont i.i.d. de loi $Exp(\lambda)$. D'après l'exemple, $\phi_{X_i}(t) = (1 - it/\lambda)^{-1}$. Par la propriété,

$$\phi_Y(t) = (\phi_{X_1}(t))^n = \left(1 - \frac{it}{\lambda}\right)^{-n}.$$

Plus généralement, pour tout $\alpha > 0$ réel, la loi $Ga(\alpha, \lambda)$ a pour fonction caractéristique

$$\phi(t) = \left(1 - \frac{it}{\lambda}\right)^{-\alpha}.$$

(4) Loi du $\chi^2(n)$: comme $\chi^2(n) = Ga(n/2, 1/2)$, sa fonction caractéristique est

$$\phi(t) = (1 - 2it)^{-n/2}.$$

Ces fonctions caractéristiques sont résumées dans le tableau.

Ainsi, on obtient

$$\begin{aligned} E(X) &= \frac{\phi'(0)}{i} = \frac{\alpha}{\lambda}, \\ \text{Var}(X) &= -\phi''(0) + (\phi'(0))^2 = \frac{\alpha(\alpha+1)}{\lambda^2} + \left(\frac{\alpha i}{\lambda}\right)^2 \\ &= \frac{\alpha(\alpha+1)}{\lambda^2} - \frac{\alpha^2}{\lambda^2} = \frac{\alpha}{\lambda^2}. \end{aligned}$$

La fonction caractéristique possède également les propriétés remarquables suivantes.

Théorème 2.1 (Continuité uniforme). *La fonction caractéristique $\phi(t)$ d'une variable aléatoire X est uniformément continue sur $(-\infty, \infty)$.*

Proof. Supposons X continue (la preuve pour le cas discret est analogue), de densité $p(x)$. Alors pour tous réels t, h et tout $a > 0$,

$$\begin{aligned} |\phi(t+h) - \phi(t)| &= \left| \int_{-\infty}^{\infty} (e^{ihx} - 1)e^{itx} p(x) dx \right| \leq \int_{-\infty}^{\infty} |e^{ihx} - 1| p(x) dx \\ &\leq \int_{-a}^a |e^{ihx} - 1| p(x) dx + 2 \int_{|x|>a} p(x) dx. \end{aligned}$$

Pour tout $\epsilon > 0$, choisissons a assez grand pour que $2 \int_{|x|>a} p(x) dx < \epsilon/2$. Puis, pour $x \in [-a, a]$, prenons $\delta = \frac{\epsilon}{2a}$. Alors pour $|h| < \delta$,

$$|e^{ihx} - 1| = 2 \left| \sin \frac{hx}{2} \right| \leq 2 \left| \frac{hx}{2} \right| \leq ha < \frac{\epsilon}{2}.$$

Ainsi, pour tout t ,

$$|\phi(t+h) - \phi(t)| < \int_{-a}^a \frac{\epsilon}{2} p(x) dx + \frac{\epsilon}{2} \leq \epsilon.$$

Donc ϕ est uniformément continue. $\square$

Théorème 2.2 (Non-négativité). *La fonction caractéristique $\phi(t)$ est définie non-négative, c'est-à-dire que pour tout entier n , tous réels $t_1, \dots, t_n$ et tous complexes $z_1, \dots, z_n$,*

$$\sum_{k=1}^n \sum_{j=1}^n \phi(t_k - t_j) z_k \bar{z}_j \geq 0.$$

Proof. (Supposons X continue, de densité $p(x)$.)

$$\begin{aligned} \sum_{k,j} \phi(t_k - t_j) z_k \bar{z}_j &= \sum_{k,j} z_k \bar{z}_j \int_{-\infty}^{\infty} e^{i(t_k - t_j)x} p(x) dx \\ &= \int_{-\infty}^{\infty} \left(\sum_k z_k e^{it_k x} \right) \left(\sum_j \bar{z}_j e^{-it_j x} \right) p(x) dx = \int_{-\infty}^{\infty} \left| \sum_k z_k e^{it_k x} \right|^2 p(x) dx \geq 0. \end{aligned}$$

$\square$

2.3 La fonction caractéristique détermine uniquement la loi

Par définition de la fonction caractéristique, la loi d'une variable aléatoire détermine uniquement sa fonction caractéristique.

Jusqu'à présent, nous avons toujours discuté de la fonction caractéristique à partir de la loi.

Il faut noter que si deux lois ont la même espérance mathématique, la même variance et les mêmes moments, on ne peut pas prouver qu'elles sont identiques.

En revanche, la fonction caractéristique a une propriété bien meilleure : elle détermine complètement la loi ; autrement dit, deux fonctions de répartition sont égales si et seulement si leurs fonctions caractéristiques sont égales.

Discutons de ce problème.

Théorème 2.3 (Formule d'inversion). *Soient $F(x)$ et $\phi(t)$ respectivement la fonction de répartition et la fonction caractéristique d'une variable aléatoire X . Alors pour tous points de continuité $x_1 < x_2$ de F ,*

$$F(x_2) - F(x_1) = \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} \phi(t) dt.$$

Proof. Supposons X continue (la démonstration pour le cas discret est analogue), de densité $p(x)$. Notons

$$J_T = \frac{1}{2\pi} \int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} \phi(t) dt = \frac{1}{2\pi} \int_{-T}^T \left[\int_{-\infty}^{\infty} \frac{e^{-itx_1} - e^{-itx_2}}{it} e^{itx} p(x) dx \right] dt.$$

Pour tout réel a , on a $|e^{ia} - 1| \leq |a|$. En effet, pour $a \geq 0$, $|e^{ia} - 1| = \left| \int_0^a e^{is} ds \right| \leq \int_0^a |e^{is}| ds = a$; pour $a < 0$, on utilise la conjugaison. Ainsi,

$$\left| \frac{e^{-itx_1} - e^{-itx_2}}{it} e^{itx} \right| \leq x_2 - x_1.$$

L'intégrande est bornée, on peut échanger l'ordre d'intégration :

$$J_T = \frac{1}{2\pi} \int_{-\infty}^{\infty} \left[\int_{-T}^T \frac{e^{-itx_1} - e^{-itx_2}}{it} e^{itx} dt \right] p(x) dx.$$

En utilisant les formules d'Euler et les intégrales de Dirichlet, on montre que

$$\lim_{T \rightarrow \infty} J_T = \int_{x_1}^{x_2} p(x) dx = F(x_2) - F(x_1).$$

□

Théorème 2.4 (Unicité). *La fonction de répartition d'une variable aléatoire est uniquement déterminée par sa fonction caractéristique.*

Proof. Pour tout point de continuité x de F ,

$$F(x) = \lim_{y \rightarrow -\infty} \lim_{T \rightarrow \infty} \frac{1}{2\pi} \int_{-T}^T \frac{e^{-ity} - e^{-itx}}{it} \phi(t) dt.$$

Comme une fonction de répartition est déterminée par ses valeurs sur son ensemble de points de continuité, le résultat suit. □

En particulier, pour une variable aléatoire continue, on a le résultat plus fort suivant.

Théorème 2.5. *Si X est une variable aléatoire continue de densité $p(x)$ et de fonction caractéristique $\phi(t)$, et si $\int_{-\infty}^{\infty} |\phi(t)| dt < \infty$, alors*

$$p(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \phi(t) dt.$$

Proof. En utilisant la formule d'inversion et la convergence dominée,

$$p(x) = \lim_{\Delta x \rightarrow 0} \frac{F(x + \Delta x) - F(x)}{\Delta x} = \frac{1}{2\pi} \int_{-\infty}^{\infty} \lim_{\Delta x \rightarrow 0} \frac{e^{-itx} - e^{-it(x+\Delta x)}}{it\Delta x} \phi(t) dt = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \phi(t) dt.$$

□

Ceci achève la démonstration du théorème.

$$\begin{aligned} \phi(t) &= \int_{-\infty}^{\infty} e^{itx} p(x) dx, \\ p(x) &= \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} \phi(t) dt. \end{aligned}$$

Autrement dit, la fonction caractéristique est la transformée de Fourier de la densité, et la densité est la transformée de Fourier inverse de la fonction caractéristique.

Il est important de souligner qu'en probabilités, les sommes de variables aléatoires indépendantes occupent une place centrale. Traiter ces sommes par convolution est très complexe ; l'introduction de la fonction caractéristique permet d'obtenir simplement la fonction caractéristique de la somme comme produit des fonctions caractéristiques, puis, par le théorème d'unicité, d'identifier la loi de la somme. Cela simplifie considérablement la difficulté. Le lecteur peut en prendre conscience à travers l'exemple suivant.

Nous avons démontré, par des calculs de convolution complexes, l'additivité des lois binomiale, de Poisson, Gamma et du khi-deux. Nous pouvons maintenant démontrer très simplement l'additivité de la loi normale à l'aide des fonctions caractéristiques.

Soient $X \sim N(\mu_1, \sigma_1^2)$ et $Y \sim N(\mu_2, \sigma_2^2)$ indépendantes. Leurs fonctions caractéristiques sont

$$\phi_X(t) = e^{i\mu_1 t - \frac{\sigma_1^2 t^2}{2}}, \quad \phi_Y(t) = e^{i\mu_2 t - \frac{\sigma_2^2 t^2}{2}}.$$

Par la propriété 4.2.4,

$$\phi_{X+Y}(t) = \phi_X(t) \phi_Y(t) = e^{i(\mu_1 + \mu_2)t - \frac{(\sigma_1^2 + \sigma_2^2)t^2}{2}},$$

qui est la fonction caractéristique de $N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$. Par le théorème d'unicité, $X + Y \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

De même, si les X_j sont indépendantes et $X_j \sim N(\mu_j, \sigma_j^2)$, $j = 1, \dots, n$, alors

$$\sum_{j=1}^n X_j \sim N\left(\sum_{j=1}^n \mu_j, \sum_{j=1}^n \sigma_j^2\right).$$

Soit une variable aléatoire continue de fonction caractéristique donnée ; déterminer sa loi : (1) $\phi_1(t) = e^{-|t|}$; (2) $\phi_2(t) = \frac{\sin at}{at}$.

Solution : (1) Par la formule d'inversion, la densité est

$$\begin{aligned} p(x) &= \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{-itx} e^{-|t|} dt \\ &= \frac{1}{2\pi} \left(\int_0^{\infty} e^{-(1+ix)t} dt + \int_{-\infty}^0 e^{(1-ix)t} dt \right) \end{aligned}$$

$$= \frac{1}{2\pi} \left(\frac{1}{1+ix} + \frac{1}{1-ix} \right) = \frac{1}{\pi(1+x^2)}.$$

C'est la loi de Cauchy. Donc $\phi_1(t) = e^{-|t|}$ correspond à la loi de Cauchy.

(2) $\phi_2(t) = \frac{\sin at}{at}$ est la fonction caractéristique de la loi uniforme $U(-a, a)$; par le théorème d'unicité, la loi correspondante est précisément la loi uniforme $U(-a, a)$.

Le théorème suivant établit l'équivalence entre la convergence faible des fonctions de répartition et la convergence ponctuelle des fonctions caractéristiques correspondantes.

Théorème 2.6 (Théorème de continuité de Lévy). *La suite de fonctions de répartition $\{F_n(x)\}$ converge faiblement vers la fonction de répartition $F(x)$ si et seulement si la suite des fonctions caractéristiques $\{\phi_n(t)\}$ converge ponctuellement vers la fonction caractéristique $\phi(t)$ de F .*

La démonstration (relativement longue) repose sur des résultats d'analyse mathématique et n'est pas donnée ici (voir référence [1]). On appelle souvent ce théorème théorème de continuité des fonctions caractéristiques car il montre que la correspondance bi-nivoque entre fonction de répartition et fonction caractéristique est continue.

Si X_n suit une loi de Poisson de paramètre λ , montrer que

$$\lim_{n \rightarrow \infty} P \left(\frac{X_n - \lambda}{\sqrt{\lambda}} \leq x \right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt.$$

Solution : La fonction caractéristique de X_n est $\phi_n(t) = \exp\{\lambda(e^{it} - 1)\}$. Donc celle de $Y_n = (X_n - \lambda)/\sqrt{\lambda}$ est

$$g_\lambda(t) = \phi_\lambda \left(\frac{t}{\sqrt{\lambda}} \right) e^{-i\sqrt{\lambda}t} = \exp \left\{ \lambda \left(e^{it/\sqrt{\lambda}} - 1 \right) - i\sqrt{\lambda}t \right\}.$$

Pour tout t , on a le développement

$$e^{it/\sqrt{\lambda}} = 1 + \frac{it}{\sqrt{\lambda}} - \frac{t^2}{2\lambda} + o \left(\frac{1}{\lambda} \right).$$

Alors

$$\lambda \left(e^{it/\sqrt{\lambda}} - 1 \right) - i\sqrt{\lambda}t = -\frac{t^2}{2} + o(1) \rightarrow -\frac{t^2}{2}, \quad \lambda \rightarrow \infty.$$

D'où $\lim_{\lambda \rightarrow \infty} g_\lambda(t) = e^{-t^2/2}$, fonction caractéristique de $N(0, 1)$. Par le théorème de continuité, la conclusion suit.

3 Lois des grands nombres

Il existe plusieurs formes de lois des grands nombres. Nous commençons par la plus simple, la loi des grands nombres de Bernoulli, puis introduisons progressivement diverses lois des grands nombres.

3.1 Loi des grands nombres de Bernoulli

Notons S_n le nombre d'occurrences de l'événement A dans n épreuves de Bernoulli ; on appelle S_n/n la fréquence de l'événement A .

Si l'on note p la probabilité que A se réalise lors d'une épreuve, alors S_n suit la loi binomiale $b(n, p)$; par conséquent, l'espérance et la variance de la fréquence S_n/n sont

$$E\left(\frac{S_n}{n}\right) = p, \quad \text{Var}\left(\frac{S_n}{n}\right) = \frac{p(1-p)}{n}.$$

Étudions maintenant, lorsque $n \rightarrow \infty$, le comportement limite de l'écart absolu $\left|\frac{S_n}{n} - p\right|$.

Selon le concept de limite d'une suite en analyse mathématique, si $\{S_n\}$ est une suite numérique, alors $\left\{\frac{S_n}{n}\right\}$ tend vers p signifie que pour tout $\epsilon > 0$, lorsque n est suffisamment grand, l'écart absolu est nécessairement inférieur à ϵ , c'est-à-dire

$$\left|\frac{S_n}{n} - p\right| < \epsilon.$$

Cependant, lorsque S_n est le nombre de succès (occurrence de A) dans n épreuves de Bernoulli (c'est une variable aléatoire), le phénomène ci-dessus ne se produit pas ; on ne peut pas espérer que pour tout point ω (une séquence de 0 et 1 de longueur n), l'écart absolu de la fréquence S_n/n par rapport à p soit inférieur à ϵ . Même pour un $\epsilon > 0$ très petit et un n très grand, on ne peut pas espérer que l'inégalité

$$\left|\frac{S_n}{n} - p\right| \leq \epsilon, \quad \omega \in \Omega \quad (4.3.2)$$

soit vérifiée pour tout ω . Par exemple, pour $0 < p < 1$,

$$P\left(\frac{S_n}{n} = 1\right) = P(X_1 = 1, X_2 = 1, \dots, X_n = 1) = p^n,$$

$$P\left(\frac{S_n}{n} = 0\right) = P(X_1 = 0, X_2 = 0, \dots, X_n = 0) = (1-p)^n.$$

Pour un $\epsilon > 0$ suffisamment petit, l'inégalité n'est pas toujours vraie.

Cependant, nous devons noter que lorsque n est grand, les probabilités des événements $\{S_n/n = 1\}$ et $\{S_n/n = 0\}$ sont très faibles ; nous espérons donc que la probabilité d'un grand écart $|S_n/n - p| \geq \epsilon$ soit également très petite, et qu'elle devienne de plus en plus petite à mesure que n augmente. Nous souhaitons en particulier l'énoncé probabiliste suivant :

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - p\right| \geq \epsilon\right) = 0.$$

La loi des grands nombres de Bernoulli ci-dessous résume parfaitement la discussion ci-dessus et apporte une réponse positive.

Théorème 3.1 (Loi des grands nombres de Bernoulli). *Soit S_n le nombre d'occurrences de l'événement A dans n épreuves de Bernoulli, et p la probabilité d'apparition de A à chaque épreuve. Alors, pour tout $\epsilon > 0$,*

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - p\right| < \epsilon\right) = 1.$$

Proof. Comme $S_n \sim b(n, p)$, l'espérance et la variance de $\frac{S_n}{n}$ sont données. Par l'inégalité de Tchebychev, on obtient

$$1 \geq P\left(\left|\frac{S_n}{n} - p\right| < \epsilon\right) \geq 1 - \frac{\text{Var}\left(\frac{S_n}{n}\right)}{\epsilon^2} = 1 - \frac{p(1-p)}{n\epsilon^2}.$$

Lorsque $n \rightarrow \infty$, le membre de droite tend vers 1, donc

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - p\right| < \epsilon\right) = 1.$$

□

La loi des grands nombres de Bernoulli exprime que, lorsque n augmente, la probabilité que l'écart entre la fréquence $\frac{S_n}{n}$ et la probabilité p dépasse une précision donnée ϵ devient de plus en plus faible, aussi faible qu'on le souhaite. C'est le sens de la fréquence se stabilise autour de la probabilité.

Par exemple, lançons une pièce de monnaie pour laquelle la probabilité d'obtenir face est $p = 0.5$. Si l'on lance cette pièce 10 fois, comme n est petit, la probabilité d'un écart peut parfois être grande, parfois petite. Si l'on lance cette pièce 100 000 fois, d'après l'inégalité de Tchebychev, la probabilité que la fréquence d'apparition de face s'écarte de 0.5 de plus que la précision donnée ϵ (par exemple, prenons $\epsilon = 0.01$) est

$$P\left(\left|\frac{S_n}{n} - 0.5\right| > 0.01\right) \leq \frac{0.5 \times 0.5}{n \times 0.01^2} = \frac{10^4}{4n}.$$

La probabilité qu'un grand écart se produise est inférieure à $1/40 = 2.5\%$ lorsque $n = 10^4$, et inférieure à 0.25% lorsque $n = 10^6$. On voit ainsi que plus le nombre d'essais est grand, plus la probabilité d'un grand écart est faible.

La loi des grands nombres de Bernoulli fournit une justification théorique pour l'utilisation de la fréquence comme estimateur de la probabilité. Par exemple, pour estimer le taux p de produits conformes dans un lot, on peut prélever n produits au hasard dans ce lot ; lorsque n est grand, la proportion de produits non conformes dans ces n produits peut servir d'estimation du taux p de produits non conformes.

Exemple 3.1 (Méthode de Monte Carlo pour le calcul d'une intégrale (méthode du tirage aléatoire de points)). Soit $0 \leq f(x) \leq 1$, et cherchons la valeur de l'intégrale de $f(x)$ sur l'intervalle $[0, 1]$:

$$J = \int_0^1 f(x) dx.$$

Soit (X, Y) un couple de variables aléatoires uniforme sur le carré $[0 \leq x \leq 1, 0 \leq y \leq 1]$; alors X suit la loi uniforme sur $[0, 1]$, Y suit également la loi uniforme sur $[0, 1]$, et X et Y sont indépendantes. Définissons l'événement

$$A = \{Y \leq f(X)\}.$$

La probabilité de A est

$$p = P(Y \leq f(X)) = \int_0^1 \int_0^{f(x)} dy dx = \int_0^1 f(x) dx = J,$$

c'est-à-dire que la valeur de l'intégrale J est précisément la probabilité p de l'événement A (voir figure 4.3.1). D'après la loi des grands nombres de Bernoulli, on peut utiliser la fréquence d'apparition de A dans des épreuves répétées comme estimateur de p . Cette méthode de calcul d'intégrale est également appelée méthode du tirage aléatoire de points : on considère (X, Y) comme un point tiré au hasard dans le carré $[0 \leq x \leq 1, 0 \leq y \leq 1]$, et on utilise la fréquence des points tombant dans la région $\{y \leq f(x)\}$ comme approximation de l'intégrale.

Voici comment obtenir la fréquence de A par la méthode de Monte Carlo : (1) Utiliser un ordinateur pour générer $2n$ nombres aléatoires uniformes sur $(0, 1)$, formant n paires (x_i, y_i) , $i = 1, 2, \dots, n$, avec n grand (par exemple $n = 10^4$ ou $n = 10^5$).

(2) Pour chaque paire (x_i, y_i) , $i = 1, 2, \dots, n$, compter le nombre de fois que l'inégalité $y_i \leq f(x_i)$ est vérifiée ; c'est la fréquence S_n de l'événement A . On a alors l'approximation $J \approx \frac{S_n}{n}$.

Par exemple, pour calculer $\int_0^1 \frac{e^{-x^2/2}}{\sqrt{2\pi}} dx$, la valeur exacte et les valeurs simulées pour $n = 10^4$ et $n = 10^5$ sont :

Exact	$n = 10^4$	$n = 10^5$
0.341344	0.340698	0.341355

Remarque : pour une intégrale sur un intervalle $[a, b]$ quelconque,

$$J' = \int_a^b g(x) dx,$$

on effectue le changement de variable linéaire $y = (x - a)/(b - a)$ pour se ramener à une intégrale sur $[0, 1]$. De plus, si $c \leq g(x) \leq d$, on pose

$$f(y) = \frac{1}{d - c} [g(a + (b - a)y) - c],$$

de sorte que $0 \leq f(y) \leq 1$. Alors

$$J' = \int_a^b g(x) dx = S_0 \int_0^1 f(y) dy + c(b - a),$$

avec $S_0 = (b - a)(d - c)$. Ceci montre que la méthode de Monte Carlo pour le calcul d'intégrales décrite ci-dessus a un caractère général.

3.2 Quelques lois des grands nombres usuelles

3.2.1 Forme générale d'une loi des grands nombres

La loi des grands nombres de Bernoulli traite d'une suite de variables aléatoires indépendantes et identiquement distribuées (i.i.d.) $\{X_n\}$ dont la loi commune est une loi de Bernoulli $b(1, p)$. Posons

$$X_i = \begin{cases} 1 & \text{si } A \text{ se réalise à la } i\text{-ème épreuve,} \\ 0 & \text{sinon.} \end{cases}$$

Alors $\{X_n\}$ est une suite de variables aléatoires indépendantes de Bernoulli. Considérons la somme des n premières variables

$$S_n = \sum_{i=1}^n X_i.$$

La moyenne arithmétique est $\frac{Y_n}{n} = \frac{1}{n} \sum_{i=1}^n X_i$, et son espérance est $E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i)$.

La loi des grands nombres de Bernoulli s'énonce alors : pour tout $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \epsilon\right) = 1.$$

3.2.2 Loi des grands nombres de Tchebychev

En utilisant l'inégalité de Tchebychev, on démontre la loi des grands nombres de Tchebychev.

Théorème 3.2 (Loi des grands nombres de Tchebychev). *Soit $\{X_n\}$ une suite de variables aléatoires deux à deux non corrélées, dont les variances existent et sont bornées supérieurement par une constante commune, c'est-à-dire $\text{Var}(X_i) \leq c$, $i = 1, 2, \dots$. Alors $\{X_n\}$ vérifie la loi des grands nombres.*

Proof. Comme les $\{X_n\}$ sont deux à deux non corrélées,

$$\text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) \leq \frac{c}{n}.$$

Par l'inégalité de Tchebychev, pour tout $\epsilon > 0$,

$$P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \epsilon\right) \geq 1 - \frac{\text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right)}{\epsilon^2} \geq 1 - \frac{c}{n\epsilon^2}.$$

Lorsque $n \rightarrow \infty$, le membre de droite tend vers 1, donc

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right| < \epsilon\right) = 1.$$

□

Notons que la loi des grands nombres de Tchebychev n'exige que les $\{X_n\}$ soient deux à deux non corrélées, et non qu'elles soient identiquement distribuées. Par conséquent, si $\{X_n\}$ est une suite i.i.d. de variance finie, elle vérifie la loi des grands nombres. La loi des grands nombres de Bernoulli est un cas particulier de celle de Tchebychev.

Exemple 3.2. Soit $\{X_n\}$ une suite i.i.d. avec $E(X_n^4) < \infty$. Posons $E(X_n) = \mu$, $\text{Var}(X_n) = \sigma^2$. Considérons

$$Y_n = (X_n - \mu)^2, \quad n = 1, 2, \dots$$

Alors la suite $\{Y_n\}$ vérifie la loi des grands nombres, c'est-à-dire que pour tout $\epsilon > 0$,

$$\lim_{n \rightarrow \infty} P \left(\left| \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 - \sigma^2 \right| \geq \epsilon \right) = 0.$$

Proof. $\{Y_n\}$ est une suite i.i.d. Sa variance est

$$\text{Var}(Y_n) = \text{Var}((X_n - \mu)^2) = E(X_n - \mu)^4 - \sigma^4.$$

Comme $E(X_n^4)$ existe, $E(X_n^4)$, $E((X_n - \mu)^4)$ existent également. Par la loi des grands nombres de Tchebychev,

$$\lim_{n \rightarrow \infty} P \left(\left| \frac{1}{n} \sum_{i=1}^n Y_i - \frac{1}{n} \sum_{i=1}^n E(Y_i) \right| \geq \epsilon \right) = 0.$$

Or $\frac{1}{n} \sum_{i=1}^n E(Y_i) = \sigma^2$. Donc $\{Y_n\}$ vérifie la loi des grands nombres. $\square$

3.2.3 Loi des grands nombres de Markov

On remarque que dans les démonstrations précédentes, il suffit que la condition

$$\frac{1}{n^2} \text{Var} \left(\sum_{i=1}^n X_i \right) \rightarrow 0$$

soit vérifiée pour que la loi des grands nombres s'applique. Cette condition est appelée condition de Markov.

Théorème 3.3 (Loi des grands nombres de Markov). *Pour une suite de variables aléatoires $\{X_n\}$, si la condition est satisfaite, alors $\{X_n\}$ vérifie la loi des grands nombres.*

Proof. Elle découle immédiatement de l'inégalité de Tchebychev. $\square$

L'importance de la loi des grands nombres de Markov réside dans le fait qu'elle ne fait aucune hypothèse d'indépendance, de corrélation ou d'identique distribution sur $\{X_n\}$. La loi des grands nombres de Tchebychev est évidemment un cas particulier de celle de Markov.

Exemple 3.3. Soit $\{X_n\}$ une suite de variables aléatoires identiquement distribuées, de variance finie, et telle que X_n ne soit corrélée qu'avec ses voisins X_{n-1} et X_{n+1} , et non corrélée avec les autres X_i . Cette suite vérifie-t-elle la loi des grands nombres ?

Proof. $\{X_n\}$ est une suite de variables dépendantes. Examinons la condition de Markov :

$$\frac{1}{n^2} \text{Var} \left(\sum_{i=1}^n X_i \right) = \frac{1}{n^2} \left[\sum_{i=1}^n \text{Var}(X_i) + 2 \sum_{i=1}^{n-1} \text{Cov}(X_i, X_{i+1}) \right].$$

Notons $\text{Var}(X_n) = \sigma^2$; alors $|\text{Cov}(X_i, X_j)| \leq \sigma^2$. Ainsi,

$$\frac{1}{n^2} \text{Var} \left(\sum_{i=1}^n X_i \right) \leq \frac{1}{n^2} [n\sigma^2 + 2(n-1)\sigma^2] \rightarrow 0 \quad (n \rightarrow \infty).$$

La condition de Markov est donc vérifiée, et la suite $\{X_n\}$ obéit à la loi des grands nombres. $\square$

3.2.4 Loi des grands nombres de Khinchine

On sait que si une variable aléatoire a une variance finie, alors son espérance existe ; la réciproque est fautive : une variable aléatoire peut avoir une espérance finie sans avoir de variance finie. Les lois des grands nombres précédentes supposent l'existence des variances. La loi des grands nombres de Khinchine supprime cette hypothèse en ne supposant que l'existence des espérances, mais exige en revanche que $\{X_n\}$ soit une suite i.i.d. La loi des grands nombres de Bernoulli est également un cas particulier de celle de Khinchine.

Théorème 3.4 (Loi des grands nombres de Khinchine). *Soit $\{X_n\}$ une suite de variables aléatoires i.i.d. dont les espérances existent. Alors $\{X_n\}$ vérifie la loi des grands nombres.*

Proof. Soit $E(X_i) = a, i = 1, 2, \dots$. On veut montrer que

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{P} a, \quad n \rightarrow \infty.$$

Posons $Y_n = \frac{1}{n} \sum_{k=1}^n X_k$. il suffit de montrer $Y_n \xrightarrow{L} a$. Par le théorème de continuité, il suffit de montrer que $\phi_{Y_n}(t) \rightarrow e^{iat}$. Comme les $\{X_n\}$ sont identiquement distribuées, elles ont la même fonction caractéristique, notée $\phi(t)$. De plus, $\phi'(0) = iE(X_i) = ia$, donc $\phi(t)$ admet le développement en 0 :

$$\phi(t) = \phi(0) + \phi'(0)t + o(t) = 1 + iat + o(t).$$

Par l'indépendance, la fonction caractéristique de Y_n est

$$\phi_{Y_n}(t) = \left[\phi\left(\frac{t}{n}\right) \right]^n = \left[1 + ia\frac{t}{n} + o\left(\frac{1}{n}\right) \right]^n.$$

Pour tout t ,

$$\lim_{n \rightarrow \infty} \left[\phi\left(\frac{t}{n}\right) \right]^n = \lim_{n \rightarrow \infty} \left[1 + ia\frac{t}{n} + o\left(\frac{1}{n}\right) \right]^n = e^{iat}.$$

Or e^{iat} est la fonction caractéristique de la loi dégénérée en a . Ainsi $Y_n \xrightarrow{P} a$. $\square$

La loi des grands nombres de Khinchine fournit une méthode pour estimer l'espérance $E(X)$ d'une variable aléatoire X : on répète n observations indépendantes de X , notées $X_1, X_2, \dots, X_n$; alors, sous réserve que $E(X)$ existe, la loi des grands nombres de Khinchine garantit que pour n suffisamment grand, la moyenne des observations

$$\frac{1}{n} \sum_{i=1}^n X_i$$

est une approximation de $E(X)$. L'avantage de cette méthode est que l'on n'a pas besoin de connaître la distribution de X ; le seul objectif est d'obtenir une valeur approchée de l'espérance.

En fait, l'utilisation de la moyenne d'observations pour approcher l'espérance d'une variable aléatoire est courante dans la vie réelle. Par exemple, utiliser la durée de vie moyenne de 5000 personnes dans une région comme approximation de la durée de vie moyenne dans cette région est approprié ; cette pratique repose sur la loi des grands nombres de Khinchine.

De la loi des grands nombres de Khinchine, on déduit facilement que si $\{X_n\}$ est une suite i.i.d. et si $E(|X_i|^k)$ existe (où k est un entier positif), alors $\{X_n^k\}$ vérifie la loi des grands nombres. Cette conclusion est très utile en statistique mathématique : on peut utiliser $\frac{1}{n} \sum_{i=1}^n X_i^k$ comme approximation de $E(X_i^k)$.

Exemple 3.4 (Méthode de Monte Carlo pour le calcul d'une intégrale (méthode de la moyenne)). Calculons l'intégrale

$$J = \int_0^1 f(x) dx.$$

Soit X une variable aléatoire uniforme sur $(0, 1)$. Alors $Y = f(X)$ a pour espérance

$$E(f(X)) = \int_0^1 f(x) dx = J.$$

Estimer J revient donc à estimer $E(f(X))$. D'après la loi des grands nombres de Khinchine, on peut estimer J par la moyenne des observations de $f(X)$. Voici la procédure : on génère n nombres aléatoires x_i , $i = 1, 2, \dots, n$, uniformes sur $(0, 1)$; pour chaque x_i , on calcule $f(x_i)$; finalement, l'estimateur de J est

$$\hat{J} = \frac{1}{n} \sum_{i=1}^n f(x_i).$$

Par exemple, pour $\int_0^1 e^{-x^2/2} / \sqrt{2\pi} dx$, la valeur exacte et les valeurs simulées pour $n = 10^4$ et $n = 10^5$ sont données dans le tableau suivant :

Exact	$n = 10^4$	$n = 10^5$
0.341344	0.340698	0.341355

Remarque : pour une intégrale sur un intervalle $[a, b]$ quelconque et une fonction $g(x)$ telle que $c \leq g(x) \leq d$, on se ramène au cas précédent par changement de variable affine, puis on applique la méthode de la moyenne.

4 Théorème central limite

4.1 Somme de variables aléatoires indépendantes

La loi des grands nombres discute, sous quelles conditions, la moyenne arithmétique d'une suite de variables aléatoires converge en probabilité vers la moyenne de leurs espérances. Maintenant, nous discutons, sous quelles conditions, la fonction de répartition de la somme de variables aléatoires indépendantes

$$Y_n = \sum_{i=1}^n X_i$$

converge vers une loi normale. Donnons d'abord un exemple de somme de variables aléatoires indépendantes.

Exemple 4.1. L'erreur est une variable aléatoire fréquemment rencontrée et intéressante ; de nombreuses études montrent que l'erreur est la somme d'un grand nombre de petites fluctuations aléatoires indépendantes. Par exemple, un opérateur usine des arbres mécaniques pour respecter un diamètre spécifié, mais il y a toujours un écart par rapport à la valeur requise. Cet écart est dû à de nombreux facteurs aléatoires :

- Côté machine : vibrations, vitesse de rotation.
- Côté outil : montage, usure.
- Côté matériau : composition de l'acier, provenance.
- Côté opérateur : niveau d'attention, humeur du jour.
- Côté mesure : erreur d'instrument, technique de mesure.
- Côté environnement : température, humidité, éclairage, tension du réseau.
- On pourrait encore lister d'autres facteurs.

Ces nombreux facteurs ont chacun un effet très faible sur la précision d'usinage ; leur présence est aléatoire, incontrôlable, parfois présente, parfois absente, parfois grande, parfois petite, parfois positive, parfois négative. La combinaison de ces facteurs produit finalement une erreur sur le diamètre de chaque arbre. Notons cette erreur par Y_n ; c'est une variable aléatoire que l'on peut considérer comme la somme de nombreuses petites fluctuations aléatoires $X_1, X_2, \dots, X_n$:

$$Y_n = X_1 + X_2 + \dots + X_n,$$

où n est grand. On se demande quelle est la distribution de Y_n lorsque $n \rightarrow \infty$.

Bien sûr, on pourrait utiliser la formule de convolution pour calculer la distribution de Y_n , mais ce calcul est très complexe et difficile à mettre en œuvre, comme le montre l'exemple suivant.

Exemple 4.2. Soit $\{X_n\}$ une suite i.i.d. de loi uniforme sur $(0, 1)$. Posons $Y_n = \sum_{i=1}^n X_i$, et notons $p_n(y)$ la densité de Y_n . Par convolution, on obtient :

$$p_1(y) = 1, \quad 0 < y < 1,$$

$$p_2(y) = \begin{cases} y, & 0 < y < 1 \\ 2 - y, & 1 \leq y < 2 \end{cases}$$

$$p_3(y) = \begin{cases} \frac{1}{2}y^2, & 0 < y < 1 \\ \frac{1}{2}(-2y^2 + 6y - 3), & 1 \leq y < 2 \\ \frac{1}{2}(3 - y)^2, & 2 \leq y < 3 \end{cases}$$

$$p_4(y) = \frac{1}{6} \begin{cases} y^3, & 0 < y < 1 \\ -3y^3 + 12y^2 - 12y + 4, & 1 \leq y < 2 \\ 3y^3 - 24y^2 + 60y - 44, & 2 \leq y < 3 \\ (4-y)^3, & 3 \leq y < 4 \end{cases}$$

On observe que lorsque n augmente, la courbe de $p_n(y)$ devient de plus en plus lisse et se rapproche de plus en plus d'une courbe normale.

On peut imaginer que pour $n = 100$, la densité $p_{100}(x)$ est non nulle sur $(0, 100)$; son expression par convolution nécessite de la décomposer en 100 tronçons, chacun étant un polynôme de degré 99. Une forme aussi complexe, même si on pouvait l'obtenir, serait inutilisable. Cela oblige à rechercher une distribution approchée. Si on note $F_n(x)$ la fonction de répartition de Y_n , on cherche sa distribution limite $F(x)$ au sens de la convergence faible ; alors pour n grand, on pourra approcher F_n par F .

Pour que la recherche de la limite de Y_n ait un sens, il faut d'abord bien poser le problème. On remarque que lorsque n augmente, le centre de $p_n(y)$ se déplace vers la droite et sa variance augmente. Cela signifie que lorsque $n \rightarrow \infty$, le centre de la distribution tend vers ∞ et la variance tend aussi vers ∞ ; la distribution devient très instable. Pour remédier à cet inconvénient, on standardise Y_n dans l'étude du théorème central limite :

$$Y_n^* = \frac{Y_n - E(Y_n)}{\sqrt{\text{Var}(Y_n)}}.$$

On a alors $E(Y_n^*) = 0$, $\text{Var}(Y_n^*) = 1$, ce qui permet d'examiner si la limite de Y_n^* est la loi normale centrée réduite $N(0, 1)$.

Le théorème central limite étudie la question : sous quelles conditions la distribution limite d'une somme de variables aléatoires normalisée est-elle la loi normale ?

4.2 Théorème central limite pour des variables indépendantes et identiquement distribuées

Théorème 4.1 (Théorème central limite de Lindeberg–Lévy). *Soit $\{X_n\}$ une suite i.i.d. avec $E(X_i) = \mu$ et $\text{Var}(X_i) = \sigma^2 > 0$. Posons*

$$Y_n^* = \frac{X_1 + X_2 + \cdots + X_n - n\mu}{\sigma\sqrt{n}}.$$

Alors pour tout réel y ,

$$\lim_{n \rightarrow \infty} P(Y_n^* \leq y) = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-t^2/2} dt.$$

Proof. il suffit de montrer que la suite des fonctions de répartition de $\{Y_n^*\}$ converge faiblement vers la loi normale centrée réduite. Par le théorème, il suffit de montrer que la suite des fonctions caractéristiques de $\{Y_n^*\}$ converge vers la fonction caractéristique de $N(0, 1)$. Soit $\phi(t)$ la fonction caractéristique de $X_n - \mu$. Alors la fonction caractéristique de Y_n^* est

$$\phi_{Y_n^*}(t) = \left[\phi\left(\frac{t}{\sigma\sqrt{n}}\right) \right]^n.$$

Comme $E(X_n - \mu) = 0$ et $\text{Var}(X_n - \mu) = \sigma^2$, on a $\phi'(0) = 0$, $\phi''(0) = -\sigma^2$. Le développement de Taylor donne

$$\phi(t) = 1 - \frac{\sigma^2 t^2}{2} + o(t^2).$$

Ainsi,

$$\phi\left(\frac{t}{\sigma\sqrt{n}}\right) = 1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right).$$

Par conséquent,

$$\lim_{n \rightarrow \infty} \phi_{Y_n^*}(t) = \lim_{n \rightarrow \infty} \left[1 - \frac{t^2}{2n} + o\left(\frac{1}{n}\right)\right]^n = e^{-t^2/2},$$

qui est la fonction caractéristique de $N(0, 1)$. Le théorème est démontré. $\square$

Ce théorème ne suppose que l'indépendance, l'identique distribution et l'existence de la variance. Quelle que soit la distribution d'origine, pour n suffisamment grand, on peut approcher la distribution de la somme normalisée par la loi normale. Ce théorème a donc de nombreuses applications. Il révèle notamment que les erreurs de mesure suivent approximativement une loi normale.

Exemple 4.3 (Génération de nombres aléatoires normaux). Dans les méthodes de simulation de Monte Carlo, on a souvent besoin de générer des nombres aléatoires suivant $N(\mu, \sigma^2)$. La plupart des logiciels statistiques proposent cette fonctionnalité. Comment est-elle implémentée ? L'exemple suivant utilise le théorème central limite à partir de nombres uniformes sur $(0, 1)$.

Soit X uniforme sur $(0, 1)$; son espérance est $1/2$ et sa variance $1/12$. La somme de 12 variables uniformes indépendantes sur $(0, 1)$ a donc pour espérance 6 et pour variance 1. On peut donc produire un nombre aléatoire normal $N(\mu, \sigma^2)$ de la manière suivante : (1) Générer 12 nombres aléatoires uniformes sur $(0, 1)$: $x_1, x_2, \dots, x_{12}$. (2) Calculer $y = \sum_{i=1}^{12} x_i - 6$. D'après le théorème de Lindeberg-Lévy, y peut être considéré comme une réalisation approximative de $N(0, 1)$. (3) Calculer $z = \mu + \sigma y$; z est alors une réalisation approximative de $N(\mu, \sigma^2)$. (4) Répéter (1)–(3) n fois pour obtenir n nombres aléatoires suivant $N(\mu, \sigma^2)$.

Exemple 4.4 (Analyse des erreurs en calcul numérique). En calcul numérique, tout réel x est approximé par un nombre x' ayant un nombre limité de décimales. Par exemple, avec 5 décimales, on arrondit la sixième décimale. Soient $\pi = 3,141592654\dots$ et $e = 2,718281828\dots$; leurs approximations sont $\pi' = 3,14159$ et $e' = 2,71828$.

Si l'on veut calculer la somme S de n réels x_i ($i = 1, \dots, n$), on utilise en pratique les approximations x'_i . Les erreurs individuelles sont $\epsilon_i = x_i - x'_i$. L'erreur totale est

$$S - S' = \sum_{i=1}^n \epsilon_i.$$

Si l'on conserve k décimales, on peut considérer que chaque ϵ_i suit une loi uniforme sur $(-0,5 \times 10^{-k}, 0,5 \times 10^{-k})$ et que les ϵ_i sont indépendants. Estimons l'erreur totale. Une estimation grossière est $|\epsilon_i| \leq 0,5 \times 10^{-k}$, d'où

$$\left| \sum_{i=1}^n \epsilon_i \right| \leq n \times 0,5 \times 10^{-k}.$$

Utilisons maintenant le théorème central limite. Comme les ϵ_i sont i.i.d. avec

$$E(\epsilon_i) = 0, \quad \text{Var}(\epsilon_i) = \frac{10^{-2k}}{12},$$

l'erreur totale a pour espérance 0 et pour variance $n10^{-2k}/12$. Par le théorème central limite, pour tout $z > 0$,

$$P\left(\left|\sum_{i=1}^n \epsilon_i\right| \leq z\right) \approx 2\Phi\left(\frac{z\sqrt{12}}{\sqrt{n}10^{-k}}\right) - 1.$$

En fixant cette probabilité à 0,99, on trouve $\Phi\left(\frac{z\sqrt{12}}{\sqrt{n}10^{-k}}\right) = 0,995$, d'où $\frac{z\sqrt{12}}{\sqrt{n}10^{-k}} = 2,576$, et

$$z = 2,576 \frac{\sqrt{n}10^{-k}}{\sqrt{12}} \approx 0,7436 \sqrt{n} 10^{-k}.$$

Ainsi, avec une confiance de 99%, on a

$$\left|\sum_{i=1}^n \epsilon_i\right| \leq 0,7436 \sqrt{n} 10^{-k}.$$

Par exemple, avec $k = 5$ (5 décimales) et $n = 10000$, l'estimation grossière donne 0,05, tandis que donne 0,0007436 (environ $7,4 \times 10^{-4}$).

Cet exemple montre que le théorème central limite permet non seulement d'obtenir une borne supérieure pour l'erreur totale, mais aussi d'évaluer le niveau de confiance.

4.3 Approximation normale de la loi binomiale

En appliquant le théorème de Lindeberg–Lévy à des variables de Bernoulli, on obtient immédiatement le théorème central limite de de Moivre–Laplace.

Théorème 4.2 (Théorème central limite de de Moivre–Laplace). *Soit n le nombre d'épreuves de Bernoulli, p ($0 < p < 1$) la probabilité de succès à chaque épreuve, et S_n le nombre de succès. Alors, pour tout réel y ,*

$$\lim_{n \rightarrow \infty} P\left(\frac{S_n - np}{\sqrt{np(1-p)}} \leq y\right) = \Phi(y) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^y e^{-t^2/2} dt.$$

Ce théorème est historiquement le premier théorème central limite. On parle d'approximation normale de la loi binomiale. Le théorème de Poisson donne l'approximation de Poisson de la loi binomiale. En général, lorsque p est petit, l'approximation de Poisson est meilleure ; lorsque $np > 5$ et $n(1-p) > 5$, c'est l'approximation normale qui est préférable.

Avant d'appliquer le théorème de de Moivre–Laplace, deux points sont à noter : (1) La loi binomiale est discrète tandis que la loi normale est continue. Pour améliorer la précision, on utilise souvent une correction de continuité. Si $k_1 < k_2$ sont des entiers, on approxime

$$P(k_1 \leq S_n \leq k_2) = P(k_1 - 0,5 < S_n < k_2 + 0,5).$$

Par exemple, pour $S_n \sim b(25, 0, 4)$, la valeur exacte de $P(5 \leq S_n \leq 15)$ est 0,9780. L'approximation avec correction donne 0,9754, sans correction 0,9588.

(2) On peut aussi approximer une probabilité ponctuelle :

$$P(S_n = k) \approx \frac{1}{\sqrt{2\pi npq}} \exp\left(-\frac{(k + 0,5 - np)^2}{2npq}\right).$$

Trois types de problèmes peuvent être résolus à l'aide de cette approximation :

- Connaissant n et y , trouver $\beta = P(Y_n^* \leq y)$.
- Connaissant n et β , trouver y (quantile).
- Connaissant y et β , trouver n (taille d'échantillon).

4.3.1 Premier type : connaissant n et y , trouver β (probabilité)

Exemple 4.5. Un système complexe est constitué de 100 composants fonctionnant indépendamment, chacun avec une probabilité 0,9 de fonctionner. Le système fonctionne si au moins 85 composants fonctionnent. Quelle est la probabilité que le système fonctionne ?

Proof. Soit Y_n le nombre de composants fonctionnant sur 100. Alors $Y_n \sim b(100, 0, 9)$, $E(Y_n) = 90$, $\text{Var}(Y_n) = 9$. La probabilité recherchée est

$$P(Y_n \geq 85) \approx 1 - \Phi\left(\frac{85 - 0,5 - 90}{3}\right) = 1 - \Phi(-1,833) = \Phi(1,833) = 0,9664.$$

□

Exemple 4.6. Un laboratoire pharmaceutique produit un médicament dont l'efficacité déclarée est de 80%. Pour vérifier ce taux, on effectue un essai sur 100 patients. Si au moins 75 guérissent, le médicament est approuvé. Calculer la probabilité d'approbation dans deux cas : (1) le vrai taux de guérison est 80% ; (2) le vrai taux est 70%.

Proof. (1) $Y_n \sim b(100, 0, 8)$, $E = 80$, $\text{Var} = 16$:

$$P(Y_n \geq 75) \approx 1 - \Phi\left(\frac{75 - 0,5 - 80}{4}\right) = 1 - \Phi(-1,375) = \Phi(1,375) = 0,9155.$$

(2) $Y_n \sim b(100, 0, 7)$, $E = 70$, $\text{Var} = 21$:

$$P(Y_n \geq 75) \approx 1 - \Phi\left(\frac{75 - 0,5 - 70}{\sqrt{21}}\right) = 1 - \Phi(0,982) = 1 - 0,8370 = 0,1630.$$

□

4.3.2 Deuxième type : connaissant n et β , trouver y (quantile)

Exemple 4.7. Un atelier dispose de 200 machines identiques. Chaque machine fonctionne 70% du temps pendant une heure donnée, et les fonctionnements sont indépendants. Chaque machine consomme 15 kW. Quelle puissance électrique minimale faut-il fournir pour que la probabilité de pouvoir alimenter l'atelier soit d'au moins 95% ?

Proof. Soit Y_n le nombre de machines fonctionnant simultanément, $n = 200$, $p = 0,7$. Alors $E(Y_n) = 140$, $\text{Var}(Y_n) = 42$. La puissance nécessaire est $15Y_n$. On veut $P(15Y_n \leq \gamma) \geq 0,95$, soit $P(Y_n \leq \gamma/15) \geq 0,95$. La correction de continuité donne

$$P\left(Y_n \leq \frac{\gamma}{15}\right) \approx \Phi\left(\frac{\gamma/15 + 0,5 - 140}{\sqrt{42}}\right) \geq 0,95.$$

Le quantile 0,95 de $N(0,1)$ est 1,645, donc

$$\frac{\gamma/15 + 0,5 - 140}{\sqrt{42}} \geq 1,645,$$

d'où $\gamma \geq 2253$ kW. □

4.3.3 Troisième type : connaissant y et β , trouver n (taille d'échantillon)

Exemple 4.8. Une société d'étude souhaite estimer l'audience p d'une émission de télévision. Elle veut qu'avec une probabilité de 90%, l'écart entre la fréquence observée $\hat{p}$ et la vraie valeur p soit inférieur à 0,05. Combien de personnes faut-il interroger ?

Proof. Pour n personnes interrogées, soit $X_i = 1$ si la personne i regarde l'émission, 0 sinon. Les X_i sont i.i.d. de Bernoulli de paramètre p . On note $Y_n = \sum_{i=1}^n X_i$, et $\hat{p} = Y_n/n$. On veut

$$P(|\hat{p} - p| < 0,05) \approx 2\Phi\left(0,05\sqrt{\frac{n}{p(1-p)}}\right) - 1 \geq 0,90.$$

Ainsi $\Phi\left(0,05\sqrt{n/(p(1-p))}\right) \geq 0,95$, soit $0,05\sqrt{n/(p(1-p))} \geq 1,645$, d'où

$$n \geq p(1-p) \frac{1,645^2}{0,05^2} = p(1-p) \times 1082,41.$$

Comme $p(1-p) \leq 0,25$, on a $n \geq 270,6$, donc $n \geq 271$. □

4.4 Théorème central limite pour des variables indépendantes non nécessairement identiquement distribuées

Dans la pratique, si l'indépendance est fréquente, l'identité des distributions ne l'est pas. Par exemple, pour les erreurs de mesure $Y_n = \sum_{i=1}^n X_i$, les X_i sont souvent indépendants mais de lois différentes. On cherche des conditions assurant que la somme normalisée converge vers la loi normale.

Il faut que les termes de la somme soient uniformément petits en un sens probabiliste. On centre et réduit :

$$Y_n^* = \frac{Y_n - (\mu_1 + \dots + \mu_n)}{B_n} = \sum_{i=1}^n \frac{X_i - \mu_i}{B_n},$$

avec $B_n^2 = \sum_{i=1}^n \sigma_i^2$, $\mu_i = E(X_i)$, $\sigma_i^2 = \text{Var}(X_i)$.

La condition de Lindeberg exprime que chaque terme est négligeable :

$$\forall \tau > 0, \quad \lim_{n \rightarrow \infty} \frac{1}{B_n^2} \sum_{i=1}^n E[(X_i - \mu_i)^2 \mathbf{1}_{|X_i - \mu_i| > \tau B_n}] = 0.$$

Théorème 4.3 (Théorème central limite de Lindeberg). *Soit $\{X_n\}$ une suite de variables aléatoires indépendantes satisfaisant la condition de Lindeberg. Alors pour tout x ,*

$$\lim_{n \rightarrow \infty} P\left(\frac{1}{B_n} \sum_{i=1}^n (X_i - \mu_i) \leq x\right) = \Phi(x).$$

Théorème 4.4 (Condition de Liapounov). *S'il existe $\delta > 0$ tel que*

$$\frac{1}{B_n^{2+\delta}} \sum_{i=1}^n E(|X_i - \mu_i|^{2+\delta}) \rightarrow 0,$$

alors la condition de Lindeberg est vérifiée.

Exemple 4.9. Un étudiant passe un examen de 99 questions. Pour la i -ème question, il connaît la réponse avec probabilité $p_i = 1 - i/100$. S'il ne la connaît pas, il répond au hasard parmi 5 choix. Soit $X_i = 1$ s'il répond correctement, 0 sinon. Les X_i sont indépendantes mais non identiquement distribuées. Calculons la probabilité qu'il obtienne au moins 60 bonnes réponses.

Ici $P(X_i = 1) = p_i + (1 - p_i)/5 = 1 - \frac{4}{5}p_i = 1 - \frac{4}{5}(1 - \frac{i}{100}) = \frac{1}{5} + \frac{4i}{500}$? Calculons correctement : $p_i = 1 - i/100$, donc $P(\text{réponse juste}) = p_i + (1 - p_i) \cdot \frac{1}{5} = \frac{1}{5} + \frac{4}{5}p_i = \frac{1}{5} + \frac{4}{5}(1 - \frac{i}{100}) = 1 - \frac{4i}{500}$? Non, faisons proprement : $p_i + \frac{1-p_i}{5} = \frac{5p_i + 1 - p_i}{5} = \frac{1 + 4p_i}{5} = \frac{1 + 4(1 - i/100)}{5} = \frac{5 - 4i/100}{5} = 1 - \frac{4i}{500} = 1 - \frac{i}{125}$. Ensuite $E(X_i) = 1 - i/125$, $\text{Var}(X_i) = E(X_i)(1 - E(X_i))$. On calcule les sommes $\sum E(X_i) = 49.5$ et $\sum \text{Var}(X_i) = 16.665$. Alors

$$P\left(\sum_{i=1}^{99} X_i \geq 60\right) \approx 1 - \Phi\left(\frac{60 - 49.5}{\sqrt{16.665}}\right) = 1 - \Phi(2.57) = 0.005.$$